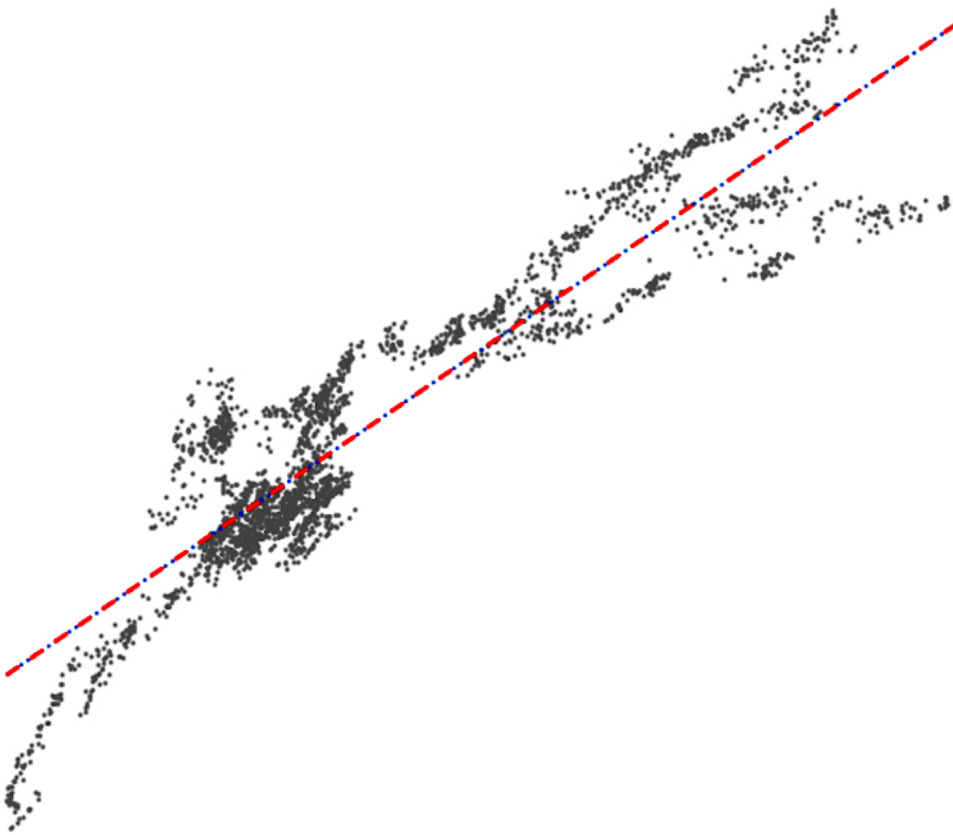
Валентин Юльевич Арьков

Статистический анализ взаимосвязи

Учебное пособие



Валентин Юльевич Арьков

Статистический анализ взаимосвязи

Учебное пособие

Издательские решения
По лицензии Ridero
2020

УДК 004
ББК 32.973
А89

Шрифты предоставлены компанией «ПараТайп»

Арьков Валентин Юльевич

А89 Статистический анализ взаимосвязи : Учебное пособие / Валентин Юльевич Арьков. — [б. м.] : Издательские решения, 2020. — 138 с.
ISBN 978-5-0050-4525-6

Рассматриваются такие инструменты статистического анализа взаимосвязи, как корреляционный и регрессионный анализ. Техника работы в электронных таблицах изучается на примере смоделированных данных. Затем полученные навыки применяются к анализу реальных данных по ценам в интернет-магазине и биржевым котировкам.

УДК 004
ББК 32.973

12+ В соответствии с ФЗ от 29.12.2010 №436-ФЗ

ISBN 978-5-0050-4525-6 © Валентин Юльевич Арьков, 2020

ПРЕДИСЛОВИЕ

Предлагаемое учебное пособие позволяет освоить базовые методы исследования взаимосвязей в пакете Microsoft Excel. Все действия описаны подробно, шаг за шагом, с примерами и комментариями. Попутно можно улучшить навыки работы в Excel, что само по себе уже полезно как элемент современной компьютерной грамотности.

Данное учебное пособие представляет собой второй выпуск серии «Бизнес-аналитика и статистика в Excel». При выполнении работы советуем использовать знания и навыки, полученные при изучении первого выпуска под названием «Анализ распределения в Excel». Рекомендуем изучать материал последовательно — и в рамках данной работы, и в рамках данной серии.

Мы будем использовать простые условные обозначения и названия:

— **жирный шрифт** — названия функций и пунктов меню;

— ЗАГЛАВНЫЕ БУКВЫ — выделение основных терминов и ключевых данных;

— КНОПКИ — кнопки на экране компьютера;

— КЛАВИШИ — клавиши на клавиатуре компьютера.

В тексте описана работа в текущей англоязычной версии Microsoft Excel из пакета Microsoft Office 365. Далее будем называть этот программный продукт просто Excel. При указании функций и пунктов меню мы будем давать оба варианта — на английском и на русском языке. На рисунках будем давать примеры англоязычного интерфейса.

ВВЕДЕНИЕ

Взаимосвязи между явлениями бывают самые разные. В данном выпуске мы будем рассматривать самый популярный вид взаимосвязи между случайными величинами, когда текущее значение одной случайной величины **Y** В СРЕДНЕМ определяется значением другой случайной величины **X**. Вокруг этого предсказуемого среднего имеется случайный непредсказуемый разброс. Лучше всего, если этот разброс постоянного размаха, то есть «сигма» разброса не меняется. Это так называемая КОРРЕЛЯЦИОННАЯ ЗАВИСИМОСТЬ.

Эта две случайные величины называют по-разному:

X — факторный признак, фактор, независимая переменная, independent variable;

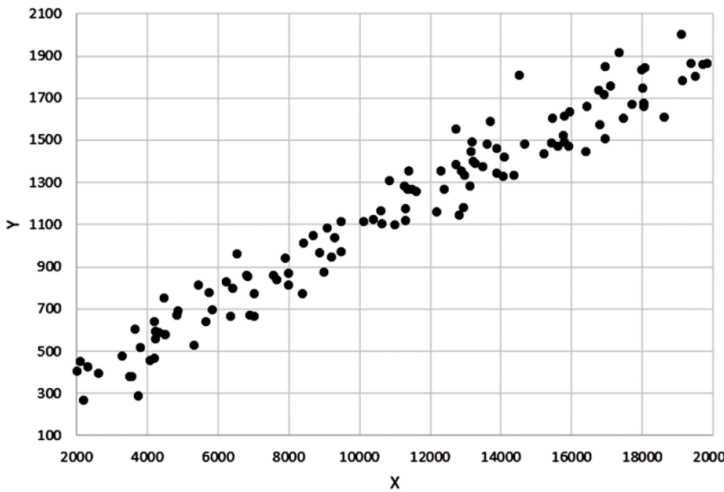
Y — результативный признак, результат, зависимая переменная, dependent variable.

На графике «иксы» откладывают по горизонтальной оси, а «игреки» — по вертикальной. В математике принято откладывать аргумент функции по оси X, а значение функции — по оси Y. В данном случае мы поступаем точно так же. Это намекает, что Y зависит от X. Например, люди высокого роста в среднем весят больше. Поэтому рост можно будет обозначить через X, а вес — через Y.

Корреляционная зависимость изучается с помощью методов КОРРЕЛЯЦИОННОГО И РЕГРЕССИОННОГО АНАЛИЗА. Кроме того, здесь мы снова проведём СВОДКУ И ГРУППИРОВКУ ДАННЫХ, но не для изучения распределения, а для анализа взаимосвязи.

Отчёт о работе оформляется по общим правилам, которые мы уже описали в первом выпуске серии и которые (как мы надеемся) уже удалось освоить в процессе выполнения заданий. Поэтому повторять рекомендации не будем, а сразу займёмся делом.

ОБЩИЕ СВЕДЕНИЯ



Корреляционная зависимость

В данной работе мы будем исследовать взаимосвязь между случайными величинами статистическими методами.

Мы познакомимся с одним из самых известных видов взаимосвязи под названием КОРРЕЛЯЦИОННАЯ ЗАВИСИМОСТЬ, или просто КОРРЕЛЯЦИЯ. Можно сказать, что это «зависимость в среднем». Пример показан на рисунке ниже.

На нашем рисунке видно, что с увеличением «икса» В СРЕДНЕМ увеличивается «игрек». Можно сказать, что здесь просматривается линия и разброс точек вокруг этой воображаемой линии. В этом случае говорят, что между «иксом» и «игреком» есть КОРРЕЛЯЦИЯ, или корреляционная зависимость, или корреляционная взаимосвязь.

Изображение того, как разбросаны точки по графику, называют по-разному:

— корреляционное поле;
— поле корреляции;
— диаграмма разброса;
— диаграмма рассеяния;
— «точечная диаграммма»;
— scatter plot.

Далее мы будем использовать название ДИАГРАММА РАЗБРОСА.

Корреляционная зависимость встречается в жизни. Вот некоторые примеры такой зависимости «в среднем»:

— рост и вес человека;
— площадь квартиры и её цена;
— уровень доходов и продолжительность жизни;
— доходы и расходы домашнего хозяйства;
— длина поездки и расход бензина;
— посещаемость занятий и оценка на экзамене.

Если рассматривать картину в целом, то здесь будет какая-то общая тенденция (прямая или кривая линия), а в каждом конкретном случае к ней добавляется случайный разброс, непредсказуемость, погрешность. По реальным данным можно оценить наличие (силу, степень, тесноту) взаимосвязи и даже построить уравнение такой зависимости. Такое уравнение даст нам только ориентир, среднюю картину и позволит делать приблизительные прогнозы.

Мы будем строить модель в виде одного уравнения, в котором есть один факторный признак и один результативный. Такая модель называется ПА́РНАЯ РЕГРЕССИЯ. Это означает, что у нас рассматривается ПАРА случайных величин, то есть в уравнении участвуют ДВЕ переменные.

Как и в предыдущей работе, вначале мы смоделируем исходные данные и познакомимся со статистическими методами. Затем мы возьмём реальные данные и применим к ним эти изученные технологии. Моделирование даёт идеальные, «краси-

вые» данные, по которым можно начать обучение. Реальные данные всегда «угловатые», «шершавые», «некрасивые», неидеальные. Но это жизнь, и именно с реальными данными приходится иметь дело исследователям, инженерам, программистам, экономистам.

Модели описывают реальную жизнь очень приблизительно, но даже такое приближённое описание может быть полезно при решении реальных задач на производстве и в бизнесе. Слово ПРИБЛИЖЁННОЕ указывает, что есть некоторая погрешность и что наша модель, наше уравнение ПРИБЛИЖАЕТСЯ к реальной жизни. То есть близко, но не точно. И это уже лучше, чем полная неизвестность и неопределённость. А полной, абсолютной точности никогда не бывает. Даже на рынке можно поторговаться, и цена изменится, причём у разных покупателей получится поразному. Так что, выходя из дома за покупками, человек только очень приблизительно может оценить предстоящие расходы.

ВАРИАНТЫ ЗАДАНИЯ

Варианты заданий представлены в таблице ниже. Здесь мы используем следующие условные обозначения.

X — факторный признак, или фактор, или независимая переменная. Мы моделируем X как случайную величину с РАВНОМЕРНЫМ РАСПРЕДЕЛЕНИЕМ в указанном диапазоне.

E — случайная составляющая. Будем моделировать E как случайную величину со СТАНДАРТНЫМ НОРМАЛЬНЫМ РАСПРЕДЕЛЕНИЕМ, то есть с нулевым средним и единичной дисперсией.

Y — результативный признак, или результат, или зависимая переменная. При моделировании мы вычисляем **Y** по формуле, в которой участвуют фактор **X** и случайность **E**. Коэффициент при случайной составляющей определяет её СИГМУ (стандартное отклонение) и, соответственно, разброс вокруг среднего.

n — объём выборки. Это количество изучаемых объектов (статистических единиц), например, людей, квартир или жёстких

дисков. У каждого объекта будут свои значения **X** и **Y**. Например, у каждого человека будет своя пара значений: роста и вес. Можно сказать, что в нашем случае объём выборки — это число строк в таблице с данными, или число записей в базе данных, или КОЛИЧЕСТВО ПАР случайных чисел **{X, Y}**. Для каждого объекта будет своя пара чисел **X** и **Y**. В нашей работе объём выборки равен **200** для всех вариантов.

Оформление отчёта подробно описано в предыдущем выпуске серии. Создадим новую рабочую книгу. Сохраним отчёт в файле с коротким информативным названием. Сделаем титульный лист отчёта и заготовку оглавления.

В данной работе мы будем вначале рассматривать линейную функцию, а затем нелинейную. Соответственно, у нас имеется две таблицы с вариантами заданий.

Выберем свой вариант задания и опишем его на новом листе отчёта.

ЗАРИСОВКА ЛИНЕЙНОЙ ФУНКЦИИ

Вначале надо представить себе, что представляют собой наши данные, как будет выглядеть график. Для этого сделаем зарисовку на бумаге — как в предыдущей работе.

Нам предстоит изобразить расположение нашей линии и форму диаграммы разброса — в самых общих чертах.

Изобразим оси координат и займём нужное место на листе бумаги.

Масштаб на графике необязательно должен начинаться от нуля. Главное, чтобы диаграмма разброса занимала всё поле графика. Метки на осях — «красивые», круглые числа.

В нулевом варианте задания **X** изменяется в пределах от **1000** до **2000**. По оси «икс» указываем крайние значения **1000** и **2000** в начале и конце оси.

Теперь оценим диапазон значений **Y**. Берём формулу для **Y**, пока без учёта случайности **E**:

$$\mathbf{Y = 1400 + 0{,}065 \cdot X}$$

Варианты заданий. Линейные функции

Вариант	X	Y
0	1000 … 2000	y = 1400 + 0,65·x + 50·e
1	1000 … 3000	y = 1000 + 0,55·x + 60·e
2	2000 … 5000	y = 2000 + 0,25·x + 40·e
3	1000 ... 4000	y = 1700 + 0,45·x + 150·e
4	2000 … 4000	y = 3500 + 1,55 x + 250·e
5	2000 … 3000	y = 500 + 1,25·x + 100·e
6	3000 … 5000	y = 2700 + 1,35·x + 250·e
7	3000 … 4000	y = 3100 + 0,15 x + 10·e
8	2000 … 4000	y = 1100 + 1,15·x + 200·e
9	1000 … 5000	y = 950 + 1,65·x + 550·e
10	4000 … 6000	y = 750 + 0,45·x + 100·e

Подставляем крайние значения **X**:

Y (1000) = 1400 +0,065 · 1000 = 2050

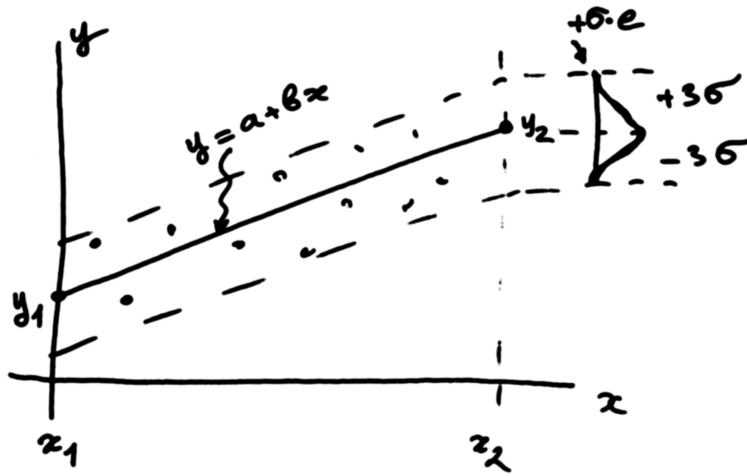
Y (2000) = 1400 +0,065 · 2000 = 2700

Выбираем масштаб по оси «игрек» от **2000** до **3000**.

Получаем 2 точки, через них проводим прямую линию.

Добавим разброс вокруг линии. Для этого используем ПРАВИЛО ТРЁХ СИГМ: почти все значения случайной величины находятся в диапазоне «среднее плюс-минус три сигмы». Когда мы строим разброс вокруг линии, в роли среднего значения будет точка на линии.

В нулевом варианте случайный разброс равен **50 · E**. Случайная составляющая E имеет единичную дисперсию. Сигма **E** тоже будет равна единице, потому что сигма — это квадратный корень из дисперсии. Если умножить случайную величину **E**



Зарисовка диаграммы разброса

на **50**, то её сигма тоже увечивается в **50** раз. Стало быть, сигма равна **50**, а три сигмы равно

3 · 50 = 150.

Вокруг первой и последней точек на графике строим разброс «плюс-минус три сигмы».

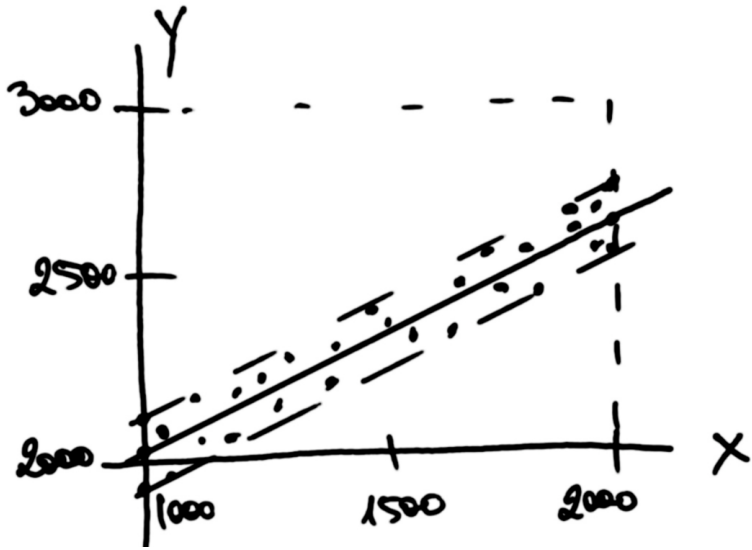
2050 — 150 = 1900
2050 +150 = 2200
2700 — 150 = 2550
2700 +150 = 2850

Проводим пунктиром две параллельные линии. Это будут границы случайного разброса.

Заполняем эту «полосу» точками — случайным образом.

Вот что мы ожидаем увидеть, когда смоделируем исходные данные — см. рисунок.

Зачем в этой работе мы делаем зарисовку? При любых вычислениях нужно уметь ЗАРАНЕЕ ОЦЕНИВАТЬ и МЫСЛЕННО ПРЕДСТАВЛЯТЬ себе будущие результаты. Тогда сразу будут видны ГРУБЫЕ ОШИБКИ. И эти ошибки можно будет сразу же



Зарисовка

выявить и исправить. Ну а ошибки будут всегда.

Если не оценивать будущий результат, то можно легко сказать: «Это компьютер так посчитал». Проблема в том, что исходные данные вводит человек и результаты будет использовать тоже человек. Программу тоже написал человек, и не один. Поэтому ОТВЕТСТВЕННОСТЬ за результаты расчётов несёт не компьютер, а человек.

ЗАРИСОВКА НЕЛИНЕЙНОЙ ФУНКЦИИ

Вторая часть задания — это нелинейная функция второго порядка. Варианты заданий приводятся в таблице. Другие названия: квадратичная функция, парабола — см. формулу.

Уравнение параболы можно записать разными способами, поэтому нужно следить за тем, в каком порядке расположены члены уравнения.

Варианты заданий. Нелинейные функции

Вар.	X	Y
0	1000 … 3000	$y = 7000 - 7 \cdot x + 0{,}002 \cdot x^2 + 200 \cdot e$
1	1000 … 4000	$y = 4500 - 3{,}5 \cdot x + 0{,}00085 \cdot x^2 + 250 \cdot e$
2	2000 … 4000	$y = 10000 - 5{,}5 \cdot x + 0{,}001 \cdot x^2 + 150 \cdot e$
3	2000 … 3000	$y = 33000 - 25 \cdot x + 0{,}0055 \cdot x^2 + 150 \cdot e$
4	1000 … 3000	$y = 6500 - 5{,}5 \cdot x + 0{,}0015 \cdot x^2 + 150 \cdot e$
5	2000 … 5000	$y = 7500 - 3{,}5 \cdot x + 0{,}0006 \cdot x^2 + 200 \cdot e$
6	1000 … 3000	$y = 1500 + 4{,}5 \cdot x - 0{,}0015 \cdot x^2 + 250 \cdot e$
7	1000 … 4000	$y = 1850 + 2{,}2 \cdot x - 0{,}0006 \cdot x^2 + 150 \cdot e$
8	2000 … 4000	$y = -5000 + 7 \cdot x - 0{,}0013 \cdot x^2 + 200 \cdot e$
9	2000 … 3000	$y = -37000 + 37 \cdot x - 0{,}008 \cdot x^2 + 150 \cdot e$
10	1000 … 3000	$y = 1500 + 5{,}2 \cdot x - 0{,}0015 \cdot x^2 + 200 \cdot e$

$$y = a_2 x^2 + a_1 x + a_0$$

$$y = a_0 + a_1 x + a_2 x^2$$

Уравнение параболы

В первом примере степени аргумента расположены по убыванию. Во втором — по возрастанию. Как записать уравнение — не так важно. Главное — правильно прочитать те результаты, которые нам выдаст программа.

На новом листе отчёта опишем свой вариант задания. Напомним, что мы в качестве примера рассматриваем нулевой вариант.

Пределы изменения факторного признака: от **1000** до **3000**.

Уравнение функции:

$$x_0 = -\frac{a_1}{2a_2}$$

$$y_0 = a_0 - \frac{a_1^2}{4a_2}$$

Вершина параболы

$y = 7000 - 7 \cdot x + 0{,}002 \cdot x^2 + 200 \cdot e$

Коэффициенты уравнения:

$a_0 = 7000$

$a_1 = -7$

$a_2 = 0{,}002$

s = 200

Коэффициент при случайной составляющей **E** обозначим буквой **S**, поскольку он определяет значение «сигмы».

Чтобы сделать зарисовку параболы, нужно определить два основных момента.

Вначале определим знак старшего коэффициента при второй степени фактора a_2. Если коэффициент a_2 положителен, то ветви параболы направлены вверх. И наоборот.

В нулевом варианте старший коэффициент равен

$a_2 = 0{,}002$.

Коэффициент положительный, следовательно ветви параболы смотрят вверх.

Затем определим положение вершины параболы.

Докажите справедливость формул для нахождения координат вершины параболы, приравняв первую производную функции к нулю. Затем подставьте полученное значение x_0 в уравнение параболы и упростите выражение.

Подставляем наши коэффициенты и находим координаты вершины — см. формулы.

$$x_0 = -\frac{a_1}{2a_2} = \frac{7}{2 \cdot 0{,}002} = 1750$$

$$y_0 = a_0 - \frac{a_1^2}{4a_2} = 7000 - \frac{7^2}{4 \cdot 0{,}002} = 875$$

Координаты вершины

$$x_1 = 1000; \quad y_1 = 7000 - 7 \cdot 1000 + 0{,}002 \cdot 1000^2 = 2000$$

$$x_2 = 3000; \quad y_1 = 7000 - 7 \cdot 3000 + 0{,}002 \cdot 3000^2 = 4000$$

Крайние значения

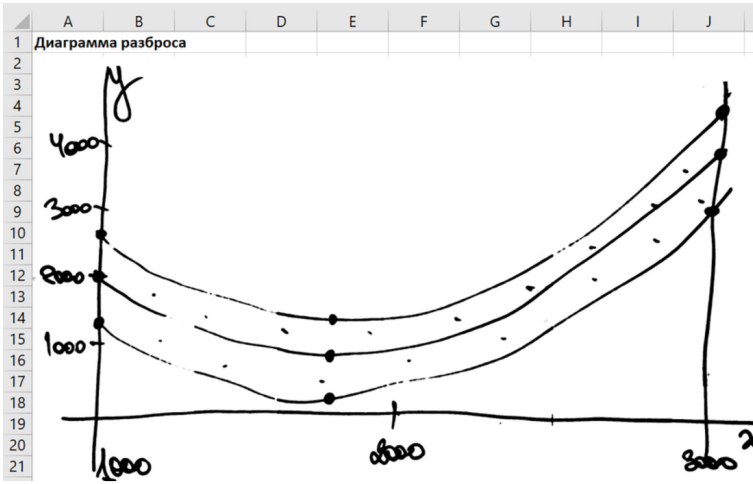
Значения функции

x	*y* – 3σ	*y*	*y* + 3σ
1000	1400	2000	2600
1750	275	875	1475
3000	3400	4000	4600

Далее определим значения функции на границах диапазона значений — см. формулы.

И наконец добавляем границы случайного разброса по «правилу трёх сигм». Сигма в нулевом варианте равна **200**, соответственно, три сигмы равно **600**. Добавляем и отнимаем **600** в каждой из трёх точек — см. формулы.

Делаем зарисовку и вставляем в отчёт, как описано в предыдущем выпуске. Цель этого упражнения — представить общую форму графика, а не демонстрировать художественный талант или способности к черчению.



Зарисовка

ИСХОДНЫЕ ДАННЫЕ

Сгенерируем исходные данные — значения двух переменных **x** и **y** — в соответствии с вариантом задания. В качестве примера разбираем нулевой вариант. Используем функцию

Random Number Generation
Генерация случайных чисел
надстройки
Data Analysis
Анализ данных.

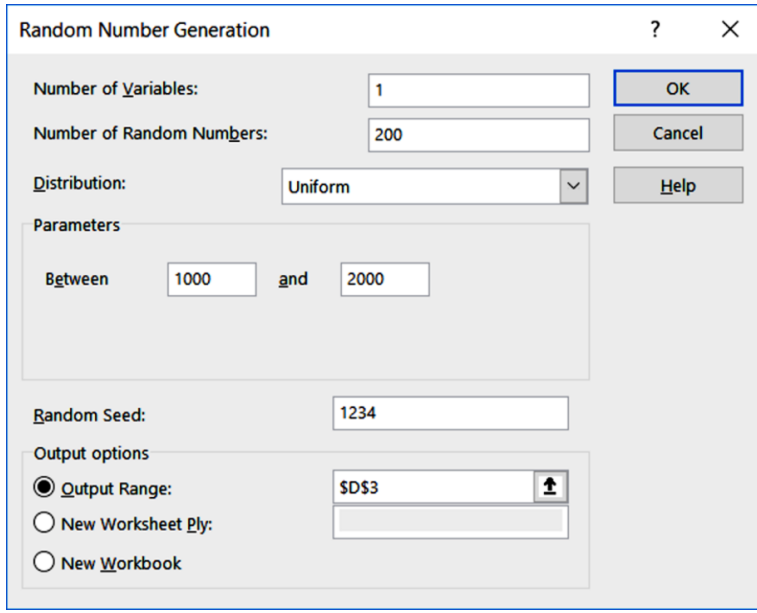
Подробности использования генератора мы уже описали в предыдущей работе. Числа округляем до целых.

Создаём столбец случайных чисел **X**.

Распределение — **Равномерное**

Левая и правая границы — **1000** и **2000**.

Начальное состояние — **1234**. Можно взять любые другие числа, но их нужно зафиксировать в отчёте, чтобы не использо-



Настройки генератора

вать второй раз.

Полученные значения **X** округляем до целых и записываем в другой столбец. Для округления используем функцию

ROUND (number, num_digits)

ОКРУГЛ (число; число разрядов).

Обратим внимание, что в английской версии аргументы функции разделяют ЗАПЯТОЙ, а в русской — ТОЧКОЙ С ЗАПЯТОЙ. Причина в том, что в английской версии десятичный разделитель целой и дробной частей — точка, а в русской — запятая.

Пример результата генерации данных и округления можно видеть на рисунке ниже. В дальнейшей работе используются именно округлённые значения **X** и **Y**.

Вспомогательная случайная составляющая **E** поможет нам

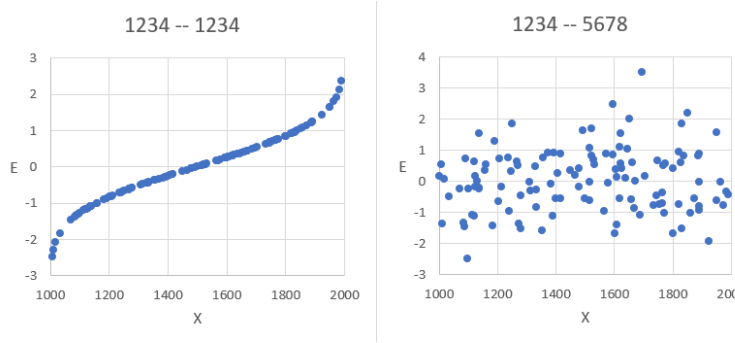
	A	B	C	D	E	F	G	H
1	**Задание**			**Генератор**			**Округление**	
2	Вариант	0		**x**	**e**	**y**	**x**	**y**
3				1124.149	0.168827	2139.138	**1124**	**2139**
4	**Фактор**			1006.5	0.543641	2081.407	**1007**	**2081**
5	**X**			1389.447	-1.12419	2246.931	**1389**	**2247**
6	равномерное			1267.281	0.633256	2255.396	**1267**	**2255**
7	от	1000		1703.635	0.169759	2515.851	**1704**	**2516**
8	до	2000		1235.511	0.76918	2241.541	**1236**	**2242**
9	начальное	1234		1466.14	0.194493	2362.715	**1466**	**2363**
10				1747.948	0.676291	2569.981	**1748**	**2570**
11	**Разброс**			1123.783	-0.18242	2121.338	**1124**	**2121**
12	**E**			1406.018	0.264644	2327.144	**1406**	**2327**
13	нормальное			1608.692	0.124747	2451.887	**1609**	**2452**
14	среднее	0		1516.312	-0.02529	2384.339	**1516**	**2384**
15	сигма	1		1755.974	-0.72947	2504.909	**1756**	**2505**
16	начальное	5678		1121.555	-1.09739	2074.141	**1122**	**2074**
17				1354.564	-1.57007	2201.963	**1355**	**2202**
18	**Результат**			1415.693	0.876516	2364.026	**1416**	**2364**
19	**Y**			1203.497	-0.63447	2150.55	**1203**	**2151**
20	1400 + 0,65·x + 50·e			1671.987	0.007459	2487.165	**1672**	**2487**
21				1033.937	-0.478	2048.159	**1034**	**2048**
22	**Выборка**			1356.304	0.754862	2319.34	**1356**	**2319**
23	**N**	200		1533.128	0.539656	2423.516	**1533**	**2424**

Сгенерированные данные

сформировать случайный разброс вокруг линии. Она имеет нормальное распределение с нулевым математическим ожиданием и единичным стандартным отклонением. Значения **E** следует сгенерировать в отдельном столбце с ДРУГИМ начальным состоянием генератора.

Программный генератор случайных чисел на самом деле создаёт ПСЕВДОСЛУЧАЙНЫЕ числа. Другими словами, они только кажутся случайными. Если задавать одно и то же начальное состояние генератора, мы получим одну и ту же последовательность «случайных» чисел.

Проведём опыт и убедимся, к чему приводят одинаковые настройки генератора. Сгенерируем столбцы **X** и **E** с одинаковым начальным состоянием генератора: **1234**. Результат —



Влияние начального состояния

на рисунке слева. Теперь сгенерируем **X** и **E** с настройками 1234 и 5678. Результат показан справа.

На левом графике можно видеть явную связь (точную функциональную зависимость) между случайными числами **X** и **E** — при одинаковой настройке генератора: **1234** и **1234**. На этом графике просматривается кривая нормального распределения. Она используется для создания случайного числа с заданным распределением. Разные настройки **1234** и **5678** дают действительно независимые случайные числа. Учтём на будущее.

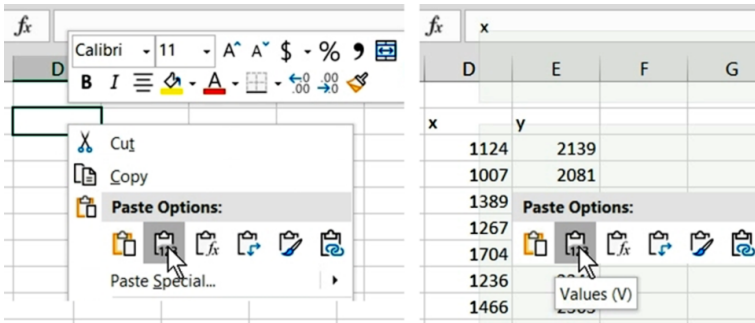
Выделим два столбца с готовыми данными — с заголовками. Вставим данные на новый лист. Выберем режим вставки значений из буфера обмена.

При выборе режима вставки из буфера можно сразу увидеть результат на экране. Нажимаем кнопку

Values

Значения.

После вставки получаем числа вместо формул в ячейках таблицы. Теперь никакие наши действия не приведут к обновлению и изменению данных.



Вставка значений

ДИАГРАММА РАЗБРОСА

Пришло время посмотреть на график наших исходных данных. На диаграмме разброса каждая пара чисел X и Y изображается отдельной точкой. Точки на графике НЕ СОЕДИНЯЮТ линиями. В примере «Рост — Вес» нет никакой связи между параметрами соседей по парте. Поэтому каждый человек — это отдельная точка на графике.

Выделяем два столбца с округлёнными значениями **X** и **Y.** Выбираем в меню:

Insert — Charts — Insert Scatter (X, Y) or Bubble Chart — Scatter — Scatter

Вставка — Диаграммы — Вставить точечную (X, Y) или пузырьковую диаграмму — Точечная — Точечная.

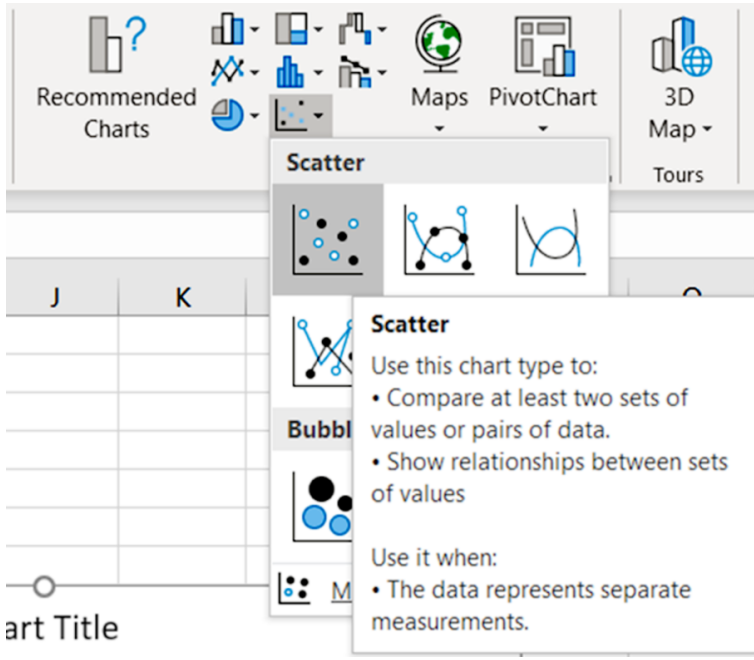
По умолчанию диаграмма разброса выглядит не слишком привлекательно — см. график. Настроим оформление графика.

Настроим масштаб по осям, чтобы диаграмма заполняла всё поле графика. Дважды щёлкнем по горизонтальной оси. В диалоговом окне

Format Axis

Формат оси

выбираем раздел



Вставка диаграммы разброса

Axis Options

Параметры оси.

Устанавливаем пределы по горизонтальной оси от **1000** до **2000**.

Щёлкнем по вертикальной оси и выберем такие значения, чтобы диаграмма разброса занимала всё место на графике.

Теперь настроим заголовки. Щёлкнем по графику и нажмём на кнопку

Chart Elements

Элементы диаграммы.

Это квадратная кнопка с символом ПЛЮС справа вверху.

Отмечаем пункт

Axis Titles

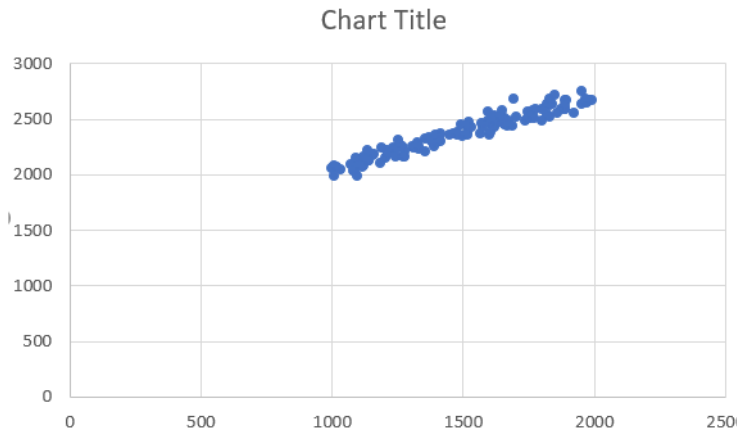
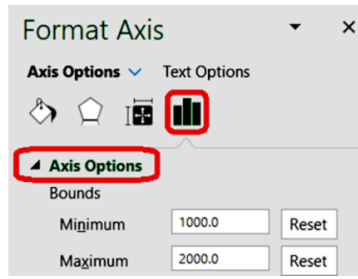


Диаграмма разброса по умолчанию



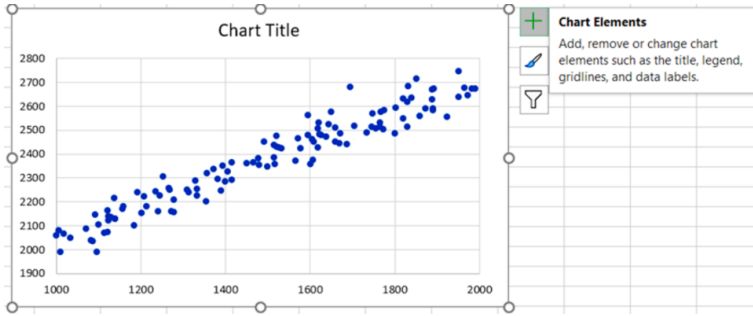
Масштаб по оси

Названия осей.

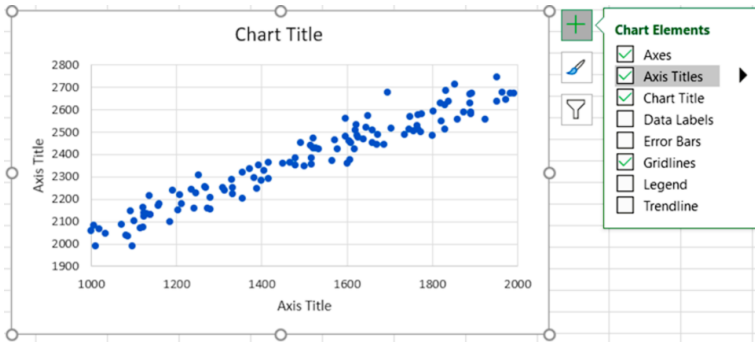
Отредактируем заголовки и укажем, где находятся наши «иксы» и «игреки». Для дальнейшего украшения развернём заголовок вертикальной оси на 45 градусов. Щёлкнем по заголовку вертикальной оси и выберем в меню:

Format Axis Title — Text Options — TextBox — Text Box — Text direction — Horizontal

Формат названия оси — Параметры текста — Надпись —



Элементы графика



Заголовки осей

Надпись — Направление текста — Горизонтально.

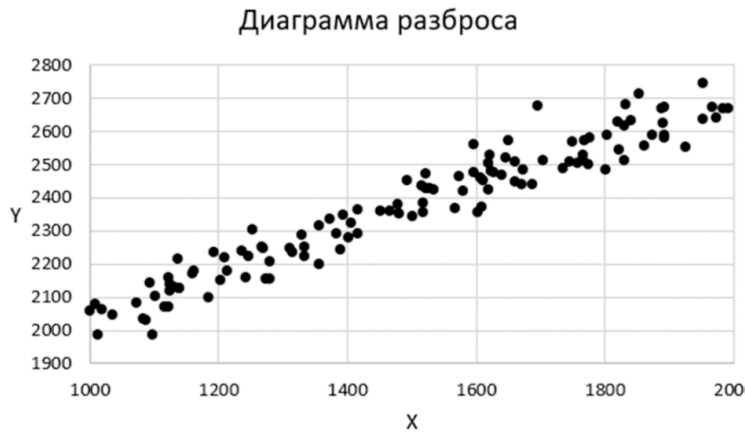
Далее установим чёрный цвет для точек-маркеров. Щёлкнем по маркерам и установим в меню чёрный цвет:

Format Data Series — Series Options — Fill & Line — Marker — Marker Options — Fill — Solid fill — Color — Black

Формат ряда данных — Параметры ряда — Заливка и границы — Маркер — Параметры маркера — Заливка — Сплошная заливка — Цвет — Чёрный.

Здесь же отключим обрамление маркеров:

Format Data Series — Series Options — Fill & Line — Marker —



Оформленная диаграмма

Marker Options — Border — No line

Формат ряда данных — Параметры ряда — Заливка и границы — Маркер — Параметры маркера — Граница — Нет линий.

После настроек диаграмма разброса должна выглядеть следующим образом — см. рисунок.

КОРРЕЛЯЦИОННЫЙ АНАЛИЗ

Корреляционный анализ позволяет исследовать тесноту связи, то есть степень разброса точек вокруг линии. Чем ближе точки к линии регрессии, тем лучше ТЕСНОТА СВЯЗИ. Имеется в виду линия, которую МОЖНО построить в среднем по этом точкам. На самом деле при анализе взаимосвязи перед нами находятся только точки, а линии пока ещё НЕТ.

Теснота линейной связи оценивается с помощью КОЭФФИЦИЕНТА ЛИНЕЙНОЙ КОРРЕЛЯЦИИ *r*. Здесь говорится именно о ЛИНЕЙНОЙ связи и анализируется разброс вокруг будущей, возможной ПРЯМОЙ линии. Другими словами, мы выясняем, есть ли смысл в построении прямой линии в среднем по нашим точкам.

Коэффициент корреляции принимает значения от **–1** до **+1** включительно.

Знак коэффициента указывает на НАПРАВЛЕНИЕ связи — прямую или обратную связь. Положительная корреляция означает, что с увеличением фактора в среднем возрастает результативный признак. Это прямая связь. Отрицательная корреляция — это обратное направление связи, то есть снижение, убывание, падение графика. С увеличением фактора убывает результат.

Величина (модуль, абсолютное значение) коэффициента характеризует ТЕСНОТУ линейной связи. Чем ближе значение к единице, тем меньше разброс, тем ближе точки к прямой линии. Чем ближе коэффициент к нулю, тем сильнее разброс вокруг прямой. Традиционное толкование величины коэффициента корреляции приводится в таблице.

Возможна и другая ситуация — НЕЛИНЕЙНАЯ зависимость, которая тоже представляет собой отсутствие линейной связи. Нелинейной зависимостью является всё, что не является линейным, например, кривая или ломаная линия. В этом случае

Коэффициент корреляции

Величина *r*	**Характер связи**
$\|r\| < 0{,}3$	Практически отсутствует
$0{,}3 \le \|r\| < 0{,}5$	Слабая
$0{,}5 \le \|r\| < 0{,}7$	Умеренная
$0{,}7 \le \|r\| < 1{,}0$	Сильная
$\|r\| = 1{,}0$	Функциональная

коэффициент линейной корреляции будет близок к нулю. Но при этом точки могут быть очень тесно расположены вокруг кривой или ломаной линии. Для анализа степени нелинейной связи используют другие коэффициенты корреляции. В данной работе мы ограничимся только анализом тесноты линейной зависимости.

Как и во многих других случаях, для вычисления коэффициента корреляции в Excel имеются несколько способов:

— надстройка;

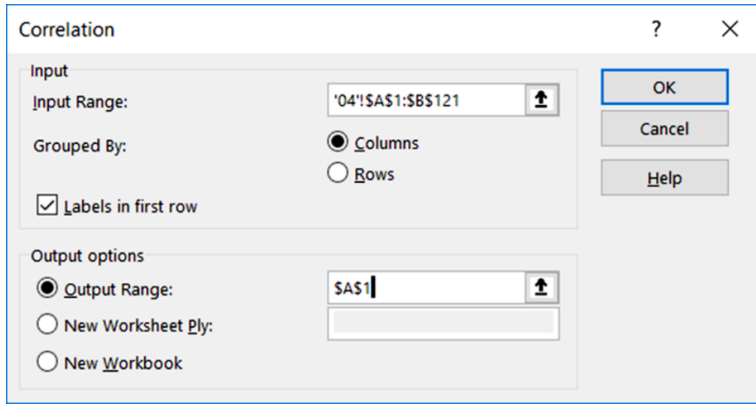
— функции;

— формулы.

В следующих разделах мы рассмотрим все эти возможности, а затем сравним полученные результаты.

НАДСТРОЙКА

Вызываем модуль **Корреляция** статистической надстройки:
Data — Analysis — Data Analysis — Correlation
Данные — Анализ — Анализ данных — Корреляция.
В диалоговом окне
Correlation
Корреляция
указываем следующие параметры:
Input — Input Range
Входные данные — Входной интервал.



Параметры корреляционного анализа

В выбранном диапазоне ячеек должны быть два столбца значений **X** и **Y**.

Затем указываем расположение исходных данных:

Labels in first row

Метки в первой строке.

Выделяем значения в столбцах **X** и **Y** вместе с их заголовками. В этом случае в таблице с результатами анализа будут выводиться названия переменных.

Указываем, что наши исходные данные расположены по столбцам:

Grouped By — Columns

Группирование — по столбцам.

Обратите внимание, что здесь имеется в виду расположение данных по столбцам, а не статистическая группировка, хотя на экране и присутствует слово ГРУППИРОВАНИЕ. Как говорил Козьма Прутков: «Не верьте глазам своим». Мы пока что просто описываем исходные данные и даже не начинали заниматься группировкой.

	A	B	C
1		*x*	*y*
2	x	1	
3	y	0.9659	1

Результаты корреляционного анализа

	A	B	C
1		*x*	*y*
2	x	1	
3	y	0.965899837	1

Точное значение коэффициента

Отмечаем первую ячейку, начиная с которой будут выводиться результаты анализа:

Output options — Output Range

Параметры вывода — Выходной интервал.

На экран выводится таблица коэффициентов корреляции. На пересечении строки **Y** и столбца **X** выводится искомый коэффициент. Единичные коэффициенты на диагонали — это корреляция переменной с само́й собой.

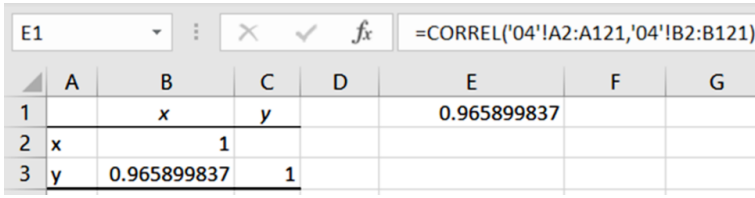
Чтобы получить больше разрядов в дробной части, увеличим ширину столбца.

ФУНКЦИЯ CORREL / КОРРЕЛ

Второй способ вычисления коэффициента корреляции — это готовая функция

CORREL (array1, array2)

КОРРЕЛ (диапазон_x; диапазон_y).



	A	B	C	D	E	F	G
1		*x*	*y*		0.965899837		
2	x	1					
3	y	0.965899837	1				

Вызов функции**CORREL**

Два обязательных аргумента — это диапазоны ячеек **X** и **Y**. Здесь «иксы» и «игреки» задаются по отдельности. Напомним, что в английской версии программы аргументы функции разделяют запятой, а в русской — точкой с запятой.

Увеличиваем ширину столбца и сравниваем результаты расчётов с предыдущим разделом. Пока всё сходится.

Теперь на новом листе сгенерируйте данные с разным разбросом, то есть с разным множителем **S** в уравнении. Определите значение коэффициента корреляции. Подберите величину случайного разброса, чтобы получить

0,3
0,5
0,7
1,0.

В электронной таблице формулы пересчитываются автоматически, а графики сами обновляются при изменении данных. Поэтому можно будет легко подобрать нужный разброс. Скопируйте графики и соберите их на отдельном листе с комментариями — какая корреляция и какая это теснота связи. При вставке графиков используйте режим вставки как изображение — **Picture (U)**, а не как исходный график. В этом случае картинки не будут изменяться и обновляться.

$$r_{yx} = \frac{n \cdot \sum(y \cdot x) - \sum y \cdot \sum x}{\sqrt{(n \cdot \Sigma y^2 - (\Sigma y)^2) \cdot (n \cdot \Sigma x^2 - (\Sigma x)^2)}}$$

Коэффициент корреляции

	A	B	C	D	E	F
1	**Корреляция: формулы**					
2						
3		**x**	**y**	**x^2**	**y^2**	**yx**
4		1124	2139	1263376	4575321	2404236
5		1007	2081	1014049	4330561	2095567
122		1333	2253	1776889	5076009	3003249
123		1242	2160	1542564	4665600	2682720
124	**Всего**	**179726**	**285038**	**278645604**	**681539346**	**433199233**

Промежуточные суммы

ФОРМУЛЫ

Вычислим коэффициент линейной корреляции вручную с помощью формул Excel.

Вот соотношение для расчётов — см. формулу.

Для вычислений нам понадобятся промежуточные расчёты. Найдём суммы «иксов», «игреков», их квадратов и произведений, которые участвуют в формуле. Для этого на новом листе организуем вспомогательную таблицу. Внизу столбцов подсчитываем суммы, воспользовавшись кнопкой экспресс-анализа.

Когда найдены необходимые суммы, можно вычислить коэффициент корреляции. Нам потребуется функция извлечения квадратного корня:

SQRT (number)

КОРЕНЬ (число).

Формула не слишком сложная. При вводе в ячейку она легко

I2 =(120*F124-B124*C124)/SQRT((120*E124-C124*C124)*(120*D124-B124*B124))

	A	B	C	D	E	F	G	H	I
1	**Корреляция: формулы**								
2								r_{yx} =	**0.965899837**
3		**x**	**y**	**x^2**	**y^2**	**yx**			
4		1124	2139	1263376	4575321	2404236			
5		1007	2081	1014049	4330561	2095567			
122		1333	2253	1776889	5076009	3003249			
123		1242	2160	1542564	4665600	2682720			
124	**Всего**	**179726**	**285038**	**278645604**	**681539346**	**433199233**			

Коэффициент корреляции

умещается на экране. Поэтому разбивать её на части не потребуется.

СРАВНЕНИЕ РЕЗУЛЬТАТОВ

Копируем полученное значение на отдельный лист для сравнения с предыдущими оценками. Записываем комментарии и сообщаем, насколько похожи оценки, полученные разными способами. А также, о чём говорят величина и знак коэффициента *r* — см. таблицу выше.

РЕГРЕССИОННЫЙ АНАЛИЗ

$$y = a + b \cdot x \ ,$$

a – свободный член уравнения,

b – коэффициент регресии.

Линейная регрессия

Переходим к регрессионному анализу. В статистике и бизнес-аналитике РЕГРЕССИЯ — это линия, которую проводят В СРЕДНЕМ по точкам. Кроме изображения линии на графике, здесь рассматривается уравнение этой линии. Задача регрессионного анализа — построить линию регрессии и получить уравнение регрессии.

ЛИНИЯ РЕГРЕССИИ проходит по большому количеству точек именно В СРЕДНЕМ. Она может не пройти ни через одну точку. Но на графике будет видно, как линия проходит по местам сгущения точек. Можно даже провести такую линию «на глазок», просто приложив линейку к графику.

УРАВНЕНИЕ РЕГРЕССИИ описывает нашу линию, которая проходит по точкам в среднем.

Если у нас прямая линия, а «икс» входит в уравнение в первой степени, то это ЛИНЕЙНОЕ УРАВНЕНИЕ — см. формулу.

Для проведения регрессионного анализа в Excel имеется несколько способов:

— элемент диаграммы;
— статистическая надстройка;
— функция **LINEST** (**ЛИНЕЙН**);
— формулы с матричными операциями.

Уравнение регрессии и соответствующая линия регрессии — это пример ПАРАМЕТРИЧЕСКОЙ модели. В такой модели участвует небольшое, ограниченное количество параметров. В нашем случае несколько коэффициентов уравнения.

Существует и второй тип моделей — НЕПАРАМЕТРИЧЕСКИЕ. В таких моделях вместо красивого уравнения используется таблица с неограниченным количеством чисел или множество точек на графике. И это количество может меняться. В нашей работе мы рассмотрим пример непараметрической модели регрессии под названием УСЛОВНОЕ СРЕДНЕЕ. Мы построим эту модель с помощью методов сводки и группировки данных — этот подход подробно рассматривался в предыдущей работе.

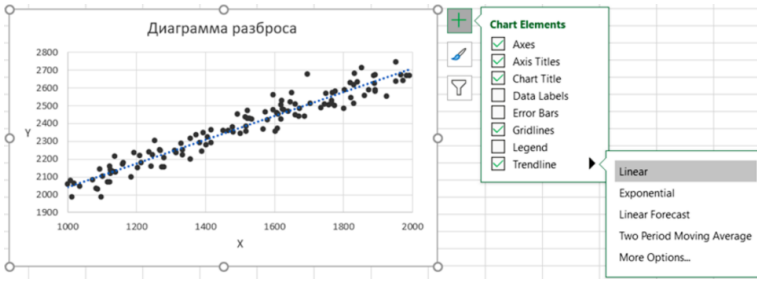
ЭЛЕМЕНТ ДИАГРАММЫ

Самый простой способ получить уравнение регрессии и нанести линию регрессии на график — построить диаграмму разброса и вызвать встроенную, автоматическую функцию

Trendline
Линия тренда.

Название этой функции достаточно своеобразное. К нему тоже надо отнестись с пониманием. На самом деле ТРЕНД — это основная тенденция, общее направление при изменении значений во времени. Подробнее мы рассмотрим тренд в третьей работе на тему «Динамика». Фактически здесь строится линия регрессии. При построении линии тренда тоже используют методы регрессионного анализа, только вместо «иксов» берут моменты времени.

Слово РЕГРЕССИЯ здесь более подходящее, оно более универсальное, хотя и незнакомое для массового потребителя. Видимо, разработчики решили, что слово ТРЕНД более привычно для пользователей. Оно часто встречается в рекламе и даже в названиях некоторых товаров.



Автоматическое построение регрессии

Щёлкнем по диаграмме разброса левой кнопкой мыши. Как показано на рисунке, справа от поля графика нажмём кнопку со знаком ПЛЮС:

Chart Elements

Элементы диаграммы.

Выбираем в качестве элемента графика

Trendline

Линия тренда.

Указываем линейную функцию:

Linear

Линейный.

Есть и другой способ управлять элементами графика. Щёлкнем левой кнопкой мыши по графику и выберем в верхнем меню:

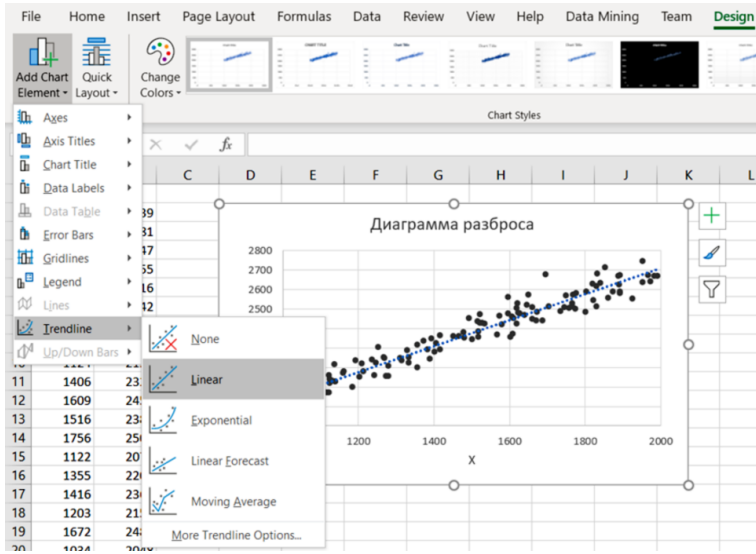
Design — Add Chart Element — Trendline — Linear

Конструктор — Добавить элемент диаграммы — Линия тренда — Линейный.

Добавим на график уравнение регрессии.

Design — Add Chart Element — Trendline — More Trendline options

Конструктор — Добавить элемент диаграммы — Линия тренда — Дополнительные параметры линии тренда.



Добавление линии тренда

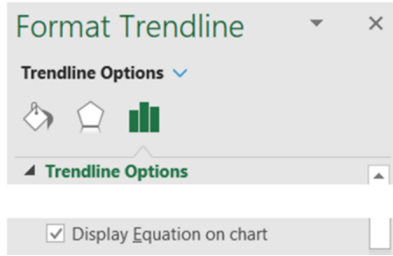
В окне настройки элементов графика выбираем:

Format Trendline — Trendline options — Display Equation on chart

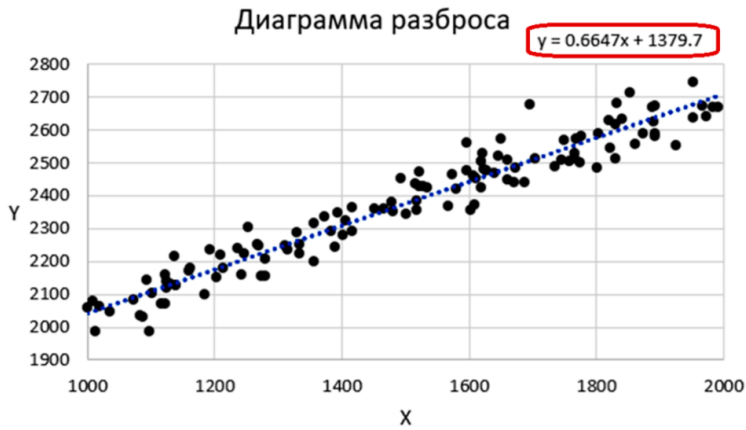
Формат линии тренда — Параметры линии тренда — показывать уравнение на диаграмме.

На графике действительно появляется уравнение. Чтобы рассмотреть его получше, перетащим это уравнение мышкой на свободное место.

Сравним полученное уравнение с нулевым вариантом задания. Значения коэффициентов похожи. Конечно, есть небольшое различие. Это случайная ошибка, вызванная случайным разбросом **E** и ограниченным объёмом выборки **N**.



Вывод уравнения регрессии



Уравнение регрессии на графике

УСЛОВНОЕ СРЕДНЕЕ

Кроме линии регрессии, есть другой способ изучения той же зависимости — УСЛОВНОЕ СРЕДНЕЕ, то есть среднее при выполнении некоторого условия. Это среднее арифметическое значений результативного признака **Y** ПРИ УСЛОВИИ, что соответствующие значения факторного признака **X** попадают в заданный интервал.

Вот пример условного среднего: средний вес людей, у которых рост окажется в диапазоне от 160 до 170 см. Мы выбираем людей ростом от 160 до 170 см, измеряем их вес и находим среднее значение веса только по этой группе. Здесь рост — это факторный признак **X**, а вес — это результативный признак **Y**. Мы получили средний «игрек», а условие определяли по «иксу».

На новом листе добавим интервалы группировки по **X**: нижние и верхние границы, а также среднее значение. Интервалы группировки выбираем точно так же, как описано в первой работе. Ссылка для скачивания пособия по первой работе приводится в конце данного выпуска.

В нашем примере возьмём 10 интервалов по 100 единиц, чтобы охватить диапазон значений от 1000 до 2000.

Для нахождения условного среднего можно использовать функцию

SUMIF

СУММЕСЛИ.

Функция позволяет вычислить сумму при выполнении заданного условия. Формат функции следующий:

SUMIF (range, criteria, [sum_range])

СУММЕСЛИ (диапазон; критерий; [диапазон_суммирования])

range — **диапазон** — диапазон ячеек;

criteria — **критерий** — условие**;**

sum_range — **диапазон_суммирования** — диапазон ячеек для суммирования. Если диапазон не указан, то суммируются значения из диапазона, указанного в первом аргументе.

Для определения средних значений фактора **X** в каждом интервале группировки используем только два первых аргумента функции.

Рассмотрим примеры условных сумм — см. формулы.

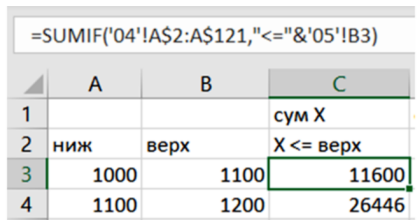
Первая формула вычисляет сумму значений фактора, не превышающих верхнюю границу первого интервала. Сюда попадут все значения из первого интервала, а также все точки, которые окажутся левее этого интервала.

```
=SUMIF('04'!A2:A121,"<="&'05'!B2)

=SUMIF('04'!A2:A121,"<="&'05'!B3)-
SUMIF('04'!A2:A121,"<="&'05'!B2)

=SUMIF('04'!A$2:A$121,"<="&'05'!B3)-
SUMIF('04'!A$2:A$121,"<="&'05'!B2)
```

Условные суммы



	A	B	C
1			сум X
2	ниж	верх	X <= верх
3	1000	1100	11600
4	1100	1200	26446

Функция**SUMIF**

Вторая формула определяет сумму значений фактора, попадающих во второй интервал.

В третьей формуле мы фиксируем номера строк для диапазона исходных данных с помощью символа **$**. Это позволит нам скопировать формулу и заполнить весь столбец.

Для упрощения расчётов мы определяем разность сумм значений, не превышающих верхние границы интервалов. В этом случае формулы получаются немного короче и понятнее. Мы уже использовали подобный приём в первой работе, когда определяли частоту попадания в интервал. Мы находили относительные частоты как разность соседних значений накопленной частоты.

При вычислении среднего арифметического нужно поделить сумму значений на их количество.

Для определения количества элементов используем функцию **COUNTIF**

```
=COUNTIF('04'!A$2:A$121,"<="&'05'!B3)

=(SUMIF('04'!A$2:A$121,"<="&'05'!B3)-
  SUMIF('04'!A$2:A$121,"<="&'05'!B4))/
 (COUNTIF('04'!A$2:A$121,"<="&'05'!B3)-
  COUNTIF('04'!A$2:A$121,"<="&'05'!B4))
```

Расчёт условного среднего

СЧЕТЕСЛИ.

Формула для расчета условного среднего фактора **X** получается довольно громоздкой — см. формулы.

Изучите формулы и найдите следующие элементы:

— диапазон ячеек от **A2** до **A121** на листе **04**;

— верхняя граница первого интервала на листе **05**;

— верхняя граница второго интервала на листе **05**.

Чтобы не запутаться, проведём наши расчёты по частям. Сначала найдём суммы и количества значений **X,** не превышающих верхней границы. Затем определим разности соседних ячеек. Затем проведём деление и в результате получим среднее значение **X** в каждом интервале группировки.

Вычисление условного среднего значения результативного признака **Y** немного сложнее. Здесь проверяется условие попадания факторного признака **X** в интервал группировки, а сумма считается по столбцу результативного признака **Y**. Для этого используется третий аргумент функции **SUMIF** — см. формулу.

Для копирования формулы фиксируем номера строк с помощью знака **$**.

После вычислений наносим линию условного среднего на диаграмму разброса. Для этого нам потребуется ломаная линия с маркерами точек.

=SUMIF('04'!A$2:A$121,"<="&'05'!B3,'04'!B$2:B$121)

'04'!B$2:B$121 – диапазон ячеек **Y** на листе **04**.

Условное среднее**Y (X)**

G3 =SUMIF('04'!A$2:A$121,"<="&'05'!B3,'04'!B$2:B$121)

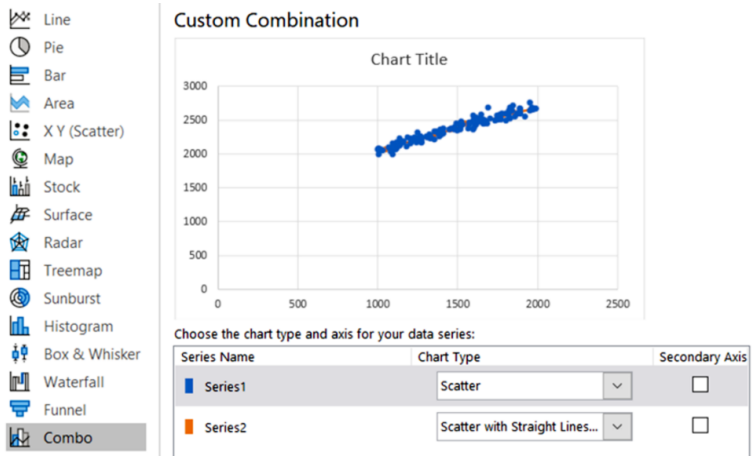
	A	B	C	D	E	F	G	H	I	J
1			сум X	сум X	кол X	кол X	сум Y	сум Y		
2	ниж	верх	X <= верх	ниж < X <= верх	X <= верх	ниж < X <= верх	X <= верх	X в инт	X ср	Y ср
3	1000	1100	11600	11600	11	11	22639	22639	**1054.545**	**2058.091**
4	1100	1200	26446	14846	24	13	50504	27865	**1142**	**2143.462**
5	1200	1300	41413	14967	36	12	77018	26514	**1247.25**	**2209.5**
6	1300	1400	57678	16265	48	12	104308	27290	**1355.417**	**2274.167**
7	1400	1500	70781	13103	57	9	125550	21242	**1455.889**	**2360.222**
8	1500	1600	89339	18558	69	12	154784	29234	**1546.5**	**2436.167**
9	1600	1700	118846	29507	87	18	199432	44648	**1639.278**	**2480.444**
10	1700	1800	138180	19334	98	11	227211	27779	**1757.636**	**2525.364**
11	1800	1900	165988	27808	113	15	266434	39223	**1853.867**	**2614.867**
12	1900	2000	179726	13738	120	7	285038	18604	**1962.571**	**2657.714**
13					**всего**	**120**				

Вычисление условного среднего

Строим диаграмму разброса, как описано выше.
Выбираем второй ряд данных:
Select Data — Select Data Source — Add
Выбрать данные — Выбор источника данных — Добавить.

Добавляем новые данные для графика. В качестве значений **x** берём условные средние «иксы», а в качестве **y** — условные средние «игреки». На графике появляются новые точки.

Изменяем тип диаграммы: щёлкаем правой кнопкой по графику и выбираем комбинированный график:
Change Chart Type – **Combo**
Изменить тип диаграммы — Комбинированная.



Комбинация графиков

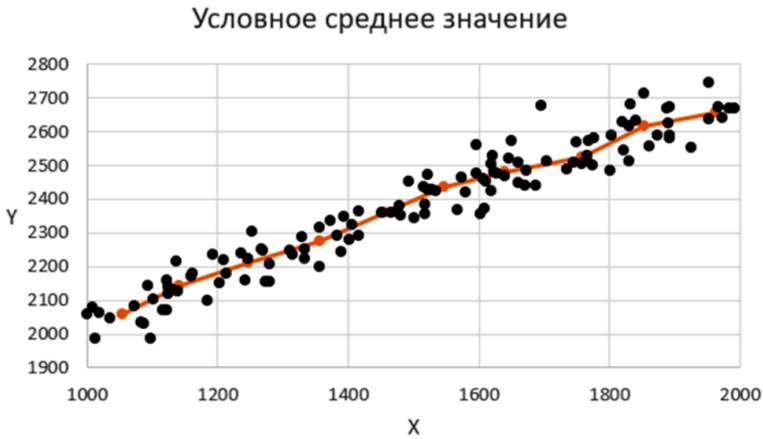
Для исходных данных оставляем диаграмму разброса:
Scatter
Точечная.

Для условного среднего выбираем ломаную линию:
Scatter with Straight Lines
Точечная с прямыми отрезками и маркерами.

Для использовани единого масштаба на графиках снимаем выбор пункта:
Secondary Axis
Вспомогательная ось.

Если на графике будет две вертикальных оси, то будет свой масштаб для каждого набора данных. Такие графики будет невозможно сравнивать. Нам нужен общий, единый масштаб.

В процессе настройки графиков можно видеть, как меняется изображение. При выборе данных для графиков мы не указыва-



Условное среднее на диаграмме разброса

ли названия рядов, поэтому они названы по умолчанию **Series1** и **Series2**. Пока на графике не так много данных, это не доставляет неудобств. В следующей работе всё-таки придётся задать имена для каждого набора данных, чтобы легче было работать с несколькими графиками.

Как и раньше, настраиваем масштаб, заголовки, цвета. График готов.

НАДСТРОЙКА

Продолжаем строить модель связи в форме уравнения регрессии. Для его построения необходимо вычислить коэффициенты регрессии.

В этом разделе используем статистическую надстройку:
Data — Analysis — Data Analysis — Regression
Данные — Анализ — Анализ данных — Регрессия.

ЛИНЕЙНАЯ РЕГРЕССИЯ

После вызова надстройки анализа данных и выбора регрессионного анализа появляется диалоговое окно настройки параметров анализа:

Regression
Регрессия.

Указываем диапазоны ячеек для входных интервалов фактора **X** и результата **Y**. Обратите внимание, что в первой строке вводятся «игреки», а во второй — «иксы». Выделяем диапазоны ячеек с заголовками и указываем это в пункте

Labels
Метки.

В уравнении регрессии будет свободный член, поэтому убеждаемся, что сняли выбор пункта

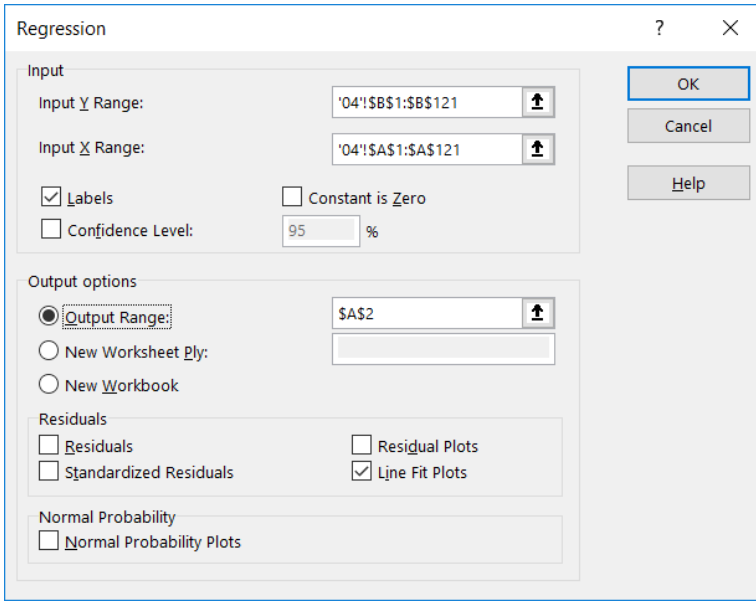
Constant is Zero
Константа — ноль.

Указываем первую ячейку для вывода результатов
Output options — Output Range
Параметры вывода — Выходной интервал.

Ещё нас интересует график. Поэтому отмечаем пункт
Residuals — Line Fit Plots
Остатки — График подбора.

Регрессию иногда не слишком грамотно называют «подбор» или «подгонка». На самом деле это попытка перевести английский термин **fit**. В качестве упражнения предлагаем заглянуть в **Википедию** и ознакомиться с англоязычным разделом **Curve fitting** и его русскоязычным вариантом **Приближение с помощью кривых**.

Более грамотный перевод слова FIT — это АППРОКСИМА-



Параметры регрессионного анализа

ЦИЯ, то есть приблизительная замена сложной функции или большого массива данных упрощённой функцией. Слово «аппроксимация» буквально означает «приближение», или «приблизительная замена».

Для нас это пример того, какие проблемы возникают у переводчиков англоязычных программных средств. Для грамотного перевода требуется профессиональное, грамотное владение предметной областью и терминологией на обоих языках. Естественно, это слишком «дорого» и «нерентабельно».

На экран выводится несколько таблиц и один график.

Среди результатов регрессионного анализа нас будут интересовать прежде всего коэффициенты уравнения. Рассмотрим третью табличку поподробнее. Увеличим ширину столбцов. Для

SUMMARY OUTPUT

Regression Statistics	
Multiple R	0.9659
R Square	0.932962
Adjusted R	0.932394
Standard E	50.47109
Observatic	120

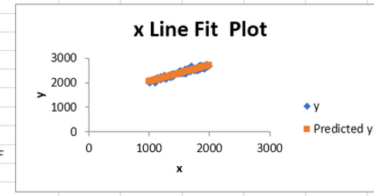
ANOVA

	df	*SS*	*MS*	*F*	*ignificance F*
Regressior	1	4183249	4183249	1642.209	4.29E-71
Residual	118	300585	2547.331		
Total	119	4483834			

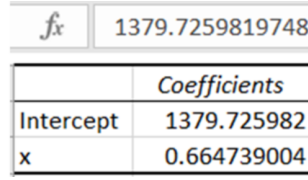
	Coefficients	*tandard Erı*	*t Stat*	*P-value*	*Lower 95%*	*Upper 95%*	*ower 95.0%*	*pper 95.0%*
Intercept	1379.726	24.99611	55.19762	3.93E-86	1330.227	1429.225	1330.227	1429.225
x	0.664739	0.016404	40.52417	4.29E-71	0.632256	0.697222	0.632256	0.697222

RESIDUAL OUTPUT

)bservatior	*Predicted y*	*Residuals*
1	2126.893	12.10738
2	2049.118	31.88184
3	2303.048	-56.0485



Результаты регрессионного анализа



Коэффициенты уравнения

точного вывода всех доступных разрядов можно щёлкнуть по ячейке и взглянуть на строку формул.

В таблице коэффициентов имеется две строчки.

В первой строке выводится СВОБОДНЫЙ ЧЛЕН уравнения регрессии. Строка обозначена следующим образом:

Intercept

Y-пересечение.

Имеется в виду значение **Y**, при котором линия регрессии

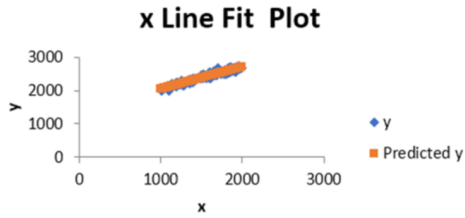


Диаграмма разброса и прогноз

ПЕРЕСЕКАЕТ вертикальную ось координат. В нашем примере свободный член уравнения обозначен буквой ***a***.

***a* = 1379.7259819748**.

Во второй строке выводится КОЭФФИЦИЕНТ РЕГРЕССИИ:

X

Переменная X 1.

В нашем уравнении коэффициент регрессии, то есть коэффициент при «иксе», обозначен буквой ***b***.

***b* = 0.664739003611188**.

Второй результат анализа, который мы рассмотрим, — это график под названием **Line Fit Plot**. Имеется в виду графическое изображение ЛИНЕЙНОЙ АППРОКСИМАЦИИ. **Predicted Y** — это ЛИНЕЙНЫЙ ПРОГНОЗ, то есть оценка значения результативного признака по уравнению регрессии.

Настроим масштаб по осям, увеличим график и отключим ЛЕГЕНДУ ДИАГРАММЫ — это условные обозначения в правой части графика. Пока у нас всего два ряда данных, нетрудно сообразить, кто есть кто.

Для исходных данных установим чёрные круглые маркеры вместо синих ромбиков.

Выбираем тип маркера большую точку (закрашенный кружочек):

Format Data Series — Series Options — Fill & Line — Marker — Marker Options — Built-in — Type — •

Формат ряда данных — Параметры ряда — Заливка и границы — Маркер — Параметры маркера — Встроенный — Тип — •.

Настраиваем заливку чёрным цветом:
Fill — Solid fill — Color — Black
Заливка — Сплошная заливка — Цвет — Чёрный.

Отключаем «границу» — обрамление маркера:
Border — No line
Граница — Нет линий.

Для линейного прогноза установим сплошную чёрную линию вместо оранжевых ромбиков:

Format Data Series — Series Options — Fill & Line — Line — Solid line

Формат ряда данных — Параметры ряда — Заливка и границы — Линия — Сплошная линия.

Устанавливаем цвет линии:
Color — Black
Цвет — Чёрный.

Оставляем только линию и убираем маркеры:
Marker — Marker Options — None
Маркер — Параметры маркера — Нет.

Задаём толщину линии:
Line — Width — 1 pt
Линия — Ширина — 1 пт.

И снова — проблема перевода. ШИРИНА чаще бывает у полосы или прямоугольника. ТОЛЩИНА ЛИНИИ звучит как-то бо-



Линейная регрессия

лее привычно. Но это, конечно же, дело вкуса — если работой занимается любитель, дилетант, то есть человек не является специалистом. Особенно, если переводить отдельные слова и не обращать внимание на окружающий текст, который называется КОНТЕКСТ.

Для специалистов, для серьёзной работы существуют СТАНДАРТЫ. И в стандартах есть грамотные названия, правильные ТЕРМИНЫ. Это язык конкретной профессии. Возьмём, к примеру, такой документ:

ГОСТ 2.303—68 ЕСКД. Линии.

Это отечественный государственный стандарт (сокращённо ГОСТ). Данный стандарт входит в Единую систему конструкторской документации (сокращённо ЕСКД). С конструкторскими чертежами работает инженер-конструктор. По сути, это изображение конструкции изделия, которое затем рабочие будут изготавливать на станках по этим чертежам. В данном стандарте есть только ТОЛЩИНА ЛИНИИ. Ознакомьтесь с текстом стандарта и обратите внимание на выражение ТОЛЩИНА ЛИНИИ.

$y = a_1x + a_0$ – прямая

$y = a_2x^2 + a_1x + a_0$ – парабола

$y = a_3x^3 + a_2x^2 + a_1x + a_0$ – кубическая парабола

Уравнения регрессии

Пока что мы рассматриваем линейную регрессию, поэтому прямая линия получилась довольно приличная. Для нелинейной регрессии линию придётся рисовать совсем по-другому.

НЕЛИНЕЙНАЯ РЕГРЕССИЯ

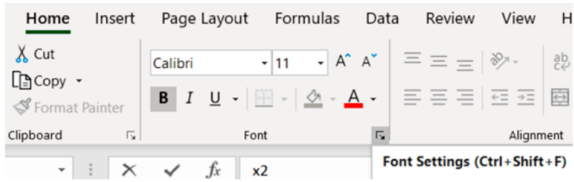
Нелинейная регрессия — это построение уравнения связи и графика с использованием нелинейной функции. Другими словами, здесь работает всё, что не является линейным. Но только с одной оговоркой: уравнение должно выглядеть как сумма или разность. Тогда для каждого члена уравнения программа сможет подобрать коэффициенты.

В данной работе мы рассмотрим самые простые уравнения регрессии, в которых «икс» участвует не только в первой степени, но также в квадрате и в кубе — см. формулы.

Для построения нелинейной регрессии придётся создать вспомогательные столбцы нелинейных членов уравнения. Для параболы и кубической параболы необходимо в качестве **входного интервала X** выбрать соответствующие столбцы с разными степенями «икса». Эти значения желательно расположить в соседних столбах и выделить как один диапазон.

Обратите внимание на то, в каком порядке идут члены уравнения. По возрастанию или по убыванию степени «икса»? За этим нужно будет следить при формировании вспомогательных столбцов, при вызове функций регрессионного анализа и при чтении результатов.

Итак, на новый лист копируем исходные данные и добавляем колонку квадратов «икса» — рядом с «иксами» в первой сте-



Форматирование текста

пени. Будущие члены нашего уравнения регрессии называются красивым словом РЕГРЕССОРЫ. Это просто «участники» уравнения, для которых подбирают коэффициенты. В этом названии нет негативного оттенка, как и в слове РЕГРЕССИЯ. В статистике слово «регрессия» означает просто «зависимость в среднем». А вот в других дисциплинах регрессия может означать движение назад, противоположность прогрессу или возвращение в прошлое.

Для дальнейшей работы все столбцы регрессоров должны идти друг за другом. Тогда мы сможем выделить их как один диапазон ячеек. Так будет проще и понятнее.

Украсим заголовки столбцов со степенями «иксов». Выделяем показатель степени — цифру **2** — и вызываем форматирование, нажав кнопку

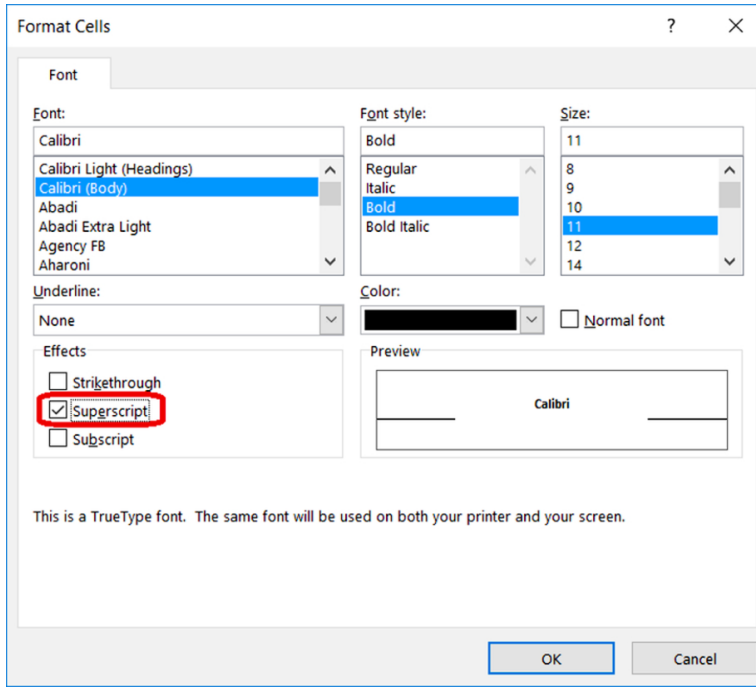
Font Settings
Настройки шрифта.

Это загадочная стрелочка в правом нижнем углу раздела
Font
Шрифт.

Появляется диалоговое окно настройки форматирования содержимого ячеек:

Format Cells
Формат ячеек.

Выбираем пункт
Superscript



Верхний индекс

Верхний индекс.

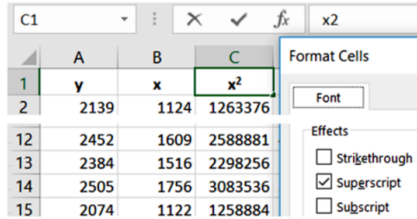
Нажимаем кнопку **OK**.

Теперь заголовки столбцов со степенями «икса» легко читаются.

Когда исходные данные подготовлены, вызываем надстройку и указываем входные данные, как показано на рисунке. По-прежнему, вначале указываем диапазон **Y**, а потом диапазон **X** в разных степенях. Заголовки столбцов пригодятся при расшифровке результатов. Поэтому выбираем пункт

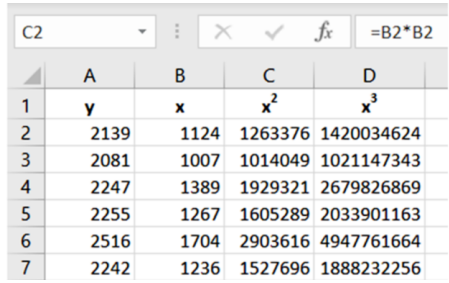
Labels

Метки.



	A	B	C
1	y	x	x^2
2	2139	1124	1263376
12	2452	1609	2588881
13	2384	1516	2298256
14	2505	1756	3083536
15	2074	1122	1258884

Форматирование заголовка столбца



	A	B	C	D
1	y	x	x^2	x^3
2	2139	1124	1263376	1420034624
3	2081	1007	1014049	1021147343
4	2247	1389	1929321	2679826869
5	2255	1267	1605289	2033901163
6	2516	1704	2903616	4947761664
7	2242	1236	1527696	1888232256

Исходные данные — регрессоры

Начнём с построения параболы. Указываем в качестве факторных признаков два столбца «иксов» — в первой и второй степени.

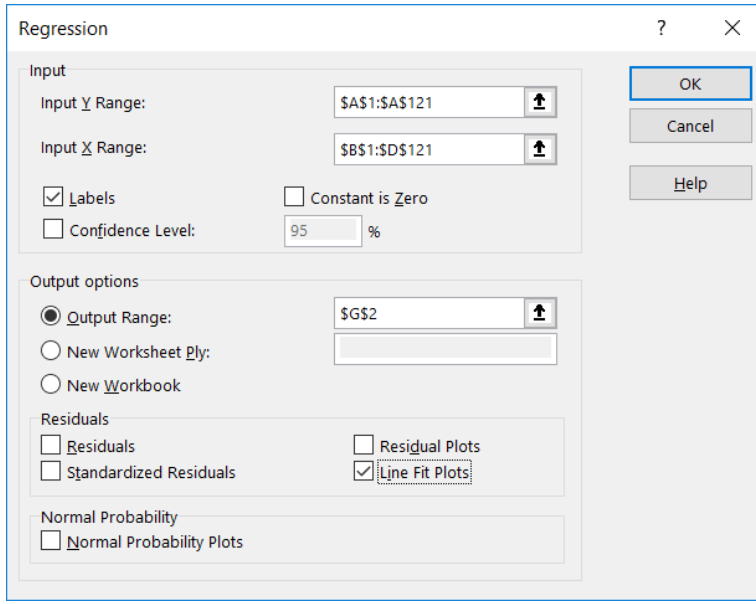
Выбираем автоматическое построение графика «аппроксимации»:

Residuals — Line Fit Plots
Остатки — График подбора.

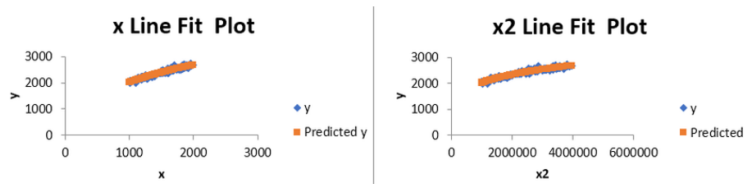
На экране появляются два загадочных графика.

Чтобы понять, почему появилось два графика вместо одного, заглянем в исходные данные второй диаграммы. Щёлкнем правой кнопкой по графику и выберем

Select Data
Выбрать данные.



Нелинейная регрессия

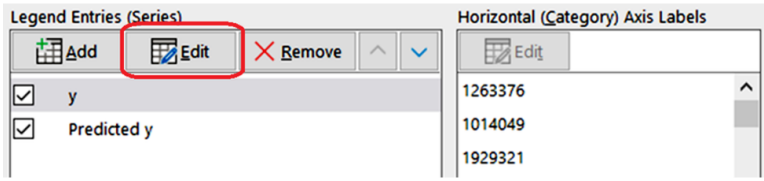


Графики аппроксимации

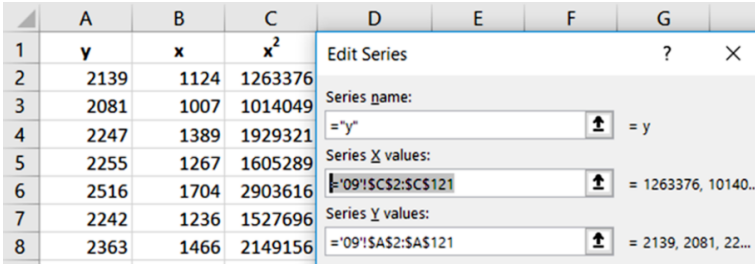
В этой диаграмме использованы два набора данных: **y** (исходные «игреки») и **Predicted y** (прогноз значений «игрека» по уравнению регрессии). В окне

Select Data Source

Выбор источника данных



Данные для второй диаграммы



Данные для второй диаграммы

выберем строчку **y** и нажмём

Edit

Изменить.

Рассмотрим, какие данные были выбраны для диаграммы. Нужные сведения выводятся в окне

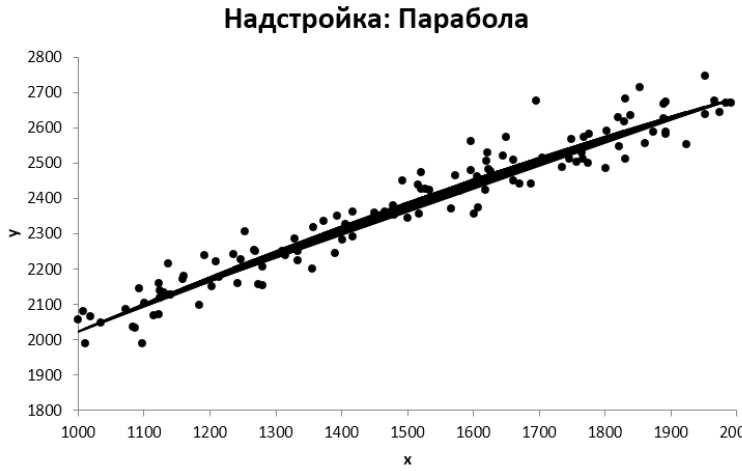
Edit Series

Изменение ряда.

Выясняется, что по горизонтальной оси были выбраны квадраты «иксов».

Оставляем только первый график, а второй — удаляем. Теперь настроим наш график аппроксимации и рассмотрим его поподробней.

Вместо ЛИНИИ регрессии можно видеть странную фигуру, которая утолщается в середине и сужается по краям. Причина



«График» параболы

в том, что соседние точки на графике соединяются отрезками. Но эти точки идут в том же порядке, как в исходной таблице, а там данные расположены в случайном порядке, не по возрастанию. Придётся кое-что подправить.

Скопируем столбец «иксов» и вставим на место столбца
Observation
Наблюдение
в таблицу
RESIDUAL OUTPUT
ВЫВОД ОСТАТКА.

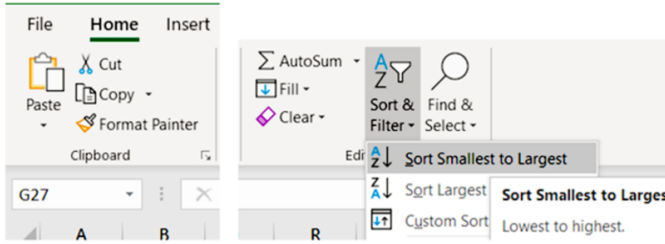
Столбец **Observation** содержит порядковые номера *i* наблюдений в таблице исходных данных.

Третий столбец
Residuals
Остатки
нам для работы не потребуется — мы его просто удаляем.

Теперь у нас есть пары соответствующих «иксов» и «игре-

RESIDUAL OUTPUT		
Observation	*Predicted y*	*Residuals*
1	2119.3696	19.630432
2	2027.9807	53.01928
3	2312.4809	-65.48091
4	2225.969	29.03101
5	2516.9768	-0.976845

Таблица прогнозов



Сортировка по возрастанию

ков». Отсортируем их по возрастанию. Для этого выделяем диапазон данных в столбцах **X** и

Predicted y

Предсказанное Y.

Вызываем сортировку через верхнее меню:

Home — Editing — Sort & Filter — Sort Smallest to Largest

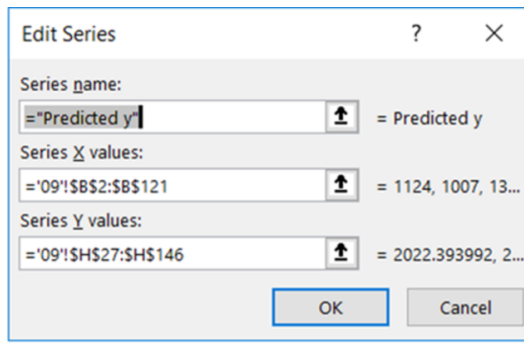
Главная — Редактирование — Сортировка и фильтр — Сортировка по возрастанию.

Сортировка ячеек выделенного диапазона выполняется по возрастанию чисел в первом столбце. Это значит, что «иксы» выстраиваются по возрастанию, а соответствующие им «игреки» перемещаются вслед за своими «иксами».

Теперь изменим диапазоны ячеек для **Predicted y** в данных

RESIDUAL OUTPUT	
x	*Predicted y*
1000	2022.393992
1007	2027.98072
1011	2031.167102
1018	2036.732714
1034	2049.403652

Отсортированные данные



Данные для**Predicted y**

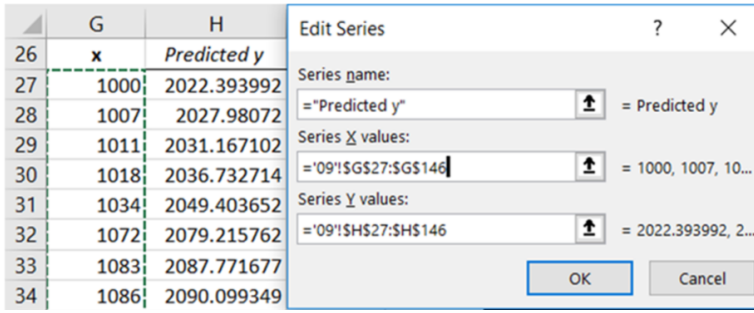
для графика:

Select Data — Select Data Source — Legend Entries (Series) — Predicted y — Edit.

Выбор данных — Выбор источника данных — Легенда — Предсказанное Y — Изменить.

Вместо столбца исходных «иксов» выбираем отсортированные «иксы» из вспомогательной таблицы. Диапазон для прогноза «игреков» оставляем тем же.

Теперь линия регрессии на графике стала похожа на линию. Поскольку мы генерировали исходные данные с помощью урав-



	G	H
26	x	*Predicted y*
27	1000	2022.393992
28	1007	2027.98072
29	1011	2031.167102
30	1018	2036.732714
31	1034	2049.403652
32	1072	2079.215762
33	1083	2087.771677
34	1086	2090.099349

Отсортированные**Predicted y**

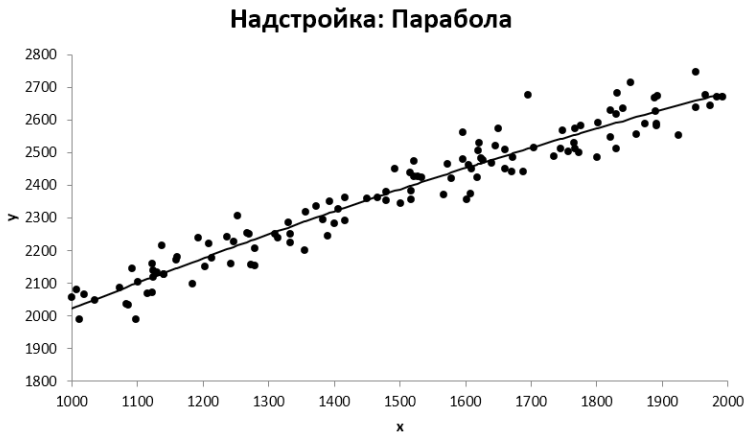


График по отсортированным данным

нения прямой линии, в наших точках особой «кривизны» не наблюдается. Так что мы видим участок параболы с очень небольшой кривизной.

Перейдём к уравнению регрессии. Надстройка выдаёт нам оценки коэффициентов уравнения. Заголовки строк указывают, к чему относится каждый коэффициент:

Intercept — свободный член уравнения;

	Coefficients
Intercept	1086.211885
x	1.073300445
x2	-0.000137118

Оценки коэффициентов

y =	1086.211885	+	1.073300445	x	-0.000137118	x^2

Уравнение регрессии

x — «иксы»;
x2 — квадраты «иксов».

В исходной таблице мы сделали красивый заголовок для квадратов «икса» x^2 с помощью форматирования. Как видим, при выводе результатов регрессионного анализа форматирование потерялось и осталось только **x2**. Делаем вывод: заголовки должны быть такими, чтобы они хорошо читались как с форматированием, так и без форматирования.

Берём коэффициенты и записываем уравнение регрессии. Нам понадобится несколько ячеек. Используем ссылки на ячейки с оценками коэффициентов.

Коэффициент при квадрате «икса» небольшой. С учётом величины квадрата «икса» получаем небольшой вклад в общий результат — на фоне остальных членов уравнения. Сравним вклад членов уравнения для среднего значения аргумента. Вычисления округлим до целых:

x = 1 500
x^2 = 2 250 000.

Свободный член: **1 086**.

Вклад **x**: **1,0733 * 1500 = 1 610**.

Вклад **x^2**: **0,000 137 * 1 500 * 1 500 = 308**.

Относительный вклад **x^2**:
308 / (1086 +1610 +308) * 100% = 10%.

Получается, что нелинейная часть уравнения даёт всего 10% изменения результативного признака.

Чтобы построить уравнение третьей степени, повторите описанные шаги для диапазона ячеек, дополнительно включающего столбец третьих степеней «иксов».

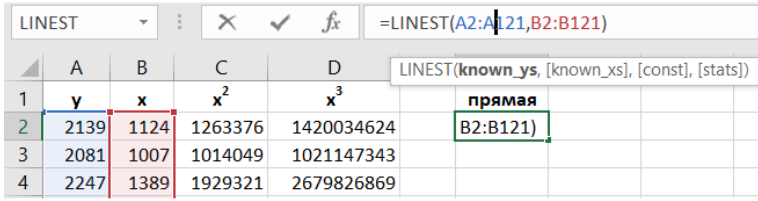
ФУНКЦИЯ LINEST / ЛИНЕЙН

Второй способ регрессионного анализа — готовая функция Excel. Коэффициенты регрессии можно найти с помощью функции

LINEST
ЛИНЕЙН.

Как и в предыдущем разделе, используем дополнительные столбцы со степенями «иксов». Скопируем исходные данные на новый лист. Значения регрессоров по-прежнему должны располагаться в соседних столбцах. При этом они указываются в виде диапазона как второй аргумент функции. В нашем случае формат вызова функции следующий:

LINEST (range_y, range_x)
ЛИНЕЙН (диапазон_y; диапазон_x).



Параметры функции**LINEST**

Функция **LINEST** выводит результаты анализа в виде массива в несколько ячеек. Вызов этой функции снова потребует от нас выполнить несколько шагов. Напомним последовательность работы с формулой массива:

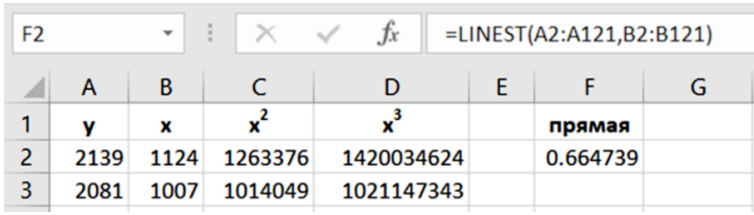
— ввести формулу в левую верхнюю ячейку диапазона;
— выделить весь диапазон ячеек;
— нажать клавишу **[F2]**;
— нажать комбинацию клавиш **[Ctrl + Shift + Enter]**.

Вначале вводим функцию **LINEST** в ячейку и указываем аргументы функции — диапазоны ячеек с исходными данными. Здесь тоже вначале идут «игреки», а потом «иксы». Всплывающая подсказка намекает, что у функции **LINEST** есть один обязательный аргумент и три необязательных — они указаны в квадратных скобках. Нам нужно указать два аргумента функции, как показано на рисунке.

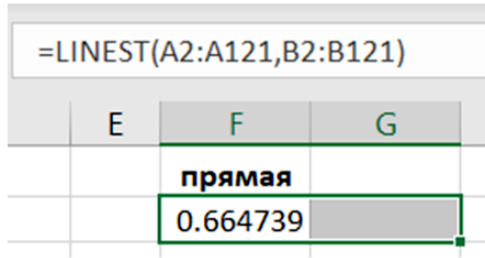
Как видим, при таком вызове функция даёт нам значение всего одного коэффициента. А в линейном уравнении их должно два.

Чтобы получить два коэффициента, проделаем описанные шаги для ввода ФОРМУЛЫ МАССИВА. Выделяем диапазон, состоящий из двух соседних ячеек **F2** и **G2**. Вторая ячейка диапазона должна быть справа от первой!

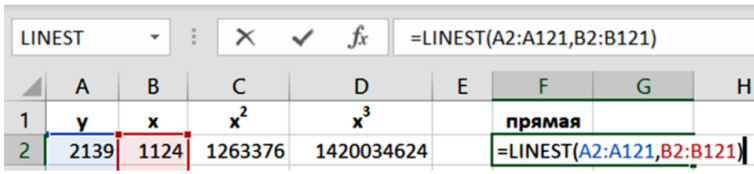
Нажимаем клавишу **[F2]**. Обычно её используют для редактирования содержимого одной ячейки. Но теперь у нас было вы-



Оценка одного коэффициента



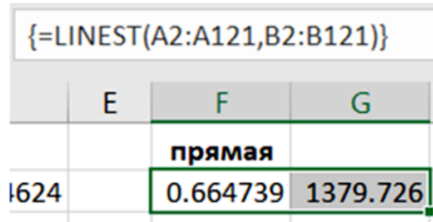
Выделение диапазона из двух ячеек



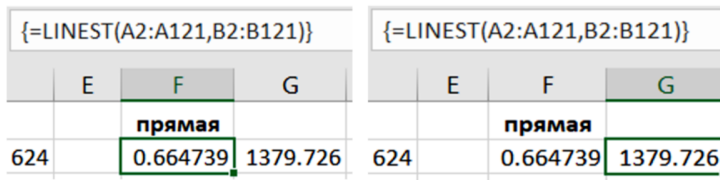
Результат нажатия **[F2]**

делено две ячейки. На рисунке можно видеть, что выделение всё ещё охватывает две наши ячейки. Обратите внимание на зелёное обрамление вокруг ячеек **F2** и **G2**. Получается что мы «редактируем» выделенный диапазон ячеек.

Наконец, нажимаем комбинацию клавиш:
[Ctrl + Shift + Enter].



Формула массива



Формула массива в каждой ячейке

Вокруг формулы появились ФИГУРНЫЕ СКОБКИ. Это говорит о том, что это формула массива.

При выборе любой ячейки диапазона можно видеть фигурные скобки фокруг формулы — см. рисунок.

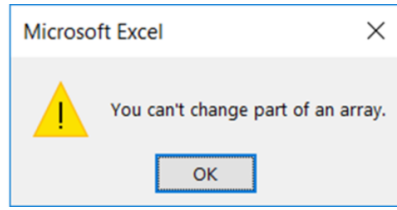
Excel не позволяет изменить или удалить содержимое ячейки, если она входит в массив. При попытке внести изменения или удалить содержимое выводится сообщение:

You can't change part of an array

Нельзя изменить часть массива.

При работе с массивом можно удалить только весь массив целиком. Выделим наш массив из двух ячеек и нажмём клавишу **Delete**. Массив удалён. Вернём результаты на место: нажмём кнопку отката **Undo** в левой верхней части окна программы. Можно также использовать комбинацию клавиш **[Ctrl + Z]**.

Повторим описанные шаги для построения уравнения регрессии второго и третьего порядка. Для параболы потребуется



Запрет изменений в массиве



Откат изменений

$$y = a_1 x + a_0 \text{ – прямая}$$
$$y = a_2 x^2 + a_1 x + a_0 \text{ – парабола}$$
$$y = a_3 x^3 + a_2 x^2 + a_1 x + a_0 \text{ – кубическая парабола}$$

Уравнения регрессии

три коэффициента, а для кубической параболы — четыре. Соответственно, нужно будет вводить формулу массива на три или на четыре ячейки.

Чтобы можно было сравнить результаты, наведём порядок в представлении. Напомним, как выглядят уравнения регрессии — см. формулы.

Обратите внимание, что во всех трёх уравнениях номер (индекс) коэффициента — это степень, в которую возводится «икс». Поэтому придётся немного перестроить таблицу для коэффициентов.

{=LINEST(A2:A121,B2:D121)}

F	G	H	I	J
	a3	**a2**	**a1**	**a0**
прямая			0.664739004	1379.725982
парабола		-0.000137118	1.073300445	1086.211885
кубич парабола	-1.44383E-07	0.000512149	0.120813203	1541.207412

Оценки коэффициентов

прямая	y =					0.664739	x +	1379.726
парабола	y =			-0.0001371	x^2 +	1.0733004	x +	1086.2119
кубич парабола	y =	-1.44383E-07	x^3 +	0.00051215	x^2 +	0.1208132	x +	1541.2074

Уравнения регрессии

Получив оценки коэффициентов, можно записать уравнения регрессии.

Следующий шаг — графики. Нам нужно построить диаграмму разброса и нанести на неё линии регрессии.

Напомним, как построить диаграмму разброса:

Insert — Charts — Insert Scatter (X, Y) or Bubble Chart — Scatter — Scatter

Вставка — Диаграмма — Вставить точечную (X, Y) или пузырьковую диаграмму — Точечная — Точечная.

Добавляем набор данных для построения диаграммы разброса:

Select Data — Add

Выбрать данные — Добавить.

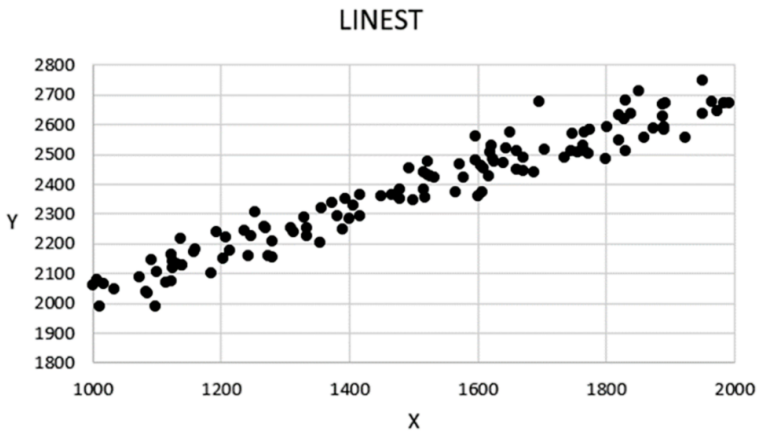


Диаграмма разброса

Настраиваем масштаб, указываем пределы значений по осям:

Format Axis — Axis options — Bounds — Minimum/Maximum

Формат оси — Параметры оси — Границы — Минимум/Максимум.

Устанавливаем тип маркеров — жирные точки:

Format Data Series — Series Options — Fill & Line — Marker — Marker Options — Built-in — •

Формат ряда данных — Параметры ряда — Заливка и границы — Маркер — Параметры маркера — Встроенный — Тип — •.

Устанавливаем чёрный цвет для заливки маркеров:

Format Data Series — Series Options — Fill & Line — Marker — Fill — Solid Fill — Color — Black

Формат ряда данных — Параметры ряда — Заливка и границы — Маркер — Заливка — Сплошная заливка — Цвет — Чёрный.

=$J$2+$I$2*F9

	G	H	I	J	K
x	**x^2**	**x^3**	**прям.**	**пар.**	**куб.пар.**
1000	1000000	1000000000	2044.464986	2022.393992	2029.787144
1100	1210000	1331000000	2110.938886	2100.929186	2101.629133
1200	1440000	1728000000	2177.412786	2176.722013	2174.184850
1300	1690000	2197000000	2243.886687	2249.772473	2246.588000
1400	1960000	2744000000	2310.360587	2320.080566	2317.972286
1500	2250000	3375000000	2376.834487	2387.646293	2387.471412
1600	2560000	4096000000	2443.308388	2452.469653	2454.219082
1700	2890000	4913000000	2509.782288	2514.550646	2517.349000
1800	3240000	5832000000	2576.256188	2573.889273	2575.994871
1900	3610000	6859000000	2642.730089	2630.485532	2629.290398
2000	4000000	8000000000	2709.203989	2684.339425	2676.369286

Данные для графиков

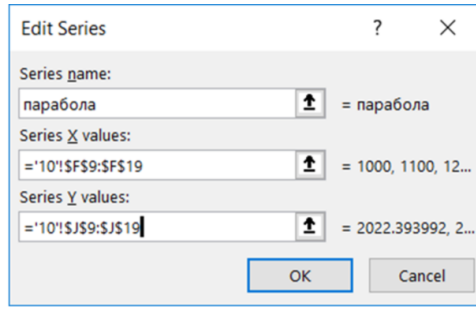
Чтобы нанести на график линию регрессию, сделаем вспомогательную таблицу. Первый столбец — десять значений «икс» от минимального до максимального. В соответствии с нашим вариантом задания, диапазон от 1000 до 2000. Для получения десяти значений берём шаг 100 единиц.

Вводим числа 1000 и 1100. Выделяем диапазон из этих двух ячеек и тянем вниз маркер заполнения. Вводим формулы для квадратов и кубов. Вычисляем прогнозы по уравнениям регрессии. Не забываем зафиксировать значения коэффициентов, нажав клавишу **F4**.

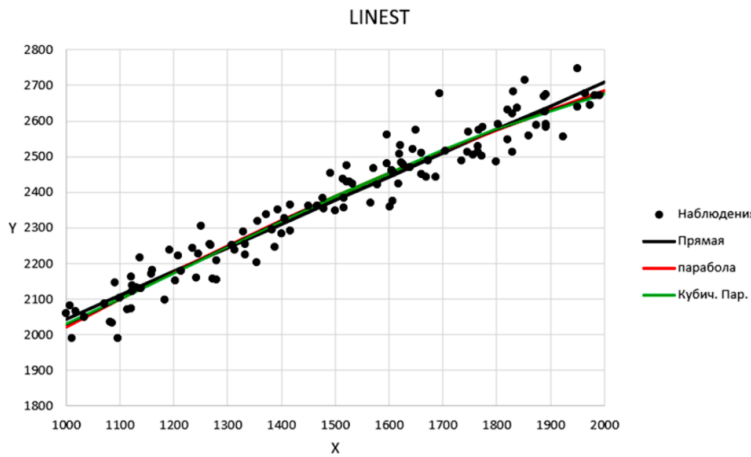
Добавляем данные для графиков. Настраиваем тип и цвет линий. Добавляем легенду. В этом случае легенда будет полезной. Она поможет различать наши три линии.

Вид нашего уравнения регрессии указываем при выборе данных для графика в окне **Edit Series** в строке **Series name**.

Получаем довольно прилично оформленный график. На нём есть исходные данные в виде точек. Три линии регрессии имеют разный цвет. Обозначения (легенда) приводятся справа от гра-



Вид уравнения регрессии



Линии регрессии

фика. На осях имеются заголовки и масштаб. У графика тоже есть заголовок. При таком оформлении можно понять, что тут нарисовано и как оно обозначено.

СИСТЕМА НОРМАЛЬНЫХ УРАВНЕНИЙ

Третий способ регрессионного анализа в Excel — это построение уравнения регрессии путём решения системы уравнений. Для этого мы будем использовать функции массивов для выполнения операций над матрицами.

Чтобы не запутаться, давайте определимся с названиями. В этом разделе мы используем два названия для одного и того же: **массив, матрица** и **диапазон**.

МАССИВ (термин из области программирования) — это особый тип данных. Переменная такого типа хранит несколько значений. Это элементы массива, к которым обращаются по одному или нескольким номерам (индексам). У массива может быть несколько измерений.

В пакете Excel мы будем работать с одномерными и двумерными массивами. Формулы массивов Excel работают с аргументами-массивами и могут выдавать результат тоже в виде массива. Формулы массивов вводят особым образом — мы с этим уже немного познакомились.

МАТРИЦА (термин из математики) — это прямоугольная таблица чисел. У матрицы может быть одно или два измерения. С матрицами выполняют различные действия, например, сложение и умножение.

Матрицы часто используют при решении систем уравнений. С матрицей можно работать и без компьютера — тогда это просто табличка с цифрами или буквами, записанными на бумаге. Если с матрицей работать в пакете программ, то её нужно будет хранить в переменной типа «массив».

С точки зрения Excel мы работаем с ДИАПАЗОНОМ ячеек. Мы указываем диапазон в качестве входного аргумента функции. Мы вводим функцию массива в диапазон ячеек, чтобы получить результат в виде массива. Мы используем функции массива для работы с матрицами.

Надеемся, что ситуация с массивами и матрицами немного прояснилась. Теперь разберёмся, как построить регрессию с по-

$$y = a_0 + a_1 x$$

$$\begin{cases} a_0 n + a_1 \Sigma x = \Sigma y \\ a_0 \Sigma x + a_1 \Sigma x^2 = \Sigma yx \end{cases}$$

Система нормальных уравнений

мощью матриц.

Рассмотрим пример линейного уравнения. Это уравнение прямой линии. Чтобы найти коэффициенты такого уравнения регрессии, нам понадобится решить систему нормальных уравнений — см. формулы.

Здесь неизвестными являются коэффициенты a_0 и a_1. Известными являются суммы «иксов» и «игреков» в разных видах, а также количество точек n. Для начала нам нужно будет подсчитать эти суммы.

Скопируем исходные данные на новый лист и добавим дополнительные столбцы для расчёта сумм.

Выделяем нужные столбцы и находим суммы по этим столбцам с помощью кнопки экспресс-анализа

Quick Analysis
Быстрый анализ.

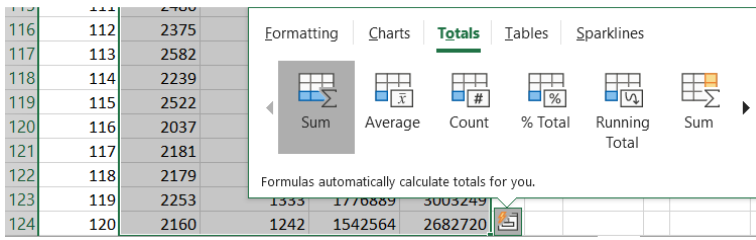
Использование экспресс-анализа подробно описано в первой работе. Ссылка на учебное пособие находится в конце данного выпуска.

Указываем в заголовке последней строки, что здесь находится сумма.

Чтобы уместить наши расчёты на одном листе в пределах видимости, скроем середину большой таблицы исходных данных. Выделим «лишние» строки с **6** по **123**, проведя мышкой с нажатой левой кнопкой по «серым» заголовкам строк и в контекстном меню выберем

	A	B	C	D	E
1	**Система нормальных уравнений**				
2	**Линейная регрессия**				
3					
4	**n**	**y**	**x**	**x^2**	**yx**
5	1	2139	1124	1263376	2404236
6	2	2081	1007	1014049	2095567
7	3	2247	1389	1929321	3121083
8	4	2255	1267	1605289	2857085
9	5	2516	1704	2903616	4287264

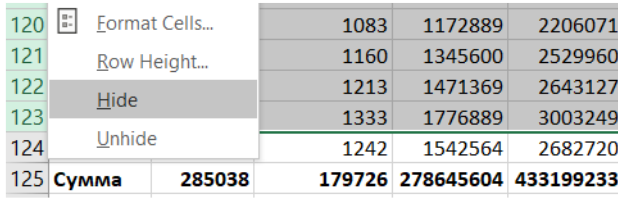
Вспомогательная таблица



Быстрый расчёт сумм

122	118	2179	1213	1471369	2643127
123	119	2253	1333	1776889	3003249
124	120	2160	1242	1542564	2682720
125	**Сумма**	**285038**	**179726**	**278645604**	**433199233**

Заголовок строки «Сумма»



120			1083	1172889	2206071
121			1160	1345600	2529960
122			1213	1471369	2643127
123			1333	1776889	3003249
124			1242	1542564	2682720
125	**Сумма**	**285038**	**179726**	**278645604**	**433199233**

Скрываем лишние строки

Hide
Скрыть.

Для вызова контекстного меню как всегда используем правую кнопку мыши.

Таблица со скрытыми строками стала более компактной. На скрытые строки намекает только двойная разделительная линия между строками **5** и **124**. Если понадобится снова показать всю таблицу, можно выделить её (в нашем случае это строки от **5** до **124**) и нажать

Unhide
Показать.

На этом листе будет несколько таблиц, которые мы обведём рамочкой. Выделим нашу таблицу и выберем в верхнем меню:

Home — Font — Borders — Thick Outside Borders
Главная — Шрифт — Границы — Толстые внешние границы.

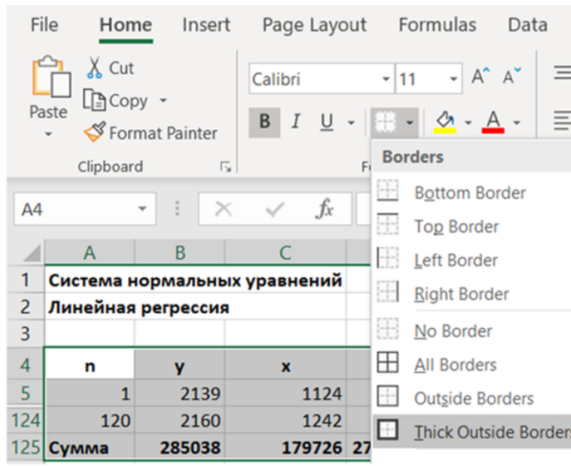
Появляется рамка, которая показывает, где находится наша таблица. Такое же обрамление мы сделаем и вокруг следующих таблиц (матриц) на этом рабочем листе.

Исходные данные готовы.

Возьмём систему нормальных уравнений и запишем её в матричном виде. Получается одно матричное уравнение, в ко-

4	n	y	x	x^2	yx
5	1	2139	1124	1263376	2404236
124	120	2160	1242	1542564	2682720
125	**Сумма**	**285038**	**179726**	**278645604**	**433199233**

Таблица со скрытыми строками



Обрамление таблицы

тором участвуют матрицы A, X и Y — см. формулы. Систему уравнений решаем путём умножения на обратную матрицу.

Чтобы иметь перед глазами формулы для расчётов и чтобы не запутать читателя, выпишем основные соотношения на листе бумаги. Сфотографируем формулы и вставим их на текущий лист Excel. Набирать формулы — довольно долгое занятие. К тому же,

4	n	y	x	x^2	yx
5	1	2139	1124	1263376	2404236
124	120	2160	1242	1542564	2682720
125	**Сумма**	**285038**	**179726**	**278645604**	**433199233**

Таблица с обрамлением

$$\begin{cases} a_0 n + a_1 \Sigma x = \Sigma y \\ a_0 \Sigma x + a_1 \Sigma x^2 = \Sigma yx \end{cases}$$

$$\mathbf{X} \cdot \mathbf{A} = \mathbf{Y}$$

$$\mathbf{X} = \begin{pmatrix} n & \Sigma x \\ \Sigma x & \Sigma yx \end{pmatrix}$$

$$\mathbf{A} = \begin{pmatrix} a_0 \\ a_1 \end{pmatrix}$$

$$\mathbf{Y} = \begin{pmatrix} \Sigma y \\ \Sigma yx \end{pmatrix}$$

$$\mathbf{A} = \mathbf{X}^{-1} \cdot \mathbf{Y}$$

Решение матричного уравнения

надо иногда учиться писать от руки. Это очень полезно — развивает и руки, и голову.

Сформируем матрицы **X** и **Y**. Все необходимые суммы уже подсчитаны. Объём выборки ***n*** тоже известен. Это число строк в таблице исходных данных — в соответствии с вариантом зада-

$$\begin{cases} a_0 n + a_1 \Sigma x = \Sigma y \\ a_0 \Sigma x + a_1 \Sigma x^2 = \Sigma yx \end{cases}$$

$$X = \begin{pmatrix} n & \Sigma x \\ \Sigma x & \Sigma x^2 \end{pmatrix}$$

$$A = \begin{pmatrix} a_0 \\ a_1 \end{pmatrix}$$

$$Y = \begin{pmatrix} \Sigma y \\ \Sigma yx \end{pmatrix}$$

$$X \cdot A = Y$$

$$A = X^{-1} \cdot Y$$

Формулы для расчётов

X =	120	179726
	179726	278645604
Y =	285038	
	433199233	

Матрицы для системы уравнений

ния. Используем ссылки на нужные ячейки. Рисуем рамки, чтобы выделить каждую матрицу.

Для решения системы нормальных уравнений нам предстоит найти обратную матрицу для **X** и умножить её на матрицу **Y**. Для этого мы будем использовать две функции Excel по работе с матрицами — обращение и умножение.

Функция нахождения обратной матрицы (обращение матрицы) **MINVERSE** возвращает обратную матрицу для матрицы, ко-

A =	1379.725982
	0.664739004

Решение системы уравнений

торая хранится в указанном массиве:

MINVERSE (array)
МОБР (массив).

Функция умножения матриц **MMULT** находит произведение двух матриц, которые хранятся в указанных массивах:

MMULT (array1, array2)
МУМНОЖ (матрица1;матрица2).

Обе функции работают с массивами и выдают результат в виде массива.

Ввод функции массива выполняем так же, как и раньше. Печатаем следующее выражение и нажимаем **OK**:

=MMULT (MINVERSE (C127:D128),C130:C131)

В текущей ячейке появляется одно число. Но результат решения системы — матрица А, столбец из двух ячеек. Поэтому выделяем вертикальный диапазон из двух ячеек, начиная с ячейки, в которую мы записали нашу формулу масива. Нажимаем клавишу **F2**, а затем комбинацию клавиш **Ctrl + Shift + Enter**.

Получаем результат решения системы уравнения — два числа, два коэффициента уравнения регрессии.

Зная коэффициенты, можно записать уравнение регрессии. Напомним, что первый элемент в матрице **A** — это a_0, а второй элемент — a_1. Уравнение регрессии записываем с помощью ссылок на эти две ячейки.

Уравнение регрессии				
y =	1379.726	+	0.664739	x

Уравнение регрессии

y	x
2139	1124
2160	1242
285038	179726
X =	120

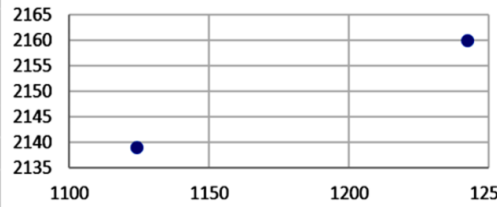


Диаграмма разброса

Переходим к графикам. Построим диаграмму разброса. Указываем диапазоны для «иксов» и «игреков». Однако на графике появляется всего две точки вместо 120.

Получается, что когда мы скрываем строки в таблице, эти данные не отображаются на графике. Нам хотелось бы держать все данные и графики перед глазами. Поэтому будем использовать для диаграммы разброса данные с другого листа, на котором отображены все 120 значений. Теперь на графике все точки на месте. Настроим тип и цвет маркера.

Добавим линию регрессии. Поскольку мы строим прямую линию, нам будет достаточно найти всего две точки. Сделаем вспомогательную табличку. Зададим два крайних значения «икс»: 1000 и 2000. Вычислим прогноз по уравнению регрессии для «игрека».

Добавим этот массив как данные для графика. Настроим тип и цвет линии. Отключим маркеры.

Рассмотрим построенный график и убедимся в правильности

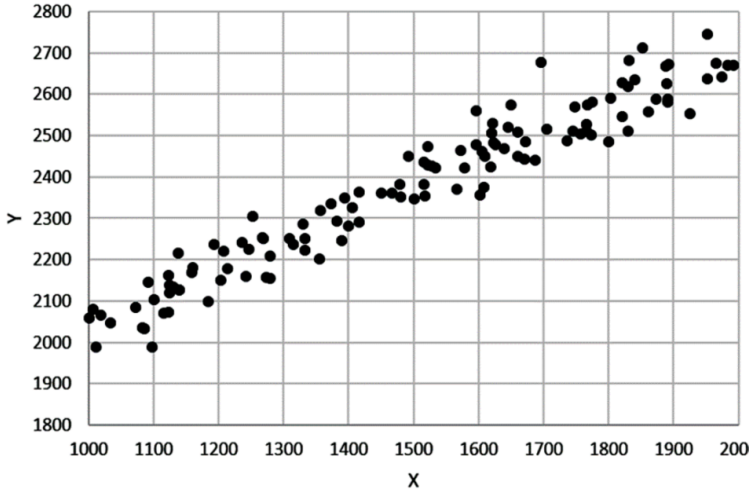


Диаграмма разброса

D138 | =$H$4+$J$4*C138

	C	D
136	**Линия регрессии**	
137	**x**	**y**
138	1000	2044.465
139	2000	2709.204

Вспомогательная таблица

расчётов. Линия регрессии проходит в среднем по исходным точкам. Значит, грубых ошибок у нас нет.

На рисунке приводится окончательный вид нашей страницы отчёта. Здесь есть заголовки, формулы, таблицы, и график. Читателю будет легко понять, что и как было сделано.

Далее самостоятельно постройте нелинейную регрессию второго и третьего порядка.

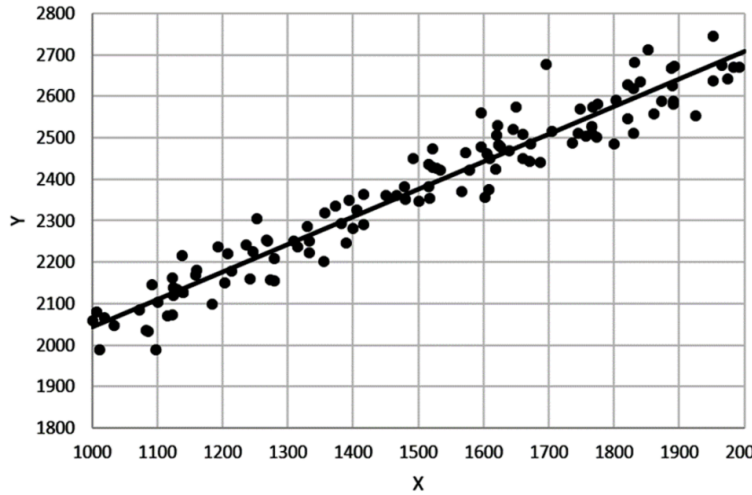
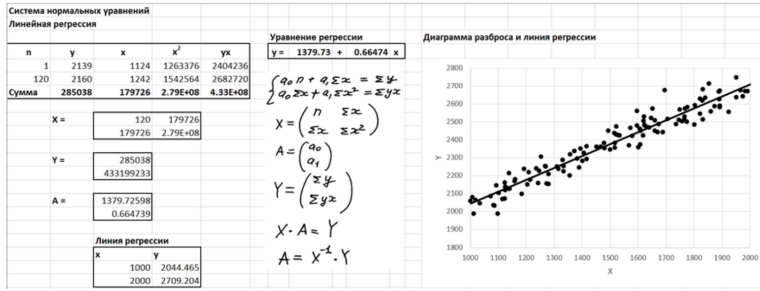


Диаграмма разброса и линия регрессии



Оформление отчёта

Уравнение второго порядка — «икс» участвует во второй степени. Система нормальных уравнений для регрессии второго порядка — см. формулы.

Уравнение третьего порядка — «икс» участвует в третьей степени. Система нормальных уравнений для регрессии третье-

$$y = a_0 + a_1 x + a_2 x^2$$

$$\begin{cases} a_0 n + a_1 \Sigma x + a_2 \Sigma x^2 = \Sigma y \\ a_0 \Sigma x + a_1 \Sigma x^2 + a_2 \Sigma x^3 = \Sigma yx \\ a_0 \Sigma x^2 + a_1 \Sigma x^3 + a_2 \Sigma x^4 = \Sigma yx^2 \end{cases}$$

Регрессия второго порядка

$$y = a_0 + a_1 x + a_2 x^2 + a_3 x^3$$

$$\begin{cases} a_0 n + a_1 \Sigma x + a_2 \Sigma x^2 + a_3 \Sigma x^3 = \Sigma y \\ a_0 \Sigma x + a_1 \Sigma x^2 + a_2 \Sigma x^3 + a_3 \Sigma x^4 = \Sigma yx \\ a_0 \Sigma x^2 + a_1 \Sigma x^3 + a_2 \Sigma x^4 + a_3 \Sigma x^5 = \Sigma yx^2 \\ a_0 \Sigma x^3 + a_1 \Sigma x^4 + a_2 \Sigma x^5 + a_3 \Sigma x^6 = \Sigma yx^3 \end{cases}$$

Регрессия третьего порядка

го порядка — см. формулы.

Нанесите линии регрессии на общий график.

СРАВНЕНИЕ РЕЗУЛЬТАТОВ

Сравним уравнения регрессии, полученные разными способами. Обратим внимание, насколько они похожи на исходный вариант задания.

На новом листе разместим свой вариант задания, а также уравнения, полученные разными способами.

Коэффициенты уравнений копировать не будем. Используем ссылки на те ячейки, в которых хранятся результаты расчетов.

Все уравнения представим в единой форме, например, в порядке возрастания показателя степени «икс».

$$y = a_0 + a_1 \cdot x$$

$$x = b_0 + b_1 \cdot y$$

Уравнения регрессии**Y (X)**и **X (Y)**

$$\begin{cases} b_0 n + b_1 \Sigma y = \Sigma x \\ b_0 \Sigma y + b_1 \Sigma y^2 = \Sigma yx \end{cases}$$

Система нормальных уравнений для**X (Y)**

Если всё сделано правильно, уравнения одного порядка, полученные разными способами, будут очень похожи друг на друга. Возможна небольшая разница в самых младших разрядах из-за вычислительных погрешностей.

Будет небольшое отличие полученных уравнений регрессии от варианта задания. Это погрешность из-за наличия случайной составляющей, которую мы добавили в исходные данные.

СВЯЗЬ УРАВНЕНИЙ Y (X) И X (Y)

В предыдущих разделах мы рассмотрели уравнение линейной регрессии «Y на X». Существует и второй вариант — обратное уравнение. Это регрессия «X на Y» — см. уравнения.

Построим обратное уравнение с помощью надстройки. В качестве «иксов» указываем «игреки» и наоборот.

Чтобы найти коэффициенты уравнения регрессии X (Y), нам понадобится решить систему нормальных уравнений:

Получаем следующее уравнение регрессии — см. формулы.

$$y = 1380 + 0{,}6647 \cdot x$$

$$x = -1836 + 1{,}404 \cdot y$$

Оценки уравнений регрессии

	A	B	C	D	E	F	G	H	I
1	x(y) =	-1836.0449	+	1.403502	y	y	x		
2	SUMMARY OUTPUT					2000	970.959		
3						2700	1953.41		
16									
17		*Coefficients*	*andard Err*	*t Stat*	*P-value*	*Lower 95%*	*Upper 95%*	*ower 95.0%*	*pper 95.0%*
18	Intercept	-1836.0449	82.53795	-22.2449	4.99E-44	-1999.49	-1672.6	-1999.49	-1672.6
19	y	1.40350196	0.034634	40.52417	4.29E-71	1.334918	1.472086	1.334918	1.472086

Регрессия**Y (X)**

Сформируем вспомогательную таблицу для построения прямой линии на графике. Выбираем крайние точки по **Y**: **2000** и **2700**. Можно выбрать любые значения, выходящие за границы поля графика. Позже при настройке масштаба по осям на графике останется только видимая часть линий. Главное — занять нашей линией всё поле графика. Вычисляем значения **X** по уравнению регрессии.

Наносим обе линии регрессии на диаграмму разброса.

Настроим тип графика для каждого набора данных. Выбираем в контекстном меню

Change Chart Type
Изменить тип диаграммы.

Устанавливаем комбинированный тип графика:
Combo
Комбинированная.

Выбираем тип графика — диаграмма разброса:
Scatter
Точечная.

Для линий регрессии **Y (X)** и **X (Y)** выбираем тип графика — ломаная линия:
Scatter with Straight Lines
Точечная с прямыми отрезками.

Чтобы оси координат были общими для всех графиков, снимаем отметки в колонке
Secondary Axis
Вспомогательная ось.
Настроим масштаб по осям и цвет линий.
Включаем вывод легенды на графике:
Chart Elements — Legend
Элементы диаграммы — Легенда.

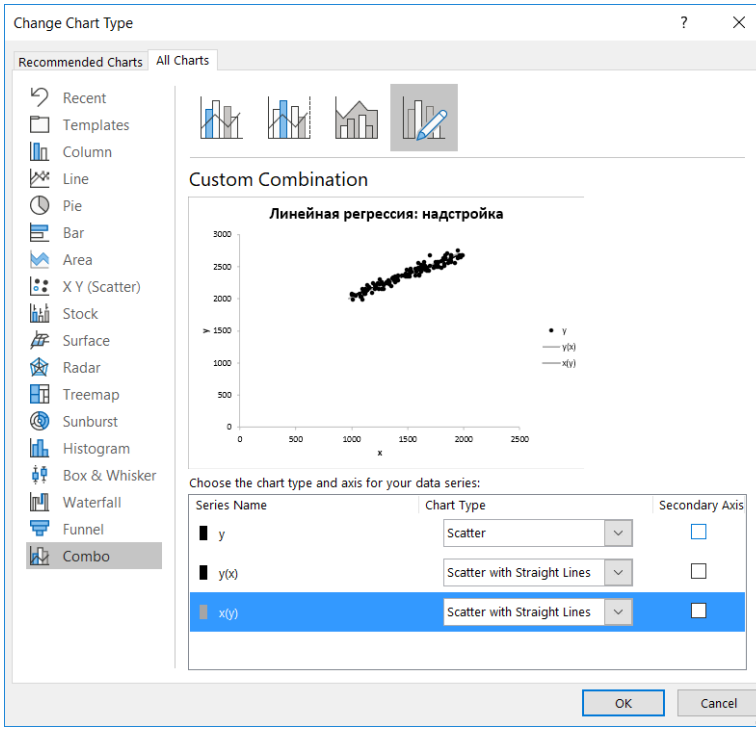
В регрессионном анализе обнаружено одно интересное свойство. Наши прямые линии **Y (X)** и **X (Y)** должны пересекаться в точке **{Xcp, Ycp}**.

Чтобы продемонстрировать это свойство, возьмём первые уравнения из систем нормальных уравнения для **Y (X)** и **X (Y)**. Поделим уравнения на ***n*** — см. формулы. Если сумму значений поделить на их количество, получится СРЕДНЕЕ ЗНАЧЕНИЕ. В наших формулах среднее обозначено чертой: «икс с чертой» и «игрек с чертой».

Можно видеть, что точка **{Xcp, Ycp}** является общей для обоих уравнений. Другими словами, уравнения линий регрессии выполняются для указанных значений.

Вычисляем средние значения **X** и **Y**. Наносим эту точку на график. Настраиваем тип и размер маркера, цвет заливки и границы.

Убеждаемся, что линии регрессии действительно пересекаются в указанной точке.



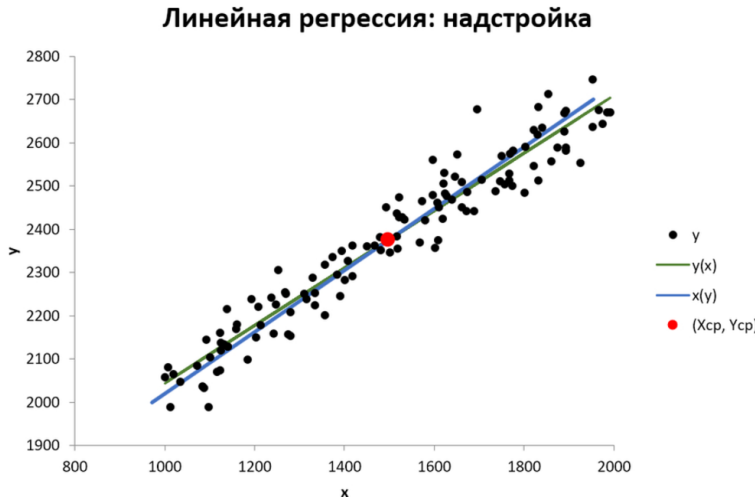
Выбор типа графиков

$$\Sigma y = an + b\Sigma x \qquad \Sigma x = cn + d\Sigma y$$

$$\frac{\Sigma y}{n} = an + b\frac{\Sigma x}{n} \qquad \frac{\Sigma x}{n} = cn + d\frac{\Sigma y}{n}$$

$$\bar{y} = a + b\bar{x} \qquad \bar{x} = c + d\bar{y}$$

Точка пересечения линий



Пересечение линий регрессии

$$r_{yx}^2 = a_1 \cdot b_1$$

$$r_{yx} = \sqrt{a_1 \cdot b_1}$$

Взаимосвязь коэффициентов

Второе примечательное свойство линейной регрессии — это взаимосвязь коэффициентов регрессии с коэффициентом линейной корреляции — см. формулы.

Проверяем выполнение указанных соотношений.

Скопируем оба уравнения на отдельный лист и организуем расчёты.

Для извлечения квадратного корня используем функцию **SQRT**

	Уравнения регрессии			
$y(x) =$	1379.725982	+	0.664739004	x
$x(y) =$	-1836.044934	+	1.403501961	y

=SQRT(L3)

H	I	J	K	L	M
	Коэфф. корр.			Коэфф. регр.	Разность
$r^2 =$	0.932962495		$a_1 \cdot b_1 =$	0.932962495	1.221E-15
$r =$	0.965899837		$\sqrt{a_1 \cdot b_1} =$	0.965899837	0

Сравнение коэффициентов

КОРЕНЬ.

Находим разность оценок коэффициента корреляции. Можно видеть, что эта разность практически равна нулю.

АНАЛИЗ РЕАЛЬНЫХ ДАННЫХ

Мы познакомились с основными методами изучения взаимосвязи. Это корреляционный и регрессионный анализ. Далее мы применим рассмотренные методы к реальным данным.

Данные для работы будем загружать из глобальной сети интернет, причём это будут открытые и общедоступные данные. Никаких платных сервисов и закрытых подписок. Мы рассматриваем реальные примеры, в которых ЯВНО просматриваются некоторые закономерности.

Конечно, реальные данные отличаются от идеальных, смоделированных. Здесь появляются более сложные закономерности, распределения отличаются от стандартных, а уравнение связи может изменяться со временем.

Тем не менее, работа с реальными данными — это важный шаг в освоении материала. От студента потребуется способность отличать важные свойства от второстепенных подробностей, а также использовать здравый смысл при формулировке выводов.

ИНТЕРНЕТ-МАГАЗИН

В соответствии с вариантом задания загрузите реальные данные о компьютерных компонентах с любого сайта компьютерного магазина, например, www.nix.ru. Выберите не менее 10 ОДНОТИПНЫХ изделий с РАЗНЫМИ характеристиками. Постройте диаграмму разброса, проведите корреляционный и регрессионный анализ тремя способами. Установите, есть ли какая-то связь и можно ли ее описать уравнением.

Рассмотрим в качестве примера решение нулевого варианта. Будем анализировать зависимость цены от жёстких дисков

Варианты заданий

№ варианта	Компьютерный компонент
0	Жёсткие диски для серверов
1	Модуль памяти
2	Блок питания
3	Жёсткие диски
4	Монитор
5	Карта памяти
6	Мышь
7	Устройство охлаждения
8	Флешка
9	Материнская плата
10	Видеокарта

для серверов от их размеров. В каждом варианте нужно выбрать самые важные параметры устройства, которые тесно связаны между собой.

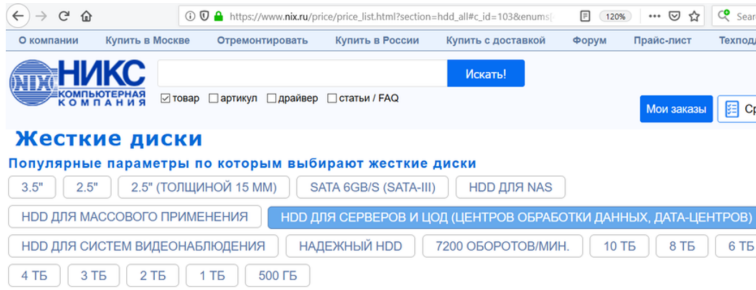
Первое требование к исходным данным: выбирать ОДНОТИПНЫЕ изделия. Нет смысла сравнивать диски для массового применения и для серверов. Это разные типы изделий, разный уровень качества, надёжности и стоимости.

Второе требование к данным: должно быть РАЗНООБРАЗИЕ параметров в пределах одного типа. Разброс параметра должен быть как можно шире. В нашем случае, это объём диска.

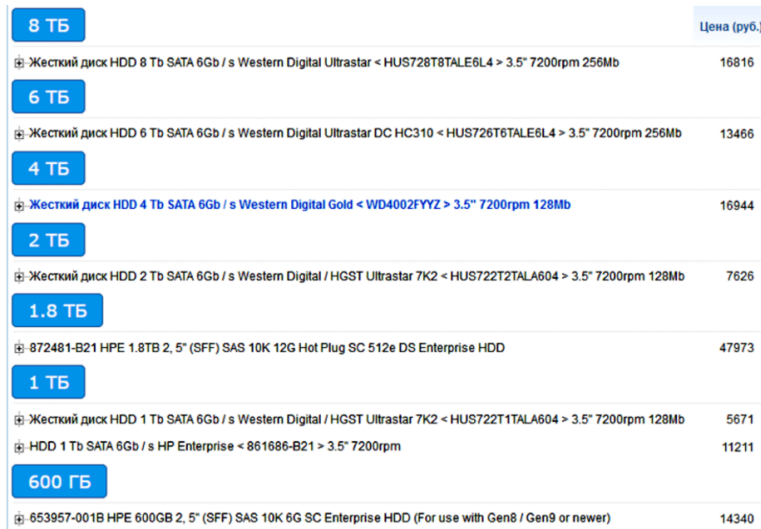
Открываем сайт www.nix.ru. Заходим в раздел **Комплектующие для компьютеров** и выбираем **Жёсткие диски — HDD для серверов**. HDD означает Hard Disk Drive, или жёсткий диск, или «винчестер».

В нашем случае выбор не слишком большой. В остальных вариантах нужно рассматривать массовые популярные комплектующие. Там выбор будет гораздо шире.

Результаты поиска приведены на рисунке. Найдено 8 дисков. Размеры от 600 гигабайт до 8 терабайт. По цифрам просматривается общая тенденция: большие диски стоят дороже. Но есть и отклонения от этой закономерности.



Диски для серверов



Результаты поиска

Вводим данные в Excel вручную. Пока данных немного, мы можем себе это позволить. Когда информации много, используют другие технологии импорта данных.

Второй вариант ввода данных — выделить текст на странице

	A	B	C	D	E	F	G	H	I
1	8 Тб								
2	+ Жесткий диск HDD 8 Tb SATA 6Gb / s Western Digital Ultrastar < HUS728T8TALE6L4 > 3.5" 7200rpm 256Mb					16816	17338	2.17	КУПИТЬ
3	6 Тб								
4	+ Жесткий диск HDD 6 Tb SATA 6Gb / s Western Digital Ultrastar DC HC310 < HUS726T6TALE6L4 > 3.5" 7200rpm 256Mb					13466	13884	2.31	КУПИТЬ

Вставка из буфера

сайта, скопировать в буфер обмена и вставить на новом листе Excel. Результаты вставки из буфера показаны на рисунке. Здесь есть некоторые проблемы. При копировании страницы сайта через буфер нам достаются не только текстовые и числовые данные, но и элементы оформления и интерфейса. К тому же, некоторые ячейки объединены, что нарушает структуру таблицы.

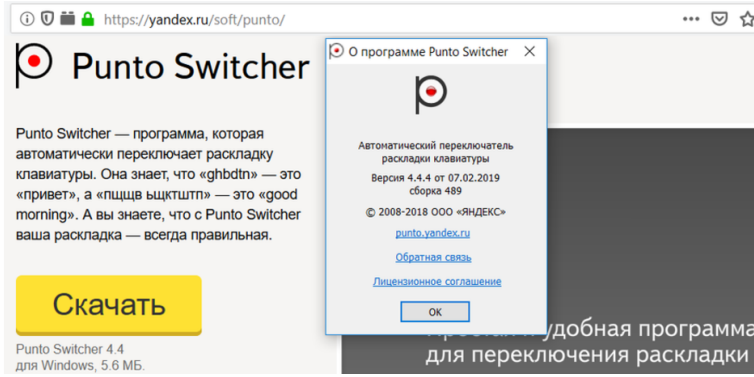
Для улучшения процесса копирования используем программу Punto Switcher. Она доступна бесплатно по адресу:

https://yandex.ru/soft/punto/

Программа позволяет автоматически переключать раскладку клавиатуры и конвертировать текст. В данной работе нам пригодится ещё одна полезная функция: вставка текста без форматирования.

Вставим данные из буфера в Excel без форматирования. Теперь мы получаем стандартное расположение ячеек электронной таблицы. Стандартный шрифт. И никаких лишних элементов.

Создадим копию листа и «очистим» данные. Удалим лишние столбцы. Оставим только размер и цену. Данные придётся скопировать в нужные ячейки вручную, потому что они находятся



Punto Switcher

	A	B	C	D	E	F	G	H
1	8 Тб							
2	+							
3	Жесткий диск HDD 8 Tb SATA 6(				16816	17338	2.17	КУПИТЬ
4	6 Тб							
5	+							
6	Жесткий диск HDD 6 Tb SATA 6(				13466	13884	2.31	КУПИТЬ

Вставка без форматирования

в разных строчках. Можно взять весь диапазон ячеек с ценами, вырезать его в буфер и вставить в нужное место таблицы. Удалим лишние строки. Сравним с исходной страничкой сайта и убедимся, что данные введены правильно. По дороге пропала одна строчка. Вводим данные вручную.

Обратите внимание на выравнивание содержимого ячеек. Первый столбец прижат влево — это текст. Второй столбец прижат вправо — это числа.

Осталось избавиться от лишних букв. После каждого числа имеется пробел и буквы Тб. В нижней строке указаны гигабайты — нужно удалить буквы Гб и перевести число в терабайты, то есть поделить его на 1000.

	A	B
1	8 Тб	16816
2	6 Тб	13466
3	4 Тб	16944
4	2 Тб	7626
5	1.8 Тб	47973
6	1 Тб	5671
7	1 Тб	11211
8	600 Гб	14340

Исходные данные

Вызываем функцию поиска и замены. Нажимаем комбинацию клавиш **[Ctrl + H]**. Появляется диалоговое окно

Find and Replace

Найти и заменить.

В строке поиска

Find what

Найти

вводим **символ пробела**, **знак вопроса** (искать любой символ) и букву **б**.

Replace with

Заменить на

Оставляем пустым.

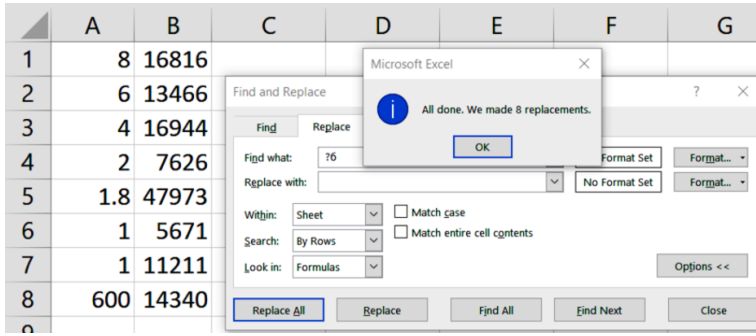
Нажимаем кнопку

Replace All

Заменить все.

В результате в первом столбце остались только числа. Первый столбец прижат вправо — теперь это числа.

Осталось вручную заменить 600 на 0.6. Напомним нашу «таблицу умножения»: в одном терабайте примерно 1000 гигабайт. Если быть точным, то вообще-то должно быть 1024.



	A	B
1	8	16816
2	6	13466
3	4	16944
4	2	7626
5	1.8	47973
6	1	5671
7	1	11211
8	600	14340

Поиск и замена

C3 =B3/1000

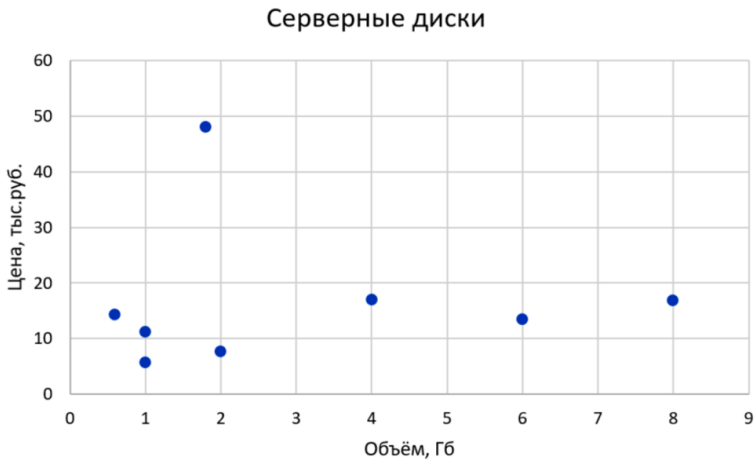
	A	B	C
1	Объём, Гб	Цена, руб.	Цена, тыс.руб.
2	x	y	y
3	8	16816	16.816
4	6	13466	13.466
5	4	16944	16.944
6	2	7626	7.626
7	1.8	47973	47.973
8	1	5671	5.671
9	1	11211	11.211
10	0.6	14340	14.34

Данные для анализа

Но многие производители компьютерной техники используют множитель 1000. Ну а сами числа хорошенько округляют.

Теперь поработаем со вторым столбцом. Здесь цены в рублях. И это пятизначные числа. Тысячи и десятки тысяч рублей. Разделим на 1000. Получаем числа попроще.

Убираем второй столбец и оставляем только очищенные,



Все загруженные данные

предварительно обработанные исходные данные. Добавляем комментарии в духе «Что? Где? Когда?» Вставляем копию страницы сайта, чтобы можно было убедиться в правильности загрузки данных.

Переходим к анализу. Вначале построим диаграмму разброса. Пока всё делаем так же, как и в предыдущих разделах. Рассматриваем график. Разброс по объёму хороший. А вот цены слишком разные. Возможно, здесь собраны диски двух видов. И для каждого вида будет своя зависимость.

Возвращаемся к исходному списку. Выясняем, что большинство дисков имеют следующие параметры:

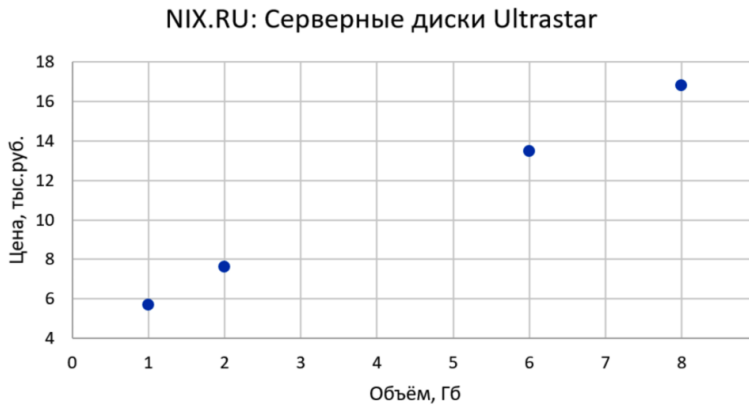
— интерфейс подключения — SATA 6Гб/сек;

— размер диска — 3.5 дюйма;

— частота вращения 7200 оборотов в минуту.

Обозначение **rpm** расшифровывается как **revolutions per minute**, то есть оборотов в минуту.

Несколько дисков выпадают из общей картины. Это другой производитель и другой тип дисков — SAS. На досуге разбери-



Однотипные диски

тесь, что такое SATA и что такое SAS.

Для обработки оставим только более-менее однотипные изделия одного семейства Ultrastar. Диаграмма разброса стала более привычной. Между делом ознакомьтесь с семействами Ultrastar и Gold. Конечно, для серьёзного анализа нужно взять данных побольше. И из разных источников. И учесть рекомендованные цены производителей.

То, что мы оставили для обработки, называется ОДНОРОДНЫЕ данные. Такие данные можно обрабатывать статистическими методами. А если у нас объекты разных типов, разных свойств, то статистика даёт совершенно дикие и никому не нужные результаты. Это всё равно, что взять взрослых людей ростом два метра и детей ростом полметра. Вычисляем средний рост: «метр с кепкой». Привозим в магазин одежду такого размера, а её никто не купит! Просто таких «средних» покупателей нет среди наших клиентов. Но зато можно найти самый ходовой размер для взрослых и для детей ПО ОТДЕЛЬНОСТИ. Вот такую одежду мы сможем продать. В статистике этот показатель называется МОДА. Это значение статистического признака, которое встречается чаще всего.

Регрессия	Y = 4,272 + 1,558 X	
	X	**Y**
	1	5.83
	8	16.736
Прогноз	4	10.504

Вспомогательная таблица

Итак, у нас осталось четыре диска. Находим коэффициент линейной корреляции. Получаем значение **0,9993**. Это практически прямая линия. Почти никакого случайного разброса вокруг прямой.

Находим уравнение регрессии с помощью надстройки:

Y = 4,272 +1,558 X.

Можно записать это уравнение в «экономическом» стиле. То есть русскими словами:

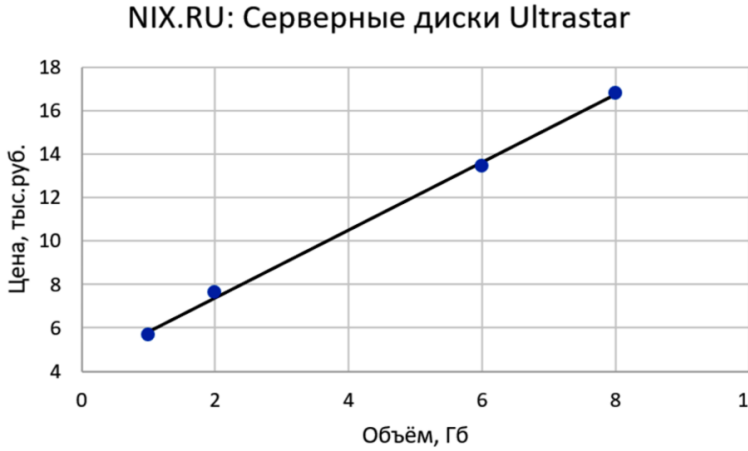
Цена диска т.р. = 4,272 +1,558 • Объём диска Гб.

По уравнению регрессии строим вспомогательную табличку из двух точек.

Попутно найдём ЛИНЕЙНЫЙ ПРОГНОЗ. Это наш прогноз значения Y для выбранного значения X по линейному уравнению регрессии. В исходных данных нет диска на 4 Гб. Судя по нашему уравнению, он должен стоить примерно 10,5 тыс. руб.

Наносим линию регрессии на диаграмму разброса. Точки почти лежат на прямой линии.

Рассмотрим ещё один популярный момент — «Цена за гигабайт». Во сколько обходится хранение данных на дисках разного размера? Просто поделим рубли на гигабайты. С увеличением объёма диска стоимость хранения данных падает. Так что для большого сервера могут оказаться более экономичными большие диски.



Линия регрессии

Объём, Гб	Цена, тыс.руб.	т.р. за Гб
x	y	Y / X
8	16.816	2.1
6	13.466	2.2
2	7.626	3.8
1	5.671	5.7

Стоимость хранения данных

ФОНДОВЫЙ РЫНОК

В этом разделе мы будем анализировать биржевые данные. Мы посмотрим, как выглядит взаимосвязь между котировками наиболее ликвидных акций и значениями соответствующего отраслевого индекса Московской биржи. Для этого нужно будет скачать два файла — котировки акции и отраслевой индекс (в соответствии с вариантом задания). Затем мы загрузим эти

Варианты заданий

№	Индекс
0	Индекс МосБиржи (IMOEX)
1	Электроэнергетика (MOEXEU)
2	Нефть и газ (MOEXOG)
3	Потребительский сектор (MOEXCN)
4	Телекоммуникации (MOEXTL)
5	Транспорт (MOEXTN)
6	Металлы и добыча (MOEXMM)
7	Машиностроение (MICEXMNF)
8	Финансы (MOEXFN)
9	Химия и нефтехимия (MOEXCH)
10	Индекс МосБиржи 10 (MOEX10)

файлы в Excel и проведём корреляционный и регрессионный анализ.

Для начала ознакомимся с заданием. Создадим новый лист в рабочей книге Excel и опишем свой вариант задания.

В интернете есть много ресурсов, где можно бесплатно загрузить биржевые котировки — так называемые ИСТОРИЧЕСКИЕ ДАННЫЕ. Адреса могут со временем изменяться. Работа сайтов может быть нестабильной. Могут появляться новые источники данных.

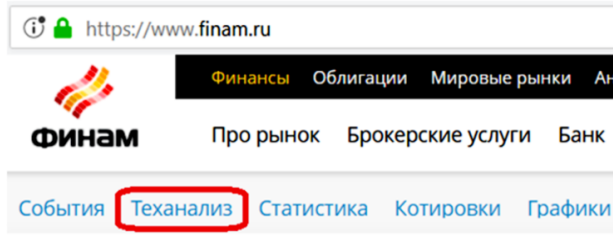
В качестве примера рассмотрим три источника данных:

MOEX.RU

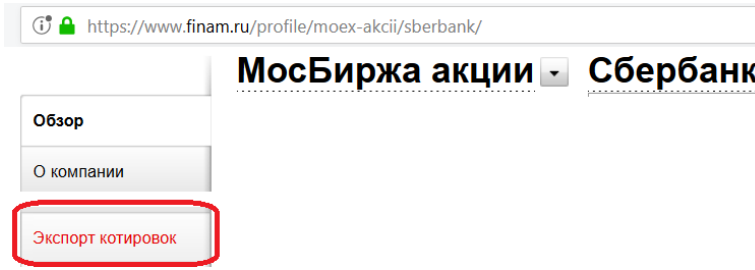
FINAM.RU

INVESTING.COM

В данной работе нас будет интересовать качество полученных данных и удобство их загрузки в Excel для дальнейшей обработки.



Сайт «Финам»



Ссылка на страницу экспорта

ФИНАМ

Откроем сайт компании «Финам» **www.finam.ru** в браузере. Перейдём по ссылке **Теханализ**.

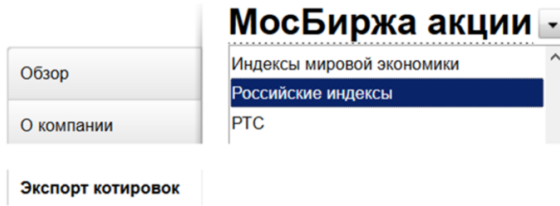
На открывшейся странице переходим по ссылке **Экспорт котировок**.

Выбираем **Российские индексы** в выпадающем списке.

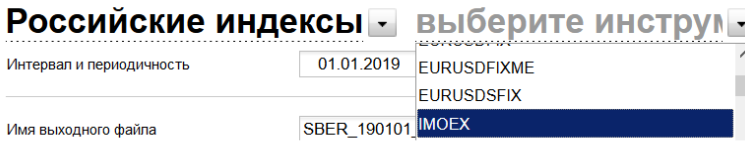
В выпадающем списке инструментов выбираем **IMOEX**.

Установим следующие настройки экспорта данных:

— интервал: диапазон дат 10 лет
— периодичность: 1 день
— разделитель полей: точка с запятой
— разделитель разрядов: нет
— формат записи: TICKER, PER, DATE, TIME, OPEN, HIGH,



Выбор индексов



Выбор инструмента

LOW, CLOSE, VOL

— добавить заголовок файла: да

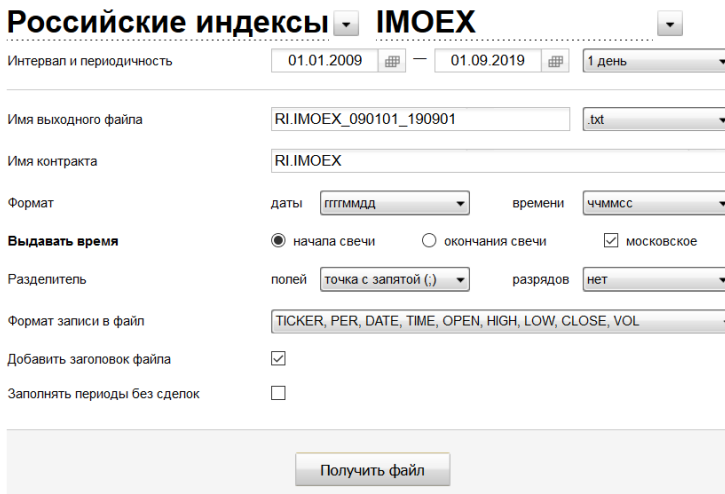
Нажимаем кнопку **Получить файл**. Сохраняем файл на диске и обращаем внимание, куда именно его сохранили. Ведь этот файл нам предстоит загружать в Excel.

Для начала ознакомимся с форматом файла. Откроем загруженный файл в текстовом редакторе **Notepad** (**Блокнот**). В первой строке находятся заголовки столбцов. Поля разделены точками с запятой. Целая и дробная часть числа разделены точкой. Напомним, что в английской версии Excel в качестве разделителя используется ТОЧКА, в русской версии — ЗАПЯТАЯ. Закрываем окно редактора.

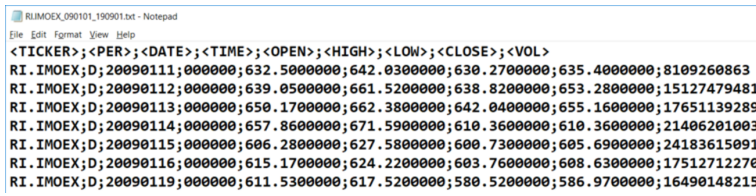
Переходим в окно Excel и выбираем в меню

File — Open — Browse — Text Files

Файл — Открыть — Обзор — Текстовые файлы.



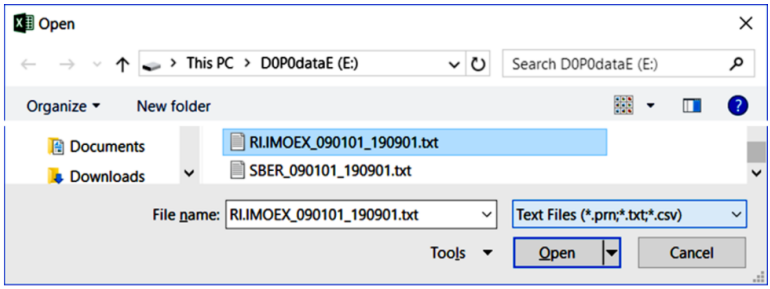
Настройки экспорта



Текстовый файл

Выбираем файл и нажимаем кнопку
Open
Открыть.

В окне
Text Import Wizard — Step 1 of 3
Мастер текстов (импорт) — шаг 1 из 3
устанавливаем пункт



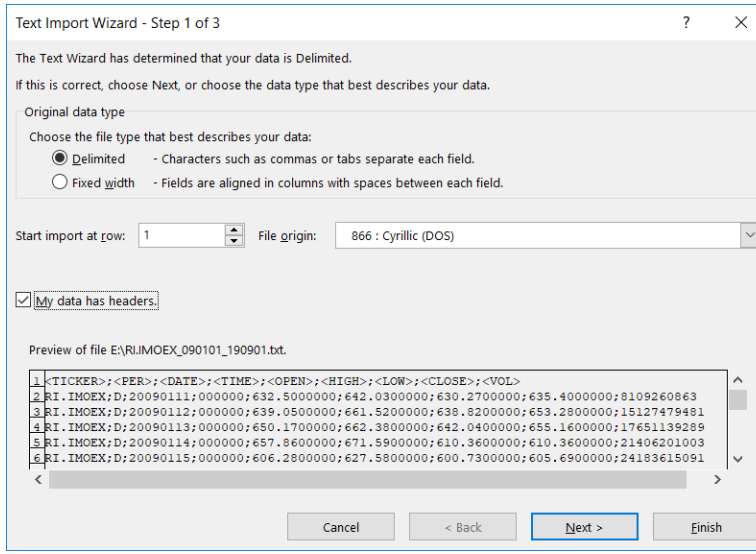
Загрузка текстового файла

My data has headers
Мои данные содержат заголовки.

Убеждаемся, что в разделе
Original data type
Формат исходных данных
указан формат данных
Delimited
(**с разделителями**).

Нажимаем кнопку
Next
Далее.
Результат импорта можно контролировать в нижней части диалогового окна мастера импорта
Preview of file
Предварительный просмотр файла.

На следующих шагах импорта эта часть окна будет называться
Data preview
Образец разбора данных.



Мастер импорта — шаг 1

По умолчанию в качестве разделителя полей установлен символ табуляции

Delimiters — Tab

Символом-разделителем является — табуляция.

На этом шаге программа не разделяет поля и рассматривает содержимое каждой строки как одну ячейку.

Установим точку с запятой в качестве разделителя:

Delimiters — Semicolon

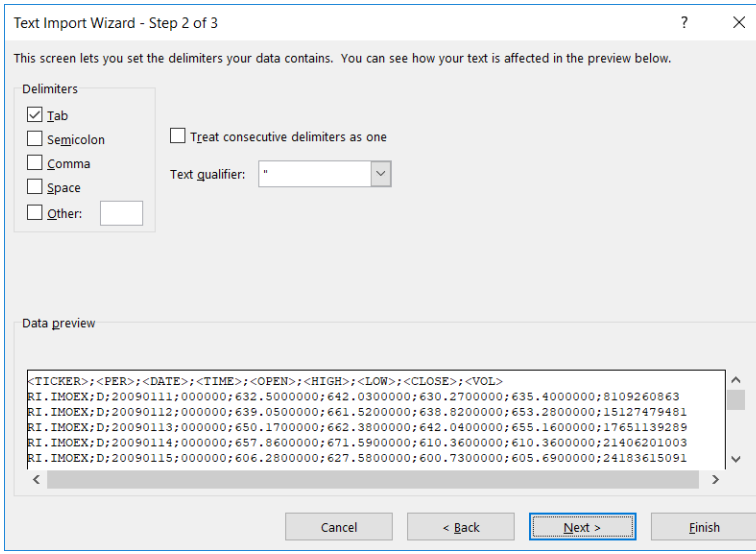
Символом-разделителем является — точка с запятой.

Убеждаемся, что в разделе предварительного просмотра появились столбцы.

Нажимаем кнопку

Next

Далее.



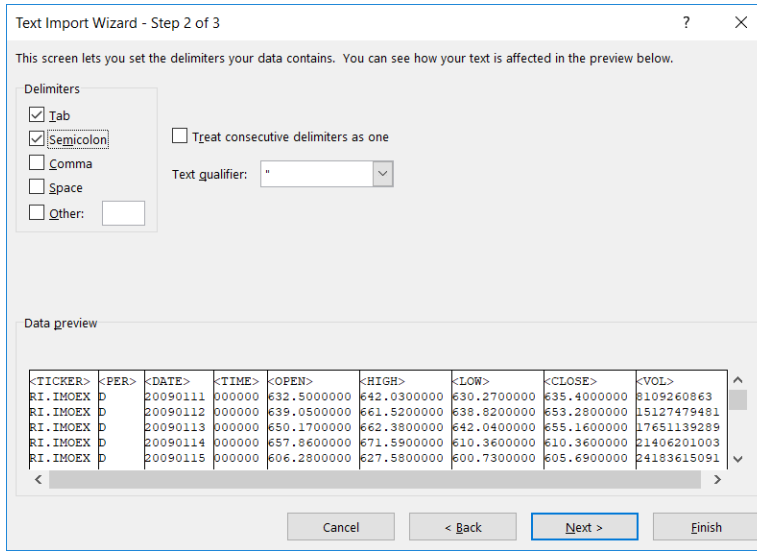
Мастер импорта — шаг 2

Выбранный формат данных для каждого столбца выводится в нижней части окна

Text Import Wizard — Step 3 of 3
Мастер импорта — шаг 3
в разделе
Data preview
Образец разбора данных.

По умолчанию для всех столбцов установлен общий формат
Column data format — General
Формат данных столбца — Общий.

Можно видеть, что столбец **<DATE>** рассматривается как целое число. Мы догадываемся, что в этом столбце записана дата в формате «год-месяц-день». Нужно сообщить об этом мастеру импорта.



Разделитель — точка с запятой

Настроим формат даты. Выбираем столбец **<DATE>** и устанавливаем формат записи даты:

Column data format — Date — YMD

Формат данных столбца — дата — ГМД.

Теперь разберёмся с форматом дробных чисел. Нажимаем кнопку

Advanced

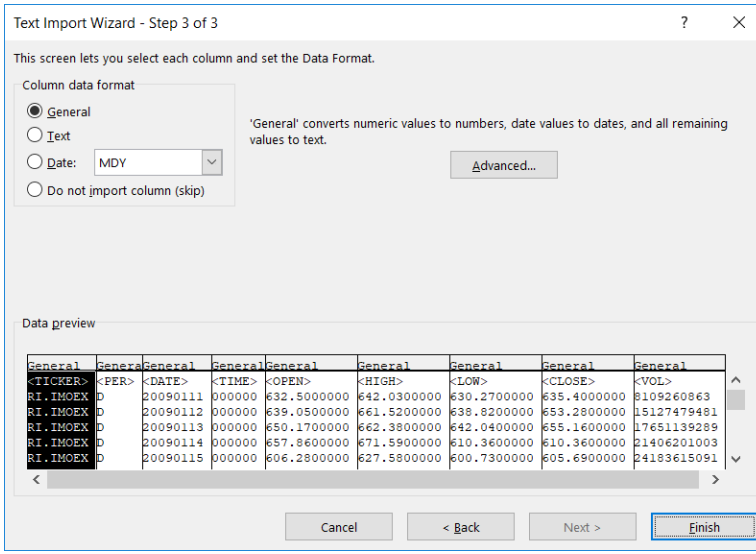
Подробнее.

Убеждаемся, что в качестве разделителя целой и дробной частей

Decimal separator

Разделитель целой и дробной части

установлена точка — как и в формате импортируемого файла.



General	General	General	General	General	General	General	General	General
<TICKER>	<PER>	<DATE>	<TIME>	<OPEN>	<HIGH>	<LOW>	<CLOSE>	<VOL>
RI.IMOEX	D	20090111	000000	632.5000000	642.0300000	630.2700000	635.4000000	8109260863
RI.IMOEX	D	20090112	000000	639.0500000	661.5200000	638.8200000	653.2800000	15127479481
RI.IMOEX	D	20090113	000000	650.1700000	662.3800000	642.0400000	655.1600000	17651139289
RI.IMOEX	D	20090114	000000	657.8600000	671.5900000	610.3600000	610.3600000	21406201003
RI.IMOEX	D	20090115	000000	606.2800000	627.5800000	600.7300000	605.6900000	24183615091

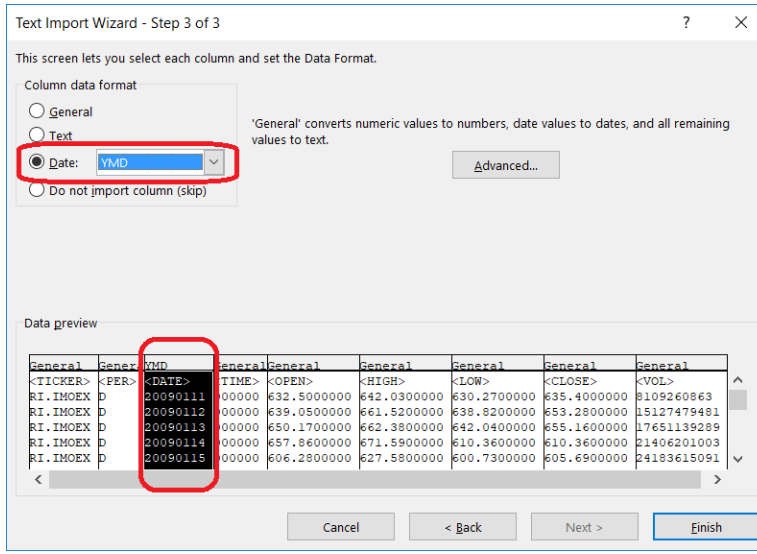
Общий формат

Нажимаем кнопки **OK** и
Finish
Готово.

Файл загружен в Excel. Убеждаемся, что импорт прошёл успешно. Дата распознана как дата — это видно в самих ячейках и в строке формул. Числа с дробной частью распознаны как числа. Напомним, что числа по умолчанию выравниваются по правому краю ячейки, а такст прижимается влево.

Копируем страницу значений индекса в отчёт. Для выделения заполненных ячеек используем комбинацию клавиш **Ctrl + Shift + Up** и **Ctrl + Shift + Down**. Стрелки вверх и вниз позволяют не только перемещаться на одну строку, но и перейти в начало и конец заполненного диапазона ячеек. Удаляем неинформативные столбцы — тикер, период, время. Делаем заголовок.

Настроим формат вывода даты. Выделяем столбец дат. В контекстном меню выбираем



Формат даты

Format Cells — Number — Category — Date — Locale (location) — Russian

Формат ячеек — Число — Числовые форматы — Дата — Язык (местоположение) — русский.

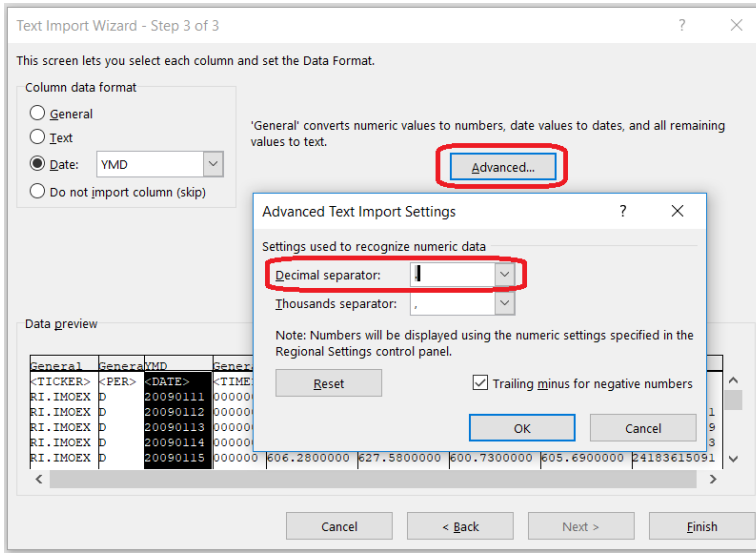
Пример отображения даты в выбранном формате можно сразу же наблюдать в разделе

Sample

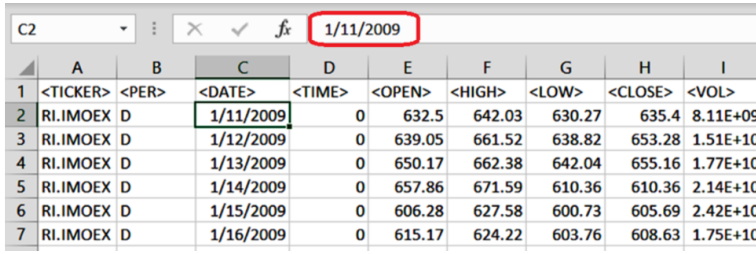
Образец.

Теперь даты выглядят более привычно: **год-месяц-день**. При этом в строке формул дата по-прежнему выводится в американском формате **месяц/день/год** — в английской версии пакета.

Построим биржевую диаграмму японских свечей. Выделяем столбцы <DATE>, <OPEN>, <HIGH>, <LOW>, <CLOSE>. Для биржевой диаграммы они должны идти именно в таком порядке. Можно также строить график без указания даты. В любом случае,



Разделитель — точка



	A	B	C	D	E	F	G	H	I
1	<TICKER>	<PER>	<DATE>	<TIME>	<OPEN>	<HIGH>	<LOW>	<CLOSE>	<VOL>
2	RI.IMOEX	D	1/11/2009	0	632.5	642.03	630.27	635.4	8.11E+09
3	RI.IMOEX	D	1/12/2009	0	639.05	661.52	638.82	653.28	1.51E+10
4	RI.IMOEX	D	1/13/2009	0	650.17	662.38	642.04	655.16	1.77E+10
5	RI.IMOEX	D	1/14/2009	0	657.86	671.59	610.36	610.36	2.14E+10
6	RI.IMOEX	D	1/15/2009	0	606.28	627.58	600.73	605.69	2.42E+10
7	RI.IMOEX	D	1/16/2009	0	615.17	624.22	603.76	608.63	1.75E+10

Результаты импорта

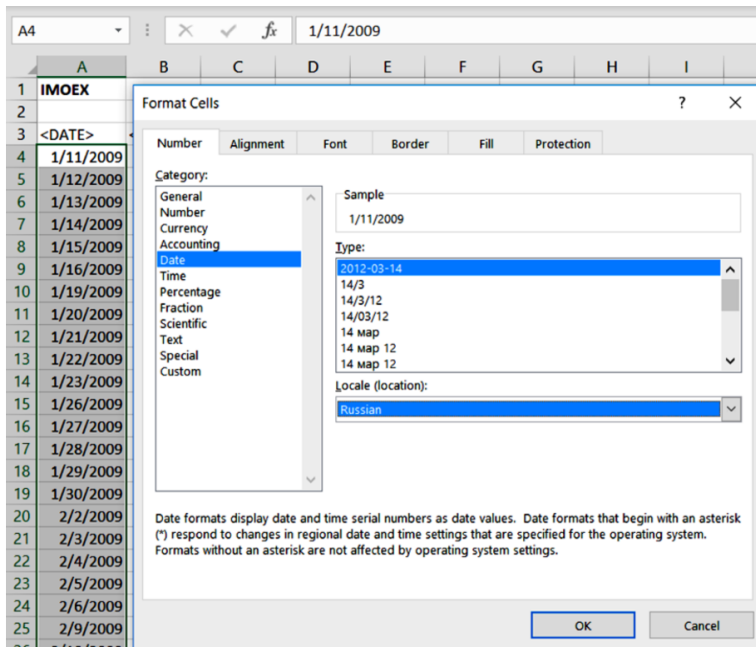
в исходном наборе данных должны присутствовать все четыре цены.

Выбираем в верхнем меню

Insert — Charts — Insert Waterfall, Funnels, Stock, Surface, or Radar Chart — Stock — Open-High-Low-Close

	A	B	C	D	E	F
1	IMOEX					
2						
3	<DATE>	<OPEN>	<HIGH>	<LOW>	<CLOSE>	<VOL>
4	1/11/2009	632.5	642.03	630.27	635.4	8.11E+09
5	1/12/2009	639.05	661.52	638.82	653.28	1.51E+10
6	1/13/2009	650.17	662.38	642.04	655.16	1.77E+10
7	1/14/2009	657.86	671.59	610.36	610.36	2.14E+10
8	1/15/2009	606.28	627.58	600.73	605.69	2.42E+10
9	1/16/2009	615.17	624.22	603.76	608.63	1.75E+10

Значения индекса



Формат даты

A4 | 1/11/2009

	A	B	C	D	E	F
1	**IMOEX**					
2						
3	<DATE>	<OPEN>	<HIGH>	<LOW>	<CLOSE>	<VOL>
4	2009-01-11	632.5	642.03	630.27	635.4	8.11E+09
5	2009-01-12	639.05	661.52	638.82	653.28	1.51E+10
6	2009-01-13	650.17	662.38	642.04	655.16	1.77E+10
7	2009-01-14	657.86	671.59	610.36	610.36	2.14E+10
8	2009-01-15	606.28	627.58	600.73	605.69	2.42E+10
9	2009-01-16	615.17	624.22	603.76	608.63	1.75E+10

Формат даты

Вставка — Вставить каскадную, воронкообразную, биржевую, поверхностную или лепестковую диаграмму — Биржевая — Биржевая (курс открытия, самый высокий курс, самый низкий курс, курс закрытия).

Отключаем легенду. Вводим заголовок диаграммы.

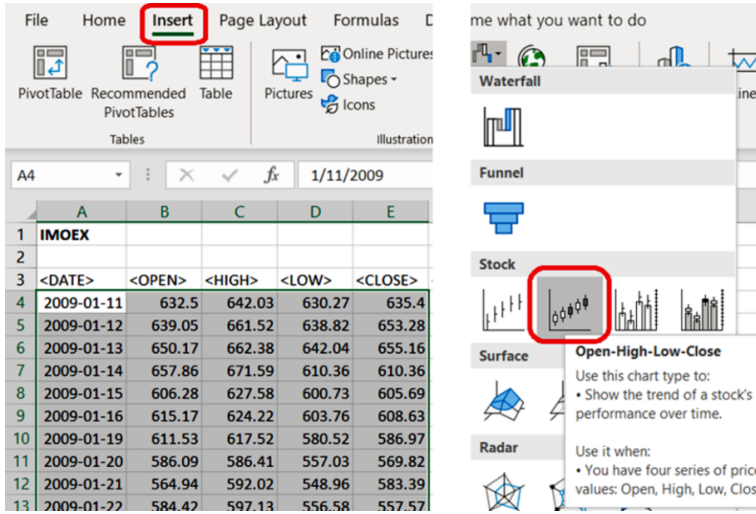
Можно рассмотреть поведение графика за текущий год. Установим масштаб по горизонтальной и вертикальной осям, как показано на рисунке.

На графике видны регулярные перерывы. Возможная причина — отсутствие торгов по выходным дням. Но этот момент мы разберём чуть позже.

Затем получим котировки обыкновенных акций Сбербанка. Выбираем категорию **МосБиржа акции** или **Мосбиржа топ**. Затем выбираем инструмент **Сбербанк**.

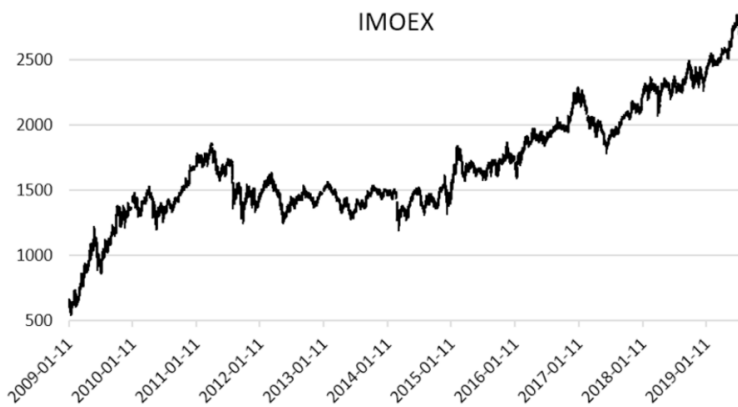
Для дальнейшей работы скопируем оба массива данных на новый лист — Индекс Мосбиржи и обыкновенные акции Сбербанка.

Проверим качество данных. Найдём разность соседних дат. Это шаг по времени, который должен быть постоянным. При экс-



	A	B	C	D	E
1	IMOEX				
2					
3	<DATE>	<OPEN>	<HIGH>	<LOW>	<CLOSE>
4	2009-01-11	632.5	642.03	630.27	635.4
5	2009-01-12	639.05	661.52	638.82	653.28
6	2009-01-13	650.17	662.38	642.04	655.16
7	2009-01-14	657.86	671.59	610.36	610.36
8	2009-01-15	606.28	627.58	600.73	605.69
9	2009-01-16	615.17	624.22	603.76	608.63
10	2009-01-19	611.53	617.52	580.52	586.97
11	2009-01-20	586.09	586.41	557.03	569.82
12	2009-01-21	564.94	592.02	548.96	583.39
13	2009-01-22	584.42	597.13	556.58	557.57

Построение свечного графика



Свечной график





Масштаб



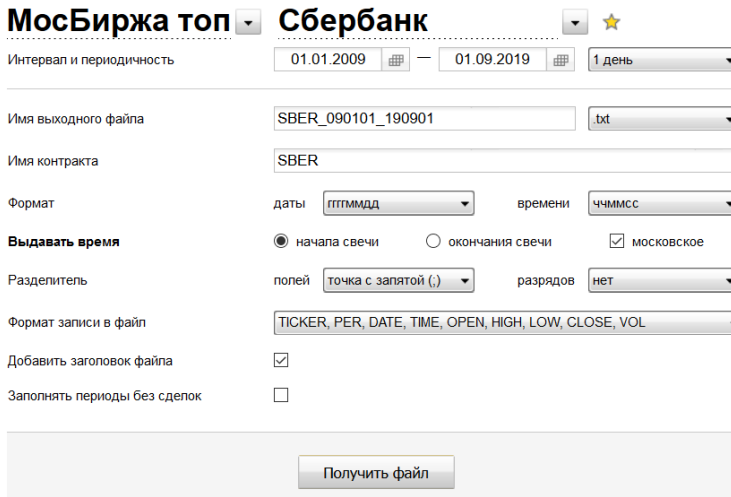
График за 2019 год

порте биржевых данных мы выбрали дневные данные. Это значит, что шаг равен 1 дню. В случае выходных и праздничных дней шаг может увеличиться.

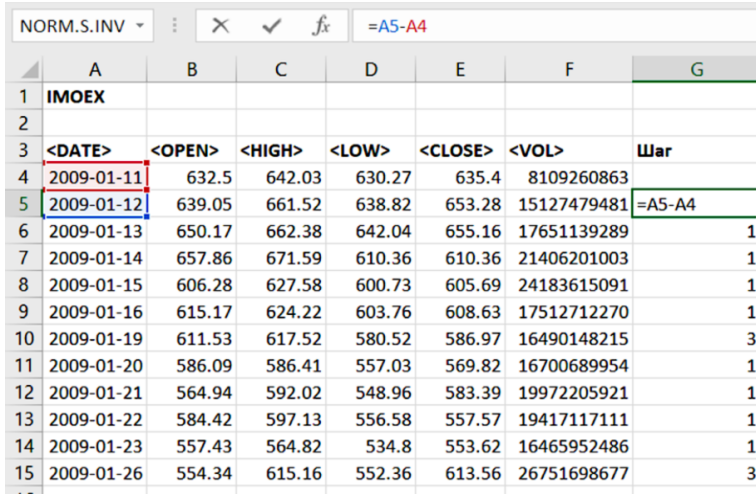
Создаём новый столбец:

Шаг — число дней между соседними строками.

Наши расчёты основаны на том, что Excel хранит дату как ПОРЯДКОВЫЙ НОМЕР ДНЯ, начиная с 1 января 1900 года. При выводе на экран применяется выбранный способ отображения даты, в нашем случае это ГГГГ-ММ-ДД. Мы можем изменить формат вывода, но содержимое ячейки при этом не меняется. Это



Экспорт котировок Сбербанка



	A	B	C	D	E	F	G
1	IMOEX						
2							
3	<DATE>	<OPEN>	<HIGH>	<LOW>	<CLOSE>	<VOL>	Шаг
4	2009-01-11	632.5	642.03	630.27	635.4	8109260863	
5	2009-01-12	639.05	661.52	638.82	653.28	15127479481	=A5-A4
6	2009-01-13	650.17	662.38	642.04	655.16	17651139289	1
7	2009-01-14	657.86	671.59	610.36	610.36	21406201003	1
8	2009-01-15	606.28	627.58	600.73	605.69	24183615091	1
9	2009-01-16	615.17	624.22	603.76	608.63	17512712270	1
10	2009-01-19	611.53	617.52	580.52	586.97	16490148215	3
11	2009-01-20	586.09	586.41	557.03	569.82	16700689954	1
12	2009-01-21	564.94	592.02	548.96	583.39	19972205921	1
13	2009-01-22	584.42	597.13	556.58	557.57	19417117111	1
14	2009-01-23	557.43	564.82	534.8	553.62	16465952486	1
15	2009-01-26	554.34	615.16	552.36	613.56	26751698677	3

Шаг по времени



Выходные дни

по-прежнему порядковый номер дня. Когда мы находим разность соседних дат, мы фактически вычитаем одно целое число из другого. Результат — число дней между датами.

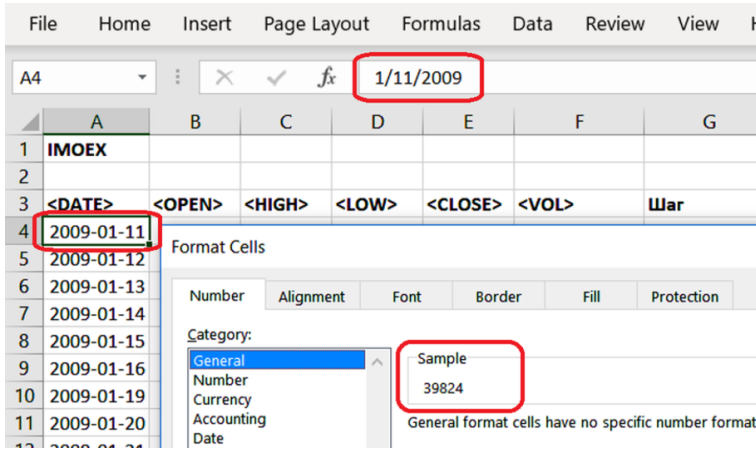
Посмотрим на календарь. Вызываем приложение Calendar. Выбираем 2009 год. Видим, что 17 и 18 января 2009 года — это выходные дни. А по выходным на бирже торгов нет. Так что между соседними рабочими днями будет шаг 1 день, а пятницей и понедельником — 3 дня.

Чтобы увидеть порядковый номер дня, выделим ячейку с датой и выберем в контекстном меню

Format Cells — Number — Category — General
Формат ячеек — Числовые форматы — Число — Общий.

При выборе формата **General** мы увидим исходное содержимое ячейки. Наше число показано в разделе

Sample
Образец
диалогового окна
Format Cells
Формат ячеек.



Порядковый номер дня

Выясняется, что дата **11 января 2009 года** на самом деле хранится как число **39824**. То есть это 39824-й день от начала отсчёта (1 января 1900 года). При этом в строке формул та же самая дата выводится как **1/11/2009**. Это американский формат **MM/DD/YYYY**. Сначала месяц, потом день и в конце — год.

Построим диаграмму разброса «Шаг по времени в зависимости от номера записи». Большинство значений равны 1 и 3. Но есть и долгие перерывы.

Подводим курсор к самой высокой точке и видим, что это пара чисел (497, 12). На 497 строке нашего массива данных разность дат составила 12 дней. Это новогодние выходные с 31 декабря 2010 года по 10 января 2011 года — см. рисунок.

Сравним данные по индексу и выбранной ценной бумаге. Найдём разность дат наших двух массивов. Построим график разностей. Разность в пять дней обнаруживается в апреле 2016 года. Сравним эти даты.

При внимательном рассмотрении таблицы выясняем, что в данных о биржевом индексе есть данные за 23 февраля 2016 года, а в котировках акций Сбербанка эта строка отсутству-

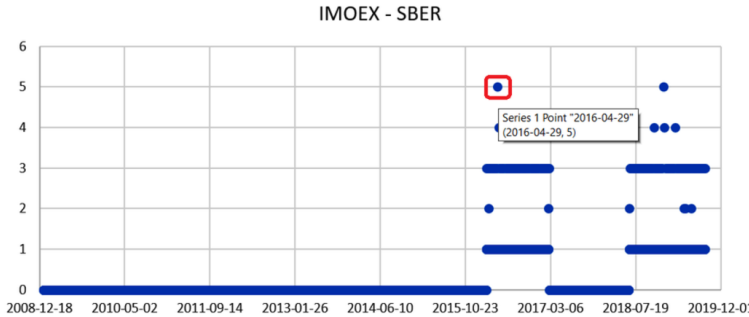




Шаг по времени

496	2010-12-24	1686.14	1686.47	1673.24	1675.81	16262577361	1
497	2010-12-27	1675.33	1676.14	1662.81	1663.55	14765027351	3
498	2010-12-28	1665.35	1671.08	1660.57	1664.86	19956220893	1
499	2010-12-29	1665.96	1678.49	1665.96	1677.68	28365348563	1
500	2010-12-30	1677.68	1687.99	1673.64	1687.99	24312897115	1
501	2011-01-11	1687.79	1714.17	1687.37	1713.97	49940444719	12
502	2011-01-12	1714.61	1759.86	1714.27	1759.46	72846541833	1
503	2011-01-13	1759.67	1768.11	1743.72	1749.75	68421637534	1
504	2011-01-14	1746.83	1757.56	1731.86	1744.74	48297570708	1
505	2011-01-17	1749.13	1773.92	1749	1771.66	52144034966	3
506	2011-01-18	1773.45	1788.74	1754.86	1765.3	65749629854	1

Новогодние выходные



Расхождение дат

	A	I	J	P	Q
1	**IMOEX**		**SBER**		
2					
3	**<DATE>**		**<DATE>**	**Шаг**	**Расхождение**
4	2009-01-11		2009-01-11		0
5	2009-01-12		2009-01-12	1	0
1787	2016-02-20		2016-02-20	1	0
1788	2016-02-22		2016-02-22	2	0
1789	2016-02-23		2016-02-24	2	1
1790	2016-02-24		2016-02-25	1	1
1791	2016-02-25		2016-02-26	1	1
1792	2016-02-26		2016-02-29	3	3
1793	2016-02-29		2016-03-01	1	1
1833	2016-04-26		2016-04-27	1	1
1834	2016-04-27		2016-04-28	1	1
1835	2016-04-28		2016-04-29	1	1
1836	2016-04-29		2016-05-04	5	5
1837	2016-05-04		2016-05-05	1	1

Расхождение дат

ет. Можно предположить, что в этот праздничный день торгов, скорее всего, не было. Получается, что в наших данных разница на один день. На этот сдвиг наложилась разница соседних дат.

Загрузите данные в соответствии со своим вариантом и проведите анализ массива. Какой шаг по времени в каждом массиве по отдельности? Есть ли разница дат в двух массивах? Зафиксируйте выводы на текущей странице отчёта.

Для анализа связи нам нужны пары значений, относящиеся к одним моментам времени. Должна быть синхронность. Качество данных нужно проверять. Как гласит народная мудрость, ДОВЕРЯЙ, НО ПРОВЕРЯЙ.

Проверим другие источники информации.

МОСКОВСКАЯ БИРЖА

На сайте Московской Биржи есть возможность ознакомиться с историческими данными. Далее можно сравнить информацию биржи с данными из других источников — для контроля качества.

Для просмотра значений индекса Мосбиржи перейдём по ссылкам:

www.moex.com — Котировки — Индексы — MOEX Russia Index — Архив значений.

Выбираем настройки
Архив значений по дням
с 20.02.2016 по 26.02.2016.

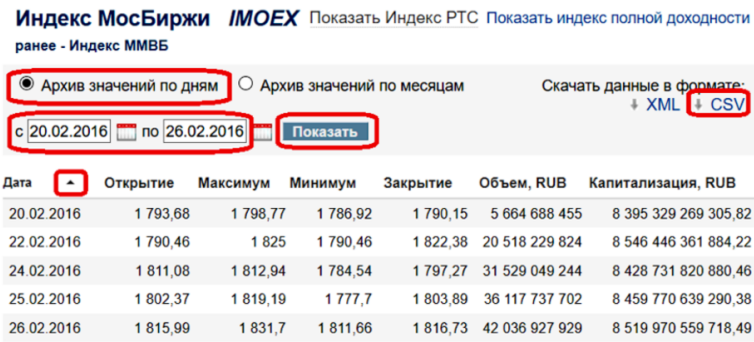
Нажимаем кнопку
Показать.

Устанавливаем сортировку даты по возрастанию. Можно видеть, что данные за 23 февраля 2016 года отсутствуют.

Сравните значения индекса IMOEX
за 22 и 24.02.2016 на сайтах Финам и Мосбиржи.

Установите диапазон дат с 01.01.2009 по 31.08.2019.

Нажмите ссылку
Скачать данные в формате — CSV.



Индекс МосБиржи ***IMOEX*** Показать Индекс РТС Показать индекс полной доходности

ранее - Индекс ММВБ

◉ Архив значений по дням ○ Архив значений по месяцам Скачать данные в формате: XML CSV

с 20.02.2016 по 26.02.2016 Показать

Дата	Открытие	Максимум	Минимум	Закрытие	Объем, RUB	Капитализация, RUB
20.02.2016	1 793,68	1 798,77	1 786,92	1 790,15	5 664 688 455	8 395 329 269 305,82
22.02.2016	1 790,46	1 825	1 790,46	1 822,38	20 518 229 824	8 546 446 361 884,22
24.02.2016	1 811,08	1 812,94	1 784,54	1 797,27	31 529 049 244	8 428 731 820 880,46
25.02.2016	1 802,37	1 819,19	1 777,7	1 803,89	36 117 737 702	8 459 770 639 290,38
26.02.2016	1 815,99	1 831,7	1 811,66	1 816,73	42 036 927 929	8 519 970 559 718,49

Значения индекса

Изучите формат полученного файла в программе
Notepad
Блокнот.

Обратите внимание на диапазон дат в файле.
Загрузите данные в Excel.

Для просмотра котировок обыкновенных акций Сбербанка перейдём по ссылкам:

www.moex.com — Котировки — Акции — Сбербанк –Итоги торгов — Инструмент — Сбербанк SBER Сбербанк России ПАО ао.

SBER — кодовое обзначение финансового инструмента;
ПАО — форма организации, сокращение от Публичное акционерное общество;
ао — акции обыкновенные.

Устанавливаем даты:
Начало и **Окончание**.

Нажимаем кнопку



МОСКОВСКАЯ БИРЖА

Итоги торгов с 20.02.2016 по 26.02.2016

Сбербанк / SBER

Группа Инструмент

SBER

Т+: Основной режим - безадр

Итоги торгов

Начало: 20.02.2016

Окончание: 26.02.2016

Дата торгов	Код	Сделок, шт.	Объем	Срвзв.цена	Первая	Минимум	Максимум	Закрытия
2016-02-20	SBER	19 344	1 856 073 801	102,12	101,61	101,5	102,6	102,39
2016-02-22	SBER	51 167	6 848 604 254	103,45	102,57	102,39	104,39	103,2
2016-02-24	SBER	63 069	9 065 264 148	101,71	102	100,79	102,7	102,1
2016-02-25	SBER	83 163	11 403 975 917	103,35	102,65	101,51	104,35	104,05
2016-02-26	SBER	88 210	15 295 321 583	106,14	105	104,83	107,15	106,24

Курс акций Сбербанка

Finam				
<DATE>	<OPEN>	<HIGH>	<LOW>	<CLOSE>
2016-02-20	1793.48	1798.71	1786.94	1790.15
2016-02-22	1794.54	1825.00	1793.03	1822.38
2016-02-23	1822.38	1822.38	1822.38	1822.38
2016-02-24	1802.90	1812.94	1784.54	1797.27
2016-02-25	1803.04	1819.19	1777.70	1797.27
2016-02-26	1815.99	1831.70	1811.66	1816.73

MOEX				
DATE	OPEN	HIGH	LOW	CLOSE
2016-02-20	1793.68	1798.77	1786.92	**1790.15**
2016-02-22	1790.46	**1825.00**	1790.46	**1822.38**
2016-02-24	1811.08	**1812.94**	**1784.54**	**1797.27**
2016-02-25	1802.37	**1819.19**	**1777.70**	1803.89
2016-02-26	**1815.99**	**1831.70**	**1811.66**	**1816.73**

Сравнение данных

Обновить.

Проверим данные с 20 по 26 февраля 2016 года. Есть данные за 22 и 24 февраля. Между ними праздничный день 23 февраля.

Сравним данные, полученные на сайте компании «Финам» и на сайте Московской биржи — см. рисунок. Зелёным выделим совпадающие значения индекса, красным — отличающиеся. Появилась лишняя строка за 23 февраля 2016 года, заполненная значением закрытия предыдущего дня. Возможно, на момент эксперимента с экспортом котировок произошёл сбой на сервере. Делаем вывод на будущее: при получении данных из интернет следует контролировать качество и выборочно сверяться с оригиналом, то есть с сайтом Мосбиржи.

Ознакомьтесь с вариантами скачивания биржевых данных на сайте Мосбиржи.

Сравните значения котировок из разных источников за любую «сомнительную» дату. Опишите обнаруженные проблемы в отчёте.

FUSION MEDIA

Ещё один источник данных можно найти по адресу:
investing.com.

Почитайте статью о портале **investing.com** в **Википедии**. Выясните, что это за компания и какие услуги на этом сайте имеются.

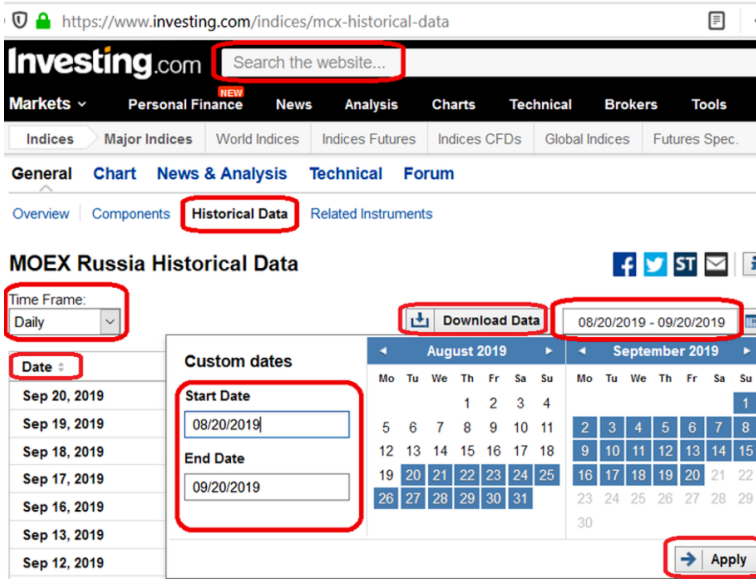
Переходим на указанный сайт и в строке поиска
Search the website
находим
IMOEX
Выбираем раздел
Historical Data
Прошлые данные.

В браузере отображается адрес текущей страницы сайта:
https://www.investing.com/indices/mcx-historical-data
Настраиваем параметры загрузки, как показано на рисунке.
Time Frame — Daily
Дневные.

Начало и конец периода:
Custom dates.

Здесь проще всего вручную напечатать начальную и конечную даты:
Start Date — 01/01/2009
End Date — 08/31/2019

Здесь снова используется американский формат даты: месяц — день — год.



Настройки скачивания данных

Нажимаем кнопку
Apply.

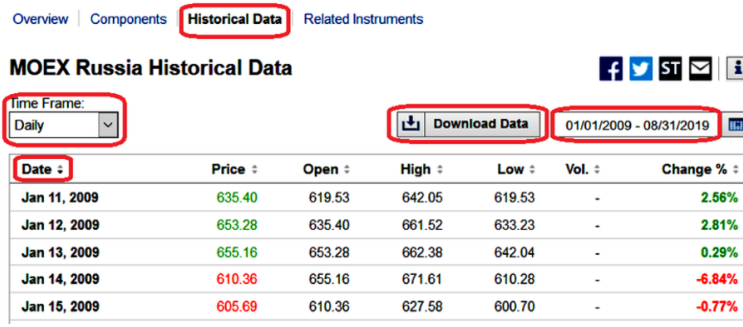
Проводим сортировку по возрастанию даты:
Date.

Для загрузки данных нажимаем кнопку
Download Data.

Для скачивания данных может потребоваться бесплатная регистрация пользователя на сайте. Можно также войти на сайт через социальную сеть **Facebook**.

Загружаем файл и сохраняем его на диске. Не забываем выбрать рабочий каталог для сохранения файла. И запоминаем, куда сохранили файл — нам его ещё загружать предстоит.

Обращаем внимание, что это файл с расширением ***.CSV**. Это



Date	Price	Open	High	Low	Vol.	Change %
Jan 11, 2009	635.40	619.53	642.05	619.53	-	2.56%
Jan 12, 2009	653.28	635.40	661.52	633.23	-	2.81%
Jan 13, 2009	655.16	653.28	662.38	642.04	-	0.29%
Jan 14, 2009	610.36	655.16	671.61	610.28	-	-6.84%
Jan 15, 2009	605.69	610.36	627.58	600.70	-	-0.77%

Скачивание данных

формат **Comma Separated Values**. Здесь запятые разделяют данные (то есть поля в пределах каждой строки, или записи). Другими словами, запятые указывают на расположение данных по столбцам.

Открываем файл в программе
Notepad
Блокнот.

Рассматриваем содержимое файла
MOEX Russia Historical Data. csv.

Все поля в кавычках. Десятичный разделитель — запятая. Разделитель полей –точка. Закрываем **Блокнот**.

Двойным щелчком открываем файл в Excel и изучаем результаты. Судя по выравниванию, даты и числа распознаны корректно.

Файл открывается в Excel автоматически, без вызова мастера импортаимпорта. Причина в том, что формат **CSV** можно открыть в Excel без импорта и преобразований.

Экспорт из английской версии сайта и загрузка в английскую версию Excel прошли успешно. Здесь наблюдается хорошая совместимость.

Рассмотрим заголовки столбцов:

MOEX Russia Historical Data.csv - Notepad

File Edit Format View Help

```
"Date","Price","Open","High","Low","Vol.","Change %"
"Jan 11, 2009","635.40","619.53","642.05","619.53","-","2.56%"
"Jan 12, 2009","653.28","635.40","661.52","633.23","-","2.81%"
"Jan 13, 2009","655.16","653.28","662.38","642.04","-","0.29%"
"Jan 14, 2009","610.36","655.16","671.61","610.28","-","-6.84%"
"Jan 15, 2009","605.69","610.36","627.58","600.70","-","-0.77%"
```

Формат файла на английском

A2 | 1/11/2009

	A	B	C	D	E	F	G
1	Date	Price	Open	High	Low	Vol.	Change %
2	11-Jan-09	635.4	619.53	642.05	619.53	-	2.56%
3	12-Jan-09	653.28	635.4	661.52	633.23	-	2.81%
4	13-Jan-09	655.16	653.28	662.38	642.04	-	0.29%
5	14-Jan-09	610.36	655.16	671.61	610.28	-	-6.84%
6	15-Jan-09	605.69	610.36	627.58	600.7	-	-0.77%

Загрузка файла на английском

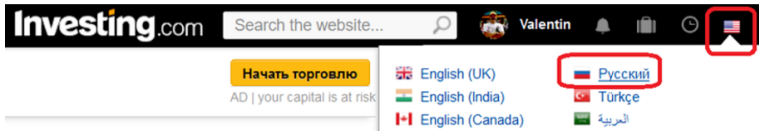
Date — Price — Open — High — Low.

Здесь отсутствует цена закрытия **Close**, зато есть цена под названием **Price**, то есть **Цена**. Судя по всему, это и есть цена закрытия. Дело в том, что при анализе котировок самой важной считается именно цена закрытия. В некоторых случаях остальные значения практически игнорируют.

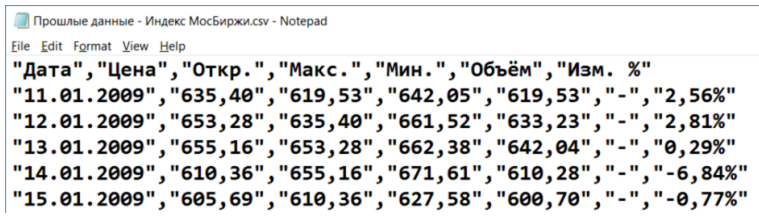
Переименуем заголовок **Price** и введём информативное название **Close**. Расставим столбцы в правильном порядке для построения графиков:

Date — Open — High — Low — Close.

Теперь проверим работу русской версии сайта. Для переключения языка щёлкнем по изображению флага в правом



Выбор языка



Формат файла на русском

верхнем углу страницы. Выбираем в списке языков:

Русский.

Обращем внимание на адрес страницы в браузере:

https://ru.investing.com/indices/mcx-historical-data.

В начале адреса появились буквы RU вместо WWW. В остальном всё без изменений.

Загружаем те же данные. Рассмотрим содержимое файла **Прошлые данные — Индекс МосБиржи. csv**.

Все поля в кавычках. Десятичный разделитель — запятая. Разделитель полей — точка. Закрываем **Блокнот**.

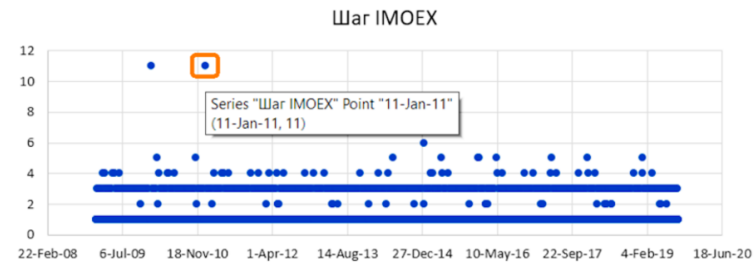
Открываем файл ***.CSV** в английской версии Excel. Судя по выравниванию содержимого ячеек, данные загружены как текст, а не как даты и числа. Текст выровнен по левой стороне. Даты тоже распознаны как текст.

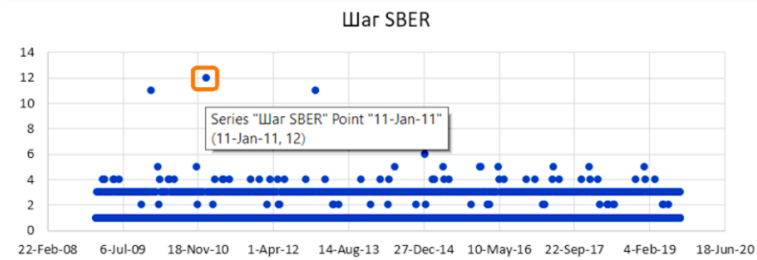
Проверьте, как загружаются в русскую версию Excel файлы, полученные через английскую и русскую версии сайта.

A2 | 11.01.2009

	A	B	C	D	E	F	G
1	Дата	Цена	Откр.	Макс.	Мин.	Объём	Изм. %
2	11.01.2009	635,40	619,53	642,05	619,53	-	2,56%
3	12.01.2009	653,28	635,40	661,52	633,23	-	2,81%
4	13.01.2009	655,16	653,28	662,38	642,04	-	0,29%
5	14.01.2009	610,36	655,16	671,61	610,28	-	-6,84%
6	15.01.2009	605,69	610,36	627,58	600,70	-	-0,77%

Загрузка файла на русском





Шаг по времени

Переключаемся на английский язык и загружаем данные по котировкам акций Сбербанка — код бумаги: **SBER**. Выбираем тот же диапазон дат.

Проведём анализ шага по времени, как в предыдущих примерах.



Нулевое расхождение дат

Здесь тоже можно обнаружить расхождения по датам. Для анализа связи придётся пожертвовать частью данных. Удаляем строки, которые выпадают из общей картины.

Добиваемся нулевого расхождения по датам в обоих наборах данных — см. рисунок.

Данные «очищены», то есть приведены в некоторый порядок. Переходим к анализу связи между курсом акций и значениями индекса.

Копируем лист с биржевыми данными в отчёт. Для этого щёлкаем правой кнопкой мыши по вкладке листа и выбираем в контекстном меню **Move or Copy**.

Вставим лист из текущей рабочей книги в другую книгу — а наш отчёт, последним листом. Переименуем лист для единообразия.

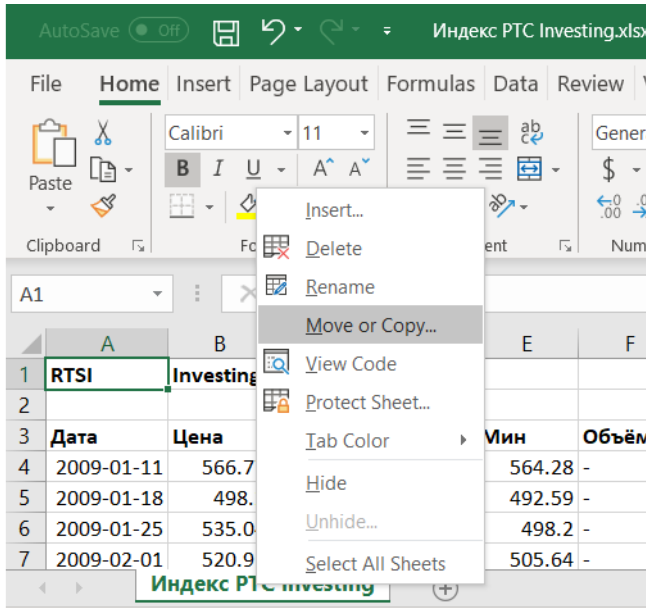
Копируем даты и цену закрытия для обоих инструментов на новый лист.

Построим совмещённый график изменения во времени.

Настроим раздельный масштаб, чтобы лучше рассмотреть оба графика.

Открывается диалоговое окно

Change Chart Type



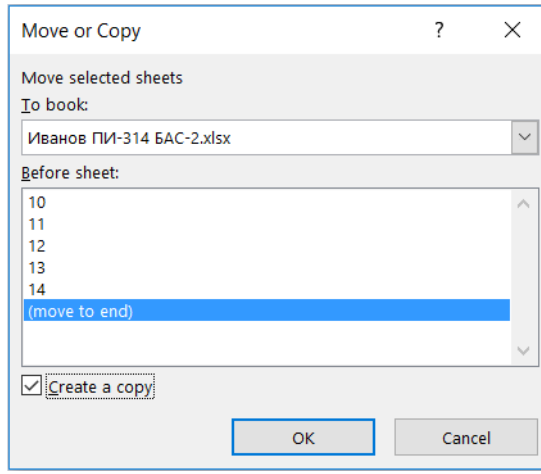
Копирование листа

Изменить тип диаграммы.

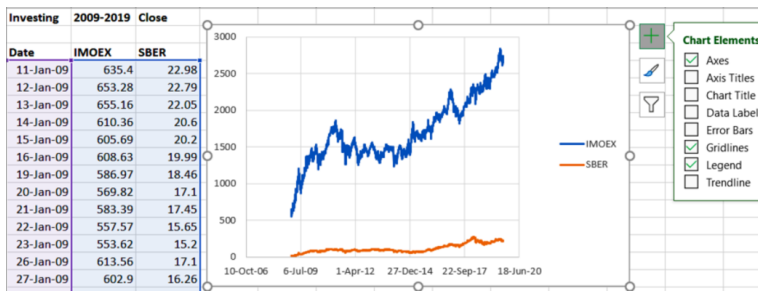
Выбираем комбинированный тип графика:
Combo
Комбинированная.

Устанавливаем для обоих графиков
Scatter with Straight Lines
Точечная с прямыми отрезками.

Включаем вторую вертикальную ось:
Secondary Axis
Вспомогательная ось.
Настраиваем диапазон значений по каждой оси. Устанавли-



Копирование листа в другую книгу

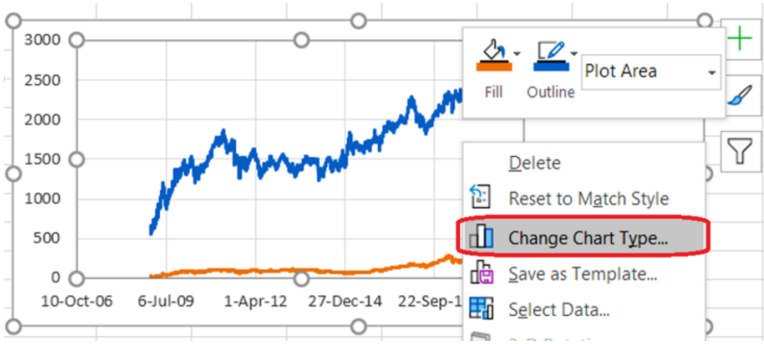


Совмещённый график

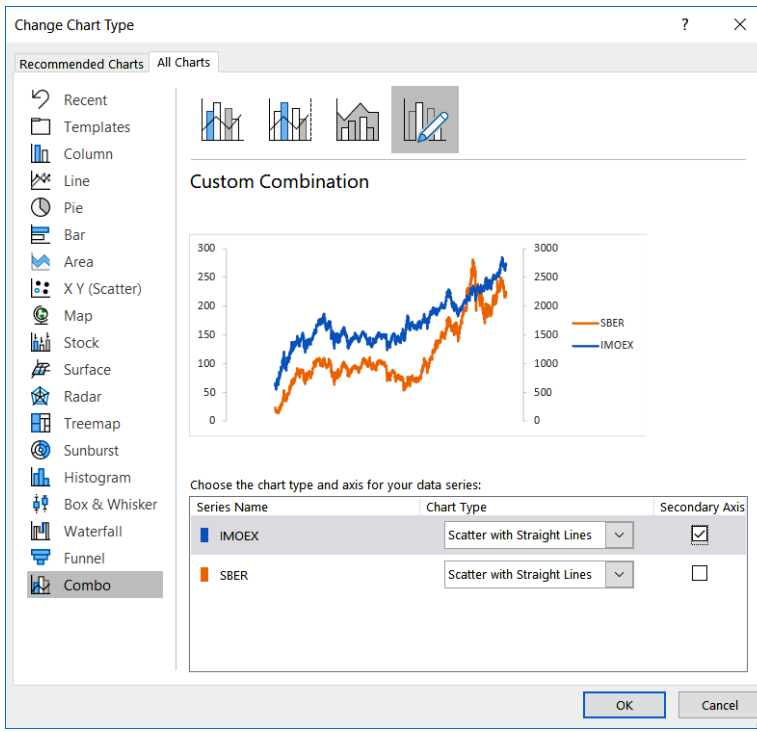
ваем заголовки по осям. Получаем более-менее информативную диаграмму — см. рисунок.

Можно видеть, что в целом направление изменения совпадает, хотя иногда котировки акций отклоняются от движения индекса.

Построим диаграмму разброса. Настраиваем заголовки,



Изменение типа графика



Комбинированный график



Комбинированная диаграмма

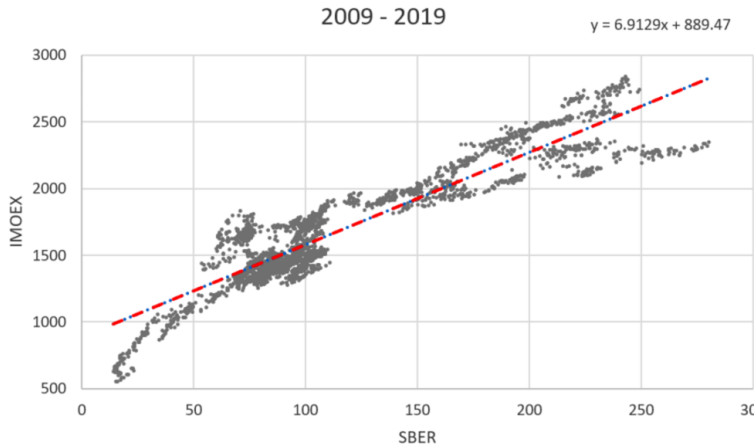


Диаграмма разброса

маркер, линию. Включаем построение линейной регрессии и вывод уравнения на экран.

Подобный анализ проводится при построении инвестиционного портфеля. Прочитайте статью **Бета-коэффициент** в **Википедии**.

Вызываем функцию **CORREL** и находим значение коэффициента линейной корреляции: ***r* = 0.924**. Это значение говорит о тесной положительной линейной связи между котировками акций и значением индекса.

БЛАГОДАРНОСТИ

Автор выражает глубокую признательность студентам, участвовавшим в подготовке данных методических указаний. Следующие студенты активно помогали в постановке лабораторных работ и составлении чернового варианта методических указаний:

— Корнеева Мария
— Кострюкова Анна
— Токарева Татьяна
— Муслимов Роберт

В тестировании учебных материалов, выявлении упущенных моментов и оценке трудоёмкости работ участвовали следующие студенты:

— Яковлева Виктория
— Исхаков Радмир
— Халиков Ильшат
— Мурадян Гарик
— Мухаметьянова Ольга
— Хайретдинова Ирина
— Макаров Владислав
— Макрушин Константин
— Портнов Владислав

В рамках проекта тестировщики общались с составителями, и после каждого очередного исправления текст становился всё более понятным.

Такое разделение труда позволило автору сосредоточиться на творческой части работы и увидеть картину в целом, не отвлекаясь на текущие вопросы.

Кстати, в процессе работы попутно выяснилось, насколько большой поток информации требуется обрабатывать для текущей координации проекта. Так что в следующий раз нам допол-

нительно потребуется куратор, который освоит управление проектом.

ПОСЛЕСЛОВИЕ

В данном выпуске мы познакомились с анализов взаимосвязи методами корреляционного и регрессионного анализа. Это второй выпуск в серии «Бизнес-аналитика и статистика в Excel». В нашей серии учебных пособий имеются следующие выпуски:

1. Анализ распределения. Сводка и группировка данных. Оценка формы распределения. Вычисление статистических показателей. Соответствующие разделы предмета: «Введение», «Распределение», «Статистические показатели», «Сводка и группировка», «Статистические графики». В конечном счёте мы построим графики (гистограмму и кумуляту), а также оценим значения показателей — таких как «сигма».

2. Корреляционный и регрессионный анализ. Статистическое изучение взаимосвязи. Соответствующий раздел предмета: «Взаимосвязь явлений», «Фондовые индексы». Мы узнаем, что прямую линию можно провести через любое количество точек, если делать это «в среднем». А ещё нам предстоит выяснить, как связаны между собой различные отрасли экономики — если посмотреть на них глазами Московской биржи.

3. Анализ динамики. Компоненты рядов динамики. Скользящие средние. Уравнение и линия тренда. Соответствующий раздел предмета: «Динамика». Здесь мы рассмотрим составные части динамики (изменения во времени) и биржевые графики, на которых наносят общую тенденцию (тренд).

4. Бизнес-аналитика на основе сводных таблиц. Соответствующий раздел предмета: «Бизнес-аналитика». Это одновременно и самый простой, и самый сложный раздел, потому что настройка таблиц делается визуально, через меню, а внутри спрятаны уже изученные статистические методы: сводка и группировка, показатели, взаимосвязь, динамика и т. д. Снаружи мы в конечном счёте увидим «приборную панель» руко-

водителя предприятия — такую же, как приборная панель автомобиля.

Каждый метод анализа данных вначале рассматривается на примере смоделированных данных, а затем с использованием реальных данных из интернет.

СПИСОК ЛИТЕРАТУРЫ

1. Статистика: Учебник для вузов / Под ред. И.И.Елисеевой. — СПб.: Питер, 2010. — 368 с.

2. Теория статистики: Учебник / Р.А.Шмойлова, В.Г.Минашкин, Н.А.Садовникова, Е.Б.Шувалова; под ред. Р.А.Шмойловой. — М.: Финансы и статистика, 2014. — 656 с.

3. Практикум по теории статистики / Р.А.Шмойлова, В.Г.Минашкин, Н.А.Садовникова; под ред. Р.А.Шмойловой. — М.: Финансы и статистика, 2014. — 416 с.

4. Вадзинский Р. Н. Статистические вычисления в среде Excel. Библиотека пользователя. — СПб.: Питер, 2008. — 608 с.

5. Пустыльник Е. И. Статистические методы анализа и обработки наблюдений. — М.: Наука, 1968. — 288 с.

6. ГОСТ 2.303—68 ЕСКД. Линии.

С текстом стандарта можно ознакомиться в интеренете, например, по адресу:

http://docs.cntd.ru/document/gost-2-303-68-eskd

7. Арьков В. Ю. Анализ распределения в Excel: Учебное пособие.– [б.м.]: Издательские решения, 2019.– 158 с.

Первый выпуск серии.

Бесплатный доступ к электронной версии:

https://ridero.ru/books/analiz_raspredeleniya_v_excel/

ОГЛАВЛЕНИЕ

Предисловие ... 3
Введение ... 4
Общие сведения ... 5
  Варианты задания ... 7
  Зарисовка линейной функции ... 8
  Зарисовка нелинейной функции ... 11
  Исходные данные ... 15
  Диаграмма разброса ... 19
Корреляционный анализ ... 24
  Надстройка ... 25
  Функция CORREL / КОРРЕЛ ... 27
  Формулы ... 29
  Сравнение результатов ... 30
Регрессионный анализ ... 31
  Элемент диаграммы ... 32
  Условное среднее ... 35
  Надстройка ... 41
  Линейная регрессия ... 42
  Нелинейная регрессия ... 48
  Функция LINEST / ЛИНЕЙН ... 59
  Система нормальных уравнений ... 68
  Сравнение результатов ... 79
  Связь уравнений Y (X) и X (Y) ... 80
Анализ реальных данных ... 86
  Интернет-магазин ... 86
  Фондовый рынок ... 96
  Финам ... 98
  Московская Биржа ... 117
  Fusion Media ... 120
Благодарности ... 132
Послесловие ... 134
Список литературы ... 136

Валентин Юльевич Арьков

Статистический анализ взаимосвязи

Учебное пособие

Создано в интеллектуальной издательской системе Ridero

Арьков Валентин Юльевич — доктор технических наук, профессор кафедры автоматизированных систем управления Уфимского государственного авиационного технического университета. Опыт преподавания в вузе более 30 лет.

Рассматриваются такие инструменты статистического анализа взаимосвязи, как корреляционный и регрессионный анализ. Техника работы в электронных таблицах изучается на примере смоделированных данных. Затем полученные навыки применяются к анализу реальных данных по ценам в интернет-магазине и биржевым котировкам.

ISBN 978-5-0050-4525-6



Rideró

Rideró.ru — издай книгу бесплатно!