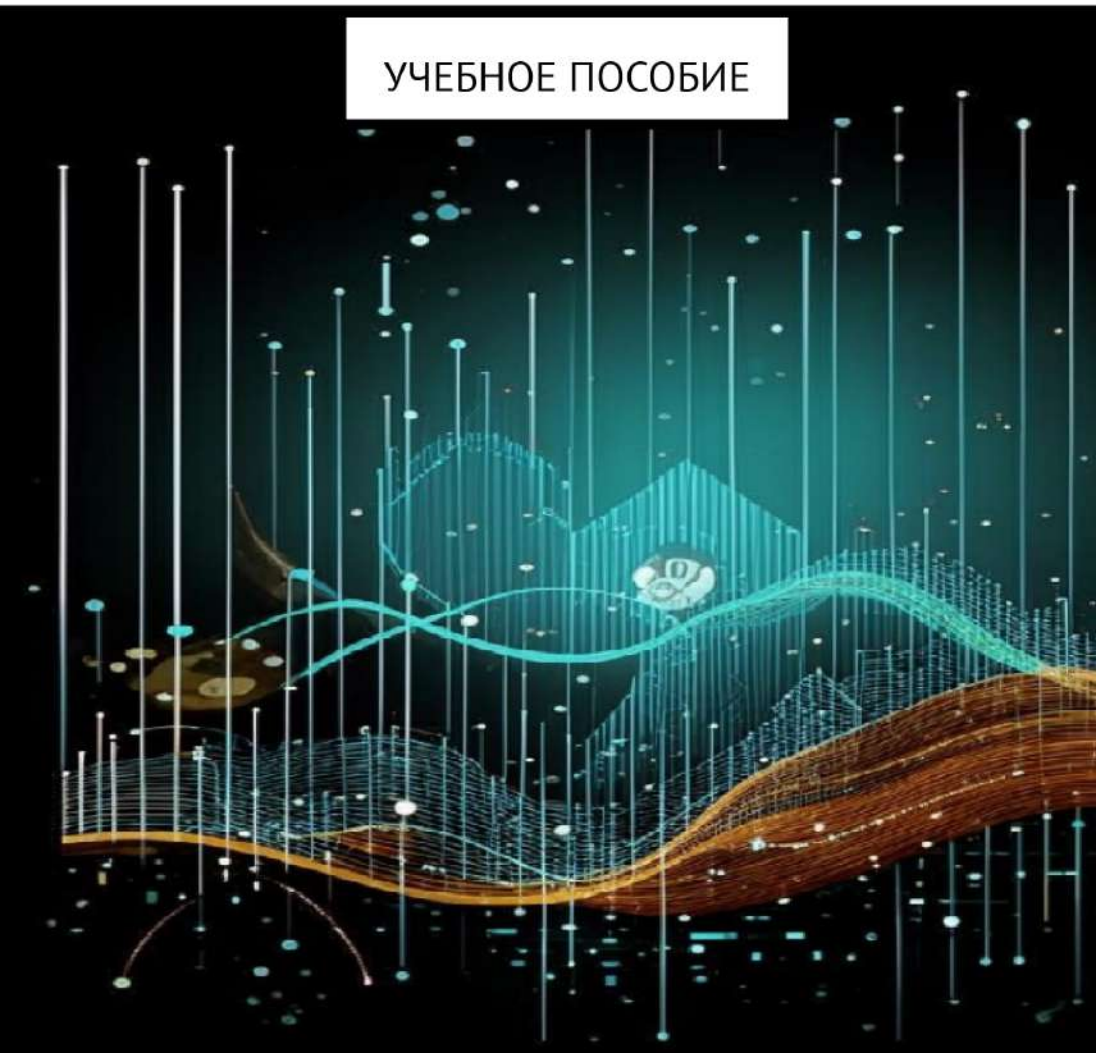
ВАЛЕНТИН ЮЛЬЕВИЧ АРЬКОВ

# Цифровая нефть. От больших данных к большим доходам



Валентин Юльевич Арьков

# Цифровая нефть. От больших данных к большим доходам

Учебное пособие

Издательские решения
По лицензии Ridero
2024

УДК 004
ББК 32.973
А89

Шрифты предоставлены компанией «ПараТайп»

**Арьков Валентин Юльевич**

А89 Цифровая нефть. От больших данных к большим доходам : Учебное пособие / Валентин Юльевич Арьков. — [б. м.] : Издательские решения, 2024. — 148 с.
ISBN 978-5-0064-6561-9

Большие данные — это сколько? Это что-то новое, или мы этим уже занимались? Чем отличаются открытые, свободные и бесплатные инструменты? Вопросов много, а ответ один: это просто бизнес… А ради прибыли бизнес пойдёт на всё. Даже на хорошую зарплату для хороших специалистов. Что же это за профессия такая — анализ больших данных? Давайте разбираться.

**УДК 004**
**ББК 32.973**

12+ В соответствии с ФЗ от 29.12.2010 №436-ФЗ

ISBN 978-5-0064-6561-9

© Валентин Юльевич Арьков, 2024

# ВВЕДЕНИЕ

Первое знакомство с человеком должно быть лёгким, приятным и ни к чему не обязывающим. Возможно, тогда захочется это знакомство продолжить.

Первое знакомство с таким предметом как «большие данные» тоже не должно быть слишком сложным и слишком болезненным. Первые сто страниц ещё не сделают из вас специалиста — вспомним правило десяти тысяч часов. Для достижения мастерства в любой области придётся потратить примерно такое количество времени на изучение и практику. Зато общее знакомство с темой и основными терминами может быть очень даже полезным.

Ссылки на источники приводятся в конце каждой главы. Наш материал также доступен в видеоформате.

# ГЛАВА 1. СБОР И ПРЕДОБРАБОТКА БОЛЬШИХ ДАННЫХ

**Во всем есть своя мораль,**
**нужно только уметь ее найти!**
**Льюис Кэрролл «Алиса в стране чудес».**

## ВВЕДЕНИЕ

Технологии анализа больших данных — есть, оказывается и такое. И мы начнем рассматривать методы сбора и предобработки больших данных. Для начала посмотрим, как менялось количество запросов с ключевыми словами Big Data, см. рис.

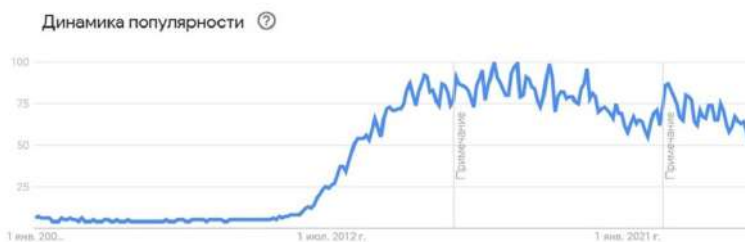



Рис. Интерес публики к тематике больших данных

Можно видеть, что начиная примерно с 2012 года резко увеличился интерес к этой теме. Затем в течение нескольких лет мы вышли на «установившийся режим», на стабильный уровень интереса. И в последнее время интерес немного уменьшился в связи с тем, что публика уже насытилась первоначальной ин-

формацией по данному предмету. Картина очень напоминает «цикл хайпа» по Гартнеру. Сначала этого просто нет, затем оно появляется и мы видим первый всплеск, затем падение интереса, затем второй неторопливый рост и участок «плато». Но и это пройдёт, как написано в мудрых книгах.

## ПОНЯТИЕ И КЛАССИФИКАЦИЯ БОЛЬШИХ ДАННЫХ

Для начала попробуем определить, что же такое «большие данные». В соответствии с названием это данные с большим «чем-то». Прежде всего, это большой размер, или объём, или проще говоря количество данных. И мнения здесь немного различаются, но в целом обычно имеется в виду такое количество данных, которое сложно или даже невозможно обработать традиционными методами. Такое количество данных, которое не умещается на обычном настольном компьютере. На самом деле, все эти технологии применимы к любым размерам выборки. Итак, первое свойство больших данных это объем.

На самом деле, в определении больших данных есть несколько слов, которые начинаются на английскую букву V. Их так и называют: три буквы V, пять букв V и так далее, см. рис.




Рис. Пять V в определении больших данных

Второе слово на букву V — это velocity, то есть скорость поступления данных. Имеется в виду, что данные поступают с очень большой скоростью. Данные создаются, обрабатываются, поступают, и их нужно либо хранить, либо обрабатывать на ходу. В этом случае используются технологии обработки потоков данных. Их так и называют — «потоковые данные».

Третье свойство больших данных — это различные типы, различные форматы. И это у нас третья буква V — variety, разнообразие. Имеется в виду данные, которые отличаются от того, что обычно хранится в реляционных базах данных в виде таблиц, связанных между собой по ключевому полю. Данные могут быть не только красиво структурированными в виде таблиц, но и не структурированными или частично структурированными. Примером может быть аудиозапись разговора или лекции. Здесь вообще никакой структуры нет. Частично структурированные данные — это могут быть документы с более или менее типовыми полями. Хотя работа с текстом — это отдельная проблема. Но тем не менее из текста можно попытаться извлечь отдельные свойства, которые более или менее повторяются.

Следующее свойство — достоверность. И здесь речь идет о том, что данные, которые собирают из различных источников, могут быть достоверными, а могут и не быть таковыми. И это значит, что то, что мы добываем из различных интернет-источников… с этим нужно что-то делать, определять качество данных и устанавливать степень нашего доверия к ним.

Наконец, еще одно свойство — Value. Тоже слово на букву V, условно это называют «ценностью». Здесь надо вспомнить основные определения из области информатики. Данные — это любые сведения, в том числе и те, в которых ничего полезного нет. А вот информацией называют то, что содержится в этих данных. То, что уменьшает неопределенность. То, что увеличивает наше понимание процесса или объекта. Следующим уровнем понимания в анализе данных является знание.

Итак, у нас есть данные на нижнем уровне, это любые сведения или факты. Далее идет информация, которая может представлять полезность или ценность. И следующий уровень — это понимание, знание или, как еще его называют, «инсайт». Это новое понимание, новые взаимосвязи, новые закономерности.

В качестве упражнения мы предлагаем вам подробнее познакомиться, в частности, с определениями того, что такое большие данные. Здесь нам может помочь «народная энциклопедия». Конечно, это не самый лучший и не самый надежный источник. Однако, это более или менее стабильный ресурс. Эти данные совершенно не обязательно являются качественными, правильными, полными, исчерпывающими и так далее (это мы намекаем на одно из свойств больших данных — см. выше). Рассматривайте это просто как упражнение и как пример того, как могут выглядеть те самые большие данные.

Больше информации находится в англоязычном варианте того же текста. Находим статью под названием Big Data. Если имеются трудности с пониманием английского языка, можно включить автоматический перевод. Такая функция доступна во многих современных инструментах. Достаточно нажать кнопочку «Перевести», и мы получаем достаточно приличный перевод.

Обратите внимание, что здесь говорится по поводу слов на букву V. Три слова на букву V, пять слов на букву V и так далее. Сколько всего здесь таких слов собрано. В принципе, это всё расширяет наше понимание самой концепции, что такое большие данные.

Ещё одно упражнение, которое нам предстоит выполнить. Посмотрите, что общего и чем отличаются технологии анализа больших данных и технологии бизнес-аналитики (или как её в настоящее время называют, BI-аналитика). Это прежде всего анализ информации, которая присутствует в корпоративных информационных системах. Для того, чтобы обобщить эти сведения и получить ответы на наши вопросы, вам предлагается не только заняться привычным поиском по ключевым словам, но и позвать на помощь наших интеллектуальных помощников. Заодно можно будет разобраться, как именно ими пользоваться.

## ИИ-ПОМОЩНИКИ

Работа с интеллектуальными помощниками отличается от простого поиска в интернете и иногда бывает достаточно полезной. Хотя, опять же, качество ответов не всегда будет удовлетворительным. Поэтому здесь требуется проверять факты, руководствоваться здравым смыслом и заниматься тем, что называется «факт-чекинг». Fact Checking. Проверка правильности фактов.

Есть несколько источников, которые можно порекомендовать. Опять же, это не самые лучшие, не самые подробные сведения, но тем не менее, в достаточно доступном изложении. Ссылки приведены в конце главы.

Можно также предложить вводное описание технологии больших данных — обзор проблемы из серии «Для чайников»: Hurwitz (2013) Big Data For Dummies. «Большие данные для чайников», или «для сомневающихся», написана на достаточно популярном языке. Здесь на простых примерах объясняют основные проблемы и технологии.

Еще одна книга, которая посвящена данной проблеме: Лесковец (2016) Анализ больших наборов данных. В оригинале называется «Разведочный анализ», или «Дата майнинг». Книга основана на материалах университетского курса Стэнфорда. Желающие могут найти в открытом доступе и полный текст книги, и отдельные главы, и даже слайды для чтения лекций.

И здесь просматривается идея, которая продвигалась лет за 10—15 до всплеска интереса к большим данным. Это так называемый «дата майнинг» — разведочный анализ данных, или, как его ещё переводят, интеллектуальный анализ данных. Здесь более подробно описаны сами методы, сами технологии анализа. И меньше внимания выделяется облачным сервисам, которые служат для организации такой работы.

Отметим, что книга Лесковец доступна в университетской библиотечной системе. Если в вашей организации есть подписка, то вы совершенно свободно можете получить доступ к этой книге на русском языке.

Поскольку нас интересует литература по данной теме, попробуем составить такой список силами интеллектуальных помощников. В качестве упражнения попробуйте дать такое задание той системе, которая вам больше нравится. Мы будем рассматривать пример ИИ-помощника под названием perplexity, что переводится как «замешательство», или «запутанность». Видимо, он помогает эту «запутанность» распутать. Дальнейшие технические подробности мы обсуждаем в рамках лабораторной работы.

Мы формируем очень подробное задание, и оно звучит так. Вначале мы определяем роль. Мы говорим: «Твоя роль — опытный методолог онлайн-курсов». От того, как мы определим роль, будет зависеть поведение системы искусственного интеллекта. Дальше мы даём собственно задание: «Составь список из топ-10 книг на русском языке по методам и технологиям анализа больших данных».

Обычно большинство пользователей ограничивается этой фразой. Но мы пойдем немножко дальше. Мы определяем роль, даём задание, а дальше мы объясняем контекст. Можно явно

вставить слово «контекст», либо указать, для кого будет предназначен ответ, это будущее произведение. Итак, мы говорим: «Твоя аудитория — слушатели курсов повышения квалификации с высшим образованием». Если бы мы сказали: «Твоя аудитория — школьники» или «Твоя аудитория — академики», ответ был бы совсем другим.

Дальше мы описываем формат вывода. Что именно мы хотим? Просто список? Или подробное описание книг? Или ссылки на сайты издательства? Или анализ цен? Или просто сводную табличку? Можно попросить всё, что угодно. В нашем случае мы говорим: «Выведи результаты в виде списка с заголовками». Значит, это должен быть текст, разбитый на абзацы с заголовками. Можно даже привести примеры того, что нам нужно, и сообщить, что это примеры.

Дальше мы уточняем: «Для каждой книги приведи краткое содержание в одном абзаце». И, наконец, мы просим, нам оформили ссылки на книги в соответствии с требованиями действующего государственного стандарта на библиографическое описание. Тогда можно будет использовать данный список практически один к одному, скопировать и вставить в список литературы, см рис.

При большом желании поэкспериментировать можно дополнительно указать «температуру». Этот параметр управляет вариативностью ответов и фантазией нашего помощника.

- **Prompt**
- Твоя роль: опытный методолог онлайн-курсов. Составь список из топ-10 книг на русском языке по методам и технологиям анализа больших данных. Твоя аудитория: слушатели курсов повышения квалификации с высшим образованием. Выведи результаты в виде списка с заголовками. Для каждой книги приведи краткое содержание в одном абзаце. Оформи ссылки на книги в соответствии с требованиями действующего ГОСТ на библиографическое описание.

Рис. Пример подробного запроса (промпта)

Конечно, нам понадобится проверить факты и убедиться, что это не придуманные названия, что эти книги действительно существуют. И для этого у нас в рассматриваемом инструменте для каждого ответа приводятся ссылки на источники, которые всегда можно открыть и посмотреть. Как минимум, мы можем убедиться, что указанные источники существуют.

Для наших экспериментов мы создаем новый thread, то есть новую «нить», новую «ветку» или «беседу», в рамках которой будет поддерживаться определённый контекст, и интеллектуальная система будет помнить наши предыдущие запросы и ее ответы. Теперь мы вставляем наш запрос — так называемый промпт. Смотрим на него еще раз. У нас есть роль, у нас есть задание, у нас есть контекст, формат вывода и все прочее. Запускаем и удивляемся.

Предупреждаем, что результаты могут быть непредсказуемыми. Более того, если вы отправите один и тот же запрос несколько раз, вы можете получить совершенно разные ответы. Возможно, вы получите похожие книги или те же книги, но в другом порядке. Здесь есть такая вариативность ответов, ее обычно называют параметром «температура». Чем она «горячее», тем больше вариативность. И её тоже можно указать в своём запросе к нейросети. Теперь посмотрим на полученный ответ, см. рис.


Вот список из топ-10 книг на русском языке по методам и технологиям анализа больших данных для слушателей курсов повышения квалификации с высшим образованием:

1. Фрэнкс Б. Революция в аналитике. Как в эпоху **Big Data** улучшить ваш бизнес с помощью операционной аналитики. М.: Альпина Паблишер, **2020**. **320** с.

Книга раскрывает концепцию операционной аналитики и ее применение в бизнесе. Автор объясняет, как использовать большие данные для принятия более эффективных решений в режиме реального времени, улучшая бизнес-процессы и повышая конкурентоспособность компании [1].

2. О'Нил К. Убийственные большие данные. Как математика превратилась в оружие массового поражения. М.: АСТ, 2018. 294 с.

Рис. Ответ системы — список книг с пояснениями

В ответе в начале указаны источники, которые можно открыть и увидеть, из каких текстов было собрано, обобщено то, что нам выведено на экран.

Просматриваем ответ. Пункт первый: «Революция в аналитике». Здесь идёт абзац текста с пояснением, о чём эта книга. И далее идет ссылка, очень похожая на требования стандарта. Здесь может быть указано количество страниц. Или не указано — в зависимости от настроения нашего инструмента. Мы можем более подробно описать требования к оформлению библиографии с указанием того, что именно мы хотим получить: количество страниц, серийный номер книги ISBN, использовать ли тире и так далее. Можно даже дать несколько примеров оформления ответа. Все эти требования мы можем дополнительно указывать. И так постепенно дорабатывать свой запрос — подобно тому, как программист отлаживает свою программу. Фактически, промпт — это и есть программа, просто она написана человеческим языком.

Итак, мы получили список. Он действительно состоит из 10 пунктов. Это радует. Далее. У нас есть кнопочка «копировать в буфер». Мы копируем ответ в буфер. На месте этой кнопки на экране появилась галочка. Далее мы можем перенести этот текст в интерактивный блокнот/тетрадку Jupyter Notebook. В том числе, это средство работает и как локально установленная программа. Подробнее он обсуждается в других разделах нашего курса.

Мы создаём новый блокнот, в нём создаём текстовую ячейку, дважды щелкаем по этой ячейке, комбинацией клавиш [Ctrl + V] вставляем из буфера наш результат, нажимаем [Shift + Enter] и рассматриваем полученный результат, см. рис.

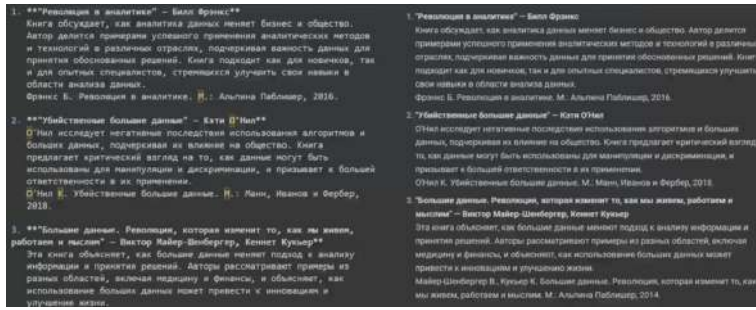



Рис. Формат Markdown и экранное представление

Мы видим пронумерованные заголовки наших абзацев. Они выделены жирным шрифтом — двойные звёздочки. Чтобы текст не сливался в один абзац, вставляем пустые строчки. Ещё раз нажимаем [Shift + Enter]. На самом деле, формат ответа соответствует технологии под названием Markdown.

В рамках такого диалогового блокнота, или «тетрадки» Jupyter — в рамках одного документа — можно объединить и текст программы в кодовых ячейках, и любые необходимые пояснения и комментарии в текстовых ячейках — причем с форматированием.

Markdown — это язык разметки текста. На досуге можете поподробнее с этим ознакомиться и поэкспериментировать в рамках текстовой ячейки интерактивного блокнота Jupyter Notebook.

Простейшие элементы форматирования выглядят так. Одиночные звездочки выделяют курсив, двойные звездочки — жирный шрифт. Вставка фрагментов кода — это обратный апостол. Списки могут выделяться звездочкой, черточкой, плюсиком, а также цифрой с точкой. При этом нумерованный список не обращает внимания на сами цифры, и элементы будут нумероваться по порядку. Наконец, символы решетки — это уровни заголовка. Заголовки будут выделяться жирным шрифтом.

При каждом обращении к нейросети мы получаем очень похожие результаты, но книги расположены немножко в другом порядке. При этом ссылки на веб-ресурсы практически те же. Форматирование в стиле библиографии делается более или менее грамотно — с указанием количества страниц. В остальном мы получаем примерно тот же результат.

Ваша задача: попробовать ввести это задание нейросети несколько раз и сравнить полученные результаты.

Теперь обратим внимание на вторую книгу. Если в первой в названии участвует Big Data, а также говорится про операционную аналитику бизнеса, во втором названии сочетаются такие вещи, как «большие данные» и «математика». И это подводит нас к вопросу истории и эволюции, см. рис.

**КРАТКАЯ ИСТОРИЯ АНАЛИТИКИ**




Рис. Краткая история аналитики данных

## АНАЛИЗ ИСТОРИИ АНАЛИТИКИ

Мы очень кратко пройдемся по некоторым историческим этапам, основным вехам в развитии данного предмета, данной области знания, данной области деятельности (информация не строгая и тоже рекомендуется к «проверке фактов»). Похоже, что во времена Древней Греции математика оформилась как отдельная наука. Само слово «математика» буквально переводится с древнего варианта греческого языка как «наука». По крайней мере, так утверждает этимологический словарь. Похоже, древние греки считали, что математика — это наука (единственная в своём роде), а всё остальное — в лучшем случае «искусство».

Следующим шагом было выделение экономики в отдельную область знания, в отдельную область деятельности. Напомним, что экономика буквально переводится как «ведение хозяйства». «Эко» означает «дом или хозяйство», а «ном» — это менеджер, управляющий — эконом, который вёл хозяйство. Это тоже сведения из этимологического словаря. Постепенно эта профессия оформилась как отдельная область знания, наука, дисциплина. Естественно, существует экономика как область человеческой деятельности, связанная с производством, распределением, обменом и потреблением товаров и услуг. Есть и такое определение. И есть экономика как учебная дисциплина, экономика как наука — экономическая теория. Можно обнаружить книги самого разного толка на эту тему. В последнее время на Западе стало популярным одно из направлений экономической теории, которое называется «экономикс». В русском варианте обычно говорят «экономика» или «экономическая теория».

Далее, параллельно с этой областью деятельности сформировалась статистика. Появилась она не так давно, лет 200—300 назад. И первоначально слово «статистика» означало «описание достопримечательностей государства», «изучение страны» или даже «государствоведение». Фактически это была попытка подсчитать и измерить всё, что происходит внутри страны.

Сколько живет людей, какой у страны бюджет, сколько собирают налогов, какая нужна армия, какая площадь земельных владений и прочих богатств. Сколько и чего нужно для управления страной. Таким образом, статистика оформилась как самостоятельный предмет, связанный с управлением страной. И по сути это «сбор и обработка данных для принятия решений на основе фактов». В данном случае для управления страной.

Одновременно те же самые методы и те же самые закономерности развивались, открывались применительно к другим областям деятельности, к другим областям знания. В частности, математики применяли эти же самые методы к природным процессам, к примеру, для вычисления астрономических прогнозов движения планет.

Примерно полвека назад на основе статистики и экономической теории был создан искусственный, синтетический предмет под названием эконометрика. Название буквально расшифровывается как «измерения в экономике». Это построение статистических моделей для экономических объектов и процессов на основе реальных, фактических данных.

Аналогичная область деятельности в технических системах называется идентификация систем. Во многом эти области деятельности пересекаются — статистика, эконометрика, идентификация.

Далее начал развиваться Data Mining — «разведочный» анализ данных, или интеллектуальный анализ данных. Эти названия время от времени всплывают, они присутствуют в различных программных продуктах. Но внутри каждый раз мы обнаруживаем ту же самую статистику, тот же самый анализ распределения, корреляцию, вариацию и прочие привычные статистические методы. Просто каждый раз появляется новое «зонтичное» название, к примеру, «дата-майнинг». Буквально это означает «добыча полезной информации из больших массивов сырых, необработанных данных». Дата-майнинг до сих пор присутствует как элемент меню в электронных таблицах и в системах управления базами данных.

Следующим шагом стало появление целого семейства или целой линейки продуктов под названием Business Intelligence (BI). В русском варианте может называться бизнес-аналитика, в последние годы чаще говорят: «BI-аналитика». Что имеется в виду? Само название Business Intelligence сложно перевести, потому что, во-первых, слово «бизнес» в данном случае означает «любое предприятие», ну а слово intelligence — это не обязательно «интеллект». Слово intelligence может иметь отношение к разведке и к анализу данных.

Речь идет об анализе данных в масштабах предприятия, причём исходные данные берутся из учётных систем. Это системы, например, из области бухгалтерского учета. Здесь все события, связанные с жизнью предприятия, фиксируются в какой-то базе данных и постепенно накапливаются. Ну а для задач управления предприятием, для задач принятия решений, нужны обобщённые данные. И теперь нужны не конкретные сведения о конкретной операции, о продаже, скажем, одного мешка картошки. А речь идет об обобщённых, укрупнённых, усреднённых показателях. К примеру, выручка за конкретный месяц, за сентябрь такого-то года, в таком-то городе, в таком-то магазине.

Так вот, обобщением, получением обобщенных показателей и красивым визуальным представлением на экране занимается BI-система. В чём-то они пересекаются с тем, что сейчас называется большими данными.

Последний пункт в нашем списке — большие данные, а также наука о данных. Эти термины очень близкие, но есть некоторая разница. Большие данные подразумевают работу с этими данными, в том числе получение таких данных, хранение таких данных и организация всех этих процессов, чаще всего с использованием больших серверов и облачных технологий. А что именно делают с этими данными? Вот этим занимается Data Science — так называемая «наука о данных». Но если открыть любую книгу по поводу больших данных, то обнаруживаем ту же самую статистику и бизнес-аналитику. Тот же самый разведочный анализ данных и интеллектуальный анализ данных.

И в том числе мы обнаруживаем методы статистики и эконометрики, которые известны уже довольно давно. Теперь те же самые методы, к примеру, регрессия, классификация, прогнозирование на основе моделей, на основе реальных данных применяются к большим массивам данных. Они большие, и их нельзя обработать вручную.

Здесь могут выделяться особые технологии, связанные с тем, что данные непрерывно поступают в виде потока событий, потока сообщений. Это так называемые «потоковые данные».

А в целом мы обнаруживаем всё те же методы анализа, которые известны уже десятки, а то и сотни лет. Просто теперь у нас есть компьютерная реализация и облачные технологии.

### ИСТОЧНИКИ БОЛЬШИХ ДАННЫХ

Далее рассмотрим основные источники тех самых больших данных, см. рис. Один из популярных источников — это социальные сети. Каждый пользователь социальных сетей вводит огромное количество информации своими руками. Загружает фотографии, пишет посты, пересылает сообщения, ставит отметки о том, что ему нравится и не нравится, ставит лайки и дизлайки — и так далее. Заводит друзей, отправляет запросы дружбы, отклоняет эти запросы либо принимает. Все эти события фиксируются на платформах социальных сетей и представляют собой огромное количество информации.

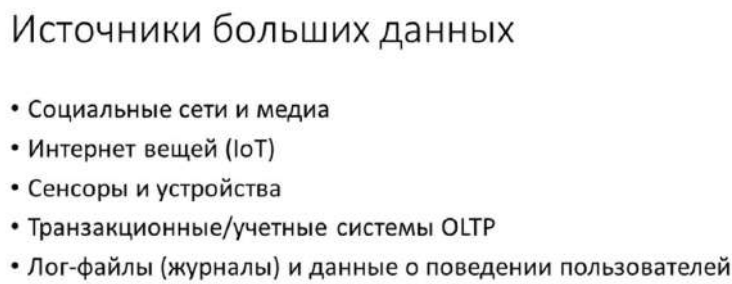



Рис. Источники данных

Аналогично работают платформы, где размещаются медиаресурсы — фотографии, звук, видео — всё, что угодно. Это тоже огромный источник данных — и самих данных, и того, как ими пользуются. Если это видео — платформа фиксирует, сколько минут этот ролик смотрели, перематывали, рекомендовали и так далее.

Следующий источник — это интеллектуальные устройства, подключенные к сети передачи данных. Теперь это называется интернет вещей — Internet of Things (IoT).

Кроме этого, работают отдельные датчики, сенсоры и другие специализированные устройства, которые порождают большие потоки информации. Например, видеопотоки, которые практически невозможно записать и хранить длительное время — в лучшем случае несколько дней.

Далее идут учетные системы или транзакционные системы. Система обработки транзакций в реальном времени — OnLine Transaction Processing (OLTP). Здесь огромное количество событий, связанных с покупкой и продажей товаров.

Отдельной строкой идут так называемые «логи». Это протоколы, или журналы — то есть файлы, где просто фиксируются события. Например, когда пользователь регистрируется в информационной системе, вводит логин и пароль, и когда он завершает работу с системой. В журнале также автоматически

фиксируются все действия пользователя внутри компьютерной системы. На самом деле логи — это просто текстовые файлы, где указана дата, время и события. Переходы от одной страницы к другой, вызов пункта меню и так далее. Все эти записи характеризуют действия пользователя.

По логам можно анализировать индивидуальное поведение пользователя либо можно выводить некие усредненные закономерности.

Ну и поскольку данные имеют огромные размеры, объемы, скорости передачи, разнообразие — те самые три первых буквы V — с этим связаны и особенности проблемы. Данные такого большого объёма хранить сложно и в некоторых случаях просто невозможно. Ну и обрабатывать традиционным способом тоже не получится, см. рис.




Рис. Не всё так просто

Другой ряд проблем связан с тем, что большие данные содержат сведения о конкретном человеке — на сегодняшний день это называется «персональные данные» — и эти сведения могут использоваться, в том числе, и злоумышленниками. Вопрос безопасности здесь встает очень серьёзным образом. Даже

если в данных компьютерной системы нет фамилии человека и его фотографий, можно, сравнивая сведения в разных системах, сопоставляя их, очень легко выяснить и фамилию, и номер телефона, и номер автомобиля, и домашний адрес, и всё, что потребуется. С точки зрения служб безопасности это, возможно, плюс, а вот с точки зрения мошенников — это колоссальные возможности для нанесения вреда.

Далее, поскольку большие данные нужно хранить и обрабатывать особым образом, здесь требуются совсем другие аппаратные решения. Эта область деятельности называется высокопроизводительное вычисление или High Performance Computing (HPC). Это целая профессия: как написать программу, которая будет производить нужные вычисления, но не на одном компьютере, а, к примеру, на тысяче или на миллионе процессоров. Как разделить задачу на небольшие части так, чтобы не потерять в производительности? Или, по крайней мере, достичь приемлемого ускорения?

Ускорение — это, кстати, одна из характеристик вычислений (и измеряется ускорение не обязательно в метрах на секунду в квадрате). Фактически, ускорение отвечает на вопрос, во сколько раз быстрее удалось выполнить расчеты. И совсем не обязательно, что на тысяче процессоров можно работать в тысячу раз быстрее. Потому что, во-первых, нужно передать исходные данные, распределить задания между вычислителями, а затем собрать и агрегировать результаты вычислений. И при большом количестве вычислительных узлов совсем не обязательно достигаются хорошие показатели ускорения. Фактически, нынешние высокопроизводительные системы могут эффективно использовать только единицы процентов своей вычислительной мощности при решении больших сложных задач.

Следующая проблема — это качество данных, особенно если они вводятся людьми, например, сведения, собранные из социальных сетей. Ну и, наконец, отдельной строкой мы выделили понятие масштабирование. Здесь речь идёт о том, что при необходимости нарастить вычислительную мощность приходится ре-

шать особый класс задач. Совсем не обязательно добавление вычислительных узлов позволяет пропорционально ускорять вычисления. Не говоря уже о том, что изменение схемы вычислений может повлиять на эффективность расчетов.

**ИНСТРУМЕНТЫ АНАЛИЗА**




Рис. Как нам справиться с большими данными?

Далее мы обсудим несколько популярных технологий, имеющих отношение к работе с большими данными, см. рис. Ну, во-первых, есть фреймворки, или платформы, для работы с большими данными. Это прежде всего Hadoop, Spark, MapReduce и аналогичные инструменты. У каждого инструмента свои особенности, свои плюсы и минусы. К примеру, Hadoop лучше работает с пакетными заданиями, а Spark лучше предназначен для обработки потоковых данных. При этом они могут работать сов-

местно, и, к примеру, Hadoop обеспечивает распределенное хранение данных на нескольких носителях или на нескольких компьютерах. А Spark позволяет перенести вычисления и хранение промежуточных результатов в оперативную память. И это тоже инструмент для ускорения вычислений. Далее, при анализе данных появляются особые сложности, связанные с обработкой баз данных. Жизнь заставила программистов-разработчиков изменить способы хранения данных — для того, чтобы их легче было агрегировать. Задача агрегирования — это, прежде всего, подсчеты сумм или средних значений по столбцам. Напомним, что и в базах данных, и в электронных таблицах переменные хранятся по столбцам. Но при этом реляционные базы данных записывают файлы, в которых записи в таблицах хранятся по строчкам. Просто потому что новые данные приходят в виде очередной записи. А это и есть новая строка в таблице. Так вот, извлечение и обработка данных, которые расположены в одном столбце, гораздо легче будет происходить, если каждый столбец хранится непрерывным фрагментом файла. Вот этим занимаются так называемые колоночные базы данных.

Далее у нас перечислены инструменты, связанные с потоковыми данными и названо несколько облачных платформ.




Рис. Какие бывают данные?

Если рассматривать типы данных, которые предстоит обрабатывать, то очень условно выделяются структурированные, неструктурированные и слабо-, частично-, или «полу-структурированные» данные, см. рис. Идеально структурированные данные — это таблица, одна или несколько таблиц, где в каждом столбце находятся данные одного типа, относящиеся к одному и тому же параметру, или, как говорят, полю. Противоположностью структурированным данным является неструктурированные данные, где нельзя выделить однотипные поля или столбцы. Это может быть изображение, текст или видео. Есть файлы типа XML или JSON, которые ближе всего в программировании соответствуют понятию словарь или dictionary, когда у нас есть поле и соответствующие ему значения. Причём для разных объектов может быть разный набор полей — в зависимости от свойств объекта и от имеющихся данных. Про это мы еще отдельно поговорим.

Второй вид классификации — это источники данных. И прежде всего можно выделить данные, которые создаются людьми,

и данные, которые создаются с помощью оборудования. Пользователи могут сами вводить огромное количество сведений, — с учетом того, что на Земле проживает несколько миллиардов человек, и многие из них регулярно выходят в интернет. Соответственно, есть социальные сети, блоги и тому подобное. Такие ресурсы являются источником больших данных. Ну, а то, что генерирует оборудование, это сенсоры, логи и интернет вещей. Это самый быстрорастущий сегмент больших данных.

Далее, в том, что касается создания и генерации данных, можно обсуждать обработку того, что лежит в архивах и того, что поступает в виде потока, который практически невозможно записать и хранить. То есть нужна обработка данных по мере поступления — практически в реальном времени — и возможно с каким-то небольшим учётом предыстории. Это особая технология, здесь есть свои особенности.




Рис. Где всё это применить?

На следующем рисунке перечислено несколько примеров того, в каких областях деятельности могут применяться большие данные. Анализируя поведение человека, можно заниматься таргетированной рекламой (от слова target — «цель», «целиться» — то есть «прицельная реклама»). Это означает, что человек будет получать рекламные предложения, подходящие к его профилю, связанные не только с возрастом, местом проживания, областью деятельности, но и с какими-то особенностями его поведения в сети.

Далее, многие компании всё больше начинают анализировать поведение своих клиентов. И, к примеру, для сотовых компаний существенным является своевременное прогнозирование так называемого оттока клиентов (churn). В какой момент человек начинает задумываться о том, чтобы перейти к другому поставщику услуг. Он ещё даже не задумывался

об этом, но в его поведении появляются «подозрительные», характерные изменения. Ну и задача компании удержать клиента. А это значит, что нужно подобрать ему такое предложение, которое будет лучше, чем у конкурентов — с точки зрения этого конкретного человека.

Следующий шаг — это рекомендательные системы. Это, к примеру, рекомендации фильмов, или аудиотреков, или книг, или товаров. Когда человека рассматривают, анализируют, относят к какому-то классу или кластеру, здесь в чистом виде работает кластерный анализ. И этому клиенту рекомендуют то, что уже сработало для других клиентов, похожих на него по каким-то характеристикам, по каким-то особенностям поведения.

Следующий пример — это прогнозы, в том числе прогнозы нежелательных событий. Если имеется достаточное количество записей об истории какого-то экономического, технического или природного процесса, можно прогнозировать его дальнейшее развитие. Естественно, при выполнении ряда условий, с рядом оговорок. И звучит постановка задачи примерно так: если и дальше события будут развиваться, как прежде, тогда можно ожидать то-то и то-то. В самых разных ситуациях прогнозы могут быть очень эффективными, даже если они не слишком точны.

Особая область деятельности — это оптимизация бизнес-процессов, то есть того, что происходит на конкретном предприятии (напомним, что слово «бизнес» может означать «предприятие»), см. [Вики: Бизнес]. И здесь начинает работать анализ так называемых логов. Эта область деятельности на сегодняшний день становится все более популярной, и она называется Process Mining, что очень напоминает предыдущий термин Data Mining.

Теперь это «разведочный анализ» бизнес-процессов. И речь идёт о том, что, анализируя большое количество журналов событий, так называемых логов, определяют типовое, типичное, усреднённое поведение разных видов клиентов в рамках корпоративной информационной системы. И далее можно уже определять возможности улучшения бизнес-процес-

сов, исходя из типового поведения разных классов пользователей.

Следующий пример — это медицина. Это диагностика с применением машинных рекомендаций. Это может быть обсуждение различных лабораторных анализов, это может быть исследование рентгеновских снимков, томографии, просто целой истории болезни. Имея большое количество статистики, можно улучшить качество прогнозов, качество диагнозов и качество рекомендаций по лечению. Тем более, что компьютерные системы могут распознать многие заболевания на ранней стадии и сделать лечение более успешным. Такие системы не устают, работают круглые сутки и замечают малейшее отклонение от того, что можно считать здоровым состоянием организма.

Ну и наконец, то, что развивается в настоящее время в связи с развитием онлайн-образования. Многие онлайн-платформы накапливают большие массивы данных о том, как ведут себя обучающиеся. Благодаря анализу таких сведений, можно выяснять, как происходит обучение, насколько оно идёт успешно, где возникают трудности у большинства пользователей и что можно улучшить, как можно усовершенствовать эту деятельность. Чем-то это перекликается с оптимизацией бизнес-процессов в целом.

**ДАЛЁКОЕ СВЕТЛОЕ БУДУЩЕЕ**




Рис. Что же дальше?

После того, как мы рассмотрели примеры применения больших данных, стоит упомянуть перспективы дальнейшего развития. В этой области всё меняется очень быстро. Поэтому то, что сегодня мы называем перспективами, на самом деле где-то уже реализуется. Вот, например, аналитика в реальном масштабе времени, то есть с той же скоростью, как поступают новые данные. В том числе, это будет полезно для того, чтобы в самих бизнес-процессах происходило использование аналитики.

Так что мы отмечаем такую тенденцию, как интеграцию аналитики в бизнес-процессы. Некоторые зачатки этого мы уже наблюдаем, когда BI-аналитика, то есть аналитика данных из учетных систем, становится доступной любому руководителю любого уровня. Теперь это называется «аналитика для конечного пользователя» или самообслуживание: self-service BI. Этот инструмент можно использовать либо с минимальным знанием программирования, либо вообще без использования программирования — с визуальной настройкой нужных показателей и визуализации.

Следующая тенденция — это всё большее использование технологий машинного обучения искусственного интеллекта.

Требования к уровню владения программированием могут быть и не такими серьезными, как сейчас, для того, чтобы реализовать готовые алгоритмы с помощью готовых программ.

Соответственно, можно ожидать, что результаты обработки больших данных всё больше будут использоваться при принятии решений. Если раньше был девиз: «Принятие решений на основе фактов», потом «на основе данных». Появился термин Data Driven Decision Making. Сейчас, соответственно, Big Data будет всё больше проникать в этот процесс принятия решений.

Ну и поскольку данные так или иначе затрагивают личность конкретного человека, появляется все больше внимания к вопросам, насколько это закономерно, насколько это законно — использовать данные. Насколько это этично и морально — использовать данные о человеке, причём чаще всего без согласия самого человека. Так что вопросы этичного использования данных и законодательного регулирования этих действий — это тоже большая проблема.

Умные устройства, такие как интернет вещей, и всё, что сегодня называется «умный город», Smart City, — это всё большее количество устройств, подключенных к интернету и работающих автоматически. Они тоже являются источником растущего количества данных.

**РАЗМЕРНОСТЬ И ОБЪЕМ ДАННЫХ**

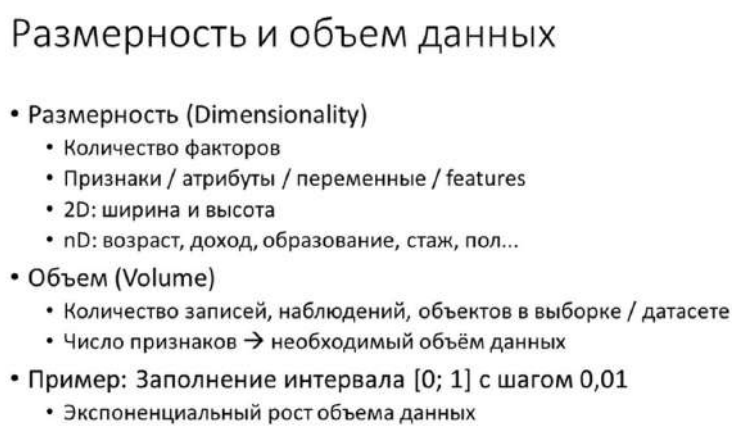



Рис. Всё дело в размере...

Когда мы говорим о количестве данных, о том, что они «большие», что у нас «большой объем данных» — здесь есть еще один аспект. И это то, что называется «размерность» — Dimensionality. Вообще слово dimension означает «измерение». Можно сказать, что размерность — это количество осей координат, если мы попробуем изобразить любую запись в нашей базе данных в виде точки в каком-то многомерном пространстве. Можно сказать, что речь идет о количестве факторов, которые учитываются при построении машинных моделей. Их можно также называть словом «признаки», или по-английски «feature». Можно также называть их «свойства», «атрибуты», «переменные», «параметры». Важно понимать, что речь идет о свойствах, которые мы фиксируем. Применительно к каждому объекту или, как говорят в статистике, к «статистической единице». Если у нас два измерения, это плоская двумерная картина, это значит, что мы смотрим на ширину и высоту. Но на самом деле для самых разных объектов можно получить гораздо больше характеристик.

Ну, в частности, если мы будем пытаться что-то прогнозировать в отношении человека, то придется рассматривать буквально десятки, а может быть и сотни разных характеристик. Это значит, что в нашей модели будет учитываться и возраст, и уровень дохода, и уровень образования, и стаж, и профессия, и пол, и семейное положение, и владение какими-то объектами недвижимости, и задолженности и так далее.

Всё это может влиять на тот конечный признак, который нас будет интересовать в плане прогнозирования. А это может быть и здоровье, и шансы найти работу, и возможность вернуть кредит. Всё, что угодно, можно пытаться спрогнозировать, если мы располагаем достаточным количеством данных. И здесь-то и появляется самая большая проблема.

### ПРОКЛЯТИЕ РАЗМЕРНОСТИ

Когда мы пытаемся учитывать большое количество факторов, признаков, «фичей», нужно будет фиксировать значение каждого признака для каждой записи, то есть для каждого объекта выборки. Это значит для каждого человека или объекта недвижимости, или технического устройства, или экономического объекта.

Соответственно, для построения моделей увеличение числа признаков существенно увеличивает потребный объём данных. А это приведёт к огромному количеству дополнительных вычислений. Есть даже утверждение, что такая проблема разрастается «экспоненциально». Так что мы рассмотрим простой пример для демонстрации «сложности», связанной с этим ростом количества данных. Эту ситуацию упоминает Беллман в своей книге «Динамическое программирование», написанной в середине прошлого века, см. [Беллман Размерность].

Задача выглядит так. Если у нас одно-единственное измерение, один признак «икс», и мы заполняем интервал от 0 до 1 значениями с шагом 0,1 — то очевидно, что у нас будет 100 точек. И если нас будет интересовать так называемая

«представительная выборка», то будет желательно обеспечить самые разные значения этого самого x.

Теперь представим, что у нас будет два измерения — две переменных x1, x2, и для каждого измерения диапазон значений от 0 до 1 нужно будет заполнить шагом 0,1. Понятно, что теперь это уже двумерная картина, соответственно, для количества данных мы получаем оценку 100 в квадрате.

Для трёх признаков, чтобы заполнить все это многомерное пространство с равномерным шагом, потребуется уже 100 в третьей степени.

Таким образом, наша задача начинает разрастаться очень быстро. Достаточно добавить ещё один признак, и мы увеличиваем степень на единицу. Вот поэтому говорят про экспоненциальный рост количества данных.




Рис. Позвольте пару слов о регрессии

Теперь рассмотрим проблему размерности применительно к задаче регрессии, см. рис. Большое количество данных затруд-

няет и процесс построения модели, и процесс визуализации, интерпретации построенной модели. Во-первых, появляется так называемая разреженность данных. То есть мы не имеем достаточное количество данных в каждой точке многомерного пространства. Если мы хотим охватить самые разные комбинации значений признаков, то не все они в природе могут быть представлены, или в нашей выборке, в нашем датасете. Если мы попытаемся собрать данные, относящиеся к каждой точке, с определенным шагом, или хотя бы приблизительно с таким шагом, как на предыдущем слайде, задача становится «неподъёмной».

В связи с этим, статистики сразу же попытались предложить решение и немножко «проредить» данные с помощью технологии планирования эксперимента — Experiment Design. Что это значит? Это значит, что мы заранее вносим пропуски в наши данные. И некоторые точки в пространстве заведомо будут отсутствовать.

Вторая проблема, которая вытекает из этого, называется «переобучение». Это значит, что модель начинает подстраиваться под конкретные данные. Она просто запоминает значения для конкретных комбинаций «иксов» при прогнозировании «игрека». А машинная модель строится совсем с другой целью — с целью обобщения. Обобщающая способность модели — это попытка вывести закономерность и не отвлекаться на шум, не отвлекаться на случайности, выделять самые общие свойства. Вместо этого модель подстраивается под случайное отклонение, под конкретные объекты. Соответственно, теряется обобщающая способность и происходит подстройка под данные, то есть переобучение. И это значит, что на обучающей выборке результаты прогнозов будут хорошими, будут совпадать с исходными данными, а вот на контрольной выборке, или, как говорят, на тестовой выборке, все будет гораздо хуже.

Наконец, интерпретировать и визуализировать результаты становится всё труднее. Если в двух измерениях график построить достаточно легко. Постепенно добавляя количество «иксов»,

мы совершенно затрудняем, усложняем возможности построения графиков. Многомерные графики практически невозможно воспринять. Даже трехмерные воспринимаются сложно. В разных дисциплинах есть соответствующие приёмы, в частности, третье измерение вводится как расслоение характеристик. Это характерно и для задач механики, и для задач в области электроники, и в теории управления. Но это даже не четыре измерения, а всего три. А при этом график мы должны построить на плоскости — то есть в двух измерениях. Дальше все становится практически не интерпретируемо.

Поэтому сложно объяснить в соответствии с нашей моделью, какой признак каким образом влияет на результативный. Соответственно, принятие решений на основе таких «необъяснимых» моделей становится достаточно безответственным занятием. Каждый раз говорить, что «у нас нет оснований не доверять искусственному интеллекту...» На самом деле, у нас есть такие основания.




Рис. Что мы имеем в итоге...

Подведем итоги, см. рис. Высокая размерность задачи, попытка учитывать большое количество признаков, вначале дей-

ствительно немного улучшает точность прогнозов, но затем качество модели начинает ухудшаться — по нескольким причинам. Первое — это усложнение вычислений и требование всё большего количества данных. А это так называемая «вычислительная сложность», вплоть до полной невозможности решения задачи — в том, в чистом виде, как она поставлена. С тем количеством признаков.

Далее у нас имеется проблема переобучения и настройки под шум. И как здесь указано, некоторые признаки становятся излишними, избыточными, дублирующими, слишком сильно коррелированными с остальными признаками. И в принципе их можно было бы и исключить из рассмотрения. Но об этом мы поговорим чуть позже.

Визуализация тоже становится всё более затруднённой.




Рис. Хотели как лучше...

Вся эта проблема была названа проклятием размерности, или по-английски The Curse of Dimensionality, см. рис. При увеличении количества измерений мы получаем многомерное пространство, в котором всё хуже решаются задачи классификации или кластеризации. То есть расстояние между точками становит-

ся настолько большим, что становится практически невозможно с этими данными работать (и замечать на этом фоне различия между классами).

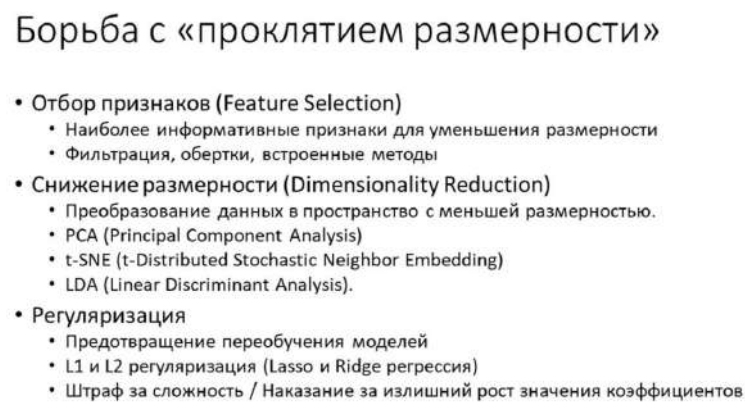



Рис. Вся наша жизнь — борьба

Поскольку увеличение размерности является нежелательным, очевидным решением проблемы является уменьшение этой самой размерности, см. рис. Как же это достигается? Количество факторов, количество признаков, каким-то образом нужно уменьшить. Либо нужно оставить только самые информативные и убрать малоинформативные, зашумленные, или постоянные значения, или слишком коррелированные признаки. Так появляется отбор признаков — Feature Selection.

С другой стороны, можно попытаться сохранить всю имеющуюся информацию, но при этом уменьшить количество признаков. И это приводит нас к созданию, «конструированию» новых признаков — небольшого количества новых признаков на основе большого количества имеющихся. Для этого используются технологии понижения размерности (или снижения размерности) — Dimensionality Reduction — путём преобразования данных в пространство с меньшей размерностью. Были разра-

ботаны, в частности, метод главных компонентов и дискриминантный анализ (уже лет эдак сто тому назад).

Плюс к этому существуют технологии регуляризации, когда при обучении модели в критерий вводится дополнительная поправка –штраф за сложность модели. С помощью дополнительного критерия в уравнение вводится ограничение, например, на величину коэффициентов при наших параметрах.

Все эти технологии известны и присутствуют даже в библиотеке под названием sklearn, см. [Вики: Scikit-learn] и [scikit-learn].

### ЭТАПЫ БОЛЬШОГО ПУТИ: ЖИЗНЕННЫЙ ЦИКЛ АНАЛИТИКИ ДАННЫХ




Рис. Всё идёт по кругу (картинка из Википедии)

Теперь рассмотрим жизненный цикл аналитики данных, см. рис. Понятие «жизненный цикл» применимо к самым разным ситуациям и к самым разным объектам. Но в любом случае имеется в виду повторяющаяся последовательность действий, потому что цикл — это движение по кругу.

В данном случае идея жизненного цикла применяется к анализу данных. И мы напомним определение, что речь идет о том,

как собрать данные, что с ними сделать и что делать с результатами обработки данных. Так вот, жизненный цикл включает в себя основные этапы, начиная от постановки задачи и заканчивая готовым решением.

В качестве примера мы рассматриваем один из промышленных стандартов, который был разработан лет 20 назад и относился еще к действиям по разведочному или интеллектуальному анализу данных — дата майнингу. Называется он CRISP-DM — Cross-Industry Standard Process for Data Mining. Здесь мы приводим картинку из Википедии, см. [Вики: CRISP-DM]. Собственно, это картинка из первоначального описания самого стандарта.

И что мы здесь видим? Мы видим, что кроме движения по кругу в целом, еще и несколько внутренних итераций. Речь идет о том, что фактически здесь реализована методология гибкой разработки, так называемая Agile, когда движение идет небольшими итерациями, но в конце каждой итерации появляется очередной элемент конечного продукта. Поэтому внутри мы видим дополнительный цикл, и про эти этапы мы еще с вами поговорим, см. рис.

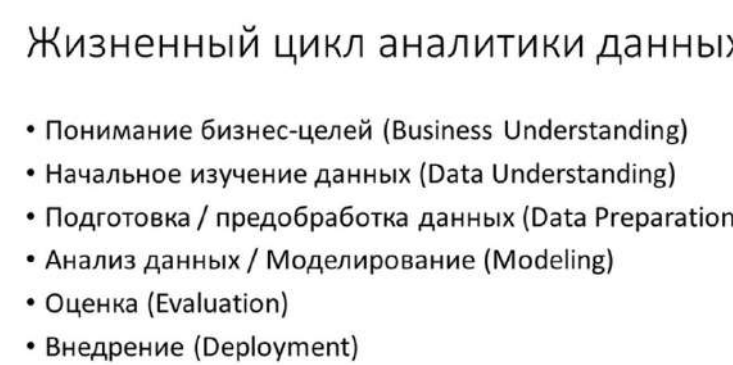



Рис. Основные этапы анализа

На этом слайде перечислены основные этапы, и мы их рассмотрим далее поподробнее. Перевод на русский язык доста-

точно условный, и он не всегда передает смысл, основную идею. Когда мы разберем содержание каждого этапа, всё более или менее прояснится.

Первый этап — это понимание бизнес-целей или Business Understanding, см. рис. Прежде всего надо пояснить, что слово «бизнес» в данном контексте означает «предприятие, компания, организация». Соответственно, мы рассматриваем, какие цели и задачи ставятся предприятием в рамках проекта по анализу данных. Кто здесь представляет интерес с точки зрения предприятия, с точки зрения заказчика.

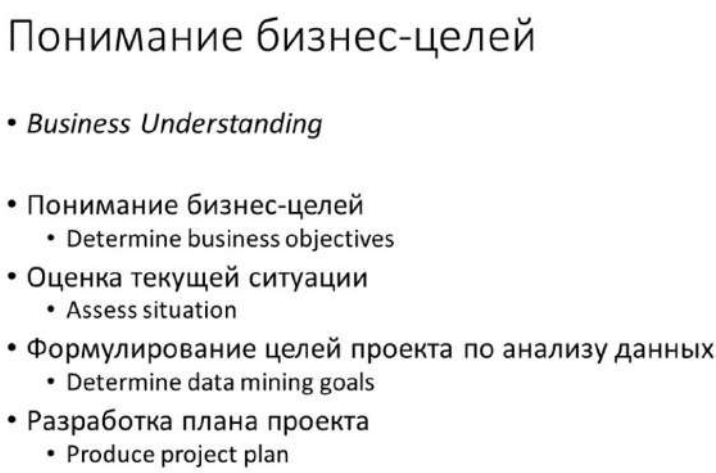



Рис. Цели предприятия

Далее формулировка этой задачи с точки зрения предприятия будет преобразована в формулировку задачи по анализу данных. Понимание целей с точки зрения предприятия. Сюда входит предварительная информация о том контексте, в котором будет проводиться работа. И, что самое интересное, на этом этапе определяется сразу же критерий или условие успешности проведения анализа и внедрения его результатов.

Что должно улучшиться и как именно это можно будет измерить.

Далее идет оценка текущей ситуации. И, по сути, формулирование проблемы, которая будет решаться. Сюда входит, в том числе, анализ имеющихся ресурсов. Например, персонал. Или возможности по добыче или выгрузке данных. Возможности по обработке и хранению данных, а также оценка рисков или событий, которые могут повлиять на результаты данного проекта. И только после этого определяют цели проекта по анализу данных. В оригинальной терминологии это проект по дата-майнингу. На самом деле в аналитике данных мало что изменилось, кроме названий.

Итак, здесь определяют цели — для чего будет проводиться анализ данных. То есть для достижения целей, поставленных перед предприятием. И насколько можно будет измерить успешность и чем. После того, как определились целями и задачами проекта, переходит к составлению плана проекта по анализу данных. Все эти этапы должны быть согласованы между собой и фактически на каждой итерации эти моменты постепенно уточняются. Но тем не менее, даже на этапе составления плана проекта проводится первоначальная оценка располагаемых ресурсов, инструментов, методов, методик и так далее.




Рис. Этап изучения данных

Следующий этап — Data Understanding. Буквально можно перевести как «понимание данных», но фактически речь идет о первоначальном знакомстве с данными. Можно также перевести как « (перво) начальное изучение данных». Здесь первым шагом идет сбор исходных данных — Collect Initial Data. Речь идет о тех данных, которые уже были определены в рамках плана проекта по анализу данных.

Данные могут собирать из различных источников. Это может быть выгрузка из базы данных. Это может быть сбор отдельных файлов. Это может быть получение данных через интерфейс API и как угодно ещё.

Следующим шагом идет первоначальное описание данных Describe Data. Здесь речь идет о том, чтобы объяснить, что представляют собой данные, какие типы значений, какие у них характеристики, формат, структура и прочее. В настоящее время такие характеристики данных еще называют термином «мета-

данные». Это выражение переводится приблизительно как «данные о данных».

Следующий шаг — это исследование данных или, как ещё говорят, «исследовательский анализ данных» или «разведывательный анализ данных» — Exploratory Data Analysis — или можно сказать EDA. Иногда и такое можно встретить.

Первоначальное исследование данных — это простейшее агрегирование, визуализация, выявление каких-то очевидных шаблонов, аномалий или взаимосвязей. Это, естественно, улучшает наше общее понимание и знакомство с этими полученными, собранными данными.

Далее проводится анализ качества полученных собранных данных. Ну, например, насколько полными являются эти данные. Какие случаи они описывают, есть ли пропуски, которые понадобится заполнить. И вообще, не содержится ли в этих данных каких-то ошибок или искажений.

Отдельная проблема — это так называемые дубликаты. Одно и то же событие, особенно после загрузки данных из нескольких источников, появляется в нескольких записях. Совершенно идентичных или может быть даже слегка различающихся. Но поскольку речь идет об одном событии, об одном и том же событии, то вообще-то дубликаты надо исключать.

Таким образом, при сборе, загрузке и первоначальном анализе данных появляется отдельная проблема. Предварительная обработка, преобразование, очистка и так далее.

На этом слайде мы также указываем еще одно действие — документирование. Этот термин является просто буквальной записью английского слова Documenting. Это действие по составлению документации. Фактически, это записи о том, какие данные были собраны, какие проблемы были выявлены в этом процессе, что на этом этапе было обнаружено и не нужно ли что-нибудь скорректировать. На самом деле в рамках модели CRISP-DM предполагается составление отчетов по каждому шагу в рамках каждого этапа.




Рис. Готовим данные: моем, чистим, нарезаем…

Следующий этап условно называется подготовка данных — Data Preparation, см. рис. В последнее время часто используется термин предварительная обработка, «предобработка» или даже «препроцессинг» — Pre-processing. Речь идет о том, чтобы подготовить данные для дальнейшего анализа.

Что же производится при предварительной подготовке данных? Первое — это отбор данных, которые действительно будут полезны при решении задачи анализа. Какие именно признаки нам понадобятся, какие фрагменты, записи, строки в таблице нам понадобятся. То есть какие объекты будут нас интересовать. Что нужно будет включить в дата-сет (выборку), а что нужно будет исключить.

Далее на этапе очистки данных производится очень своеобразное действие. Итак, очистка данных. Мы уже упоминали удаление дубликатов. Отдельная проблема — это пропущенные значения, то есть данные, которые должны быть, но они отсутствуют. Есть технологии, которые позволяют работать даже с пропусками, но большинство методов обработки данных все-таки требует присутствия данных. Либо незаполненные ячейки

или значения могут заполняться средним значением, либо прогнозом, либо как-нибудь ещё. В крайнем случае, данные, содержащие пропуски, просто удаляют. То есть эти записи будут отсутствовать и не будут использоваться в дальнейшем анализе.

Еще одна проблема — это выбросы или аномалии. Они сильно отличаются от основной массы значений, могут искажать обобщённые результаты. Большинство статистических методов чувствительны к наличию так называемых выбросов. Это могут грубые ошибки, а могут быть объекты совсем другого типа. И для них будут работать другие модели, другие закономерности. Так что либо мы эти выбросы «выкидываем», «выбрасываем», «отбрасываем, либо обрабатываем, анализируем отдельно.

Ну и особая задача, особая проблема — это данные, которые выражаются словами. Для того, чтобы использовать их в формулах, придется каким-то образом такие данные представить в виде чисел. Это особая технология кодирования. Коды типа бегущей единицы или One-Hot Encoding (OHE) очень часто используются для этого шага. Подробно такие вещи изучаются, например, в курсе эконометрики. И это достаточно давно было проработано.

Далее отдельным шагом идет конструирование данных. В создании новых признаков в настоящее время такие действия называются Feature Engineering — конструирование новых признаков на основе имеющихся. Это могут быть вычисления или объединения нескольких полей в одно, или преобразования в какой-то другой новый формат. Все что угодно, что мы делаем с данными, когда создаем новые признаки [Duboue 2020 Feature Engineering].

Затем данные объединяют, занимаются слиянием — Merge — или объединением — Integrate. Объединение может затрагивать разнородные таблицы, которые каким-то образом соединяют. Ну, простейший пример — это JOIN — связывание таблиц по ключевому полю в рамках одной базы данных. Кроме этого, на этом шаге может проводиться агрегирование данных. Самое простое агрегирование — это сумма, либо среднее значение, ли-

бо минимум, либо максимум. И такое агрегирование может выполняться после группировки (деления данных на группы или на категории).

Наконец, приведение данных к нужному формату — это тоже необходимое действие. То, что было загружено из разных источников, может представлять собой те форматы, которые нам не подходят для нашей задачи. Можно менять типы переменных: где-то нужно целое, где-то нужно число с плавающей точкой, с дробной частью, где-то требуются строковые значения. Всё это нужно будет приводить к тому формату, который действительно можно будет обрабатывать.

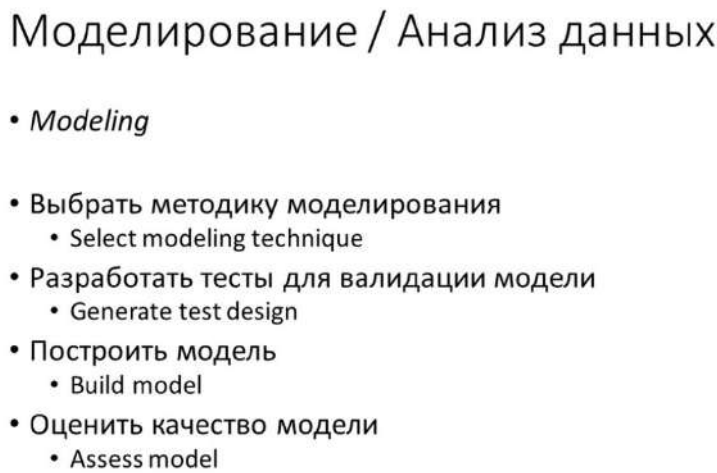



Рис. Проведём кастинг моделей

Следующий этап работы с данными назван словом «моделирование». В данном случае имеется ввиду «построение модели», возможно даже «машинной модели». Фактически, на этом этапе и производится собственно анализ данных, потому что до этого их только собирали и готовили.

Здесь первым шагом выбирают ту методику, которая дальше будет использоваться. То ли это будет регрессия по методу наименьших квадратов, то ли это будет решающее дерево, то ли это будет случайный лес, то ли что-нибудь ещё.

Далее нужно продумать так называемые тесты или способы валидации построенной модели. По существу, это оценка качества. Технологии валидации не обязательно совпадают с теми критериями, по которым наша машинная модель обучалась. Эти инструменты могут использоваться в процессе обучения машинной модели, когда выборку делят на обучающую и контрольную: Train-Test-Split. Иногда выборку делят даже на три части, когда выделяют отдельно контрольную выборку и отдельно валидационную (для окончательной проверки и приёмки).

На следующем шаге модель строят в соответствии с выбранной методикой, то есть подбирают её параметры и так называемые гиперпараметры. На сегодняшний день есть много любопытных инструментов, которые в целом называются AutoML. То есть это автоматическая настройка моделей машинного обучения.

Наконец, полученную модель нужно оценить — то есть оценить её качество и подтвердить, насколько успешно она себя зарекомендует.

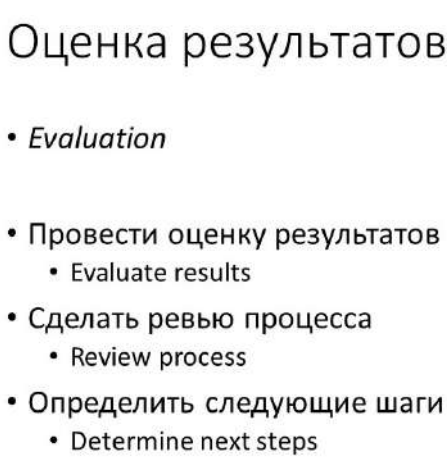



Рис. Приглашаем на помощь оценщика

Следующий этап — это оценка результатов проекта по анализу данных. Или по-английски Evaluation. На этом этапе возвращаются к тем самым бизнес-целям, которые были заявлены вначале. Когда оценивают результаты анализа данных, рассматривают, насколько эти результаты помогают достичь целей, стоящих перед предприятием, то есть бизнес-целей.

Далее идет пересмотр или «ревью» — Review. И речь идет о том, чтобы провести анализ проделанной работы и самого процесса анализа данных. Сюда входит анализ ошибок, недостатков, упущений и формулирование новых, дополнительных шагов. Речь идет о том, что нужно сформулировать шаги, которые нужно предпринять на следующей итерации в рамках этого длительного процесса.

Естественно, все полученные выводы, заключения, оценки должны фиксироваться в виде документов. Здесь мы снова возвращаемся к понятию документирования.

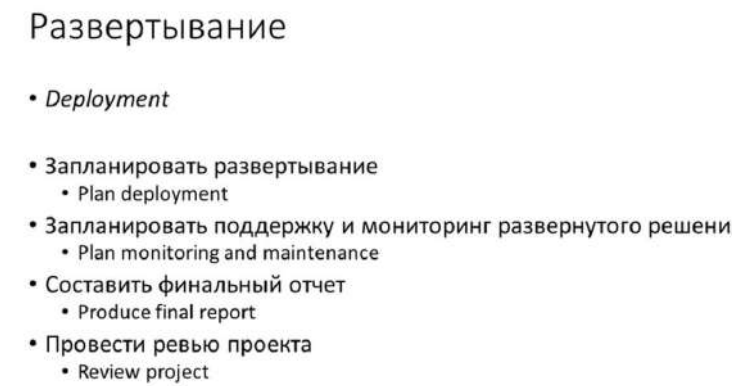



Рис. Эх, сейчас как развернёмся...

Наконец, заключительный этап такой модели называется Deployment — развертывание. В принципе, такой термин в настоящее время очень популярен среди разработчиков программного обеспечения. Когда они разрабатывают программу, окончательное внедрение в эксплуатацию, так и называется: развертывание. Так вот, этот же термин здесь применяется к результатам анализа данных.

Эти результаты могут быть использованы либо в виде отчёта, либо на самом деле это может быть внедрение тех самых машинных моделей. Чаще всего здесь участвует сам клиент, заказчик, предприятие и команда, занимающаяся анализом данных. Либо все передается клиенту.

План развертывания или Deployment Plan — это подробный план того, как будет внедряться построенная модель. Как она будет внедряться в производственный процесс или в бизнес-процесс. Естественно, как в любом планировании, здесь есть шаги, сроки и ответственные лица.

Далее составляется план того, как будет проводиться наблюдение за работой аналитического решения. Называется это поддержкой и мониторингом развертываемого решения. Под-

держка — Maintenance — другими словами, сопровождение в процессе эксплуатации.

Естественно, для наблюдения за работой нужно определиться с критериями, показателями или, как их ещё называют, метриками. Метрики позволяют оценить эффективность построенного и внедренного решения.

Далее следует оформление отчетности и пересмотр — Review.

Все эти шаги, все эти этапы в рамках модели гибкой разработки Agile или Scrum выполняются через итерации. Много раз повторяется этот цикл внутри одного проекта, и на каждой итерации постепенно достигаются новые результаты. Естественно, разные предприятия могут использовать свои модифицированные методики, но в целом вот эта вот идея жизненного цикла, она передает основные шаги, основные этапы, основные действия, связанные с анализом данных.

**EXTRACT-TRANSFORM-LOAD (ETL)**




Рис. Извлекаем из базы и загружаем в хранилище

Собственно, получение и подготовка данных в последнее время стали называться ETL, что расшифровывается как Extract, Transform и Load, см. рис. Имеется в виду извлечение, преобразование и загрузка данных, предназначенных для анализа. И этот этап присутствует и в системах Business Intelligence, и в системах, связанных с аналитикой больших данных. Во многом эти технологии пересекаются. Что имеется в виду?

Когда говорят «извлечение», имеется в виду получение данных из внешних источников. Внешних по отношению к аналитической системе. Для этого могут использоваться встроенные инструменты, либо какие-то внешние дополнительные средства. Откуда же берутся данные? Ну, например, из так называемых «учетных систем». Есть такое красивое название OLTP, которое расшифровывается как Online Transaction Processing, то есть обработка транзакций в реальном времени, или «система транзакционной обработки», или «транзакционная система». Проще го-

воря, это система типа бухгалтерского учета, где фиксируется каждая операция. Так вот, из таких систем можно данные выгружать, либо экспортировать и затем загружать для анализа.

Другой источник данных это, собственно, веб-сайты или какие-нибудь социальные сети. Чтобы выгрузить данные из таких систем используются особые технологии, которые часто называются такими словами как парсинг, скрайпинг, краулинг и прочее. Речь идет о том, чтобы скачивать веб-странички, а потом из них извлекать нужные свойства, нужные поля, нужные атрибуты.

Далее, есть вариант обращения по API, программному интерфейсу, к системам, у которых есть такой интерфейс.

Есть вариант использования облачных хранилищ или сбора отдельных файлов — то, что называется неструктурированные или слабо структурированные данные.

Есть самые разные источники, и первый этап извлечения — это «добыча» данных — Extract.

Второй этап — преобразование — Transform. Можно считать, что здесь происходит «трансформация», то есть преобразование в нужный формат. Здесь могут присутствовать операции очистки данных и обогащения данных. Некоторые из этих моментов мы уже затрагивали на предыдущих слайдах.

Что касается обогащения, речь идет о том, чтобы добавить информацию и сделать данные более полезными. В частности, можно добывать данные из объявлений о продаже недвижимости. Тогда основным источником будет сайт с объявлениями — такие системы, как Яндекс. Недвижимость, к примеру. Но если мы захотим какие-то дополнительные сведения получить, которых может и не быть на страничке объявления, тогда придется использовать дополнительные источники. Например, нас будет интересовать дата последнего капитального ремонта или год капитального ремонта, который только планируется. В объявлении этих сведений может и не быть. Тогда что? Тогда придется обратиться к внешней, к другой системе, связанной с управлением коммунальным хозяйством. И где-то там можно будет раздобыть именно эти конкретные значения — в каком году ожидается кап-

ремонт для конкретного объекта. Вот таким образом происходит обогащение.

Ну или, к примеру, цены указаны в рублях, а кого-то интересует перевод на ходу, перевод в другую какую-нибудь денежную единицу. Причем на конкретную дату. И вот это вот все берется из других систем и будет называться обогащением.

Ну и, наконец, третий этап — загрузка данных — Load. Имеется в виду загрузка собранных сведений в какую-нибудь базу данных, или в хранилище, или в собственную аналитическую систему. Если это хранилище данных, у него есть свое красивое название: Data Warehouse. И это особый вид баз данных, куда складывают информацию именно для целей анализа, а не для учёта. Появилось это понятие достаточно давно — как только стало понятно, что не стоит загружать сервер учетной базы данных дополнительными аналитическими заданиями. Тогда и решили разделить эти задачи. Текущий учет — это одна задача, а вот аналитика — это совсем другая. Перерабатывать терабайты информации — это большая нагрузка на сервер. Лучше поручить это какому-нибудь другому устройству.

Так и появилась эта технология хранилищ данных. Здесь могут храниться либо сами исходные данные, которые были экспортированы из учетной системы, либо они могут предварительно агрегироваться. Так вот, хранение агрегированных данных в настоящее время называется OLAP — Online Analytical Processing. И это достаточно своеобразное название, потому что на самом деле обработка данных происходит заранее, в пакетном режиме, в течение нескольких часов, а то и дней. Но агрегированные данные… к ним доступ действительно происходит в реальном времени. Поэтому здесь и говорится: «онлайн».

Ну и наконец, данные, которые хранятся в этом самом хранилище могут предоставляться пользователям не напрямую, а через дополнительную систему, которая будет называться «витрина данных» — Data Mart. В этом случае в витрину выставляется только тот фрагмент информации, который предназначен

для конкретного пользователя. Для разных подразделений компании могут формироваться разные витрины.

Все эти действия E-T-L стараются автоматизировать. И на сегодняшний день вся эта технология называется словом «конвейер». Или по-английски: Pipeline. Иногда даже пишут русскими буквами «пайплайн». Примеры вот этих технологий мы будем разбирать на лабораторных работах.

Здесь появляется еще одна особенность, еще одна проблема. Преобразование данных после извлечения может занимать достаточно много времени. И второе, могут происходить потери информации или искажения за счет преобразования и очистки. Поэтому в некоторых случаях эта цепочка действий строится по-другому. И конвейер выглядит как ELT: сначала E, потом L, а потом уже T. Эта технология в настоящее время реализована в некоторых ведущих системах, в том числе в облачных. И здесь происходит загрузка сырых данных в облачные хранилища. И только потом производится необходимое преобразование. Эти преобразования можно использовать по-разному. Можно обратиться снова к источнику сырых данных, ну и так далее. Собственно, такие вещи у нас реализованы. Это все перекликается с предыдущей схемой CRISP-DM. Ну, здесь есть свои особенности.

**КОМАНДА ДЛЯ РАБОТЫ С ДАННЫМИ**




Рис. Команда молодости нашей...

Теперь рассмотрим роли и компетенции команды специалистов для организации работы с данными, для организации аналитики. Здесь выделяют чаще всего как минимум три направления, но периодически добавляются — в зависимости от решаемой задачи — еще некоторые роли.

Итак, первые три пункта. Data Scientist — специалист по данным или, как еще говорят, исследователь данных. Дальше. Data Engineer — инженер по работе с данными или инженер по подготовке данных. И, наконец, Data Analyst — аналитик данных. Здесь роли распределяются очень просто. Инженер готовит данные, аналитик проводит анализ, а вот специалист или исследователь разрабатывает методы и методики, а также машинные модели, которые потом в готовом виде применяет аналитик.

Иногда выделяют отдельную специальность Business Analyst — бизнес-аналитик. Это уже специалист, который больше понимает специфику работы предприятия.

В аналитическом проекте может также принимать участие Machine Learning Engineer (ML Engineer) — инженер по моделям машинного обучения. Если в проекте по аналитике используется много этих технологий, то можно выделить и такую роль.

Рассмотрим каждую из этих ролей поподробнее.




Рис. Data Scientist — это не учёный, а специалист по Data Science

Итак, первая профессия с непереводимым названием — Data Scientist — «дата саентист» — специалист или исследователь, см. рис. Что он должен знать? Он должен понимать всю теорию, технологии, методики, методологии, все, что касается работы с данными. А это включает в себя и статистику, и машинное обучение. Такие знания условно называют Data Science — «наука о данных».

Плюс к этому он сразу же обкатывает все разработки на примере программ, и для этого как минимум нужно знать Python. Плюс для обращения к базам данных нужно владеть SQL. Соответственно, он будет писать программы, разрабатывать алгоритмы, и он должен понимать еще и теорию алгоритмов и оценивать вычислительную сложность предложенных ал-

горитмов. Естественно, все это ради того, чтобы анализировать данные, интерпретировать полученные выводы.




Рис. Data Engineer — это совсем не инженер, а программист

Следующая профессия — тоже с непереводимым названием — Data Engineer — инженер по работе с данными, или инженер по подготовке данных, или просто «дата-инженер» — это специалист, который полностью погружается в специфику конкретной платформы. Он подробно знакомится с тем, как подключаться к разным источникам данных и занимается технологией ETL, которую мы только что обсуждали. Кроме этого, он готовит все разработанные алгоритмы, реализует их так, чтобы они выполнялись на распределенных системах, а это значит — параллельные, высокопроизводительные технологии. Как видим, его роль — это организация самого процесса сбора и хранения данных, но никак не анализ.




Рис. Data Analyst — это ещё один программист

Наконец, Data Analyst –аналитик данных — это человек, который непосредственно занимается анализом. При этом он должен представить результаты анализа в понятном, наглядном виде, а это значит, что он должен заниматься ещё и визуализацией.

Чаще всего для этого могут использоваться готовые библиотеки Python, либо готовые инструменты, связанные, к примеру, с BI-аналитикой. Так же, как и остальные, он должен знать особенности работы с базами данных. И в конечном счете его продукт — это аналитика, которая необходима для поддержки принятия решений. То, что называется Data-Driven Decision Making.




Рис. Business Analyst не занимается бизнесом; он больше интересуется бизнес-процессами

В сложных, объемных проектах в такой работе и в команде по аналитике данных может принимать участие бизнес-аналитик — Business Analyst. Иногда эту профессию называют «системный аналитик». Всё определяется традициями конкретной компании, организации. И это человек, который лучше остальных понимает особенности работы предприятия, то, что называется бизнес-процессы. Его работа — превращать бизнес-задачи в задачи для разработки программ, алгоритмов, методик, методов. Ну и, как видим, он должен связать аналитику и бизнес-цели.

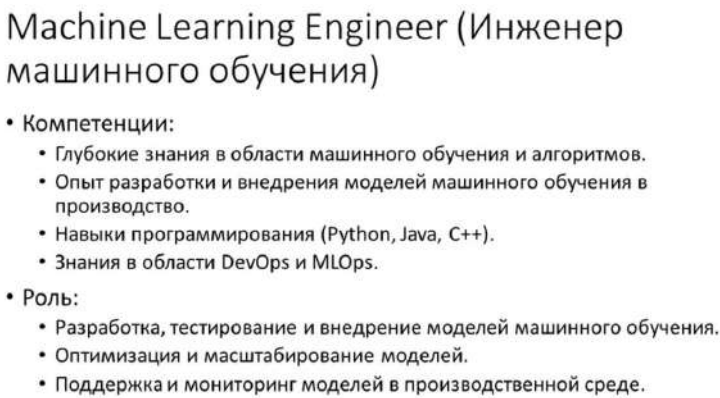



Рис. Machine Learning — и снова программист!

Если в проекте по анализу данных строят сложные модели машинного обучения, могут выделять отдельных людей или целую группу, которая занимается именно этим аспектом. ML — Machine Learning. Естественно, эти специалисты должны глубже остальных понимать все особенности машинного обучения, алгоритмов обучения, должны, как и остальные, знать языки программирования. И плюс к этому здесь отмечены DevOps и MLOps. Речь идет об управлении версиями программного продукта Development Operations, а также об управлении версиями машинных моделей и вообще о построении так называемого «пайплайна» обучения моделей. Как видим, здесь обсуждаются именно модели — со всех сторон, включая не только разработку модели, но ещё и поддержку и мониторинг. И эти слова у нас уже встречались в модели CHRISP-DM.

**ВИДЕОРОЛИКИ К ЛЕКЦИИ 1**

Данная глава написана по мотивам лекции 1 про большие данные — очень большие и не очень, см. [Rutube: ETL].

[Rutube: ETL] Большие данные. Лекция. Сбор и предобработка данных https://rutube.ru/video/b7f81608a1749cf24a9d9dc8f90e59e2/?r=plwd

[Rutube: AI-Assistants] Большие данные. Лабораторная работа. Интеллектуальные помощники https://rutube.ru/video/09ee5886d924b15cecf60549d854b8f3/?r=plwd

**ССЫЛКИ К ЛЕКЦИИ 1**

[Google Trends] https://trends.google.com/trends/

[Gartner Hype Cycle] Gartner Hype Cycle for Emerging Technologies. Цикл зрелости технологий Gartner. TAdviser, 2024. https://www.tadviser.ru/index.php/Статья:Gartner_Hype_Cycle_for_Emerging_Technologies_%28Цикл_зрелости_технологий_Gartner%29

[Hurwitz 2013 Amazon] Hurwitz 2013 Big Data For Dummies https://www.amazon.com/Big-Data-Dummies-Judith-Hurwitz/dp/1118504224

[Hurwitz 2013 Litres] Hurwitz 2013 Big Data For Dummies https://litres.com/book/raznoe-3366526/big-data-for-dummies-28316409/

[Лесковец 2016 ЛАНЬ] Лесковец 2016 Анализ больших наборов данных https://e.lanbook.com/book/93571

[Лесковец 2016 ДМК] Лесковец 2016 Анализ больших наборов данных https://dmkpress.com/catalog/computer/data/978-5-97060-190-7/

[Leskovec 2020 Mining] Leskovec, Rajaraman, Ullman 2020 Mining of Massive Datasets http://www.mmds.org/

[Perplexity.ai] Perplexity. Conversational search engine https://perplexity.ai/

[Вики: Markdown] Википедия: Markdown https://ru.wikipedia.org/wiki/Markdown

[EtymOnline: Mathematic] Этимология (происхождение) слова «Математика» https://www.etymonline.com/search?q=mathematic

[EtymOnline: Economy] Этимология (происхождение) слова «Экономика» https://www.etymonline.com/search?q=economy

[Вики: Бизнес] Определение слова «бизнес» https://ru.wiktionary.org/wiki/бизнес

[Беллман Размерность] Беллман, Р. Динамическое программирование. — Москва: Наука, 1960. — 400 с. https://ru.wikipedia.org/wiki/Проклятие_размерности

[Вики: Scikit-learn] Библиотека Scikit-learn https://en.wikipedia.org/wiki/Scikit-learn

[scikit-learn] scikit-learn. Machine Learning in Python https://scikit-learn.org/

[Вики: CRISP-DM] CRISP-DM. Cross-Industry Standard Process for Data Mining https://ru.wikipedia.org/wiki/CRISP-DM

[Duboue 2020 Feature Engineering] Duboue 2020 The Art of Feature Engineering. Essentials for Machine Learning https://www.cambridge.org/ru/universitypress/subjects/computer-science/pattern-recognition-and-machine-learning/art-feature-engineering-essentials-machine-learning http://artoffeatureengineering.com

# ГЛАВА 2. МЕТОДЫ И ИНСТРУМЕНТЫ ВИЗУАЛИЗАЦИИ

> «Какой смысл в книге, если там нет картинок?» Льюис Кэрролл «Алиса в стране чудес»

## ВВЕДЕНИЕ В ВИЗУАЛИЗАЦИЮ

В этой главе мы поговорим про визуализацию. Это может быть начальным знакомством с данными, это может быть инструментом анализа данных, и это может быть инструментом представления результатов анализа данных. Во многом визуализация больших данных и бизнес-аналитика, или как говорят BI-аналитика — во многом эти области пересекаются и очень часто ссылаются в разных источниках на очень похожие или на одни и те же инструменты.

Для чего же используется визуализация? Ну, прежде всего, гораздо приятнее воспринимать образы, чем большие таблицы с числами, особенно если они больше, чем один экран. А нынешние объемы данных это даже не терабайты и даже не петабайты. На сегодняшний день речь идет об экзабайтах информации. Так вот, вместо таких больших объемов данных мы получаем доступное, понятное, легко воспринимаемое графическое представление. Гораздо проще такую информацию воспринимать в графическом виде, см. рис.




Рис. Зачем нужны картинки, если есть цифры?

Второй момент — это возможность изучения скрытых закономерностей. То, что скрывается за цифрами. При визуализации мы сразу можем некоторые вещи увидеть, рассмотреть. В том числе тенденции изменения во времени, какие-то характерные, как говорят, «паттерны», шаблоны поведения данных. И плюс к этому на фоне закономерностей мы можем увидеть, выявить некоторые аномалии. Их ещё называют «выбросы». Это существенное отклонение от какой-то средней закономерности.

Естественно, визуализация помогает в принятии решений. Это, во-первых, интерпретация данных. Соответственно, это возможность сделать более обоснованные выводы и на их основе принимать решения, как говорят, основанные на фактах или, в последнее время говорят, основанные на данных. Data-driven decision-making.

Наконец, визуализация помогает просто передавать идею с помощью образов. Это может быть комбинация текста и графики, то есть «инфографика». Это может быть целая история, рассказанная с помощью данных и с помощью графиков — «сторителлинг». Это может быть анимация на основе данных. Это может быть анимация на основе данных и просто взаимодей-

ствие пользователя с графикой. Тогда это интерактивность. Интерактивные элементы.




Рис. Картинки бывают разные

Очень условно все методы визуализации можно разделить на несколько групп, см. рис. В частности, статические методы визуализации — это картинки, которые по определению не меняются. Интерактивность — это взаимодействие пользователя с элементами визуализации. Возможность настраивать, менять масштаб, переходить от одного графика к другому и так далее. Отдельно можно выделить привязку к данных к географическим картам — это геопространственная визуализация. Наконец, то, что связано с сетями и графами, — это тоже целый набор отдельных инструментов. Конечно, можно перечислить и другие инструменты, но вот эти четыре направления точно можно выделить.




Рис. Картинки неподвижные — это статика

**СТАТИЧЕСКАЯ ГРАФИКА**

Для начала посмотрим на самые простые, стандартные, привычные методы — статические, см. рис. Статические методы визуализации –это общепринятые диаграммы и графики, которые раньше вообще рисовали вручную. Затем те же инструменты были реализованы и с помощью компьютерных технологий. Кстати говоря, многие компьютерные технологии основаны именно на опыте предыдущей работы, когда что-то делалось вручную. Это более привычно, это интуитивно понятно, и это то, что легко воспринимается. Как известно, человек легче воспринимает что-то знакомое. Гораздо приятнее делать то, что знакомо и привычно.

Итак, простейшие графики — это, прежде всего, графики в виде линий, в виде точек, в виде столбиков, в виде кружочков. Соответственно, мы получаем «линейные» графики, когда у нас отдельные точки соединяются линиями. Это могут быть прямые отрезки или сглаженные, красивые. Дальше всевозможные столбики — это столбиковые диаграммы, которые уже дают возможность что-то сравнивать. Круговые диаграммы чаще всего связа-

ны с тем, что мы изучаем соотношение частей. В это статистике называется структура явления — соотношение частей, соотношение долей. Пропорции.

Особая разновидность столбиковой диаграммы — это гистограммы, которые нужны для того, чтобы продемонстрировать форму распределения.

Одним из популярных инструментов, особенно при работе с языком Python, является библиотека matplotlib. mat означает математические, plot означает графики, ну а lib — это library, то есть библиотека [Matplotlib]. Самые разные графики можем наблюдать в этом пакете, см. рис.

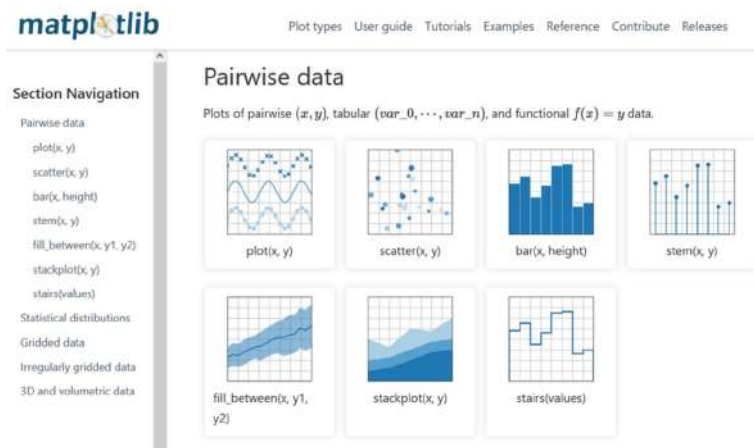



Рис. Простые плоские графики Matplotlib

Вот, в частности, линейчатый график — plot.

Точечный график, или как говорят, диаграмма разброса, диаграмма рассеяния или просто корреляционное поле — scatter.

Дальше идет столбиковая диаграмма — бары — bar.

Диаграмма в виде ступенек, когда мы демонстрируем ступенчатые изменения, дискретные шаги по времени — stairs.

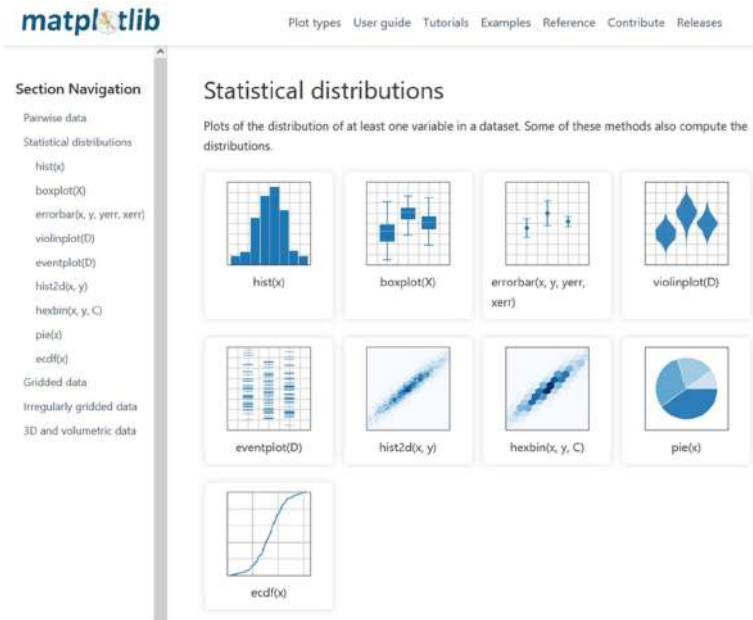



Рис. Изображение распределений

В том, что касается изучения распределений, у нас есть всего два представления: плотность вероятности и (интегральная) функция распределения. Их можно изобразить для одной и для двух переменных — так и получаются все статистические графики, см. рис.

Здесь есть гистограмма — histogram — hist (x), которая соответствует понятию плотность вероятности.

Соответственно, есть график накопленных частот — кумулята, или (интегральная / «кумулятивная») функция распределения — empirical cumulative distribution function — ecdf (x).

Также у нас имеется двумерная гистограмма, позволяющая рассматривать распределение в двух измерениях — 2D histogram plot — hist2d (x, y).

Здесь у нас имеется круговая диаграмма — pie chart — pie (x).

Есть также box plot — boxplot (x) — box and whisker plot, она же диаграмма размаха, которая показывает, в каких пределах меняется значение каждой переменной. Иногда не шибко грамотные программисты переводят это название как «ящик с усами», «ящичный график», а то и «диаграмма Бокса и Вискерса». Не обращайте внимания, им статистика просто не нужна, им и так хорошо платят. На таком графике показаны квартили и предельные значения для выявления выбросов. В данном случае английское слово box означает прямоугольную рамку, отмечающую межквартильный размах.

И аналогичная, более симпатичная диаграмма — это график под кодовым названием violin plot — violinplot (x), напоминающий скрипку — «скрипичная диаграмма». На самом деле это несколько графиков распределения, плотность вероятности распределения по каждой переменной. Здесь вероятности откладывают по горизонтальной оси, а значения случайно величины «икс» –по вертикальной. Это просто график плотности вероятности, повернутый набок — чтобы сравнить несколько распределений между собой. А для красоты этот график откладывают симметрично — и влево, и вправо от вертикальной оси.

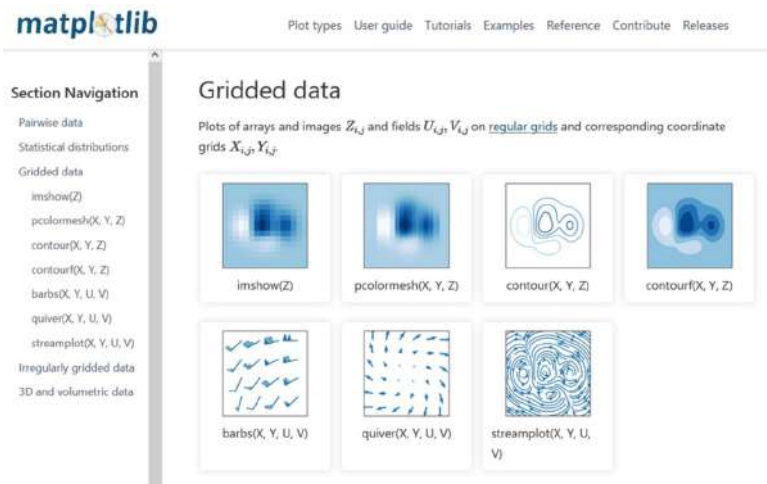



Рис. Три измерения на плоскости

Есть здесь и попытки изобразить трехмерные графики. Они тоже напоминают то, что давно известно, см. рис. В частности, напоминают географические карты, линии уровня. А также то, что в физике изображает распределение энергии и напряжённости, связанное с полями. Электрические, магнитные и прочие поля, где в каждой точке имеется направленность, стрелка. При этом длина стрелки показывает величину напряженности поля или направление, куда что-то будет перемещаться. Это графики типа quiver (X, Y, U, V) — 2D field of arrows.

Соответственно, линии уровня — это contour (X, Y, Z) — Plot contour lines.

Есть тут и трёхмерные графики типа color mesh — pcolormesh (X, Y, Z) — pseudocolor plot with a non-regular rectangular grid.

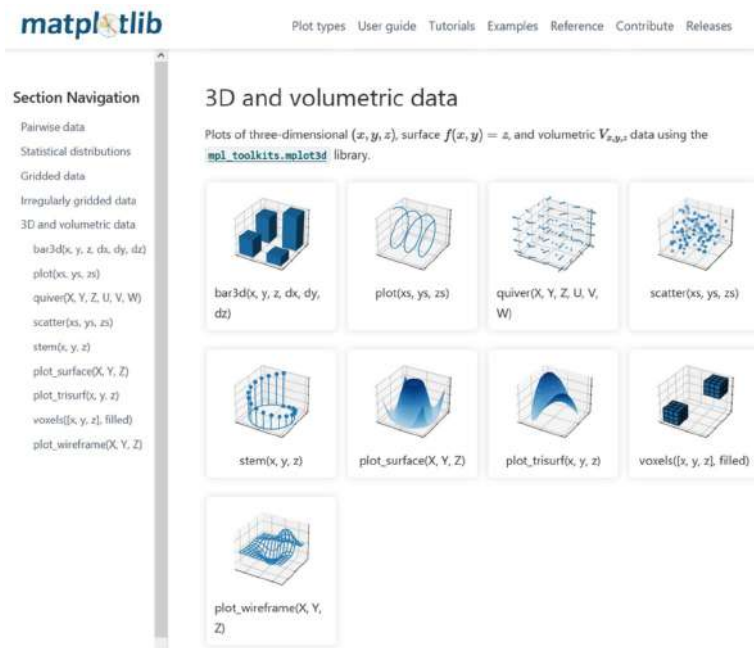



Рис. Очень трёхмерная графика

Далее мы находим целое семейство трехмерных графиков, см. рис.

Трехмерные столбики — three-dimensional barplot — bar3d (x, y, z, dx, dy, dz).

«Векторный график» — напряжённость поля в трёх измерениях — quiver (X, Y, Z, U, V, W) — 3D field of arrows.

Линии в трёхмерном пространстве — plot (xs, ys, zs) — plot 3D data.

Трёхмерная диаграмма разброса — scatter (xs, ys, zs) — scatter plot.

Есть и классические трехмерные поверхности в виде закрашенной поверхности — plot_surface (X, Y, Z) — surface plot. Цвет передаёт значение по оси Z.

В разделе Gallery можно найти ещё больше примеров всех этих видов графиков. Столбиковые, линейные, всевозможные гистограммы, диаграммы разброса, вывод изображений, тепловые карты.

Также имеется возможность нанести несколько графиков на один лист — subplot — «подграфики».

Есть еще больше дополнительных статистических функций, в том числе линейный график с указанием пределов разброса для каждого значения «икс», графики временных рядов, самые разнообразные круговые диаграммы.

Отдельно можно выделить совмещение гистограммы и диаграммы разброса.

Есть здесь и возможность анимации.

Что особенно приятно, это набор шпаргалок в разделе Matplotlib cheatsheets and handouts, см. [Matplotlib cheatsheets]. Это простые и удобные справочники в виде таблиц — больших листов. Очень рекомендуем.

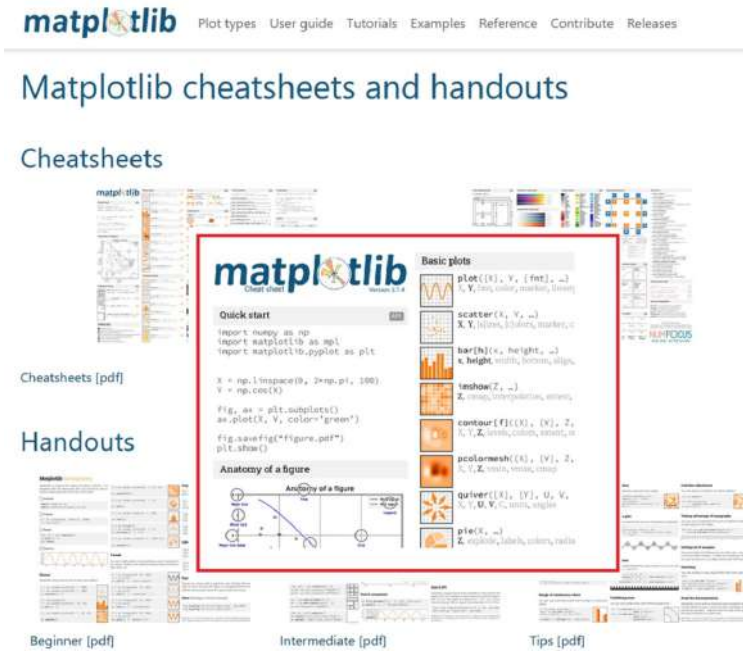



Рис. Полезные шпаргалки

**ПРОДВИНУТЫЕ ВИЗУАЛИЗАЦИИ**

В показанных примерах мы уже наблюдали некоторые продвинутые методы визуализации, см. рис.

Например, так называемые тепловые карты– Heat Map – это еще не географическая карта. Это скорее квадрат с ячейками разного цвета. Фактически, здесь используются две оси координат, а значение третьего признака передается цветом.




Рис. Продвинутые графики для продвинутых аналитиков

Корреляционная матрица показывает взаимосвязь признаков. Здесь иллюстрируется только попарная взаимозависимость. Для каждой пары признаков мы получаем коэффициент корреляции. Но если признаков несколько, тогда пар признаков может быть много. Этот график может комбинироваться с тепловой картой, когда одновременно у нас выводится и числовое значение в каждой ячейке, и выделение цветом, передача цветом этого значения, см. [Heatmaps].

**ДРЕВОВИДНАЯ ДИАГРАММА**

Есть особый вид диаграмм, который условно называется «древовидная диаграмма», хотя до дерева здесь не так просто добраться, см. [Вики: Treemapping]. К иерархии она тоже имеет очень отдаленное отношение. Здесь иерархия в очень переносном смысле — это в большей степени средство визуализации, чем внутреннее содержание. Очень часто такая древовидная диаграмма используется для визуализации состояния, ну, например, фондового рынка. Покажем пару примеров.

Рассмотрим популярный сервис визуализации экономиче-

ских данных — TradingView. Trading — трейдинг — это торговля на фондовом рынке. Это акции, облигации и прочие инструменты. Можно зарегистрироваться на этом сервисе и получить базовые услуги бесплатно, см. [TradingView]. Есть пробный ознакомительный период, и для нас этого будет достаточно. Можно даже использовать учетную запись Google и обойтись без дополнительного пароля.

На странице [Stock Heatmap] мы находим примеры таких «древовидных» диаграмм, см. рис. Здесь цвет — это попытка передать процентное изменение, например, по сравнению со вчерашним днем, по сравнению с ценой закрытия вчерашних торгов, то есть на сколько процентов сегодня изменилась цена акций. Как видим, по объемам торгов лидируют компании Apple и Nvidia. Акции Apple упали на 0,12%, Nvidia на 0,03%. Серый цвет — несущественные изменения. Завтра все может измениться. И чем меньше объем торгов, тем, соответственно, меньше по размеру будут квадратики.

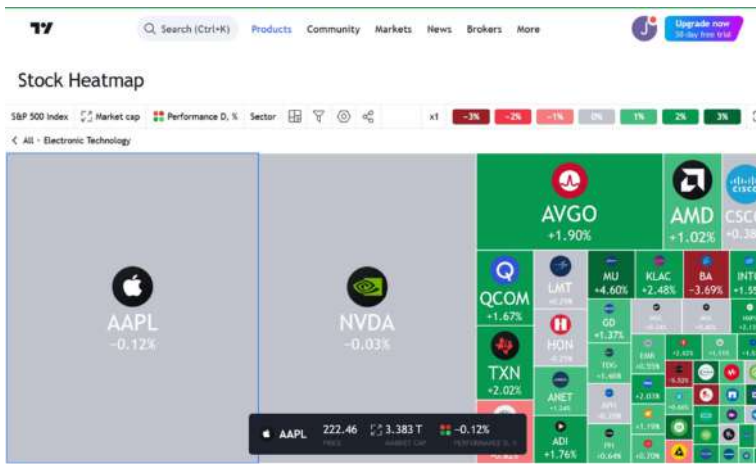



Рис. Карта рынка акций ИТ-компаний

Другие цифры могут быть по величине больше, но по объему торгов с этим активом меньше. Так что мелкие квадратики могут быть ярко-зелёными и ярко-красными. Это пример карты западных рынков.

Аналогичный график для Московской биржи, см. например [smart-lab]. Как видим, здесь точно также имеется разбивка по отраслям, финансы, нефтегазовые отрасли, IT, транспорт, см. рис.

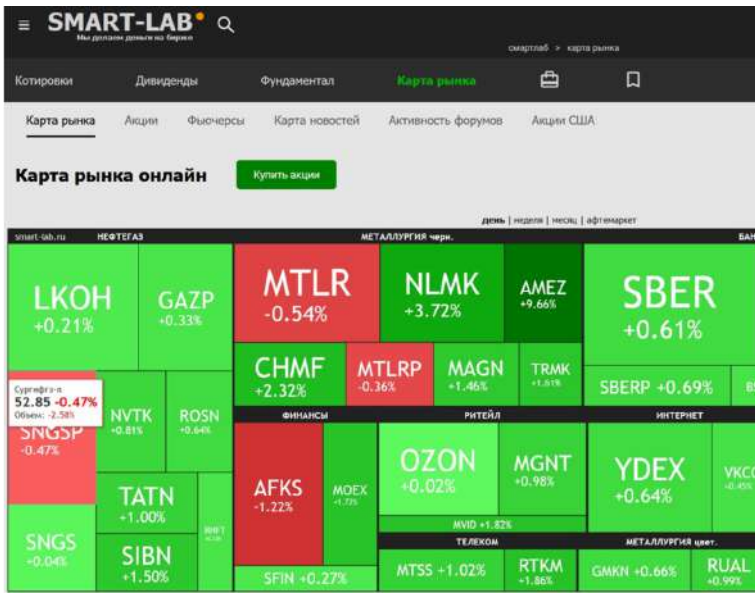



Рис. Карта российского рынка

На некоторых сайтах типа [stockchart] есть и дополнительные сервисы. Когда мы наводим курсор на квадратик выбранной компании, можем увидеть и график изменения во времени, см. рис. Это так называемые японские свечи.

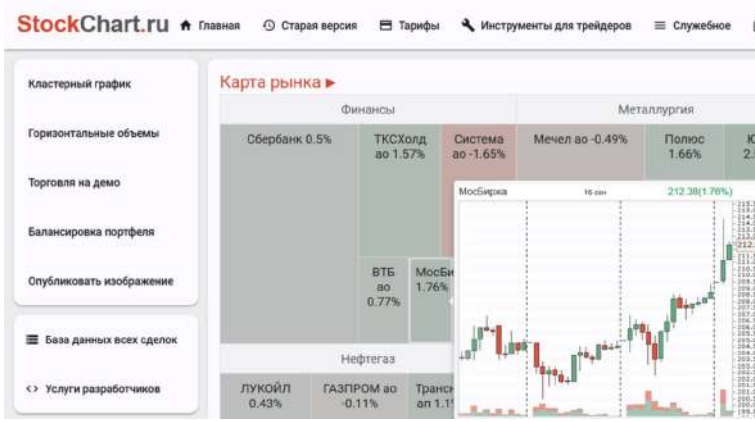



Рис. Карта рынка и свечной график

Здесь же, под основным графиком выводятся объемы торгов. Точно также — то, что торгуется больше по объему (например, в рублях) — даёт прямоугольник размером побольше. Сбер — побольше, ВТБ — поменьше. Тоже есть разбивка по отраслям: финансы, нефть и газ, металлургия и т. д.

Изменения в плюс или в минус стандартно передаются оттенком зеленого или красного цвета. Чем более насыщенный цвет, тем больше изменения.

Итак, карта рынка, или market map, — это не географическая карта. Это просто попытка изобразить на плоском два параметра: объём торгов и процентные изменения. Больше похожа на «тепловую карту», но со своей спецификой.

### ИНТЕРАКТИВНАЯ ВИЗУАЛИЗАЦИЯ

Далее переходим к «интерактиву». Интерактивная визуализация — это графики, которые могут откликаться на участие пользователя. Это могут быть просто графики, для которых можно менять масштаб и чуть подробнее их рассматривать, см. рис.

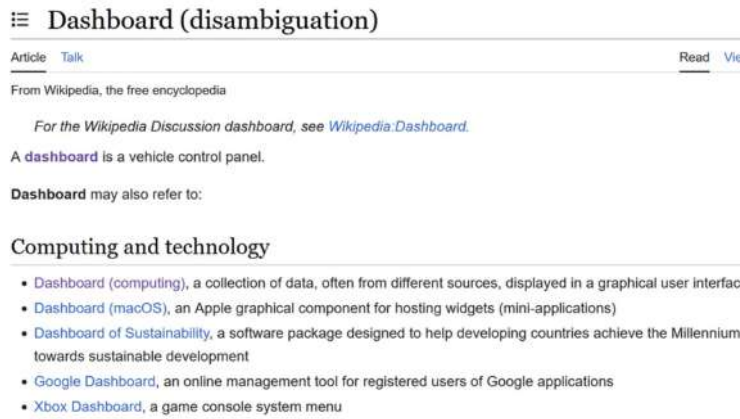



Рис. Интерактив, диалог, взаимодействие

Более продвинутые инструменты — это графики, которые передают не само значение признака, а обобщенные характеристики. Это «дашборды» или «дэшборды». Это (как часто бывает) английское слово dashboard, написанное русскими буквами. Ещё их называют «информационные панели».

Здесь чаще всего данные представлены в реальном масштабе времени. Мы можем не только менять масштаб, мы можем применять фильтрацию и сортировку этих самых данных — и сразу же видеть изменения на графике.

Сам термин «дэшборд» очень многогранный. У него очень своеобразная история. Если обратиться к Википедии, особенно к англоязычной страничке, мы можем видеть, прежде всего, дэшборд применительно к компьютерным программам, см. рис.



Dashboard (disambiguation)

Article Talk Read View

From Wikipedia, the free encyclopedia

*For the Wikipedia Discussion dashboard, see Wikipedia:Dashboard.*

A **dashboard** is a vehicle control panel.

**Dashboard** may also refer to:

Computing and technology

- Dashboard (computing), a collection of data, often from different sources, displayed in a graphical user interface
- Dashboard (macOS), an Apple graphical component for hosting widgets (mini-applications)
- Dashboard of Sustainability, a software package designed to help developing countries achieve the Millennium towards sustainable development
- Google Dashboard, an online management tool for registered users of Google applications
- Xbox Dashboard, a game console system menu

Рис. Дэшборды бывают разные

Это окно, которое содержит несколько графиков, см. [Вики: Dashboard 1]. Причем графики могут быть линейные, столбиковые, круговые диаграммы, есть тут таблицы, а также индикаторы, напоминающие автомобильные приборы.

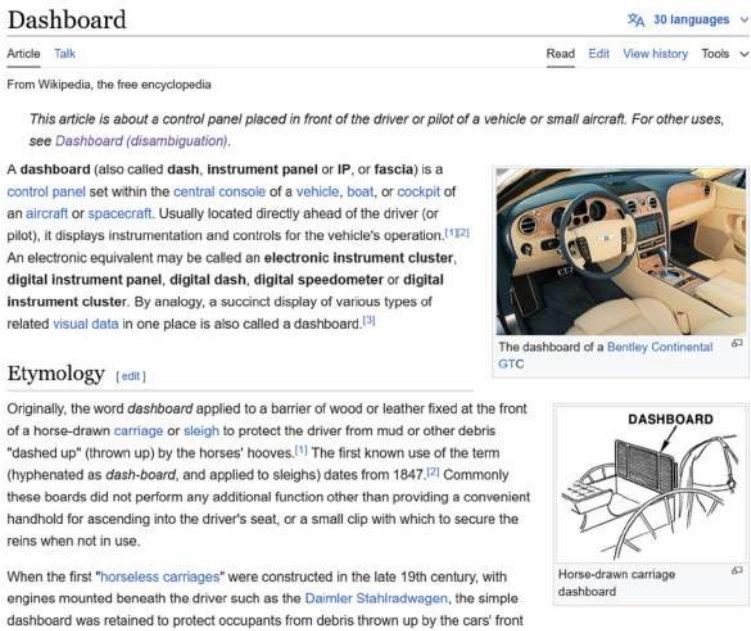
И это не просто так. Если обратиться к другой статье Википедии о дешбордах предыдущих, аппаратных [Вики: Dashboard 2], то обнаруживаем, что имеется в виду приборная панель автомобиля. И здесь показаны знакомые, традиционные приборы.

Что здесь интересно? Традиционно самые важные показания должны передаваться большим размером. Например, скорость движения автомобиля и обороты двигателя — это самое главное. Машина нужна, чтобы ехать с нужно скоростью. Для этого мотор должен крутиться и крутить колеса. Обороты двигателя не слишком быстрые и не слишком медленные — это будет «красная зона» и зелёная зона». Менее важное значение, например, количество бензина или температура двигателя, — соответственно, и прибор размером поменьше. Совсем несущественная информация может отображаться циферками, такая как пробег автомобиля. И, наконец, тут есть лампочки — это

приборы индикации, сообщающие о каких-то событиях: «Напоминаем, что у вас включён стояночный тормоз».

Так вот, вся эта идея полностью перекочевала в компьютерные программы. И компьютерный дэшборд использует все эти традиционные проверенные методы: размеры графиков, красные и зелёные зоны, цифры и экранные «лампочки» -индикаторы.

Но, как выясняется, и это ещё не все. Автомобильная приборная панель появилась как развитие идеи дэшборда, который был на повозке с лошадями, см. рис.



Dashboard

30 languages

Article Talk | Read Edit View history Tools

From Wikipedia, the free encyclopedia

*This article is about a control panel placed in front of the driver or pilot of a vehicle or small aircraft. For other uses, see Dashboard (disambiguation).*

A **dashboard** (also called **dash**, **instrument panel** or **IP**, or **fascia**) is a control panel set within the central console of a vehicle, boat, or cockpit of an aircraft or spacecraft. Usually located directly ahead of the driver (or pilot), it displays instrumentation and controls for the vehicle's operation.[1][2] An electronic equivalent may be called an **electronic instrument cluster**, **digital instrument panel**, **digital dash**, **digital speedometer** or **digital instrument cluster**. By analogy, a succinct display of various types of related visual data in one place is also called a dashboard.[3]

The dashboard of a Bentley Continental GTC

Etymology [edit]

Originally, the word *dashboard* applied to a barrier of wood or leather fixed at the front of a horse-drawn carriage or sleigh to protect the driver from mud or other debris "dashed up" (thrown up) by the horses' hooves.[1] The first known use of the term (hyphenated as *dash-board*, and applied to sleighs) dates from 1847.[2] Commonly these boards did not perform any additional function other than providing a convenient handhold for ascending into the driver's seat, or a small clip with which to secure the reins when not in use.



Horse-drawn carriage dashboard

When the first "horseless carriages" were constructed in the late 19th century, with engines mounted beneath the driver such as the Daimler Stahlradwagen, the simple dashboard was retained to protect occupants from debris thrown up by the cars' front

Рис. Дэшборд — это «борд» против «даш»

И вот этот вот дэшборд — это была защитная доска (по английски board), или щиток. Эта или доска защищала кучера —

«водителя кобылы» — от всего, что летит из-под копыт его лошадки. Если летят брызги и грязь, получаем полосы грязи. Если летят камушки, можно получить синяки и царапины. А царапина по-английски будет dash. Так что дэшборд — это доска BOARD, которая защищает от царапин DASH. Ещё слово DASH означает отбрасывать. Копыта лошади отбрасывают грязь и камни, а доска отбрасывает, отражает все эти неприятности.

В общем-то, очевидное решение, когда лошадь заменили двигателем, первое очевидное решение было взять ту же самую повозку и к ней приделать двигатель — спереди или сзади. А вот эту доску, этот щиток, этот дэшборд оставили. Он тоже отбрасывал грязь и камни, которые летели в водителя и пассажиров из-под колес. На нём разместили приборы управления и приборы измерительные. Так что индикация и управление традиционно были под руками у водителя. Это сохранилось в автомобилях, и потом эта вся идея перекочевала в компьютерные программы.

Ещё одно значение дэшборда — это стартовая страница прикладной программы или даже веб-сайта. Здесь можно выбрать нужный раздел сайта. В облачных сервисах дэшбордом могут называть личный кабинет пользователя, где он выбирает нужные услуги и следит за расходом средств, см. рис.

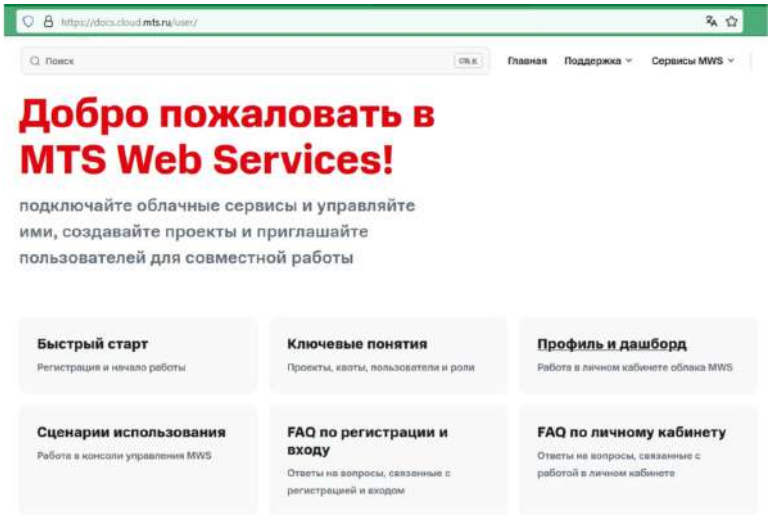



Рис. Дэшборд в управлении облаками

**ГЕОГРАФИЯ**

Как мы уже говорили, в некоторых случаях данные можно привязать к географической карте. Здесь есть свои отработанные приемы, свои стандарты, опять же разработанные для ручных технологий, но перекочевавшие и в компьютерные программы. Это соединение карты с какими-нибудь числовыми данными, см. рис.




Рис. Раскинем наши карты...

Каким образом данные накладываются на карту? В виде цвета, в виде изображений, в виде штриховки или в виде диаграмм. У всех этих технологий есть свои красивые названия. Иногда они пересекаются. Но в любом случае, если что-то выделяется цветом, это либо тепловая карта, либо фоновая картограмма. КАРТО + ГРАММА означает, что на карте что-то изображается. На картограмме разные области на карте закрашены разным цветом, и этот цвет как раз и передает значение, см. [Вики: Фоновая картограмма]. Здесь показано значение, относящееся к какому-то региону или к стране.

Картограмма, на которой различные значения выделяют цветом, может называться по-английски Choropleth map. Здесь скрываются греческие корни: «хорос» означает «место», «плетос» означает много, или значение, или количество, см. [Вики: Choropleth]. Примеры — это распределение значения ВВП и индекса человеческого развития по странам мира на географической карте. Здесь каждая страна выделена своим цветом, см. [Вики: ВВП], [Вики: ВВП Ном]. На картограмме приводится шкала — перевод цвета в числовые значения. Это номинальный

ВВП. То есть выраженный в валюте с пересчетом по официальному курсу. Обратим внимание, что здесь используется логарифмическая шкала: одинаковое расстояние от десяти до ста и от ста до тысячи. Это линейная шкала в отношении логарифма значения. Или 50 — 500 — 5000.

Кроме этого, карта может совмещаться с диаграммами. И тогда для каждого региона или для каждой страны будет построена своя маленькая диаграмма, см. [ArcGIS: Картодиаграммы]. В этом случае пытаются передать гораздо больше сведений, больше информации на одной совмещенной картинке, см. рис. Такие представления можно строить и в универсальных программных пакетах, и в специализированных.

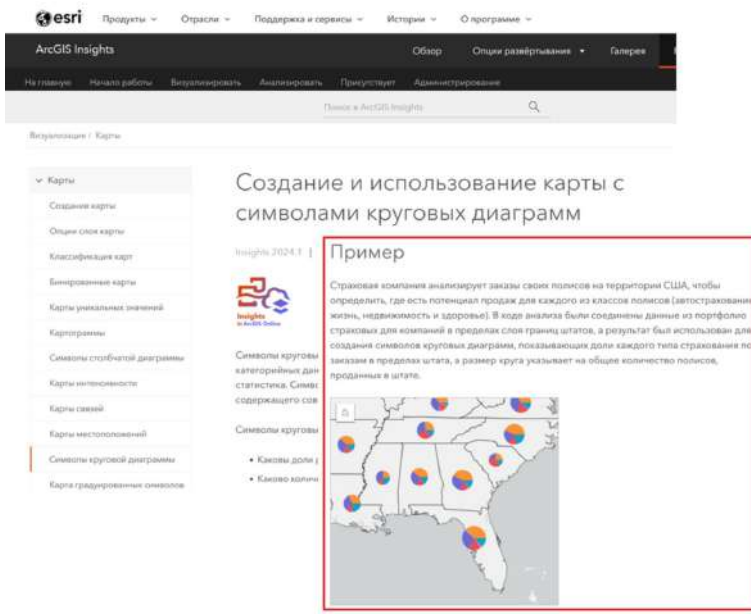



Рис. Карта плюс диаграммы

В примере на рисунке показана страничка сайта с описанием

ГИС — географической информационной системы. В ГИС всё строится вокруг карты. Все данные изначально привязаны к географическим координатам. В универсальных пакетах такую привязку приходится делать почти вручную, дополнительно подгружать карты и справочники координат и географических названий, и заниматься интеграцией (связывать все данные в единое целое). Все это может использоваться для разных целей.

### ВИЗУАЛИЗАЦИЯ СТАТИСТИКИ

Рассмотрим пример визуализации, который используется Федеральной службой государственной статистики, [Росстат]. Прошлое название: Госкомстат — Государственный комитет по статистике. Сайт Росстат расположен по адресу rosstat.gov.ru. Здесь GOV означает Government, то есть правительство, то есть государственное учреждение. На сайте имеется раздел под названием BI-система. Так что здесь есть Business Intelligence, и речь идет именно о визуализации, см. рис.

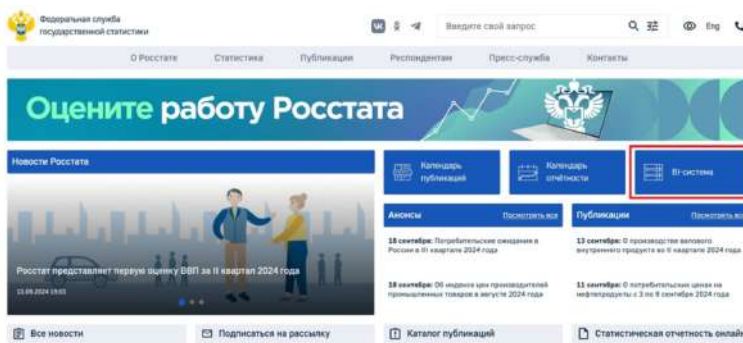



Рис. BI-система для государственной статистики

Переходим по этой ссылке и наблюдаем знакомое слово Dashboard в строке адреса, см. рис. Это выбор раздела сайта для работы. И мы выбираем нужный раздел, нажимая на очень

большие «кнопки» на экране. Этот дэшборд в смысле выбора раздела сайта.

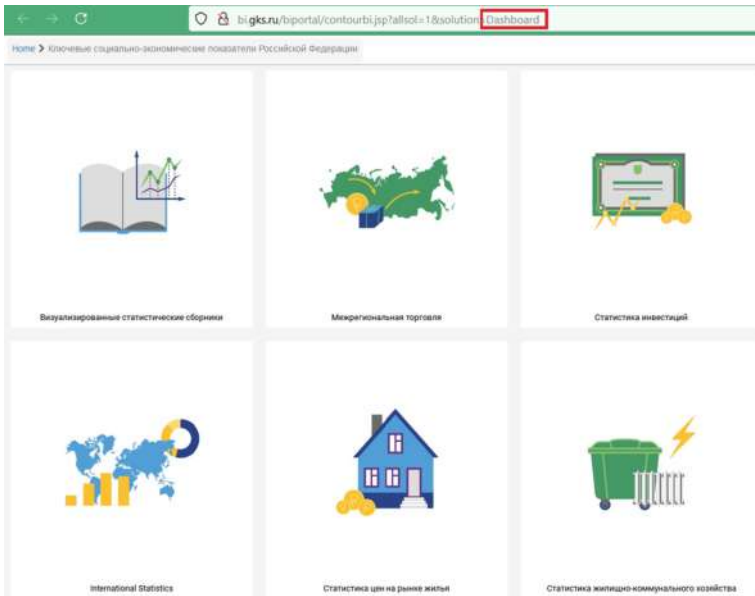



Рис. Дэшборд для BI- системы

Находим раздел, где обсуждается торговля между регионами, см. рис. И здесь у нас и по строчкам, и по столбцам имеются одни и те же названия. Соответственно, мы можем видеть ввоз и вывоз между соответствующими регионами. Для такой информации лучше подошло представление обобщённых данных в форме таблицы.

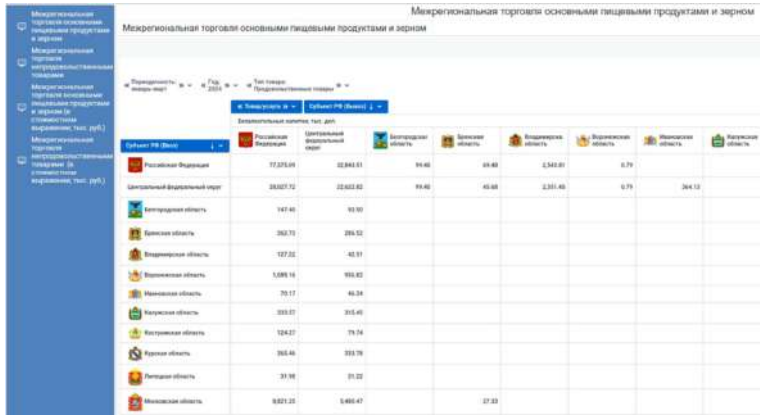



Рис. Торговля между регионами

Особый вид диаграммы — поло-возрастная пирамида, [Росстат: Пирамида]. Здесь у нас по вертикальной оси указан возраст, а влево и вправо дается численность женщин и мужчин каждой возрастной категории см. рис. В нижней части графики симметричные. После 40 лет число мужчин непропорционально снижается. Делаем выводы, задаём вопросы, выясняем причины, ищем решение.




Рис. Состав населения (2020)

**DATA LENS ОТ ЯНДЕКСА**

Ещё один пример интерактивного инструмента — это разработка Яндекса под названием Data Lens. Data — это данные, а Lens — это «объектив фотокамеры или микроскопа». Так что этот инструмент позволяет рассмотреть данные (как в микроскоп) и что-нибудь в них обнаружить. Инструмент бесплатный, см. [DataLens], [DataLens: Cloud]. Более того, разработчики выложили исходные тексты программы в открытом доступе, см. [GitHub: DataLens].

На странице [DataLens: Marketplace] можно ознакомиться с примерами дэшбордов. В частности, есть пример использования DataLens для анализа данных по COVID-19: Коронавирус — Дашборд и данные. Мы можем перейти по этой ссылке и ознакомиться с примером Dashboard по версии Яндекса, см. [DataLens: Covid].

Здесь есть привязка данных к географической карте, вывод данных в виде обобщенных показателей, числами, а также динамика в виде линейного графика, см. рис. Плюс к этому у нас имеется всплывающая подсказка, сообщающая точные значения

на выбранную дату. Здесь есть возможность фильтрации, в частности, кроме статистики по миру, мы можем посмотреть статистику по России.

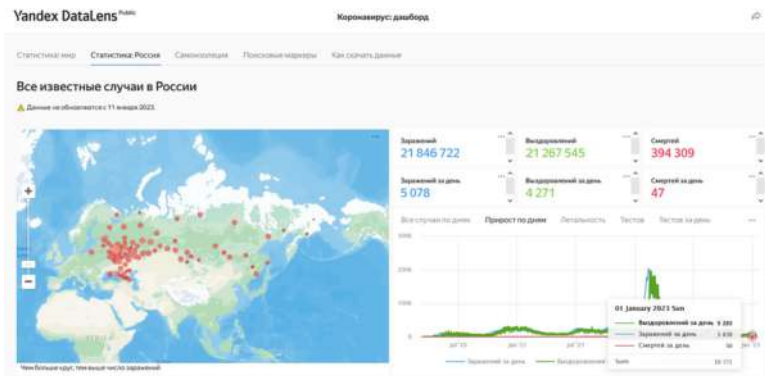



Рис. Статистика развития и распространения

При большом желании мы можем скачать и развернуть этот инструмент на своей базе либо поработать с ним в облаке Яндекса. Здесь можно работать с разными источниками данных. Есть возможность настраивать графики и проводить собственный анализ. Яндекс даже предлагает бесплатный курс по работе с DataLens, см. [DataLens: Training]. Курс очень хороший, доступный и полезный — я сам его прошёл и могу уверенно порекомендовать его всем, кто хочет познакомиться с технологиями аналитики и визуализации в облаке.

### ГРАФЫ И СЕТИ

Отдельно следует отметить визуализацию данных, которые содержат внутри себя некие сетевые структуры. Это самые разные графы и сети, в том числе социальные сети, см. рис. Можно сказать, что первоначально графы развивались как инструмент анализа, например, дорог. Мы смотрим на сеть дорог и выбира-

ем наилучший маршрут из точки А в точку Б. Или если хотим обойти/объехать несколько мест и потратить на путешествие некое разумное время. Собственно, это мы наблюдаем, например, в приложении Яндекс. Навигатор, когда в реальном времени анализируется дорожное движение, пробки и предлагается наилучший (с точки зрения программы) маршрут — пешком, на машине, на транспорте. Это применение теории графов к задаче из реальной жизни и реализация решения в виде очень удобного приложения.

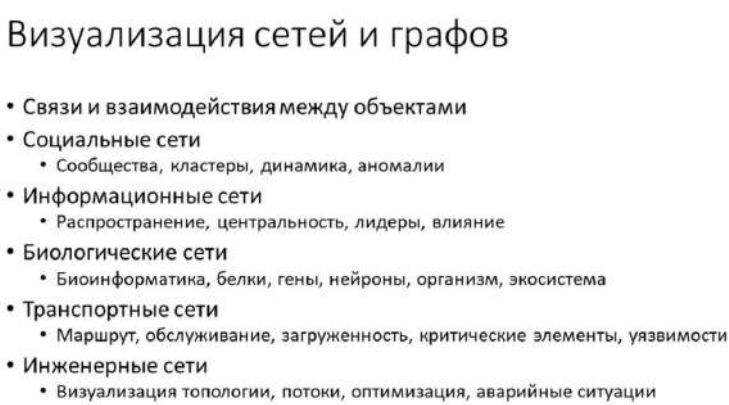



Рис. Сказ про то, как графы попадают в сети

Что касается визуализации социальных сетей, можем привести парочку любопытных примеров. На сайте Mozilla описан инструмент под названием Social Media Analysis Toolkit (SMAT), см. [Mozilla: SMAT]. Это инструмент для анализа социальных сетей, см. рис. Здесь, в частности, можно проводить анализ динамики — как меняется частота упоминания ключевого слова или фразы во времени.

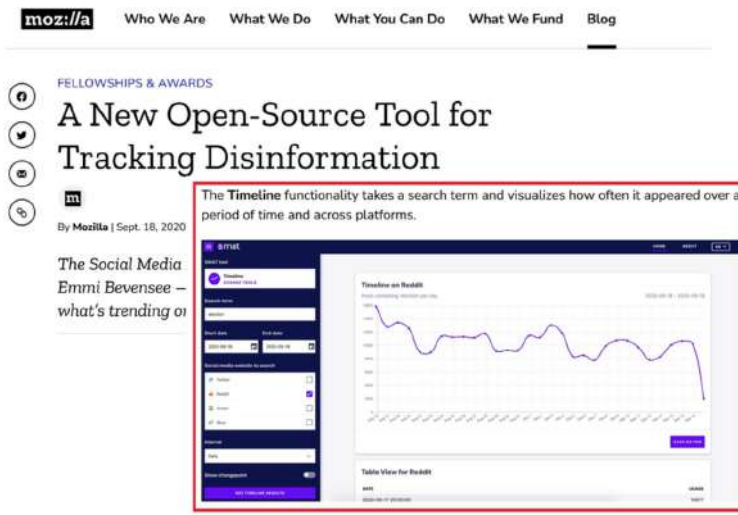



Рис. Динамика публикаций в соцсетях по теме

В качестве примера в статье [Bevensee 2020 SMAT] авторы программы обсуждают данные из социальной сети, связанные с конкретным событием — обсуждением выборов. И здесь мы видим точку, из которой исходит множество линий. Этот граф показывает взаимосвязи между пользователями социальной сети, см. рис.

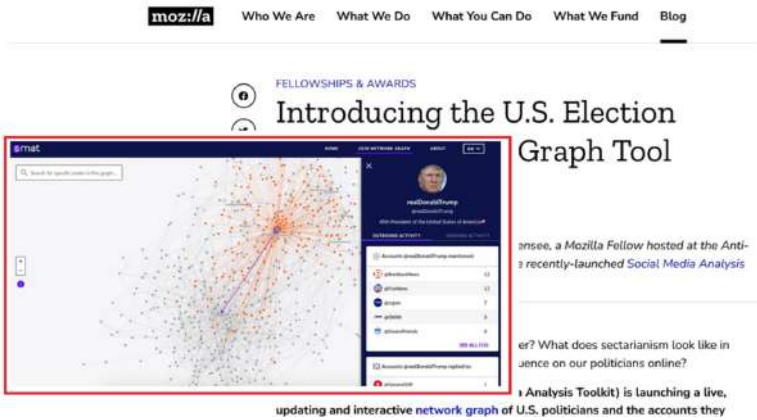



Рис. Визуализация процесса распространения сообщений

Любопытно, что авторы сравнивают распространение информации в соцсетях и распространение болезни во время эпидемии. Они даже придумали соответствующее название: «инфодемия» — то есть «информационная пандемия».

В статье можно найти пояснения, как работает анализ графов — применительно к социальной сети.

Описаны основные понятия:

— nodes — «ноды», то есть узлы или вершины;

— edges — рёбра;

— direction — направление, которое передаётся разными цветами (упоминания, ссылки, репосты и т.п.).

Указанный инструмент SMART является программой с открытым исходным кодом — Open Source Tool. На домашней странице этого инструмента [Open Measures] мы обнаруживаем новое название: Open Measures. Слово Open означает «открытые» — в смысле Open Source, а Measures — это «меры», то есть «средства измерения». Здесь по-прежнему упоминается, что это платформа с открытым исходным кодом. Далее поясняется, что платформа остаётся свободной (для распространения) и доступной для общественного использования. Имеются средства анализа,

в том числе для изучения динамики.

Что интересно, здесь имеется также инструмент для программистов — API — Application Programming Interface. То есть интерфейс прикладного программирования. Это интерфейс взаимодействия программ (без участия пользователя). Это значит, что мы из своей программы можем обратиться к этому источнику. Переходим по ссылке «API» и находим описание — какие методы используются, какие ключи и что здесь можно получить? См. рис.

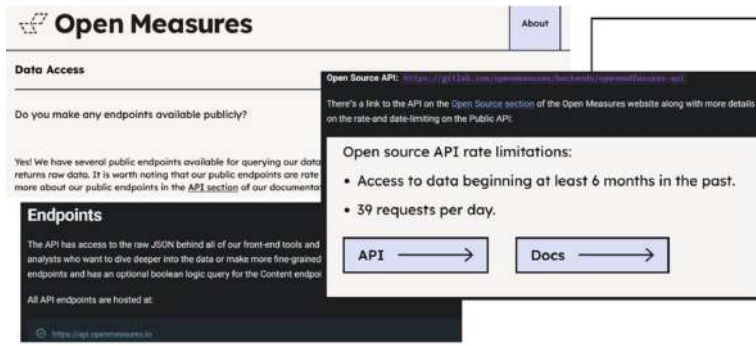



Рис. Доступ по API с небольшими ограничениями

Для бесплатного обслуживания предоставляется до 39 запросов по API с день. Работа идёт через endpoint — это, фактически, адрес веб-сайта. Детали запроса мы указывает как параметры этого URL, а результаты получаем в популярном формате JSON. Подробнее такие API мы рассматриваем в наших лабораторных работах, см. например [Видео: MOEX API] и [Видео: OpenWeatherMap API].

### АНАЛИЗ ТРЕНДОВ

Еще один инструмент визуализации — это работа с трендами. Слово «тренд» означает «долгосрочная тенденция», «общее направление азвития». Пример — сервис [Google Trends] —

тренды от компании Google. Здесь можно увидеть, насколько популярными являются поисковые запросы, какие слова в какие годы чаще использовались

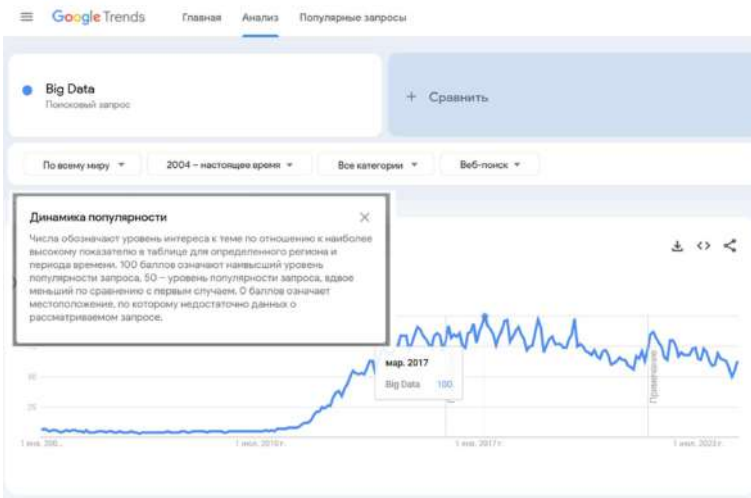



Рис. Большим данным — большая популярность

Посмотрим на популярность запроса со словами Big Data, мы можем изучать эти результаты поиска и фильтровать их, см. рис. Можно, к примеру, применить фильтр по странам или по всему миру. За день или за всю историю. По категориям поиска или по всем категориям. Ну и, как видим, здесь имеется отдельно веб-поиск или поиск в YouTube, отдельно в новостях, отдельно по товару.

По таким графикам видно, на какой стадии находится «хайп» по конкретному направлению или технологии. По большим данным массовые запросы шли лет 10 тому назад. Сейчас накал страстей спадает, страсти улеглись, и начинается серьёзная работа. В компании Гартнер этот период условно называется «плато продуктивности», см. [Gartner: Hype Cycle] и [Вики: Gartner hype cycle].

**СОЦИАЛЬНЫЕ СЕТИ**

Теперь обсудим визуализацию в отношении сетей и графов. Фактически, речь идет о разных названиях и разных областях деятельности, имеющих отношение к одному и тому же объекту. У нас есть некоторые точки, или узлы, или объекты, — и своего рода связи между ними. Что это может быть? Ну, прежде всего, это социальные сети, повторим наш предыдущий рис.




Рис. Графы и сети

Что здесь можно визуализировать или анализировать? В таких сетях есть сообщества. И это значит, что мы можем изучать людей, которые в эти сообщества вошли. Это могут быть подписки и всевозможные другие способы объединения пользователей. Дальше можно выделять кластеры — в зависимости от поведения пользователей. Либо можно исследовать динамику — как меняется во времени то, что нас интересует. Это либо поведение, либо состояние сети, появление новых связей и так далее. Ну и на фоне всего этого можно пытаться обнаружить аномалии. Все это можно делать с разными, с самыми разными целями.

Очень близко к социальным сетям понятие информационные сети. Речь идёт о распространении информации. В том числе здесь можно анализировать средства массовой информации, в том числе сетевые. И представляет интерес то, как распространяется информация. Можно проводить так называемый анализ центральности и выявлять ключевые узлы — лидеров мнений — и использовать результаты для оказания влияния на большую аудиторию.

Как выясняется, самые разные объекты, в том числе и природные, можно рассматривать как сети. В частности, на сегодняшний день развивается такой предмет, как биоинформатика, см. [Вики: Bioinformatics]. И в том числе здесь обсуждается возможность рассматривать белки и их взаимодействие тоже как своеобразную сеть или граф. То же самое касается анализа генов, ДНК, построения нейронных сетей внутри организма. И, кстати, это совсем не то, как строятся искусственные нейронные сети. Здесь только названия похожи. Собственно, весь организм и метаболизм, обмен веществ в организме, тоже можно моделировать с помощью графов. Ну и наконец, целая экосистема, цепочки питания и так далее. Все это взаимодействие каких-то объектов, все это элементы больших сложных биологических сетей.

Еще один вид сетей — это транспортные сети. Как мы говорили, самое простое в области транспорта — это построение маршрута. Можно также искать точки или зоны обслуживания для того, чтобы охватить наибольшее количество потребителей. Можно проводить анализ загруженности, искать критические элементы уязвимости и так далее.

Аналогичные задачи можно решать и в отношении самых разных инженерных сетей и компьютерных сетей. И во всех случаях речь идет о том, чтобы не только заниматься визуализацией, топологией, но и отслеживать разные события. Это могут быть потоки, проходящие через ребра между объектами. Это может быть решение задачи оптимизации и выявление различных аварийных или нежелательных, или критических ситуаций.

Но в том, что касается социальных сетей, — это особое явление, которое еще предстоит изучить и освоить. Внешне — для пользователя — всё выглядит очень просто, буднично и удобно. Достаточно зарегистрироваться в ВКонтакте, в Одноклассниках или в каком-нибудь бизнес-сообществе типа Тенчата и начинать общаться и заводить друзей, см. рис.

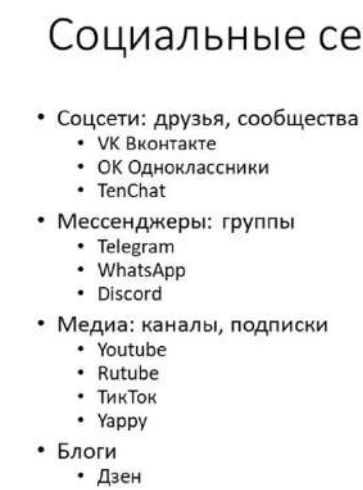



Рис. Сети бывают социальные и антисоциальные

Что здесь происходит? Происходят самые разные виды деятельности, активности, когда пользователи сами вводят огромное количество информации, см. рис. В качестве особого вида социальных сетей можно рассматривать различные мессенджеры, средства обмена сообщениями, в которых тоже появляется все больше возможностей, характерных для социальных сетей, но это, прежде всего, группы и сообщества. Таким образом, появляется возможность работать с большой аудиторией. Можно использовать самые разные мессенджеры, но общие закономерности остаются теми же.

Отдельной строкой следует упомянуть различные медиасервисы, где тоже появляется своего рода социальная сеть, но только в отношении видео- или аудио-продукции. Здесь точно так же появляется регистрация пользователей, подписки, группы, каналы и так далее.

Ну и наконец, в информационном отношении существуют различные интернет-журналы. То, что называется «блоги» и «влоги». Например, Дзен, который недавно отделился от Яндекса. Все это можно анализировать с точки зрения графов и сетей.

Соцсети представляют большой интерес с точки зрения анализа информации, поскольку здесь циркулирует огромное количество данных. Это классический пример того, что и называется большие данные. Причем здесь происходит и сбор данных, и обработка данных, и использование — в том числе в коммерческих и других целях, см. рис.




Рис. Сети — данные — прибыль

Что же здесь циркулирует? Это данные о пользователях, фактически, это персональные данные. Здесь собираются самые разные сведения, и не только о личности человека, но и о его

поведении, о его действиях, о его предпочтениях и о его взаимодействии с другими пользователями. Особенностью соцсетей является то, что весь контент порождается самими пользователями. Это то, что называется User-Generated Content (UGC). Если верить некоторым источникам, этот контент практически невозможно удалить. Он продолжает храниться на сервере компании-владельца ресурса, даже если для пользователя недоступен (он просто помечен как «удаленный»). Он не отображается на экране, но в базах данных все это остается.

При регистрации в соцсети нужно нажать несколько раз ОК (конечно же, не читая длинное соглашение) — и, по сути, пользователь соглашается на то, что социальная сеть будет использовать его персональные данные. Ну а дальше эти данные собираются, анализируются и используются — конечно же, прежде всего, с коммерческими целями. Это прекрасная возможность целенаправленно воздействовать на массовую аудиторию. Причем обходится это достаточно дешево. Фактически, данные здесь превращаются в полезный ресурс, подобный различным природным ресурсам, полезным ископаемым. Поэтому в последнее время большие данные сравнивают с нефтью и говорят, что «данные — это новая нефть». В том смысле, что их можно добывать, обрабатывать и «монетизировать» — превращать в источник дохода. Либо просто продавать напрямую, либо превращать в средства обогащения.

В связи с этим стоит упомянуть книгу автора Шошана Зубофф под названием «Надзорный капитализм», см. [Зубофф 2022 Эпоха надзорного капитализма]. Оригинальное название «Surveillance capitalism» имеет смысл «Получать прибыть за счёт скрытого наблюдения (слежки) за пользователями», см. [Вики: Zuboff Surveillance Capitalism]. Буквально Surveillance — это системы наблюдения, такие как, скажем, видеокамеры на дорогах. Речь идет о том, что ИТ-компании собирают данные и формируют цифровые ресурсы с целью извлечения прибыли. Это включает не только анализ данных, но и возможность влиять на поведение пользователей и управлять поведением потре-

бителей — в интересах корпораций, см. [Гавриленко 2023 Надзорный капитализм].

И здесь появляется, естественно, некоторое противоречие. Люди регистрируются в качестве развлечения или из профессионального интереса, но по сути превращаются в источник данных, приносящий пользу компании, а вовсе не участникам, см. [Вики: Surveillance capitalism], [Вики: Надзорный капитализм]. Более того, во многих случаях требуется вводить больше данных, чем это необходимо. Ну, к примеру, для оформления дисконтной карты в каком-нибудь магазине требуется вводить большое количество персональных данных, хотя достаточно было просто иметь номер этой самой карты. Покупателя привлекают скидками, а расплачиваться за эти скидки приходится своими данными.

Изначально заявляется, что это «для вашего же удобства», но надо понимать, что это для удобства компании. Ну и, к сожалению, здесь возможно массовое злоупотребление, и мы регулярно наблюдаем новости об утечках данных, в том числе из очень серьёзных компаний. Выясняется, что этим занимаются сотрудники этих же компаний. Проблема в том, что законодательно эта область пока очень слабо регулируется, и, судя по всему, наказание недостаточно суровое. Штрафы здесь небольшие и они не способствуют тому, чтобы отвратить сотрудников от торговли персональными данными. Выгода перевешивает возможные убытки.

В качестве примеров законодательного регулирования можно назвать отечественный федеральный закон о персональных данных [152-ФЗ]. В Евросоюзе есть аналогичный документ, который называется общий регламент защиты персональных данных [Вики: GDPR], [Вики: GDPR 2]. Ну а в том, что касается американского законодательства, здесь целый ряд документов на федеральном уровне и на уровне штатов или регионов, см [ГРЧЦ 2024]. Очень быстро развивается ситуация, и законодательное регулирование чаще всего не поспевает за этим процессом. Есть некоторое отставание. И надо понимать, что на сего-

дняшний день во многих странах наблюдается несовершенство законодательства в области цифровых и информационных технологий.

Итак, данные превращаются в сырьё для зарабатывания денег. Набирает обороты деятельность по сбору данных и превращению их в инструмент для зарабатывания денег корпорациями.

Рассмотрим поподробнее некоторые примеры законодательства о персональных данных. Начнём с Федерального закона о персональных данных 152-ФЗ. Статья 3. Основные понятия. Здесь говорится, что «персональные данные — это любая информация, относящаяся к физическому лицу». Здесь есть понятие «обработка персональных данных», это «любые действия над такими данными, с использованием средств автоматизации или без использования таких средств». И есть «обезличивание персональных данных». Речь идёт о том, чтобы удалить привязку к конкретному человеку, но при этом сохранить возможность анализировать такие данные в рамках больших датасетов, наборов данных. Фактически здесь говорится о том, чтобы продолжить обработку данных, но не указывать человека, к которому они относятся.

Далее имеется Статья 8. Общедоступные источники персональных данных. Выясняется, что есть и такое понятие. Так вот, с письменного согласия человека здесь могут размещаться любые, практически любые персональные данные. Нужно только согласие человека, и мы знаем, как легко нажать кнопку ОК при регистрации на сайте…

Далее в Статье 3 вводится понятие «оператор» — это тот, кто занимается обработкой персональных данных.

Второй закон, который имеет отношение к информации — это [149-ФЗ] Об информации, информационных технологиях и о защите информации. В качестве примера откроем статью 7 под названием «Общедоступная информация». Так вот, это сведения, доступ к которым не ограничен. Здесь говорится, что общедоступную информацию может использовать любое лицо.

Далее, если информацию можно использовать автоматизированным образом, ее называют «информацией в форме открытых данных».

Таким образом, мы получаем «персональные» данные, «общедоступные» и «открытые». С этими вещами приходится иметь дело, когда речь идет об анализе больших объемов данных. Все зависит от того, из каких источников берут эти сведения. Соблюдается ли действующее законодательство, делается это для личного пользования или для корпоративного, ну и так далее.

В том, что касается сроков хранения информации, мы можем спросить нейросеть: «Расскажи о сроках хранения персональных данных в соответствии с требованиями российского законодательства». Естественно, потом нужно будет провести факт-чекинг и проверить, насколько точны эти сведения. Нейросеть выдаёт нам не только ответ, но и ссылки на правовые информационные ситемы типа «Гаранты» и «Консультант». Можно увидеть сроки в 6 месяцев (данные интернет-компании) и 75 лет (персональные данные). Попробуйте ввести свой запрос и обязательно проверьте факты.

Следующий документ — это европейский регламент GDPR. Есть парочка статей на Википедии, с которыми тоже можно познакомиться, чтобы представить себе общую картину [Вики: GDPR]. Есть и русскоязычная страничка [Вики: GDPR 2]. Здесь попутно упоминается и второй законодательный акт. Защита конфиденциальности в секторе электронных средств связи [Вики: ePR]. Здесь есть один любопытный момент, который обычно называют «право на забвение». В данном случае это право на удаление данных. Но речь идет о том, что человек может обратиться в организацию, где хранятся его данные и потребовать, чтобы данные о нем были удалены. Насколько это требование будет выполняться, пока что остается вопросом. В целом эксперты утверждают, что законодательства очень похожи по формулировкам: и европейское, и российское — в отношении персональных данных.

Теперь по поводу законодательства США — картина очень своеобразная. Здесь действует большое количество законода-

тельных актов на федеральном уровне: семейные права, частная жизнь водителей, медицинские данные, видео, дети и так далее. А ещё есть масса законов, которые действуют на уровне штатов.

В качестве примера посмотрим некоторые положения Калифорнийского закона о защите частной жизни потребителей California Consumer Privacy Act [CCPA]. Здесь говорится, что жители Калифорнии обладают правом на неприкосновенность частной жизни. Рассказано о том, как коммерческие предприятия обращаются с персональными данными потребителей или клиентов. В преамбуле этого закона достаточно подробно и очень простыми словами описывается вся проблема. В частности, говорится: в марте 2018 года десятки миллионов людей обнаружили, как используются их персональные данные компанией под названием Cambridge Analytica. Это фирма, занимающаяся дата-майнингом, то есть интеллектуальным анализом данных. Можете подробно ознакомиться с этим документом. Здесь раскрываются достаточно любопытные подробности.

Если у читателя пока остаются некоторые трудности с пониманием английского, мы можем использовать интеллектуальный переводчик, который на сегодняшний день интегрирован и в Google Chrome, и в построенный на его основе Яндекс. Браузер. Мы нажимаем кнопочку «Перевести» и видим, что страница переведена, см. рис. Здесь можно будет увидеть достаточно приличный перевод.

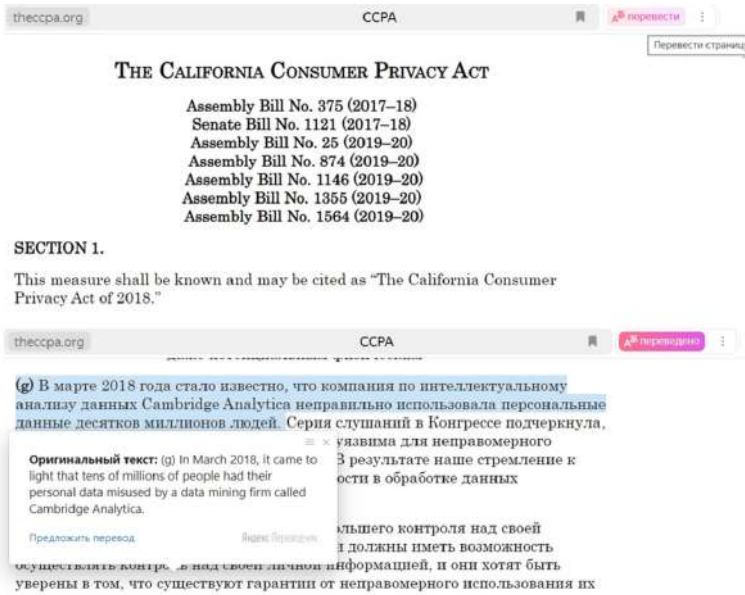



Рис. Оригинал и перевод CCPA

Вот посмотрим, что было в марте 2018 года. Заодно всплывающая подсказка показывает нам оригинальный текст.

Хотелось бы отметить одно любопытное примечание. Раздел 3, пункт B. Предприятие, которое собирает личные персональные данные потребителя, во-первых, информирует потребителя об этом, а во-вторых, не следует собирать дополнительные сведения сверх того, что требуется для заявленных целей. Вот эта идея как раз пересекается с книгой Зубофф по поводу надзорного капитализма. Фактически коммерческие предприятия собирают излишние данные, которыми далее пользуются либо в своих целях, либо для продажи третьим странам.

Следует отметить, что социальные сети предоставляют возможности для самых разных злоупотреблений. К сожалению, они либо не справляются с этими трудностями, либо сознатель-

но допускают такие вещи и даже зарабатывают на этом. В частности, в последнее время все больше становится популярным автоматическое создание контента с помощью искусственного интеллекта. Нынешние нейросети позволяют генерировать не только текст, но и изображение и видео. В результате мы получаем огромное количество контента, который не всегда удается отличить от того, что создано живым человеком. Естественно, используется это прежде всего в коммерческих целях, для рекламы, продвижения, маркетинга или пиара. Ну и, к сожалению, для создания и распространения фейков, см. рис.

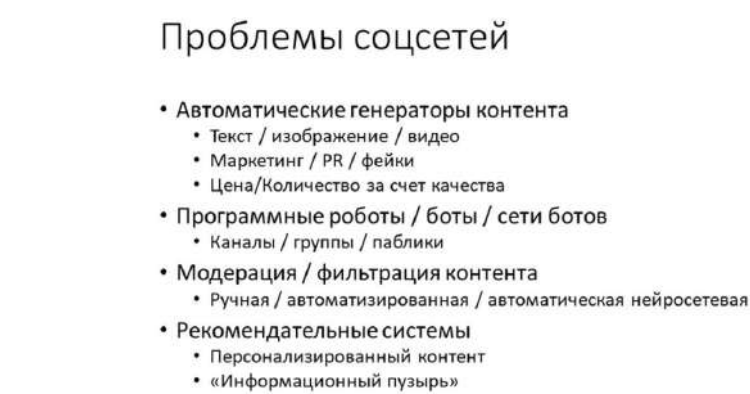



Рис. Какие проблемы, вы же сами подписали согласие…

В целом, специалисты отмечают, что поскольку стоимость генерации такого контента не очень большая, многие компании идут на то, чтобы генерации такого контента не очень большая, многие компании идут на то, чтобы генерировать контент не слишком высокого качества. И при этом результат оправдывает снижение качества контента. Существенное снижение качества контента, при том, что эти затраты все равно окупаются. К сожалению, это современная тенденция, когда количество становится важнее, чем качество. Игорь Ашманов называет такие

инструменты «бредогенераторами» и «интеллектуальным дошираком», см. например [Ашманов 2024 Бредогенератор] и [Ашманов 2023 SEO].

Отдельной проблемой является не только создание контента, но и его распространение. Для этого массово используются программные роботы, или так называемые «боты». Чаще всего в социальных сетях запускается целая сеть ботов, которые автоматически, по расписанию или по алгоритму распространяют определенные сообщения. Эти сообщения могут быть одинаковыми, или однотипными, или даже разными — за счет того, что можно генерировать тексты на определенные темы с помощью интеллектуальных систем. Ну а далее организуются каналы для распространения сообщений.

Каким образом можно организовать фильтрацию контента в условиях, когда количество сообщений растет, можно сказать, экспоненциально. Если раньше удавалось модерировать сообщения вручную и вручную отслеживать жалобы пользователей на оскорбительный и незаконный контент или фейки, на сегодняшний день это физически невозможно — слишком много сообщений в расчёте на одного модератора. Можно ожидать от компаний внедрения автоматизированных или автоматических систем, например, на основе нейросетей. Но здесь, к сожалению, начинает действовать простейшая экономика, когда компании получают прибыль за счет таких сервисов. Им становится невыгодно удалять контент, за который пользователи заплатили.

Ну и наконец, еще одна проблема, связанная с использованием социальных сетей, это так называемые рекомендательные технологии или рекомендательные системы. С одной стороны, эта идея продвигается как дополнительное удобство для пользователя. Каждый пользователь получает так называемый персонализированный контент. Только то, что интересно пользователю, только то, что соответствует его интересам. И на первый взгляд это логично и понятно. Но с другой стороны, эксперты отмечают, что каждый пользователь в таком случае оказывается в «информационном пузыре». Он получает сведения из очень

ограниченного набора источников и лишается возможности получать альтернативную точку зрения. Он получает только то, что подтверждает его точку зрения. С точки зрения теории управления это классический пример положительной обратной связи. Ну а положительная обратная связь — вещь не очень желательная в любых системах. Она вызывает неустойчивость. Она усиливает сигнал до бесконечности и загоняет объект управления в крайнее, «пограничное» состояние.

Теперь рассмотрим то, что говорит социальная сеть ВКонтакте своим пользователям. Открываем ссылку «Помощь» и читаем, что нам говорят по поводу персональных данных: «Вы сами делаете свои данные публичными». Далее нам сообщают, что на самом деле пользователи могут указывать ненастоящее имя и фамилию, и это совершенно допустимо правилами соцсети. Ещё раз дополнительно указывается, что такое решение полностью на совести пользователя, ну а руководство соцсети относится к пользователю заведомо с доверием, см. [VK FAQ].

Далее есть дополнительные сведения о защите приватности, то есть частной жизни [VK Приватность]. Мы можем выгрузить свой собственный персональный архив — все свои данные. После чего уточняется: «Мы предоставляем всю информацию, даже удаленную». Другими словами, если вы что-то удалили, эти сведения некоторое время ещё хранятся — как минимум, в соответствии с законодательством. Ну и более конкретные сведения находятся здесь же с указанием на Федеральный закон о защите информации. Здесь говорится, что такие сведения хранятся в течение одного года. На этой же странице упоминается Европейский закон GDPR. Для резидентов ЕС предоставляются услуги в соответствии с этим регламентом по защите персональных данных.

Следующая страничка. Принципы защиты информации [VK Защита]. И здесь мы обнаруживаем те самые рекомендательные системы: мы собираем информацию, чтобы лучше вас понимать и соответственно обслуживать. Персонализированные сервисы: мы лучше понимаем ваши потребности и создаем

уникальные сервисы. Мы будем предлагать больше похожих публикаций.

Далее у нас имеются правила защиты информации о пользователях сайта [VK Правила]. Можно увидеть, какие сведения относятся к персональным данным пользователей и каким образом происходит обработка персональных данных. Здесь говорится: передача персональных данных возможна при наличии согласия. Что же это означает? Если вы закрыли свой профиль, это не значит, что про вас никто ничего не узнает. Потому что у ваших друзей могут быть ссылки на вас и на ваши фотографии.

Далее имеется отдельная политика в отношении cookie — «куки» [VK Cookies]. Напомним, что «куки» — это маленькие текстовые файлы, которые позволяют более удобно отслеживать действия пользователя на конкретном сайте. Это удобно для обслуживания пользователя. Среди прочего здесь говорится, что «куки» нужны для таргетированной рекламы. Эти «куки» собирают сведения о том, как вы просматриваете сайты для того, чтобы рекламные объявления и предоставляемый контент соответствовали вашей личности и вашим интересам.

Уточним, что же такое cookie и есть ли какая-то связь с персональными данными. Спросим об этом ближайшую нейронную сеть. Ответ звучит так: «Куки — это небольшие текстовые файлы. Их создают веб-сайты, которые мы просматриваем. Эти файлы хранятся на устройстве самих пользователей». Что же это такое? Это адаптация контента под предпочтение пользователя. Это в том числе логины, пароли и прочие настройки. И это позволяет улучшить пользовательский опыт.

Далее мы обнаруживаем правила пользования сайтом ВКонтакте [VK Правила 2]. И здесь кое-что говорится по поводу обработки персональных данных. Обработка персональных данных осуществляется в соответствии с законодательством Российской Федерации. Здесь кое-что говорится насчёт передачи третьим лицам в целях обеспечения требований действующего законодательства. Здесь упоминается также и раскрытие предоставленной информации.

Наконец, у нас есть инструмент для программистов под названием API, который позволяет работать с этой платформой, в том числе скачивать сведения, либо управлять своим аккаунтом и своим сообществом [VK API]. Естественно, есть определенные ограничения, например, на количество запросов, чтобы не давать излишнюю нагрузку на веб-сервер. Что касается использования этого API, официальные сведения звучат как «десятки миллиардов запросов от 45 миллионов пользователей», см. рис. Вот это тот объем обращений к серверу, который заявлен официально. В качестве упражнения поделите число запросов на число пользователей. Это будет очень приблизительная, очень усреднённая оценка активности рядового «юзера» в одной, отдельно взятой соцсети.

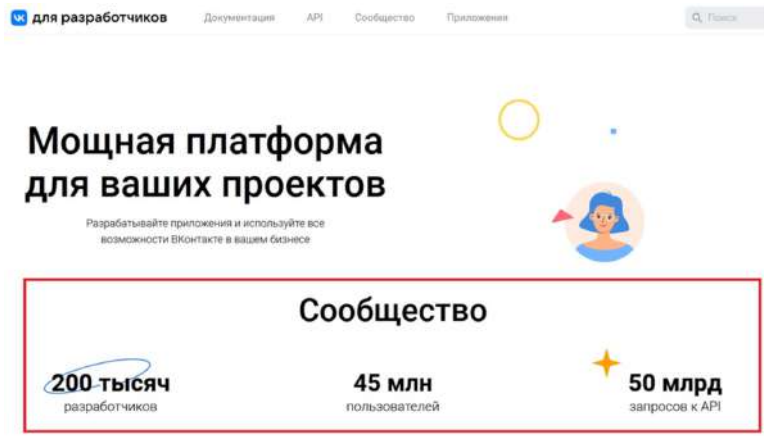



Рис. Средства ВК для разрабов

**АНАЛИЗ СОЦИАЛЬНЫХ СЕТЕЙ**

Что же делается в плане анализа социальных сетей? Прежде всего, можно заниматься визуализацией структуры сети и пытаться обнаружить какие-нибудь закономерности. Далее можно

проводить анализ контента, информационного наполнения сети. Здесь, соответственно, появляются самые разные задачи. Начиная, например, от анализа тональности текста, см. рис. Далее можно даже анализировать тональность по времени, по регионам, по группам пользователей и так далее. Можно изучать особенности поведения и взаимодействия пользователей. Можно изучать особенности поведения и взаимодействия пользователей.




Рис. Займёмся вашими анализами...

Особый интерес представляет изменение во времени — так называемая динамика, обнаружение долгосрочных тенденций, трендов и все, что с этим связано. В конечном счете, анализ нужен для того, чтобы выявлять закономерности, а также обнаруживать аномалии, которые выбиваются из общей картины и отклоняются от общей закономерности.

Отдельным пунктом можно отметить выявление лидеров мнений, то что сейчас называется модным словом «инфлюенсер». Английское слово influence означает влияние, так что инфлюэнсеры — это люди, которые имеют влияние, то есть влиятельные личности, см. рис.




Рис. Не путайте инфлюэнсеров и инфлюэнцу

В конечном счете анализ информации и соцсети очень часто используется для маркетинга. Напомню, что маркетинг происходит от слова market, то есть рынок, и это значит анализ рынка, и это значит влияние на рынок. Это продвижение товара и реклама. Это то, что называется контекстная и таргетированная реклама. Контекст означает, что при поиске информации человеку предлагается список, определенный заранее, настроенный на конкретного пользователя. Таргетированная реклама означает, что мы нацеливаемся на определенную целевую аудиторию. Английское слово target означает «цель» и «целиться». Таргетированный — значит нацеленный, прицельный.

Ну и с другой стороны, если речь идет об удобстве, анализ данных, касающихся социальных сетей, может улучшить так называемый клиентский опыт — user experience (UI). Здесь целая область деятельности со своей терминологией. Есть понятие клиентский путь, клиентский опыт и вокруг этого много различных наработок.

Мы уже упомянули инфлюенсеров. И на самом деле это личности, которых можно выявлять за счет анализа данных, которые циркулируют в социальных сетях. И это будет объективный вывод, а не личное мнение. Называться эти личности могут поразному, например, social media influencer, то есть влиятельная личность в соцсетях, либо интернет-селебрити — celebrity, знаменитость интернета, либо key opinion leader, законодатели мнений. Чаще всего это люди, которые ведут свой журнал в интернете, текстовый, или видео, или аудио, и имеют большое количество подписчиков. Соответственно, их называют блогеры, влогеры, ютьюберы, тиктокеры и так далее. В зависимости от того, каким контентом и какой платформой они пользуются.

Здесь надо пояснить, что слово блогер означает «тот, кто ведет блог». Это сокращение от слова веблог — weblog. Web — это интернет, сеть, ну а log — это журнал.

Всё начинается с понятия бортовой журнал или судовой журнал. Бортовой или судовой журнал — это книга, в которую записывают все текущие события за время плавания корабля или за время полета самолета, включая подготовку и послеполетное обслуживание. Такой журнал по-английски называется Logbook. И вот от этого термина как раз и пошли красивые названия.

Кстати говоря, журналы или протоколы действий пользователя в любой компьютерной системе тоже называются словом Log. И есть целая технология анализа логов.

Итак, logbook — судовой или бортовой журнал — превратился просто в слово log. Дальше у нас есть weblog, из которого получился blog. Далее в развитии этого термина мы получаем videolog или videoblog, сокращенно vlog.

Анализ позволяет выявлять ключевые узлы, у которых много подписчиков. Соответственно, распространение информации по этим каналам происходит лавинообразно, быстро и с очень небольшими затратами. Подписчики чаще всего обладают некоторым доверием к этому источнику и начинают участвовать в самых разных видах деятельности. Прежде всего пересылают эти

сообщения, то есть делают «репосты» / «перепосты». Если post — «пост» — это исходное сообщение, то «репост» — это пересылка «поста». Очень приблизительно можно сказать, что репост и перепост — это почти одно и то же. Но репост — это пересылка без изменений, а перепост — это пересылка с добавлением комментариев. Люди используют метки, хэштеги, ставят лайки и дизлайки. И все это является источником информации, источником данных для анализа.

Так вот, на основе всего этого потока сообщений можно выявлять так называемую «центральность узлов». Это узлы, у которых действительно много подписчиков. Таким образом можно выявлять инфлюенсеров и обнаруживать источники новостей, сообщений, если речь идет об информационных сетях. С источниками можно работать, через них можно распространять нужные сообщения.

Ну а с точки зрения маркетинга и с точки зрения безопасности интерес представляет кластеризация. Это выявление групп пользователей, которые чем-то схожи между собой — по интересам, по характеристикам, по поведению. С такой целевой аудиторией затем можно работать проверенными методами.

Итак, огромное количество информации, которая циркулирует в социальных сетях, может представлять интерес, прежде всего, коммерческий. Но с другой стороны, это возможность для серьезных злоупотреблений и даже правонарушений. Поэтому к таким данным проявляют большой интерес и службы безопасности самых разных видов, и спецслужбы, и силовые структуры.

### КРИБРУМ

В качестве примера следует отметить комплекс под названием Крибрум и соответствующую одноименную компанию, которая предоставляет аналитические услуги [Крибрум]. Фактически это то, что называется OSINT — Open Source Intelligence. Такое выражение переводится обычно как исследование, расследование или разведка по открытым данным, по открытым

источникам. На сайте компании «Крибрум» можно найти интересные документы, с которыми мы предлагаем вам ознакомиться. В частности, здесь есть раздел «Социально значимые проекты» [Крибрум Социальные проекты].




Рис. Крибрум как пример аналитики данных

Ну а в том, что рассказывает эта компания о себе, — они занимаются сбором информации самого разного рода, не только из социальных сетей, но и из интернет-СМИ. Сбор этих данных проводится в реальном времени и накапливается это все в огромном хранилище данных. Это петабайты, а на сегодняшний день, скорее всего, уже и экзабайты информации. Естественно, эта деятельность дорогостоящая, и такие услуги не представляются бесплатно.

Откроем сайт kribrum.ru. Как видим, это исследовательская и технологическая компания. Основатели компании: Игорь Ашманов и Наталья Касперская. Для подробного ознакомления мы можем порекомендовать три аналитических отчета, которые доступны на сайте совершенно бесплатно в разделе [Крибрум Социальные проекты]. Например, отчет «Информационная война». Открываем файл формата PDF. Здесь рассматриваются основ-

ные приемы изучаемого явления, в том числе работа с хэштегами. И все это на основе больших объемов данных.

В том, что касается технологий, здесь можно видеть работу с текстом, с изображениями, с аккаунтами. И в качестве источников данных используются не только социальные сети, но и интернет-СМИ и различные порталы. Поток данных, который собирается в реальном времени, ежедневное количество можно видеть на этой странице. Ну и в качестве оценки объемов информации здесь указаны петабайты данных, по которым можно проводить интеллектуальный анализ, см. рис.




Рис. Большие данные — это петабайты

Ещё один интересный момент — это раздел по образовательной деятельности. Здесь имеется брошюра — план занятия о работе с большими данными и цифровой гигиене [Крибрум 2023 Гигиена]. Вводный модуль для учащихся от 12 лет. Как говорит И.С.Ашманов, интернет — это не то же самое, что кран с водопроводной водой, которую можно пить. Интернет –это очень враждебная и опасная, токсичная и ядовитая, но очень легко доступная среда. Это кран, из которого одновременно можно налить питьевую воду, и цианистый калий. И здесь гигие-

на — это вопрос жизни и смерти. Как говорится в русской народной сказке — «не пей из лужи (из копытца)...»

Следующий продукт — это [Крибрум. про]. Как видим, это возможности по мониторингу, статистике и представлению в интуитивно понятном виде, см. рис. Здесь имеются различные источники данных, как здесь говорится, разнородные источники информации. источники информации.




Рис. «Про» — значит «профессионально»

Собранные сведения помещаются, судя по всему, на облачную платформу, ну а пользователь получает результаты анализа, представленные, скорее всего, в текстовом, табличном и графическом виде. Здесь представлены примеры экранных форм и отчетов, см. рис.

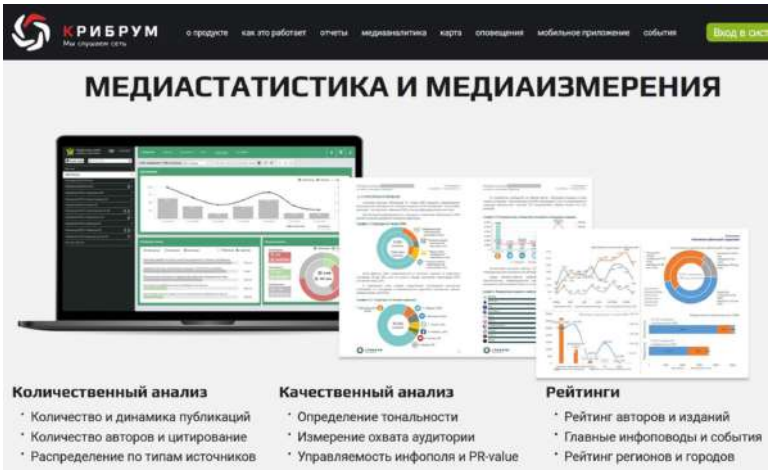



Рис. Аналитические отчеты

Тут все графики для нас привычные и знакомые. Это и столбики, и полосы, и линейные графики, и круговые диаграммы.

Отдельным разделом идет привязка данных к географической карте, см. рис. Как видим, здесь есть возможность изменения масштаба, здесь это называется детализация. Дальше имеется возможность фильтрации и анализа тональности по региону. Тональность — это эмоциональная окраска сообщений. И это отражение настроений широких слоёв пользоватлей.

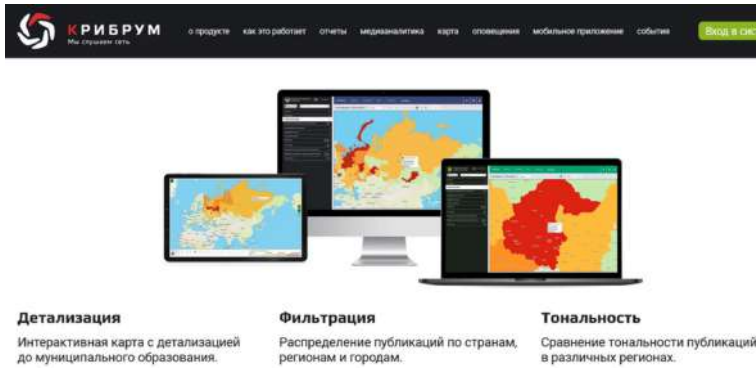



Рис. Картограммы и возможности

Ну а в том, что касается реализации, как видим, имеется и вариант для настольного приложения, и для ноутбука, и вариант в виде мобильного приложения.

Анализ динамики распространения новостей позволяет достаточно оперативно выявлять «вбросы» и «фейки». Как это происходит? Обычная новость о событии распространяется естественным образом, и вначале наблюдается пик интереса, пересылок, вопросов, комментариев, хэштегов, см. [Ашманов 2012 Новость]. Затем этот интерес очень быстро спадает, потому что публика в интернете не способна сконцентрироваться на одной теме в течение долгого времени, см. рис. Чаще всего, если это реальное событие, после него может происходить некоторое уточнение данных, дополнительные новости, и тогда можно наблюдать несколько новых всплесков, которые чаще всего быстро спадают. В течение нескольких дней интерес к этой новости падает практически до нуля. Это поведение обычной новости. Интерес публики быстро затухает, и «потребители контента» жадно припадают к следующему источнику эмоций, следующему событию.




Рис. Динамика «вброса» новости

А то, что называется вбросами, фейками и пропагандой — здесь совершенно другая картина. Здесь динамика выглядит так. Быстрый подъем количества сообщений, а далее он держится в течение некоторого времени на одном постоянном уровне. Потому что этим занимаются профессионально, эта работа оплачивается, этим занимаются чаще всего инфлюенсеры, а также большая армия ботов — программных роботов. Этот постоянный уровень активности в отношении выбранной темы продолжается в течение какого-то времени, а затем, когда финансирование прекращается, очень быстро падает до нуля. Нет денег –нет перепостов.

Таким образом, анализ динамики позволяет выявить характер события: то ли это настоящая новость, то ли это вброс и фейк. Причем для этого не нужно анализировать смысл сообщения, а только следить за количеством постов. Любопытный подход, который демонстрирует свою работоспособность.

**INFOWATCH**

Еще один пример, тоже отечественный продукт, это компания InfoWatch, см. [Вики: InfoWatch]. Info — от слова информация, а Watch означает наблюдение. Эта компания занимается вопросами информационной безопасности. от слова информация, а watch означает наблюдение.

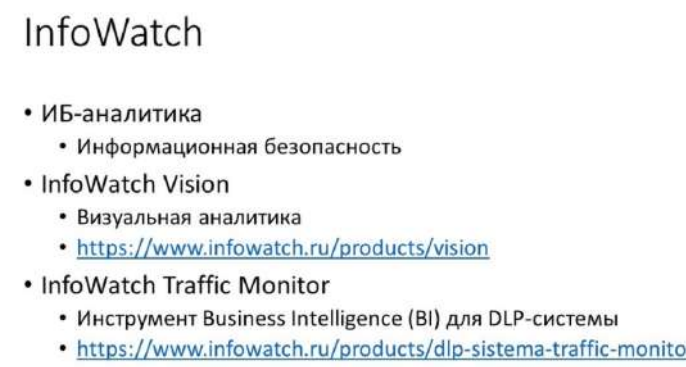



Рис. InfoWatch — тоже пример аналитики данных

Эта компания занимается вопросами информационной безопасности и соответственно здесь аналитика используется именно с этими целями. На сайте компании [InfoWatch] мы видим пояснение, что здесь разрабатывают решение по информационной безопасности, см. рис.

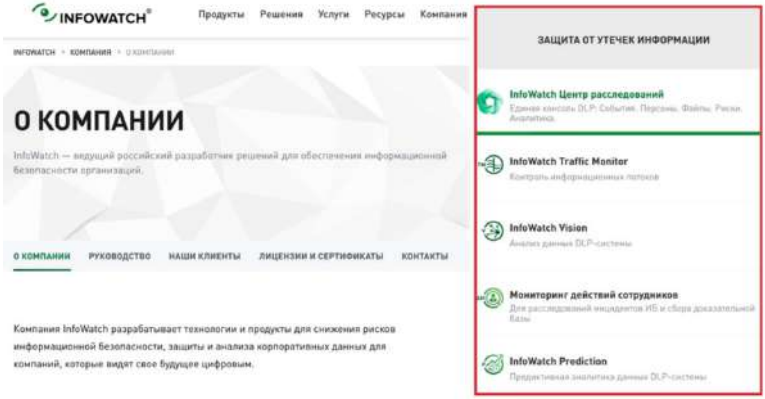



Рис. Безопасность через защиту данных

Попробуем уточнить с помощью нейросети, используется ли аналитика больших данных в этой компании, см. рис. Ответы ссылаются в том числе и на страницы этого сайта. Итак, о чем здесь говорят? Лингвистический анализ документов, обнаружение выгрузки данных из базы, технология машинного обучения и визуальная аналитика для обнаружения утечки данных. Здесь также упоминается анализ графа. Как видим, для анализа информационных потоков используется AI, то есть искусственный интеллект.

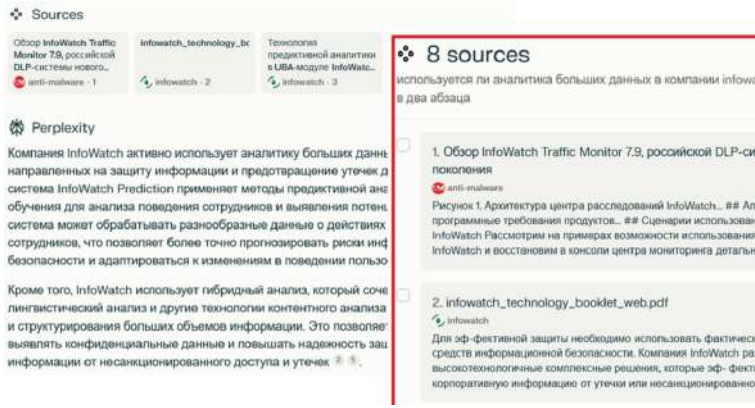



Рис. Поисковая нейросеть даёт ответы и ссылки

Ну и в качестве упражнения предлагаем ознакомиться с отчетами по утечкам информации. Переходим по ссылке [InfoWatch: Аналитика]. Как видим, здесь представлено большое количество материалов. Скачайте пару отчётов и ознакомьтесь с материалами, чтобы почувствовать все масштабы проблемы информационной безопасности и утечек данных.

Рассмотрим пару страниц, где приводятся примеры визуализации. Мы посмотрим на них с точки зрения решаемых задач, источников данных, методов анализа и визуализации. Здесь также приводятся примеры реальных кейсов внедрения и использования.

Один продукт — это InfoWatch Vision — BI-система для анализа событий DLP. Data Leak Prevention — это предотвращение утечки данных, см. [Вики: DLP]. Страница продукта: [InfoWatch Vision]. Здесь тоже упоминается граф. Имеется построение диаграмм, граф связей. Кстати, можно скачать 15 примеров — кейсов применения этого продукта. Тоже после простой регистрации. Один из примеров визуализации — это граф связей с указанием фамилии сотрудника и его фотографии.

Теперь рассмотрим информацию по второму продукту — [InfoWatch Traffic Monitor]. В данном случае Traffic — «трафик» — это движение информации, движение документов в корпоративной информационной системе. И анализ проводится, опять же, с точки зрения DLP, с точки зрения утечки данных. Основные решаемые задачи — это предотвращение утечки данных, а также мониторинг действий сотрудника.

Переходим по ссылке с описанием технологий работы данного продукта. В частности, здесь говорится, что проводится лингвистический анализ потока документов. А документов миллионы в рамках одной кампании. Это тоже пример больших данных. В данном случае документы будут классифицироваться по категориям и по уровню конфиденциальности. Другие инструменты в рамках продукта:

— детектор текстовых объектов;
— детектор эталонных документов;
— детектор графических объектов с распознаванием текста;
— обнаружение выгрузки из базы данных;
— отслеживание заполненных бланков.

Всё это выполняется на основе анализа больших объемов данных с использованием искусственного интеллекта.

На странице Википедии можно обнаружить, что данная компания контролирует половину российского рынка систем DLP, см. [Вики: InfoWatch].

### ИНСТРУМЕНТЫ ВИЗУАЛИЗАЦИИ

Рассмотрим несколько примеров инструментов для визуализации. На этот счёт можно найти много обзоров. Каждый год аналитики строят рейтинги инструментов анализа и визуализации, см. рис.

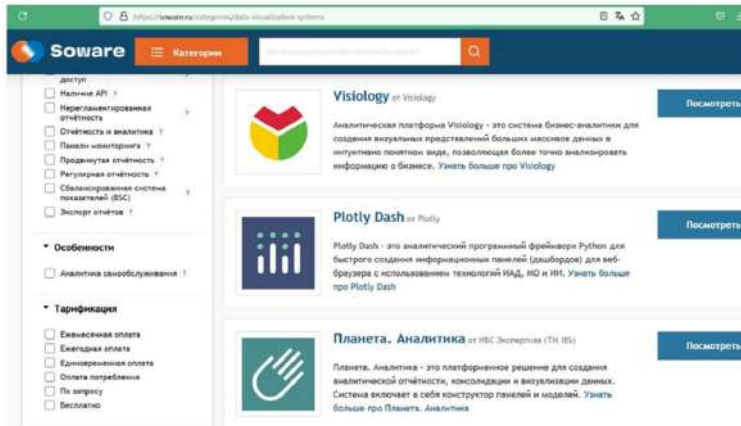



Рис. Аналитический обзор аналитических инструментов

Как мы уже говорили, очень часто визуализация аналитики больших данных и BI-аналитика имеют дело с одними и теми же проблемами. Очень часто BI-инструменты используются для визуализации больших данных.

## Инструменты для визуализации больших данных

- Tableau
- Power BI
- D3.js
- Plotly
- Apache Superset
- Google Data Studio / Looker Studio
- Yandex DataLens

Рис. Красивые ностальгические названия

Традиционно в течение многих лет в нашей стране использовались программные продукты западного происхождения, но в последнее время многие иностранные компании уходят из нашей страны и прекращают обслуживание. Попутно (по команде сверху) они уничтожают данные своих клиентов. В частности, уходит компания Tableau, она входит в состав корпорации Salesforce. С самого начала Salesforce продвигала свои услуги как облачные корпоративные системы. Итак, «таблО» более не доступно, см. рис.

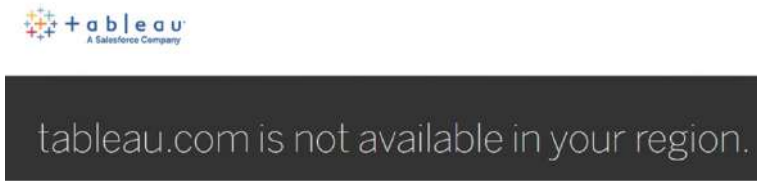



Рис. На табло — по нулям

Сайт qlik.com даже не открывает первую страницу.

Компания IBM тоже сворачивает свою деятельность в регионе.

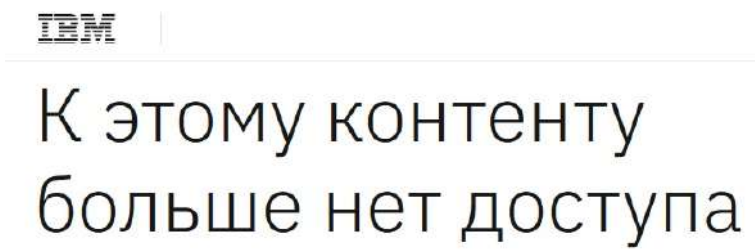



Рис. Вне зоны доступа...

Сервисы компании Microsoft, типа Power BI, доступны ча-

стично, лицензии заканчиваются, и блокировка может наступить в любой момент. Компания прекращает / приостанавливает продажу своих продуктов в регионе. То же самое касается и сервисов, которые интегрируются с программными продуктами Microsoft.

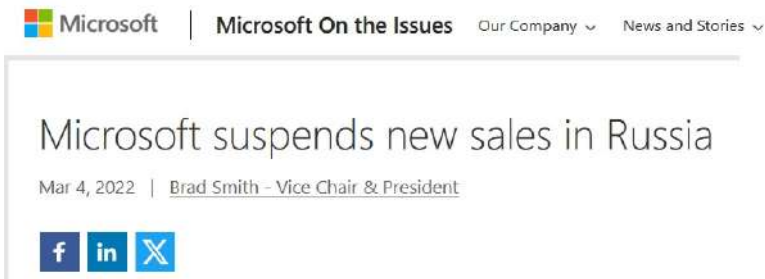



Рис. Маленькая мягкая корпорация...

Некоторые сервисы Google на сегодняшний день пока еще работают, но нет никаких гарантий.

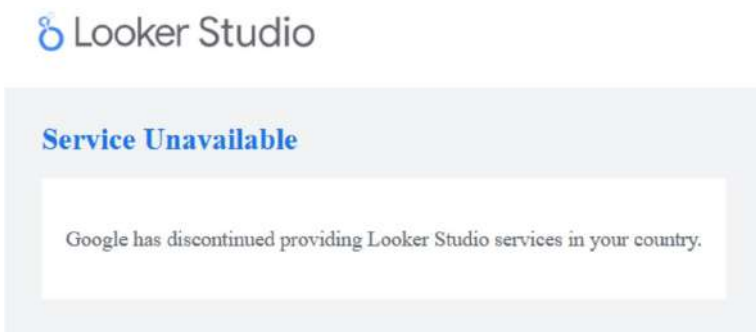



Рис. Looker is looking forward to seeing you again...

**ЗАМЕСТИТЕЛЬНАЯ ТЕРАПИЯ**

В плане импортозамещения существует ряд иностранных программных продуктов — бесплатных, с открытым исходным кодом, Open Source. Есть и отечественные разработки — бесплатные и коммерческие.

Из бесплатных продуктов зарубежного производства можно выбрать достаточно большое количество. В частности, отметим D3 на JavaScript (не путать с 3D), см. [D3].

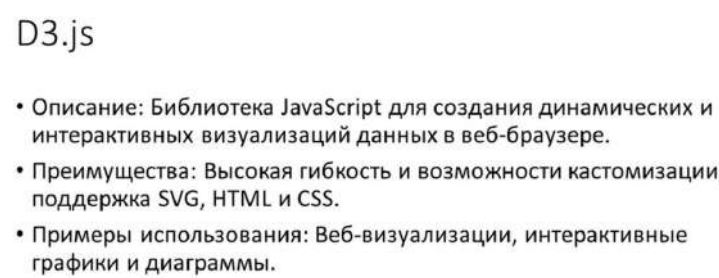



Рис. Графика в браузере

Название намекает на три буквы D — Data-Driven Documents. То есть документы, которые мы создаём на основе данных. Написана эта библиотека (фреймворк) на JavaScript, и позволяет она создавать динамические интерактивные (с возможностями взаимодействия) визуализации данных.




Рис. Бесконечная гибкость ручного кодинга

Инструмент потребует интенсивного программирования, сами авторы пишут, что это low-level toolbox. Здесь придётся очень подробно прописывать все элементы изображения или графика. Нам предлагают посмотреть примеры на сайте https://observablehq.com.

В галерее примеров [D3 gallery] приведено огромное число разнообразных доступных визуализаций. Для каждого графика можно изучить исходный текст и поиграться с ним.

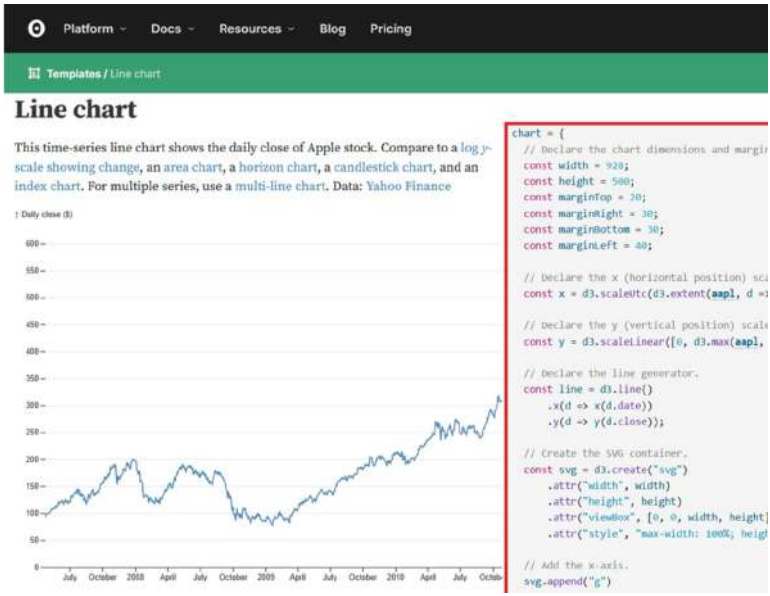



Рис. Линейный график на D3

В приведённом выше примере показано, что для вывода одного несложного графика потребовалась аж целых 56 строк кода. Конечно, это уже слишком. Для ускорения работы можно найти готовые шаблоны и заготовки. Мне кажется, это всё же инструмент для больших любителей ручного кодинга, веб-дизайна и красоты векторной графики. Однако, репозиторий D3 входит в топ-100 самых популярных на GitHub — занимает почетное 49 место и порядка 100 тысяч звёздочек, см. рейтинг [Github 100 Stars]. Разработчики этот инструмент уважают, и, видимо, есть за что.

**PLOTLY**

Отметим инструмент [Plotly], который хорошо интегрируется в Python. На сайте упоминаются более 97,000 звёздочек GitHub для репозиториев Plotly. Компания Plotly (от слова plot — рисо-

вать графики) предлагает одноимённую библиотеку визуализации, фреймворк для создания веб приложений Dash (намёк на дашборд) и множество дополнительных инструментов. Часть инструментов бесплатная — есть open source вариант и есть корпоративный тариф.

Программа на Python с использованием Plotly похожа на работу стандартной библиотеки Matplotlib, однако результатом будет не статический график, а интерактивный. На диаграммах Plotly появляются дополнительные возможности взаимодействия (интерактива, диалога).

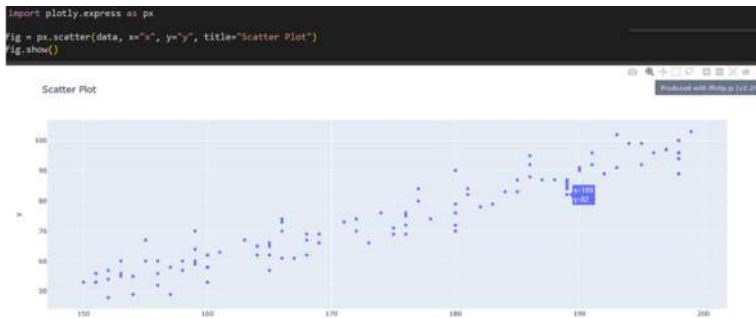



Рис. Интерактивная графика Plotly

В нашем примере мы импортируем библиотеку Plotly Express для быстрого создания визуализаций и назначаем её псевдоним (alias) px. Затем формируем диаграмму рассеяния Scatter Plot. Третья строчка запускает вывод интерактивного графика на экран. Теперь мы можем наводить курсор на точки (hover over points) и получать дополнительные подробности (значения «икса» и «игрека»). Можно также увеличивать и уменьшать масштаб (zoom in/out.).

В галерее [Dash] представлено более сотни демонстрационных примеров, см. рис. Упоминаются самые разные отрасли: авиакосмическая и автомобильная промышленность, энергетика, медицина, фармакология, розничная торговля, спорт.

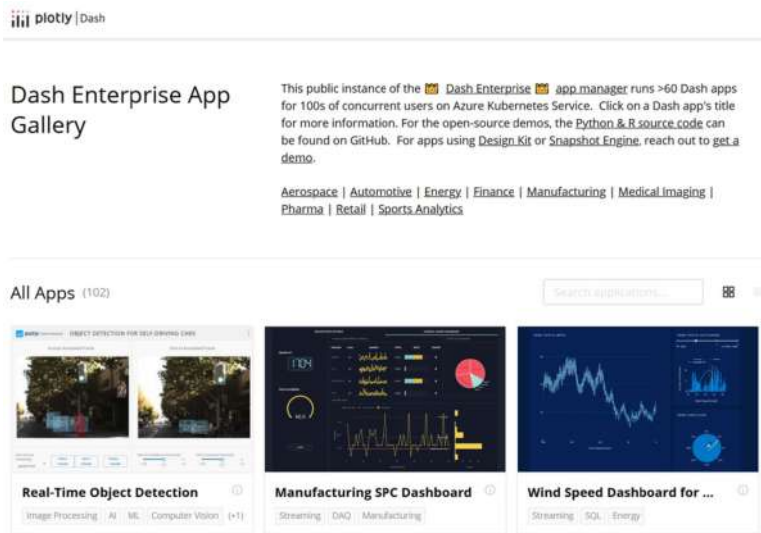



Рис. Примеры интерактивных веб-приложений

Здесь же приводится ссылка на репозиторий исходных текстов примеров на GitHub.

**ВИДЕОРОЛИКИ К ЛЕКЦИИ 2**

Данная глава написана по мотивам лекции 2 про большие данные — очень большие и не очень, см. [Видео: Визуализация].

[Видео: Визуализация] Большие данные. Лекция. Визуализация данных. https://rutube.ru/video/b94a9d944b10e1db987e1b6983c90ccf/

[Видео: MOEX API] Большие данные. Лабораторная работа. Доступ к MOEX API из Python. https://rutube.ru/video/c00aed115472d506ab501b51de505edc/

[Видео: OpenWeatherMap API] Большие данные. Лабораторная работа. Доступ к OpenWeatherMap API из Python. https://rutube.ru/video/6ca6f923186e99564c19a7000bc37121/

**ССЫЛКИ К ЛЕКЦИИ 2**

[Matplotlib] Matplotlib: Visualization with Python https://matplotlib.org/

[Matplotlib cheatsheets] Matplotlib cheatsheets and handouts https://matplotlib.org/cheatsheets/

[Heatmaps] Creating annotated heatmaps https://matplotlib.org/stable/gallery/images_contours_and_fields/image_annotated_heatmap.html

[Вики: Treemapping] Treemapping: displaying hierarchical data using nested figures. https://en.wikipedia.org/wiki/Treemapping

[TradingView] Корпорация TradingView https://www.tradingview.com/

[Stock Heatmap] Тепловая карта акций https://ru.tradingview.com/heatmap/stock/

[smart-lab] Карта рынка онлайн
https://smart-lab.ru/q/map/

[stockchart] StockChart: инструменты анализа биржевых рынков. https://stockchart.ru/

[Вики: Dashboard 1] Компьютерный Dashboard https://en.wikipedia.org/wiki/Dashboard_(computing)

[Вики: Dashboard 2] Автомобильный Dashboard https://en.wikipedia.org/wiki/Dashboard

[Вики: Фоновая картограмма] Фоновая картограмма https://ru.wikipedia.org/wiki/Фоновая_картограмма

[Вики: Choropleth] Choropleth map https://en.wikipedia.org/wiki/Choropleth_map

[Вики: ВВП Ном] Список стран по ВВП (номинал) https://ru.wikipedia.org/wiki/Список_стран_по_ВВП_(номинал)

[Вики: ВВП] Gross domestic product
https://en.wikipedia.org/wiki/Gross_domestic_product

[ArcGIS: Картодиаграммы] ArcGIS: Создание и использование карты с символами круговых диаграмм https://doc.arcgis.com/ru/insights/latest/create/pie-chart-symbols.htm

[Росстат] Росстат: Федеральная служба государственной статистики https://rosstat.gov.ru/

[Росстат: Пирамида] Росстат: Визуализированные статистические сборники. Женщины и мужчины России в 2020 году (PDF) http://bi.gks.ru/biportal/contourbi.jsp?
allsol=1&solution=Dashboard&project=%2FDashboard%2FVisualized_statistical_co

[DataLens] DataLens: Аналитика любого масштаба https://datalens.tech/

[DataLens: Cloud] Yandex DataLens. Сервис анализа и визуализации данных от Yandex Cloud. https://datalens.yandex.cloud/

[GitHub: DataLens] DataLens: modern business intelligence

and data visualization system https://github.com/datalens-tech/datalens

[DataLens: Marketplace] Yandex DataLens: Marketplace https://datalens.yandex.cloud/marketplace

[DataLens: Covid] Yandex DataLens. Коронавирус: дашборд https://datalens.yandex/covid19

[DataLens: Training] Основы работы с DataLens. Бесплатный практический курс https://yandex.cloud/ru/training/datalens

[Mozilla: SMAT] Mozilla 2020 A New Open-Source Tool for Tracking Disinformation https://foundation.mozilla.org/en/blog/new-open-source-tool-tracking-disinformation/

[Bevensee 2020 SMAT] Bevensee 2020 Introducing the U.S. Election Twitter Network Graph Tool https://foundation.mozilla.org/en/blog/fellow-introducing-us-election-twitter-network-graph-tool/

[Open Measures] Open Measures: open source platform. https://openmeasures.io/open-source/#open-source-api

[Google Trends] Google Trends: Top search queries in Google Search. https://trends.google.com

[Gartner: Hype Cycle] Gartner Hype Cycle Research Methodology. https://www.gartner.com/en/research/methodologies/gartner-hype-cycle

[Вики: Gartner hype cycle] Gartner hype cycle. Five key phases of a technology's life cycle. https://en.wikipedia.org/wiki/Gartner_hype_cycle

[Вики: Bioinformatics] Bioinformatics: methods and software tools for understanding biological data. https://en.wikipedia.org/wiki/Bioinformatics

[Зубофф 2022 Эпоха надзорного капитализма] Шошана Зубофф. Эпоха надзорного капитализма. Битва за человеческое будущее на новых рубежах власти. Пер. с англ. А. Ф. Васильева; под ред. Я. Охонько и А. Смирнова. — М.: Издательство Института Гайдара, 2022. — 784 с. https://www.iep.ru/ru/izdatelstvo/book/2022/epokha-nadzornogo-kapitalizma-bitva-za-chelovecheskoe-budushchee-na-novykh-rubezhakh-vlasti-.html

[Вики: Zuboff Surveillance Capitalism] The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power by Shoshana Zuboff. https://en.wikipedia.org/wiki/The_Age_of_Surveillance_Capitalism

[Гавриленко 2023 Надзорный капитализм] Гавриленко О. В. Социальные технологии в эпоху «надзорного капитализма»: цифровизация и власть алгоритмов // Вестник Московского университета. Серия 18. Социология и политология. 2023. №3. https://cyberleninka.ru/article/n/sotsialnye-tehnologii-v-epohu-nadzornogo-kapitalizma-tsifrovizatsiya-i-vlast-algoritmov

[Вики: Surveillance capitalism] Surveillance capitalism: widespread collection and commodification of personal data by corporations. https://en.wikipedia.org/wiki/Surveillance_capitalism

[Вики: Надзорный капитализм] Надзорный капитализм (следящий капитализм, шпионящий капитализм): монополии получают доход благодаря тотальному надзору за каждым потребителем. https://ru.wikipedia.org/wiki/Надзорный_капитализм

[152-ФЗ] Федеральный закон «О персональных данных»

от 27.07.2006 N 152-ФЗ https://www.consultant.ru/document/cons_doc_LAW_61801/

[Вики: GDPR] General Data Protection Regulation: a European Union regulation on information privacy in the European Union (EU) and the European Economic Area (EEA). https://en.wikipedia.org/wiki/General_Data_Protection_Regulation

[Вики: GDPR 2] Общий регламент по защите данных: постановление Европейского союза по защите персональных данных всех лиц в Европейском союзе (ЕС). https://ru.wikipedia.org/wiki/Общий_регламент_по_защите_данных

[ГРЧЦ 2024] Центр правовой помощи гражданам в цифровой среде ФГУП «ГРЧЦ» 2024 Законодательство США в сфере защиты персональных данных. Система законодательства. Основные нормативно правовые акты и их материальное действие https://4people.grfc.ru/analytics-and-legislation/international-and-foreign-acts/foreign-acts/ssha/

[149-ФЗ] Федеральный закон «Об информации, информационных технологиях и о защите информации» от 27.07.2006 N 149-ФЗ https://www.consultant.ru/document/cons_doc_LAW_61798/

[Вики: ePR] Постановление ЕС о защите конфиденциальности в секторе электронных средств связи https://ru.wikipedia.org/wiki/Постановление_ЕС_о_защите_конфиденциальности_в_секторе_электронных_средств_связи

[CCPA] The California Consumer Privacy Act https://theccpa.org/

[Ашманов 2023 SEO] Optimization 2023: тренды в SEO. Дискуссионная панель. Игорь Ашманов: ChatGPT производит интел-

лектуальный «Доширак». https://www.seonews.ru/analytics/optimization-2023-trendy-v-seo-diskussionnaya-panel/

[Ашманов 2024 Бредогенератор] Ашманов и партнеры. «Говорит Ашманов». Chat Gpt — гладкий бредогенератор. https://rutube.ru/video/299fce4bc16c4403c684104f29a48110/?r=plwd

[VK FAQ] VK. Помощь. Список вопросов. https://vk.com/support?act=faqs&c=34&from=all

[VK Приватность] VK. Помощь. Приватность. https://vk.com/support?act=faqs&c=8&from=all

[VK Защита] VK. Защита данных. Принципы защиты информации https://vk.com/data_protection?section=principles

[VK Правила] Правила защиты информации о пользователях сайта VK.com https://vk.com/privacy

[VK Cookies] VK.COM Cookies policy https://vk.com/privacy/cookies

[VK Правила 2] Правила пользования Сайтом ВКонтакте https://vk.com/terms

[VK API] VK для разработчиков https://dev.vk.com/ru

[Крибрум] АО «Крибрум». Мы слушаем сеть https://www.kribrum.ru/

[Крибрум Социальные проекты] АО «Крибрум». Главная> Деятельность> Социальные проекты https://www.kribrum.ru/activity/sotsialnye-proekty

[Крибрум 2023 Гигиена] Крибрум 2023 Цифровая гигиена и работа с большими данными https://www.kribrum.ru/upload/gigiena-2023.pdf

[Крибрум. про] Крибрум. про. Экспертная система для пресс-службы и PR Мониторинг СМИ, соцмедиа и Telegram-каналов. https://kribrum.pro/

[Ашманов 2012 Новость] Игорь Ашманов 2012 Любую новость можно изобразить графически. Российская газета, 2012. https://rg.ru/2012/04/12/intellekt.html

[InfoWatch] InfoWatch — ведущий российский разработчик решений для обеспечения информационной безопасности организаций. https://www.infowatch.ru

[InfoWatch: Аналитика] InfoWatch — Аналитика — Утечки информации. Аналитика отрасли информационной безопасности https://www.infowatch.ru/analytics/utechki-informatsii

[InfoWatch Vision] InfoWatch — Продукты — InfoWatch Vision. BI-система для анализа событий DLP. https://www.infowatch.ru/products/vision

[Вики: DLP] Предотвращение утечек информации https://ru.wikipedia.org/wiki/Предотвращение_утечек_информации

[InfoWatch Traffic Monitor] InfoWatch — Продукты — Traffic Monitor InfoWatch Traffic Monitor. Интеллектуальная DLP-система https://www.infowatch.ru/products/dlp-sistema-traffic-monitor

[Вики: InfoWatch] Группа компаний InfoWatch (АО «Инфовотч»). Информационная безопасность в корпоративном секторе. Защита корпораций от утечек информации и целевых атак извне. https://ru.wikipedia.org/wiki/InfoWatch

[D3] D3.js: The JavaScript library for bespoke data visualization https://d3js.org/

[Github 100 Stars] Github Ranking. Top 100 Stars https://github.com/EvanLi/Github-Ranking/blob/master/Top100/Top-100-stars.md

[D3 gallery] Observable. D3 gallery https://observablehq.com/@d3/gallery

[Plotly] Plotly. Data Apps for Production. https://plotly.com/get-pricing/

[Dash] Dash Enterprise App Gallery https://dash.gallery/Portal/

# ЗАКЛЮЧЕНИЕ

Большие данные — это красивое название без особого смысла. Профессия развивается быстро, как и многие другие информационные технологии. У этой темы нет ни начала, ни конца. Но есть история под названием «статистика». И есть профессия Big Data, которая становится всё более востребованной. Если, конечно, верить сайту вакансий HeadHunter. Продолжение следует.

# ОБЛОЖКА

Изображение на обложке данного учебного пособия создано при помощи нейросети Kandinsky через интерфейс платформы FusionBrain, см. ссылки на указанные сервисы [Kandinsky] и [FusionBrain] в конце главы. Творческий вклад автора данного учебного пособия заключается в составлении детального запроса к нейросети и выборе наиболее подходящего варианта изображения.

Поясним, что сгенерированный контент (в данном случае изображение) является объектом интеллектуальной собственности. Здесь важно соблюдение авторских прав и выполнение требований, соглашений, лицензий и действующего законодательства. Знакомство с технологиями генеративного искусственного интеллекта должно также включать также и изучение правовых аспектов. Это позволит избежать конфликтных ситуаций при использовании такого сгенерированного контента.

Обсудим основные положения, касающиеся данной ситуации.

В соответствии с п. 5.7 Пользовательского соглашения об использовании Сервиса Kandinsky, «исключительное право на сгенерированный контент… принадлежит пользователю», см. [Kandinsky: Соглашение].

В соответствии с п. 2.3 Пользовательского соглашения сайта FusionBrain, «пользователь вправе использовать платформу в любых, как коммерческих, так и некоммерческих целях», см. [FusionBrain: Соглашение].

Далее, в соответствии с п. 6.2 того же соглашения, «исключительные права на контент принадлежат пользователю».

Наконец, в соответствии с п. 6.5 того же соглашения, «пользователь может указывать ссылку на источник…, например: «создано при помощи нейросети Kandinsky».

Теперь рассмотрим основные положения Гражданского кодекса РФ, касающиеся тех самых «исключительных прав», см. [ГК РФ].

В соответствии со ст. 1229 ГК РФ, исключительное право — это возможность использовать результат интеллектуальной деятельности по своему усмотрению. Это не точная цитата, мы только передаём основной смысл.

Таким образом, в нашей конкретной ситуации использование сгенерированного контента является допустимым и законным.

В каждом случае пользователям необходимо изучить все соглашения и требования, относящиеся к используемому сервису. Обычно ссылка на пользовательское соглашение расположена на главной странице сервиса или в информационном разделе.

**СЕКРЕТНЫЕ ССЫЛКИ**

[Kandinsky] Сервис Kandinsky 3.1: Создавай высокохудожественные изображения в разных стилях. https://www.sberbank.com/promo/kandinsky/

[Kandinsky: Соглашение] Пользовательское соглашение об использовании Сервиса Kandinsky. https://www.sberbank.com/common/img/uploaded/files/promo/kandinskiy-terms/kandinskiy-terms-of-use.pdf

[FusionBrain] FusionBrain: Идеи в образы. Интерактивный портал Института AIRI. https://fusionbrain.ai/

[FusionBrain: Соглашение] Пользовательское соглашение сайта fusionbrain.ai. https://fusionbrain.ai/static/fusion/docs/agreement.pdf

[ГК РФ] Гражданский кодекс Российской Федерации часть 4 от 18.12.2006 N 230-ФЗ. https://www.consultant.ru/document/cons_doc_LAW_64629/

# ОГЛАВЛЕНИЕ


Введение ... 3
Глава 1. Сбор и предобработка больших данных ... 4
Введение ... 4
Понятие и классификация больших данных ... 5
ИИ-помощники ... 8
Краткая история аналитики ... 14
Анализ истории аналитики ... 15
Источники больших данных ... 18
Инструменты анализа ... 22
Применение технологий больших данных в различных отраслях ... 26
Далёкое светлое будущее ... 29
Размерность и объем данных ... 31
Проклятие размерности ... 32
Этапы большого пути: Жизненный цикл аналитики данных ... 38
Extract-Transform-Load (ETL) ... 51
Команда для работы с данными ... 55
Видеоролики к лекции 1 ... 60
Ссылки к лекции 1 ... 61
Глава 2. Методы и инструменты визуализации ... 63
Введение в визуализацию ... 63
Статическая графика ... 66
Продвинутые визуализации ... 73
Древовидная диаграмма ... 74
Интерактивная визуализация ... 77
География ... 82
Визуализация статистики ... 85
Data Lens от Яндекса ... 88
Графы и сети ... 89
Анализ трендов ... 93
Социальные сети ... 95
Анализ социальных сетей ... 109

Крибрум ..... 113
InfoWatch ..... 121
Инструменты визуализации ..... 124
Заместительная терапия ..... 128
Plotly ..... 130
Видеоролики к лекции 2 ..... 132
Ссылки к Лекции 2 ..... 133
Заключение ..... 141
Обложка ..... 142
Секретные ссылки ..... 143

**Валентин Юльевич Арьков**

# Цифровая нефть. От больших данных к большим доходам

Учебное пособие

Создано в интеллектуальной издательской системе Ridero

Арьков Валентин Юльевич — доктор технических наук, профессор кафедры автоматизированных систем управления (АСУ) Уфимского университета науки и технологий (УУНиТ, Литера Т). Прежнее название вуза: Уфимский государственный авиационный технический университет. Опыт преподавания в вузе более 30 лет.

Большие данные — это сколько? Это что-то новое, или мы этим уже занимались? Чем отличаются открытые, свободные и бесплатные инструменты? Вопросов много, а ответ один: это просто бизнес... А ради прибыли бизнес пойдёт на всё. Даже на хорошую зарплату для хороших специалистов. Что же это за профессия такая — анализ больших данных? Давайте разбираться.

ISBN 978-5-0064-6561-9

Rideró

*Rideró.ru* — издай книгу бесплатно!